UNIVERSIDAD
DE GRANADA

Facultad de Ciencias y Escuela Técnica Superior de Ingenierías
Informática y de Telecomunicación

Doble Grado en Ingeniería Informática y Matemáticas

TRABAJO DE FIN DE GRADO

Inteligencia Artificial Explicable en medicina: métodos para introducir al humano en la adquisición de conocimiento

Santiago López Cerro

Curso académico 2026–2027

Inteligencia Artificial Explicable en medicina: métodos para introducir al humano en la adquisición de conocimiento

Santiago López Cerro

Santiago López Cerro *Inteligencia Artificial Explicable en medicina: métodos para introducir al humano en la adquisición de conocimiento*.

Trabajo de fin de Grado. Curso académico 2026–2027.

Responsable de tutorización

Francisco Herrera Triguero
Departamento de Ciencias de la Computación e Inteligencia Artificial

Iván Sevillano García
Departamento de Ciencias de la Computación e Inteligencia Artificial

Doble Grado en Ingeniería Informática y Matemáticas

Facultad de Ciencias y Escuela Técnica Superior de Ingenierías Informática y de Telecomunicación

Universidad de Granada

Declaración de originalidad

D./Dña. Santiago López Cerro

Declaro explícitamente que el trabajo presentado como Trabajo de Fin de Grado (TFG), correspondiente al curso académico 2026–2027, es original, entendido esto en el sentido de que no he utilizado para la elaboración del trabajo fuentes sin citarlas debidamente.

En Granada a 26 de octubre de 2026

Fdo: Santiago López Cerro

Dedicatoria (opcional)
Ver archivo `preliminares/dedicatoria.tex`

Agradecimientos

[PENDIENTE: agradecimientos]

Índice de acrónimos

Acrónimo	Significado
APS	*Adaptive Prediction Sets*
ASH	*Activation Shaping*
AUPR	Área bajo la curva precisión-exhaustividad (*Area Under the Precision-Recall curve*)
AUROC	Área bajo la curva ROC (*Area Under the Receiver Operating Characteristic curve*)
CCR	Tasa de clasificación correcta (*Correct Classification Rate*)
CNN	Red neuronal convolucional (*Convolutional Neural Network*)
CRP	*Concept Relevance Propagation*
DICE	*Directed Sparsification*
DTD	*Describable Textures Dataset*
EBO	*Energy-Based OOD*
FPR	Tasa de falsos positivos (*False Positive Rate*)
H&E	Hematoxilina y eosina
ID	Dentro de la distribución (*In-Distribution*)
KNN	k vecinos más cercanos (k-*Nearest Neighbors*)
LAC	*Least Ambiguous set-valued Classifier*
LDA	Análisis discriminante lineal (*Linear Discriminant Analysis*)
LOSO	*Leave-One-Slide-Out*
LRP	*Layer-wise Relevance Propagation*
MDS	*Mahalanobis Distance Score*
MLS	*MaxLogit Score*
MSP	*Maximum Softmax Probability*
OOD	Fuera de la distribución (*Out-of-Distribution*)
OSR	Reconocimiento en conjunto abierto (*Open Set Recognition*)
PCA	Análisis de componentes principales (*Principal Component Analysis*)
RAPS	*Regularized Adaptive Prediction Sets*
ReAct	*Rectified Activations*
RMDS	*Relative Mahalanobis Distance Score*
SHE	*Simplified Hopfield Energy*
STOOD-X	*Statistical nonparametric Test for OOD Detection with eXplainability*
TPR	Tasa de verdaderos positivos (*True Positive Rate*)
ViM	*Virtual-logit Matching*
WSI	Imagen de lámina completa (*Whole Slide Image*)
XAI	Inteligencia artificial explicable (*eXplainable Artificial Intelligence*)

Summary

[PENDIENTE: summary en inglés (800–1500 palabras)]

Resumen

[PENDIENTE: resumen en castellano]

Índice general

Agradecimientos v

Índice de acrónimos vii

Summary ix

Resumen xi

I. Introducción y estado del arte 1

1. Introducción 3
- 1.1. Contexto . . . 3
- 1.2. Descripción del problema . . . 3
- 1.3. Motivación . . . 3
- 1.4. Preguntas de investigación e hipótesis . . . 3
- 1.5. Objetivos . . . 3
  - 1.5.1. Objetivos generales . . . 3
  - 1.5.2. Objetivos específicos . . . 3
- 1.6. Principales fuentes consultadas . . . 3
- 1.7. Estructura de la memoria . . . 3
- 1.8. Planificación . . . 4
  - 1.8.1. Planificación temporal . . . 4
  - 1.8.2. Planificación económica . . . 4

2. Estado del arte 5
- 2.1. Clasificación de histopatología con aprendizaje profundo . . . 5
- 2.2. Detección de datos fuera de distribución . . . 5
  - 2.2.1. Taxonomía de la detección OOD generalizada . . . 5
  - 2.2.2. Cambio semántico y desplazamiento de covariables . . . 5
  - 2.2.3. Near-OOD y far-OOD . . . 5
  - 2.2.4. Criterio conservador en medicina . . . 5
  - 2.2.5. Métodos excluidos . . . 5
- 2.3. Explicabilidad . . . 5
  - 2.3.1. El efecto Clever Hans . . . 5
  - 2.3.2. Explicaciones locales y conceptuales . . . 5
  - 2.3.3. LRP, CRP y explicaciones glocales . . . 5

II. Fundamentos matemáticos 7

3. Aprendizaje supervisado y redes profundas 9
- 3.1. El problema de clasificación supervisada . . . 9

3.2. Función de pérdida: entropía cruzada y *label smoothing* . . . 9
3.3. Optimización: Adam y AdamW . . . 9
3.4. Arquitecturas . . . 9
3.4.1. Redes neuronales convolucionales . . . 9
3.4.2. Transformers y Vision Transformer . . . 9
3.4.3. Swin Transformer . . . 10
3.4.4. ConvNeXt . . . 10

4. Formalización de la detección OOD y métricas **11**
4.1. Distribución de los datos y cambios de distribución . . . 11
4.2. Regla de decisión por umbral . . . 11
4.3. Curva ROC y AUROC . . . 11
4.4. FPR@95 . . . 11
4.5. AUPR-In y AUPR-Out . . . 11
4.6. CCR@FPRx . . . 11

5. Métodos de detección post hoc **13**
5.1. Métodos basados en logits . . . 13
5.2. Métodos basados en la modificación de activaciones . . . 13
5.3. Métodos basados en características y distancias . . . 13
5.4. STOOD-X . . . 13

6. Inferencia estadística **15**
6.1. El test de Mann-Whitney . . . 15
6.2. Bootstrap y test de McNemar . . . 15
6.3. Predicción conforme . . . 15

7. Explicabilidad **17**
7.1. Layer-wise Relevance Propagation . . . 17
7.2. Concept Relevance Propagation . . . 17

III. Experimentación, resultados y discusión **19**

8. Materiales y métodos **21**
8.1. Conjunto de datos ID . . . 21
8.2. Partición e integridad . . . 21
8.3. Conjuntos OOD . . . 21
8.4. Entorno de ejecución . . . 21
8.5. Protocolo de entrenamiento . . . 21

9. Clasificación ID **23**
9.1. Comparación de los cinco modelos . . . 23
9.2. Elección del modelo . . . 23
9.3. Agrupaciones clínicas . . . 23
9.4. Discusión . . . 23

10. Detección OOD **25**
10.1. Near-OOD principal . . . 25

10.2. Control interno: centro frente a tejido . . . 25
10.3. Cambio de centro y resolución . . . 25
10.4. Far-OOD . . . 25
10.5. Métodos basados en logits y en modificación de activaciones . . . 25
10.6. Discusión . . . 25

11. STOOD-X **27**
11.1. Implementación . . . 27
11.2. Configuración . . . 27
11.3. Puntuación . . . 27
11.4. Resultados . . . 27
11.5. Calibración . . . 27
11.6. Sensibilidad a K . . . 27
11.7. Explicaciones por ejemplos . . . 27
11.8. Discusión . . . 27

12. Predicción conforme **29**
12.1. Detección OOD conforme . . . 29
12.2. Conjuntos de predicción APS y RAPS . . . 29
12.3. Predicción conforme Mondrian . . . 29
12.4. Discusión . . . 29

13. Fuga por lámina **31**
13.1. Identificación de las láminas . . . 31
13.2. Fuga en el espacio de características . . . 31
13.3. Efecto sobre la detección OOD . . . 31
13.4. Limitación metodológica . . . 31

14. Explicabilidad y eliminación de sesgos **33**

IV. Conclusiones y trabajo futuro **35**

15. Conclusiones y trabajo futuro **37**
15.1. Conclusiones . . . 37
15.2. Limitaciones . . . 37
15.3. Trabajo futuro . . . 37

V. Apéndices **39**

A. Tablas de AUPR-In y AUPR-Out **41**

B. Anexo: clases ADI, BACK, DEB y MUC de NCT-CRC **43**

C. Material complementario **45**

Bibliografía **47**

Parte I.

Introducción y estado del arte

1. Introducción

1.1. Contexto

[PENDIENTE: contexto]

1.2. Descripción del problema

[PENDIENTE: descripción del problema]

1.3. Motivación

[PENDIENTE: motivación]

1.4. Preguntas de investigación e hipótesis

[PENDIENTE: preguntas de investigación e hipótesis]

1.5. Objetivos

1.5.1. Objetivos generales

[PENDIENTE: objetivos generales]

1.5.2. Objetivos específicos

[PENDIENTE: objetivos específicos y grado de consecución]

1.6. Principales fuentes consultadas

[PENDIENTE: principales fuentes consultadas]

1.7. Estructura de la memoria

[PENDIENTE: estructura de la memoria]

1.8. Planificación

1.8.1. Planificación temporal

[PENDIENTE: planificación temporal y diagrama de Gantt]

1.8.2. Planificación económica

[PENDIENTE: planificación económica]

2. Estado del arte

2.1. Clasificación de histopatología con aprendizaje profundo

[PENDIENTE: estado del arte de la clasificación histopatológica]

2.2. Detección de datos fuera de distribución

2.2.1. Taxonomía de la detección OOD generalizada

[PENDIENTE: taxonomía]

2.2.2. Cambio semántico y desplazamiento de covariables

[PENDIENTE: cambio semántico frente a desplazamiento de covariables]

2.2.3. Near-OOD y far-OOD

[PENDIENTE: near-OOD y far-OOD]

2.2.4. Criterio conservador en medicina

[PENDIENTE: criterio conservador]

2.2.5. Métodos excluidos

[PENDIENTE: métodos excluidos]

2.3. Explicabilidad

2.3.1. El efecto Clever Hans

[PENDIENTE: efecto Clever Hans]

2.3.2. Explicaciones locales y conceptuales

[PENDIENTE: explicaciones locales frente a conceptuales]

2.3.3. LRP, CRP y explicaciones glocales

[PENDIENTE: LRP, CRP y explicaciones glocales]

Parte II.

Fundamentos matemáticos

3. Aprendizaje supervisado y redes profundas

3.1. El problema de clasificación supervisada

Definición 3.1 (Problema de clasificación). **[PENDIENTE: definición formal]**

Proposición 3.2 (Optimalidad del clasificador de Bayes). ***[PENDIENTE: enunciado]***

Demostración. **[PENDIENTE: demostración]** □

3.2. Función de pérdida: entropía cruzada y *label smoothing*

Definición 3.3 (Función softmax). **[PENDIENTE: definición]**

Definición 3.4 (Entropía cruzada). **[PENDIENTE: definición]**

Proposición 3.5. ***[PENDIENTE: enunciado]***

Demostración. **[PENDIENTE: demostración]** □

Definición 3.6 (*Label smoothing*). **[PENDIENTE: definición]**

Proposición 3.7 (Óptimo de la pérdida con *label smoothing*). ***[PENDIENTE: enunciado]***

Demostración. **[PENDIENTE: demostración]** □

3.3. Optimización: Adam y AdamW

Definición 3.8 (Adam). **[PENDIENTE: reglas de actualización]**

Definición 3.9 (AdamW). **[PENDIENTE: reglas de actualización]**

Observación 3.10. **[PENDIENTE: observación]**

3.4. Arquitecturas

3.4.1. Redes neuronales convolucionales

Definición 3.11 (Convolución discreta). **[PENDIENTE: definición]**

3.4.2. Transformers y Vision Transformer

Definición 3.12 (Atención por producto escalar). **[PENDIENTE: definición]**

3.4.3. Swin Transformer

Proposición 3.13 (Coste de la atención por ventanas). *[PENDIENTE: enunciado: complejidad global frente a por ventanas]*

3.4.4. ConvNeXt

[PENDIENTE: ConvNeXt]

4. Formalización de la detección OOD y métricas

4.1. Distribución de los datos y cambios de distribución

Definición 4.1 (Desplazamiento de covariables). **[PENDIENTE: definición]**

Definición 4.2 (Cambio semántico). **[PENDIENTE: definición]**

4.2. Regla de decisión por umbral

Definición 4.3 (Detector OOD por umbral). **[PENDIENTE: definición]**

4.3. Curva ROC y AUROC

Definición 4.4 (Curva ROC). **[PENDIENTE: definición]**

Teorema 4.5 (Interpretación probabilística del AUROC). ***[PENDIENTE: enunciado]***

Demostración. **[PENDIENTE: demostración]** □

Corolario 4.6 (AUROC empírico y estadístico U). ***[PENDIENTE: enunciado]***

Demostración. **[PENDIENTE: demostración]** □

4.4. FPR@95

Definición 4.7 (FPR@TPRx). **[PENDIENTE: definición]**

4.5. AUPR-In y AUPR-Out

Definición 4.8 (Precisión, exhaustividad y AUPR). **[PENDIENTE: definición]**

4.6. CCR@FPRx

Definición 4.9 (CCR@FPRx). **[PENDIENTE: definición]**

5. Métodos de detección post hoc

5.1. Métodos basados en logits

[PENDIENTE: métodos basados en logits]

5.2. Métodos basados en la modificación de activaciones

[PENDIENTE: métodos basados en la modificación de activaciones]

5.3. Métodos basados en características y distancias

[PENDIENTE: métodos basados en características]

5.4. STOOD-X

[PENDIENTE: STOOD-X]

6. Inferencia estadística

6.1. El test de Mann-Whitney

Definición 6.1 (Estadístico U de Mann-Whitney)**.** **[PENDIENTE: definición]**

Proposición 6.2 (Media y varianza de U bajo la hipótesis nula)**.** ***[PENDIENTE: enunciado]***

Demostración. **[PENDIENTE: demostración]** □

Teorema 6.3 (Aproximación normal)**.** ***[PENDIENTE: enunciado]***

Observación 6.4 (Empates, continuidad y saturación). **[PENDIENTE: desarrollo]**

Observación 6.5 (Hipótesis de independencia). **[PENDIENTE: desarrollo]**

6.2. Bootstrap y test de McNemar

Definición 6.6 (Intervalo bootstrap por percentiles)**.** **[PENDIENTE: definición]**

Proposición 6.7 (Test de McNemar)**.** ***[PENDIENTE: enunciado]***

6.3. Predicción conforme

[PENDIENTE: introducción a la predicción conforme]

7. Explicabilidad

7.1. Layer-wise Relevance Propagation

Definición 7.1 (Relevancia y conservación). **[PENDIENTE: definición]**

Proposición 7.2 (Regla LRP-z^+ como descomposición de Taylor profunda). ***[PENDIENTE: enunciado]***

Demostración. **[PENDIENTE: demostración]** □

Definición 7.3 (Regla LRP-ε). **[PENDIENTE: definición]**

7.2. Concept Relevance Propagation

[PENDIENTE: CRP]

Parte III.

Experimentación, resultados y discusión

8. Materiales y métodos

8.1. Conjunto de datos ID

[PENDIENTE: conjunto ID]

8.2. Partición e integridad

[PENDIENTE: partición]

8.3. Conjuntos OOD

[PENDIENTE: conjuntos OOD]

8.4. Entorno de ejecución

[PENDIENTE: hardware y software]

8.5. Protocolo de entrenamiento

[PENDIENTE: protocolo de entrenamiento]

9. Clasificación ID

9.1. Comparación de los cinco modelos

[PENDIENTE: comparación]

9.2. Elección del modelo

[PENDIENTE: elección del Swin-S]

9.3. Agrupaciones clínicas

[PENDIENTE: agrupaciones]

9.4. Discusión

[PENDIENTE: discusión global]

10. Detección OOD

10.1. Near-OOD principal

[PENDIENTE: near-OOD]

10.2. Control interno: centro frente a tejido

[PENDIENTE: control interno]

10.3. Cambio de centro y resolución

[PENDIENTE: PANDA]

10.4. Far-OOD

[PENDIENTE: far-OOD]

10.5. Métodos basados en logits y en modificación de activaciones

[PENDIENTE: familias]

10.6. Discusión

[PENDIENTE: discusión global]

11. STOOD-X

11.1. Implementación

[PENDIENTE: implementación]

11.2. Configuración

[PENDIENTE: configuración]

11.3. Puntuación

[PENDIENTE: puntuación]

11.4. Resultados

[PENDIENTE: resultados]

11.5. Calibración

[PENDIENTE: calibración]

11.6. Sensibilidad a K

[PENDIENTE: sensibilidad a K]

11.7. Explicaciones por ejemplos

[PENDIENTE: explicaciones]

11.8. Discusión

[PENDIENTE: discusión global]

12. Predicción conforme

12.1. Detección OOD conforme

[PENDIENTE: detección OOD conforme]

12.2. Conjuntos de predicción APS y RAPS

[PENDIENTE: APS]

12.3. Predicción conforme Mondrian

[PENDIENTE: Mondrian]

12.4. Discusión

[PENDIENTE: discusión global]

13. Fuga por lámina

13.1. Identificación de las láminas

[PENDIENTE: láminas]

13.2. Fuga en el espacio de características

[PENDIENTE: fuga]

13.3. Efecto sobre la detección OOD

[PENDIENTE: efecto]

13.4. Limitación metodológica

[PENDIENTE: limitación]

14. Explicabilidad y eliminación de sesgos

[PENDIENTE: capítulo en desarrollo]

Parte IV.

Conclusiones y trabajo futuro

15. Conclusiones y trabajo futuro

15.1. Conclusiones

[PENDIENTE: conclusiones]

15.2. Limitaciones

[PENDIENTE: limitaciones]

15.3. Trabajo futuro

[PENDIENTE: trabajo futuro]

Parte V.

Apéndices

A. Tablas de AUPR-In y AUPR-Out

[PENDIENTE: tablas AUPR]

B. Anexo: clases ADI, BACK, DEB y MUC de NCT-CRC

[PENDIENTE: anexo NCT]

C. Material complementario

[PENDIENTE: material complementario]

Bibliografía