UNIVERSIDAD
DE GRANADA

Facultad de Ciencias y Escuela Técnica Superior de Ingenierías
Informática y de Telecomunicación

Doble Grado en Ingeniería Informática y Matemáticas

TRABAJO DE FIN DE GRADO

Inteligencia Artificial Explicable en medicina: métodos para introducir al humano en la adquisición de conocimiento

Santiago López Cerro

Curso académico 2026–2027

Inteligencia Artificial Explicable en medicina: métodos para introducir al humano en la adquisición de conocimiento

Santiago López Cerro

Santiago López Cerro *Inteligencia Artificial Explicable en medicina: métodos para introducir al humano en la adquisición de conocimiento*.

Trabajo de fin de Grado. Curso académico 2026–2027.

Responsable de tutorización

Francisco Herrera Triguero
Departamento de Ciencias de la Computación e Inteligencia Artificial

Iván Sevillano García
Departamento de Ciencias de la Computación e Inteligencia Artificial

Doble Grado en Ingeniería Informática y Matemáticas

Facultad de Ciencias y Escuela Técnica Superior de Ingenierías Informática y de Telecomunicación

Universidad de Granada

Declaración de originalidad

D./Dña. Santiago López Cerro

Declaro explícitamente que el trabajo presentado como Trabajo de Fin de Grado (TFG), correspondiente al curso académico 2026–2027, es original, entendido esto en el sentido de que no he utilizado para la elaboración del trabajo fuentes sin citarlas debidamente.

En Granada a 14 de noviembre de 2026

Fdo: Santiago López Cerro

Dedicatoria (opcional)
Ver archivo `preliminares/dedicatoria.tex`

Agradecimientos

[PENDIENTE: agradecimientos]

Índice de acrónimos

Acrónimo	Significado
AD	Detección de anomalías (*Anomaly Detection*)
APS	*Adaptive Prediction Sets*
ASH	*Activation Shaping*
AUPR	Área bajo la curva precisión-exhaustividad (*Area Under the Precision-Recall curve*)
AUROC	Área bajo la curva ROC (*Area Under the Receiver Operating Characteristic curve*)
CCR	Tasa de clasificación correcta (*Correct Classification Rate*)
CNN	Red neuronal convolucional (*Convolutional Neural Network*)
CRP	*Concept Relevance Propagation*
DICE	*Directed Sparsification*
DTD	*Describable Textures Dataset*
EBO	*Energy-Based OOD*
FPR	Tasa de falsos positivos (*False Positive Rate*)
H&E	Hematoxilina y eosina
FFPE	Fijado en formalina e incluido en parafina (*Formalin-Fixed Paraffin-Embedded*)
ID	Dentro de la distribución (*In-Distribution*)
KNN	k vecinos más cercanos (*k-Nearest Neighbors*)
LAC	*Least Ambiguous set-valued Classifier*
LDA	Análisis discriminante lineal (*Linear Discriminant Analysis*)
LOSO	*Leave-One-Slide-Out*
LRP	*Layer-wise Relevance Propagation*
MDS	*Mahalanobis Distance Score*
MLS	*MaxLogit Score*
MSP	*Maximum Softmax Probability*
ND	Detección de novedades (*Novelty Detection*)
OOD	Fuera de la distribución (*Out-of-Distribution*)
OSR	Reconocimiento en conjunto abierto (*Open Set Recognition*)
PCA	Análisis de componentes principales (*Principal Component Analysis*)
RAPS	*Regularized Adaptive Prediction Sets*
ReAct	*Rectified Activations*
RMDS	*Relative Mahalanobis Distance Score*
SHE	*Simplified Hopfield Energy*
STOOD-X	*Statistical nonparametric Test for OOD Detection with eXplainability*
TPR	Tasa de verdaderos positivos (*True Positive Rate*)
ViM	*Virtual-logit Matching*
WSI	Imagen de lámina completa (*Whole Slide Image*)

Acrónimo	**Significado**
XAI	Inteligencia artificial explicable (*eXplainable Artificial Intelligence*)

Summary

[PENDIENTE: summary en inglés (800–1500 palabras)]

Resumen

[PENDIENTE: resumen en castellano]

Índice general

Agradecimientos v

Índice de acrónimos vii

Summary ix

Resumen xi

I. Introducción y estado del arte 1

1. Introducción 3
- 1.1. Contexto . . . 3
- 1.2. Descripción del problema . . . 3
- 1.3. Motivación . . . 3
- 1.4. Preguntas de investigación e hipótesis . . . 3
- 1.5. Objetivos . . . 3
  - 1.5.1. Objetivos generales . . . 3
  - 1.5.2. Objetivos específicos . . . 3
- 1.6. Principales fuentes consultadas . . . 3
- 1.7. Estructura de la memoria . . . 3
- 1.8. Planificación . . . 4
  - 1.8.1. Planificación temporal . . . 4
  - 1.8.2. Planificación económica . . . 4

2. Estado del arte 5
- 2.1. Clasificación histopatológica con aprendizaje profundo . . . 5
  - 2.1.1. Láminas completas, parches y graduación de Gleason . . . 5
  - 2.1.2. Conjuntos de datos y aprendizaje por transferencia . . . 6
  - 2.1.3. Detección OOD en patología digital . . . 6
- 2.2. Detección de datos fuera de distribución . . . 7
  - 2.2.1. Cambio semántico y desplazamiento de covariables . . . 7
  - 2.2.2. Taxonomía de la detección OOD generalizada . . . 8
  - 2.2.3. Situación de este trabajo y criterio conservador . . . 10
  - 2.2.4. Familias de métodos . . . 10
  - 2.2.5. Métodos excluidos . . . 12
  - 2.2.6. Evaluación: OpenOOD, near-OOD y far-OOD . . . 13
  - 2.2.7. Retos abiertos . . . 14
- 2.3. Explicabilidad . . . 14
  - 2.3.1. Conceptos básicos y transparencia . . . 15
  - 2.3.2. Tipos de métodos y de explicaciones . . . 15
  - 2.3.3. El efecto Clever Hans y las correlaciones espurias . . . 16

2.3.4. Explicaciones locales, globales y glocales: de LRP a CRP 17
2.3.5. Explicabilidad en la detección OOD: PCX y STOOD-X 18
2.4. Síntesis 18

II. Fundamentos matemáticos 21

3. Aprendizaje supervisado y redes profundas 23
3.1. El problema de clasificación supervisada 23
3.2. Redes neuronales 23
3.2.1. Neuronas y funciones de activación 23
3.2.2. Redes neuronales profundas 25
3.2.3. Teorema de aproximación universal 26
3.3. Función de pérdida: entropía cruzada y *label smoothing* 29
3.4. Optimización: Adam y AdamW 32
3.4.1. Adam 32
3.4.2. Regularización L_2 y decaimiento de pesos 34
3.4.3. AdamW 35
3.5. Arquitecturas para clasificación de imágenes 35
3.5.1. Redes neuronales convolucionales 35
3.5.2. Redes residuales y normalización 39
3.5.3. Transformers 41
3.5.4. Vision Transformer 46
3.5.5. Swin Transformer 48
3.5.6. ConvNeXt 50

4. Formalización de la detección OOD y métricas 55
4.1. Distribución de los datos y cambios de distribución 56
4.2. Regla de decisión por umbral 57
4.3. Métricas de evaluación 57
4.3.1. Curva ROC y AUROC 57
4.3.2. FPR@95 58
4.3.3. AUPR-In y AUPR-Out 58
4.3.4. CCR@FPRx 58

5. Métodos de detección post hoc 59
5.1. Métodos basados en logits 59
5.2. Métodos basados en la modificación de activaciones 59
5.3. Métodos basados en características y distancias 60
5.4. STOOD-X 63

6. Inferencia estadística 67
6.1. Fundamentos de los contrastes de hipótesis 67
6.2. El test de Mann-Whitney 67
6.3. El test de McNemar 67
6.4. Intervalos de confianza *bootstrap* 69
6.5. Predicción conforme 70
6.5.1. Intercambiabilidad y predicción conforme dividida 71

6.5.2. p-valor conforme y cobertura . . . 71
6.5.3. Puntuaciones para clasificación . . . 73
6.5.4. Predicción conforme condicionada por clase (Mondrian) . . . 74

7. Explicabilidad **77**
7.1. Layer-wise Relevance Propagation (LRP) . . . 78
7.1.1. Reglas de propagación . . . 79
7.1.2. LRP como descomposición de Taylor profunda . . . 81
7.1.3. Canonización y arquitecturas modernas . . . 83
7.1.4. Interpretación probabilística de la regla z^+ . . . 83
7.2. Concept Relevance Propagation . . . 83

III. Experimentación, resultados y discusión **85**

8. Materiales y métodos **87**
8.1. Conjunto de datos ID . . . 87
8.2. Partición e integridad . . . 88
8.2.1. Verificación de la integridad . . . 90
8.3. Conjuntos OOD . . . 91
8.3.1. NCT-CRC-HE-100K-NONORM . . . 91
8.3.2. PANDA . . . 92
8.3.3. Control de resolución y DTD . . . 93
8.4. Entorno de ejecución . . . 93
8.5. Protocolo de entrenamiento . . . 94
8.5.1. DataLoader . . . 94
8.5.2. Learner . . . 94

9. Clasificación ID **95**
9.1. Comparación de los cinco modelos . . . 95
9.1.1. Resultados globales . . . 95
9.1.2. Curvas de entrenamiento y matrices de confusión . . . 95
9.1.3. Sensibilidad por clase . . . 95
9.2. Elección del modelo . . . 101
9.3. Agrupaciones clínicas . . . 102
9.4. Discusión . . . 103

10. Detección OOD **105**
10.1. Near-OOD principal . . . 105
10.2. Control interno: centro frente a tejido . . . 105
10.3. PANDA: cambio de centro y de escala . . . 109
10.4. Far-OOD . . . 111
10.5. Métodos basados en logits y en modificación de activaciones . . . 111
10.6. Discusión . . . 114

11. STOOD-X **115**
11.1. Implementación . . . 115
11.2. Configuración . . . 115
11.3. Puntuación . . . 115

11.4. Resultados . . . 115
11.5. Calibración . . . 116
11.6. Sensibilidad a K . . . 118
11.7. Explicaciones por ejemplos . . . 118
11.8. Discusión . . . 118

12. Predicción conforme **121**
12.1. Detección OOD conforme . . . 121
12.2. Conjuntos de predicción APS y RAPS . . . 122
12.3. Predicción conforme Mondrian . . . 124
12.4. Discusión . . . 128

13. Fuga por lámina **129**
13.1. Identificación de las láminas . . . 129
13.2. Fuga en el espacio de características . . . 129
13.3. Efecto sobre la detección OOD . . . 129
13.4. Limitación metodológica . . . 129

14. Explicabilidad y eliminación de sesgos **133**

IV. Conclusiones y trabajo futuro **135**

15. Conclusiones y trabajo futuro **137**
15.1. Conclusiones . . . 137
15.2. Limitaciones . . . 137
15.3. Trabajo futuro . . . 137

V. Apéndices **139**

A. Tablas de AUPR-In y AUPR-Out **141**

B. Anexo: clases ADI, BACK, DEB y MUC de NCT-CRC **143**

C. Material complementario **145**
C.1. Explicaciones por ejemplos de STOOD-X . . . 145
C.1.1. Con $K = 500$ . . . 145
C.1.2. Con la variante exploratoria K_c . . . 145
C.2. Imágenes de muestra . . . 157

Bibliografía **159**

Parte I.

Introducción y estado del arte

1. Introducción

1.1. Contexto

[PENDIENTE: contexto]

1.2. Descripción del problema

[PENDIENTE: descripción del problema]

1.3. Motivación

[PENDIENTE: motivación]

1.4. Preguntas de investigación e hipótesis

[PENDIENTE: preguntas de investigación e hipótesis]

1.5. Objetivos

1.5.1. Objetivos generales

[PENDIENTE: objetivos generales]

1.5.2. Objetivos específicos

[PENDIENTE: objetivos específicos y grado de consecución]

1.6. Principales fuentes consultadas

[PENDIENTE: principales fuentes consultadas]

1.7. Estructura de la memoria

[PENDIENTE: estructura de la memoria]

1.8. Planificación

1.8.1. Planificación temporal

[PENDIENTE: planificación temporal y diagrama de Gantt]

1.8.2. Planificación económica

[PENDIENTE: planificación económica]

2. Estado del arte

Este capítulo revisa los trabajos sobre los que se apoya la memoria. La apartado 2.1 recoge el uso del aprendizaje profundo en la clasificación de imágenes histopatológicas y lo que se ha hecho en detección de datos fuera de distribución (*out-of-distribution*, OOD) en este dominio. La apartado 2.2 presenta el marco de la detección OOD generalizada, las familias de métodos y su evaluación, y la apartado 2.3, los conceptos de explicabilidad que se usan después y su aplicación a la detección OOD. La apartado 2.4 resume lo que la literatura deja abierto y cómo encaja en ello este trabajo. Las definiciones formales se dejan para la parte II.

2.1. Clasificación histopatológica con aprendizaje profundo

2.1.1. Láminas completas, parches y graduación de Gleason

El análisis histopatológico de las muestras de biopsia es la referencia clínica para determinar si hay tumor, de qué tipo es y cuán agresivo es [4]. Las muestras se tiñen con hematoxilina y eosina (H&E) y se digitalizan con escáneres de preparaciones completas, de modo que cada preparación se convierte en una *imagen de lámina completa* (*whole-slide image*, WSI) [4]. Estas imágenes contienen una cantidad de datos muy grande, y la mayor parte de su superficie no aporta información: bordes de la preparación, fondo y artefactos de escaneo [4].

Por su tamaño, la mayoría de los enfoques no procesan la WSI de una vez. La estrategia habitual es dividirla en parches pequeños, clasificar cada parche por separado y agregar después las predicciones, ya sea en proporciones de cada clase en la lámina o en mapas de probabilidad para cada patrón [4]. En el reto PANDA, la mayoría de los equipos mejor clasificados extraían una muestra de parches de cada WSI, los pasaban por una red convolucional y combinaban sus características para predecir directamente el grado de la lámina. Este entrenamiento *débilmente supervisado*, que solo necesita la etiqueta de la lámina completa y no anotaciones por píxel, permitió entrenar un único modelo de extremo a extremo [8]. La clasificación por parches tiene también consecuencias para la detección de anomalías: Linmans et al. agregan las incertidumbres de los parches para obtener una puntuación por lámina y muestran que esta puede señalar regiones OOD que ocupan una parte pequeña de la WSI [39]. En este trabajo se clasifican parches de 224×224 píxeles extraídos de WSI anotadas (apartado 8.1).

La graduación del cáncer de próstata se basa en el sistema de Gleason. Los patólogos clasifican el tumor en distintos patrones de crecimiento según la arquitectura histológica del tejido y, a partir de la distribución de esos patrones, asignan cada biopsia a uno de cinco grupos, conocidos como grupos de grado ISUP (*International Society of Urological Pathology*) [8]. Esta valoración es subjetiva y presenta una variabilidad considerable entre patólogos y en un mismo patólogo, lo que lleva tanto a infragraduar como a sobregraduar tumores [8]. Ayensa-Jiménez et al. señalan además que la mayoría de los sistemas de inteligencia artificial se limitan a las categorías estándar de Gleason y no recogen la diversidad morfológica que los patólogos distinguen en la práctica [4].

2.1.2. Conjuntos de datos y aprendizaje por transferencia

Una dificultad recurrente en patología computacional es la escasez de conjuntos de datos anotados grandes y diversos, porque el etiquetado lo deben hacer patólogos expertos y requiere mucho tiempo [4]. El conjunto de datos de este trabajo procede de Ayensa-Jiménez et al. [4], que proponen un conjunto anotado con mayor granularidad que las categorías de Gleason. Según sus autores, patólogos expertos segmentaron manualmente 7.752 regiones en 85 imágenes de lámina completa de piezas de prostatectomía radical, clasificadas en 14 categorías histológicas que reflejan patrones morfológicos reconocidos en la práctica clínica. Con este conjunto, y según el mismo artículo, el mejor modelo alcanza una exactitud del 97,33 % a nivel de parche en la clasificación en 14 clases [4]. Los propios autores advierten de que el estudio se basa en un único conjunto de datos, preparado por un mismo equipo en condiciones controladas, y de que la validación clínica requeriría conjuntos externos multicéntricos preparados, digitalizados y anotados por equipos distintos [4]. Las características del conjunto se detallan en la apartado 8.1.

El conjunto público más grande de biopsias de próstata es el del reto PANDA (*Prostate cANcer graDe Assessment*), organizado por Bulten et al. con 10.616 biopsias digitalizadas para el desarrollo de algoritmos y en el que participaron 1.290 desarrolladores [8]. Su diseño separaba a los desarrolladores de la evaluación, que se hizo de forma ciega sobre conjuntos de validación internos y externos de Europa y Estados Unidos, con distintos laboratorios, procedimientos de preparación y escáneres [8]. Según los autores, los algoritmos alcanzaron en la validación externa un acuerdo con uropatólogos expertos similar o superior al de patólogos generales; el error más frecuente fue sobrediagnosticar biopsias benignas como grupo 1, lo que atribuyen probablemente al desplazamiento de la distribución entre los datos de entrenamiento y los de validación externa [8]. En este trabajo se usan teselas de PANDA como conjunto OOD de próstata adquirido en otros centros (apartado 8.3.2).

Ante la escasez de datos médicos anotados, el aprendizaje por transferencia reutiliza los pesos de una red entrenada sobre un conjunto grande y no médico, como ImageNet [30]. Kandel y Castelli distinguen dos formas de hacerlo: el *ajuste fino*, en el que los pesos originales se reentrenan para el nuevo conjunto, y la *extracción de características*, en la que se fijan y la red se usa solo para extraer características [30]. En su estudio, con tres arquitecturas convolucionales y dos conjuntos de histopatología, ajustar la red entera no dio siempre el mejor resultado: en las dos redes menos profundas (VGG16 y VGG19) los mejores resultados se obtuvieron ajustando solo los bloques superiores, mientras que en la más profunda (InceptionV3) ajustar toda la red mejoró el rendimiento; a partir de sus experimentos, recomiendan una tasa de aprendizaje baja para no deteriorar los pesos preentrenados [30]. Los propios autores advierten de que sus conclusiones se refieren a la aplicación estudiada [30]. Ayensa-Jiménez et al. siguen también este enfoque: parten de cinco arquitecturas preentrenadas en ImageNet, tres convolucionales (ResNet50, EfficientNet-B2 y EfficientNetV2-T) y dos transformers (ViT-Base y XCiT), y entrenan sobre ellas una cabeza de clasificación [4]. Las arquitecturas usadas en este trabajo se describen en la apartado 3.5.

2.1.3. Detección OOD en patología digital

Los datos de patología digital siguen una distribución heterogénea y de cola larga, con muchas anomalías y artefactos, lo que hace especialmente difícil desplegar estos modelos en la práctica clínica [39]. Además, los modelos suelen entrenarse y evaluarse sobre conjuntos muy depurados que no reflejan esa variedad [39]. Howard et al. muestran, sobre el reposi-

torio TCGA, que las imágenes histológicas llevan una *firma propia del centro* que las envía, debida a diferencias en la obtención de la muestra, la tinción, la digitalización y la población de pacientes, y que esta firma puede restar capacidad de generalización a los modelos [26]. Bulten et al. también señalan que los algoritmos de graduación son sensibles a sesgos en su desarrollo y validación, que pueden hacer que rindan peor fuera de las cohortes con las que se desarrollaron [8].

La detección OOD en este dominio está poco explorada. Linmans et al. indican que los trabajos previos sobre estimación de incertidumbre en histopatología la relacionaban con la exactitud de las predicciones y no evaluaban la detección de datos OOD, y que el trabajo que sí la evaluaba lo hacía solo con datos de un órgano completamente distinto [39]. Su estudio evalúa varios métodos de estimación de incertidumbre sobre láminas completas, distinguiendo entre un problema *near-OOD*, la detección de linfoma en ganglios linfáticos, tejido muy parecido a la clase benigna de entrenamiento, y problemas *far-OOD*, como la presencia de tejido de colon en biopsias de próstata [39]. Según sus resultados, los conjuntos de redes (*deep ensembles*) son los mejores en far-OOD, mientras que en el problema near-OOD los supera un conjunto de cabezas entrenado para favorecer la diversidad; las conclusiones obtenidas en los benchmarks clásicos de visión por computador no se trasladan por completo a la patología digital [39]. También muestran que la presencia de tejido OOD empeora la detección del tumor, y concluyen que el ajuste de estos sistemas puede requerir conocimiento experto del problema concreto [39]. Estos trabajos motivan la revisión de la detección OOD de la sección siguiente.

2.2. Detección de datos fuera de distribución

La mayoría de los modelos de aprendizaje automático se entrenan bajo el supuesto de *mundo cerrado*: se asume que los datos de prueba proceden de la misma distribución que los de entrenamiento, la distribución *en distribución* (*in-distribution*, ID) [78]. Al desplegarlos en un escenario abierto, pueden aparecer muestras OOD que el modelo clasifica con una confianza alta en alguna de las clases conocidas [78]. Un sistema fiable debería detectar estas muestras y rechazarlas o derivarlas a una persona, como el sistema de conducción autónoma que avisa y cede el control al conductor ante una escena que no ha visto nunca [78]. Sevillano-García et al. subrayan que, en escenarios críticos, sin detección OOD el modelo toma decisiones incorrectas en lugar de remitirlas al juicio humano [62]. El término *detección OOD* apareció en 2017 y desde entonces el número de métodos propuestos no ha dejado de crecer [78].

2.2.1. Cambio semántico y desplazamiento de covariables

Yang et al. distinguen dos tipos de cambio de distribución [78]. En el *desplazamiento de covariables* cambia la distribución de las entradas, pero no el espacio de etiquetas: ejemplos de ello son los cambios de dominio o de estilo y los ejemplos adversarios. En el *cambio semántico* aparecen clases nuevas o se alteran las existentes, lo que modifica también, de forma indirecta, la distribución de las entradas. Como un cambio en las etiquetas arrastra un cambio en las entradas, los autores proponen distinguir ambos tipos por la *intención* del cambio: si se pretende modificar solo la apariencia de los datos o su contenido semántico [78]. La formalización se recoge en la apartado 4.1.

Ambos cambios se estudian con objetivos distintos. El desplazamiento de covariables se usa sobre todo para evaluar la generalización y la robustez de los modelos, que deberían

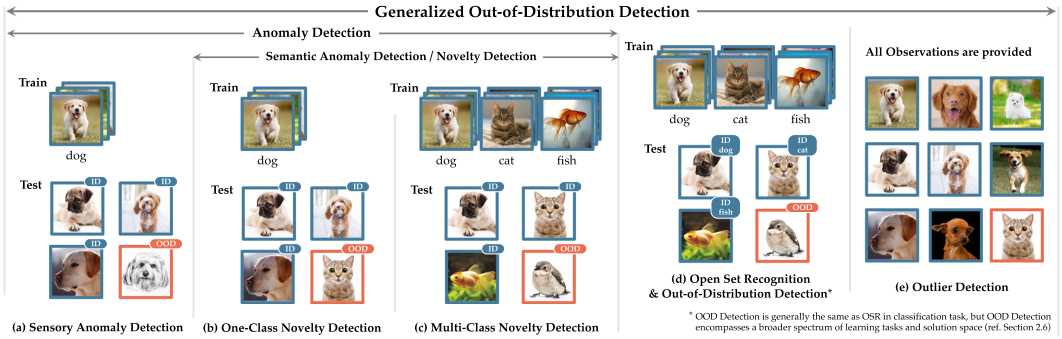

Figura 2.1.: Subtareas de la detección OOD generalizada: (a) detección de anomalías sensoriales, (b) detección de novedades de una clase, (c) detección de novedades multiclase, (d) reconocimiento en conjunto abierto y detección OOD y (e) detección de valores atípicos. Fuente: Yang et al. [78] (figura 2).

seguir clasificando bien las muestras afectadas; en cambio, el cambio semántico es el foco de las tareas de detección, porque el modelo no debería hacer ninguna predicción sobre clases que no conoce [78]. La adaptación y la generalización de dominio abordan el primer problema: esperan desplazamiento de covariables en la prueba, sin cambio semántico, y exigen que el modelo siga acertando. Cuando ocurren ambos cambios a la vez, el modelo debería ser robusto al desplazamiento de covariables y detectar el cambio semántico [78]. En este trabajo, PANDA corresponde a un desplazamiento de covariables, porque es tejido del mismo órgano adquirido en otros centros, mientras que DTD introduce un cambio semántico (apartado 8.3).

2.2.2. Taxonomía de la detección OOD generalizada

Varios problemas comparten con la detección OOD la hipótesis de mundo abierto y el objetivo de identificar muestras que no pertenecen a la distribución de referencia: la *detección de anomalías* (*anomaly detection*, AD), la *detección de novedades* (*novelty detection*, ND), el *reconocimiento en conjunto abierto* (*open set recognition*, OSR) y la *detección de valores atípicos* (*outlier detection*) [78]. Estos temas se han desarrollado de forma aislada y sus diferencias de definición confunden a menudo a investigadores y usuarios. Para ordenarlos, Yang et al. proponen el marco de la *detección OOD generalizada*, en el que los cinco problemas son casos particulares que se distinguen mediante cuatro dicotomías: si se detecta desplazamiento de covariables o cambio semántico; si los datos ID tienen una o varias clases; si la tarea exige clasificar las muestras ID; y si es inductiva, con fases de entrenamiento y prueba, o transductiva, con todas las observaciones disponibles de antemano [78]. La figura 2.1 ilustra las subtareas y la cuadro 2.1 las resume según estos criterios.

Detección de anomalías. Parte de un concepto de *normalidad* definido de antemano, normalmente sin subclases, y busca detectar en la prueba cualquier muestra que se desvíe de él [78]. Según el tipo de desviación, se habla de AD *sensorial*, que detecta desplazamiento de covariables en muestras de la misma categoría (por ejemplo, defectos en la inspección industrial), o de AD *semántica*, que detecta muestras de clases distintas de la normal. Su rasgo distintivo

Tabla 2.1.: Subtareas de la detección OOD generalizada según el tipo de cambio que detectan, el número de clases ID, la necesidad de clasificar las muestras ID y el esquema de aprendizaje. Elaboración propia a partir de Yang et al. [78].

Subtarea	**Cambio que detecta**	**Clases ID**	**¿Clasificar ID?**	**Esquema**
AD sensorial	Covariables	Indiferente (un todo)	No	Inductivo
AD semántica / ND de una clase	Semántico	Una	No	Inductivo
ND multiclase	Semántico	Varias	No	Inductivo
OSR	Semántico	Varias	Sí	Inductivo
Detección OOD	Semántico[a]	Varias	Sí[b]	Inductivo
Valores atípicos	Ambos	Mayoría de las observaciones	No	Transductivo

[a] Algunos trabajos consideran también el desplazamiento de covariables (apartado 2.2.3). [b] Salvo los métodos basados en densidad, que no la requieren.

es que trata los datos normales como un todo, sin distinguir las clases que pueda haber entre ellos [78].

Detección de novedades. Busca muestras de prueba que no pertenecen a ninguna de las categorías de entrenamiento y, a diferencia de la AD, no las considera erróneas, sino recursos para un análisis posterior o para el aprendizaje incremental del modelo [78]. Puede ser de una clase o multiclase, pero en ambos casos se plantea como una clasificación binaria entre lo conocido y lo nuevo, sin clasificar las muestras ID; por eso equivale a la AD semántica [78].

Reconocimiento en conjunto abierto. Exige al clasificador, a la vez, clasificar correctamente las muestras de las clases conocidas y detectar las de clases desconocidas [78]. Surge para corregir la tendencia de los modelos entrenados en un mundo cerrado a asignar con alta confianza las muestras desconocidas a alguna clase conocida, comportamiento al que se ha llamado «agnostofobia» [78, 13]. Su objetivo coincide con el de la ND multiclase, salvo por el requisito de clasificar bien las muestras ID [78].

Detección OOD. Nace de la observación de que los modelos profundos clasifican con exceso de confianza muestras de distribuciones semánticas distintas, y pide rechazar las entradas que no deberían recibir una predicción sin perjudicar la clasificación ID [78, 24]. En clasificación multiclase resuelve el mismo problema que el OSR, y las diferencias son de práctica: los benchmarks de OSR dividen un conjunto de datos por clases, mientras que los de detección OOD toman un conjunto como ID y otros como OOD; el OSR desaconseja usar datos adicionales en el entrenamiento; y la detección OOD abarca más tareas y más tipos de solución [78]. La métrica conjunta CCR@FPRx, propuesta para el OSR, evalúa a la vez la detección y la clasificación ID [78, 13]; las métricas se definen en la apartado 4.3.

Detección de valores atípicos. Es la única subtarea que no sigue el esquema de entrenamiento y prueba: dispone de todas las observaciones y busca las que difieren notablemente del resto,

por cambio semántico o de covariables, de modo que la «distribución ID» es la de la mayoría de los datos [78]. Se usa, por ejemplo, para depurar conjuntos de datos antes de entrenar [78].

Yang et al. relacionan además la detección OOD con otros temas vecinos, entre ellos la *predicción conforme* [78]. Este marco estadístico proporciona medidas de confianza para las predicciones y, en lugar de una única estimación, produce intervalos o conjuntos de predicción con un nivel de confianza especificado [78, 63, 3]. En la detección OOD, unos conjuntos de predicción más amplios o unos niveles de confianza más bajos pueden servir como indicio de que la muestra es OOD; según los autores, la investigación en la intersección de ambos campos es todavía incipiente, pero merece explorarse [78]. La predicción conforme se aplica en el capítulo 12.

2.2.3. Situación de este trabajo y criterio conservador

En la mayoría de los trabajos, «fuera de distribución» se entiende como «fuera de la distribución semántica o de etiquetas», y la detección del desplazamiento de covariables es una cuestión discutida, porque entra en conflicto con la generalización OOD [78]. Yang et al. ofrecen otra definición, desde el punto de vista de la generalización: la detección OOD busca las muestras a las que el modelo no puede o no quiere generalizar. En clasificación de imágenes se espera que el modelo generalice al desplazamiento de covariables y solo deje de hacerlo ante un cambio semántico, pero hay aplicaciones en las que conviene rechazar también el primero [78].

Aunque en clasificación general la detección OOD suele restringirse al cambio semántico, Yang et al. [78] señalan que en tareas de alto riesgo, como la clasificación de imágenes médicas (Zimmerer et al. [83]), se espera que los modelos sean conservadores y rechacen cualquier muestra que se desvíe de la distribución de entrenamiento. Siguiendo este criterio, en este trabajo se considera OOD tanto el cambio semántico (DTD) como el desplazamiento de covariables debido al cambio de centro (PANDA).

Con estas definiciones, este trabajo se sitúa en la subtarea (d) de la figura 2.1: el conjunto ID tiene varias clases (las 14 categorías histológicas), el clasificador debe seguir clasificándolas y se trata de detectar las muestras que no debería procesar. La inclusión de PANDA responde al criterio conservador anterior: en un contexto clínico interesa también avisar de cambios de apariencia que degradan el clasificador. El propio control de resolución de este trabajo lo ilustra, ya que la exactitud del clasificador cae del 96,88 % en el test ID al 90,77 % en las mismas imágenes con menor resolución (apartado 8.3.3).

2.2.4. Familias de métodos

Yang et al. agrupan los métodos de detección OOD en cuatro familias: basados en clasificación, en densidad, en distancia y en reconstrucción [78]. La cuadro 2.2 las resume e indica cuáles se evalúan en este trabajo. La frontera entre familias no es nítida: Yang et al. citan el modelado gaussiano por clase tanto entre los métodos de densidad como entre los de distancia, y sitúan SHE entre los métodos basados en la salida del clasificador [78]. En este trabajo se sigue la agrupación del capítulo 5.

Los *métodos basados en clasificación* son los más numerosos. La investigación en detección OOD partió de un método de referencia sencillo, que usa la máxima probabilidad *softmax* (MSP) como indicador de que la muestra es ID [78, 24], y los primeros trabajos se centraron en obtener mejores puntuaciones a partir de la salida de la red. ODIN combina escalado de temperatura y una pequeña perturbación de la entrada para separar mejor las muestras

Tabla 2.2.: Familias de métodos de detección OOD, con algunos ejemplos citados por Yang et al. [78] y los métodos evaluados en este trabajo, con la sección en la que se describen. Elaboración propia.

Familia	**Idea**	**Ejemplos**	**Evaluados aquí**
Clasificación, post hoc sobre la salida	Puntuación a partir de la salida de un clasificador ya entrenado	MSP, ODIN, Energy, SHE	MSP, MaxLogit, Energy (apartado 5.1); SHE (apartado 5.3)
Clasificación, post hoc sobre activaciones o pesos	Modificar activaciones o pesos antes de calcular la puntuación	ReAct, DICE, ASH	ReAct, ASH, DICE (apartado 5.2)
Clasificación, con entrenamiento	Regularizar el entrenamiento, a veces con datos atípicos reales o sintéticos	Rama de confianza, G-ODIN, LogitNorm, OE, MCD	—
Clasificación, basados en gradientes	Usar la información del gradiente	ODIN, GradNorm	— (apartado 2.2.5)
Densidad	Modelar la distribución ID y señalar las regiones de baja densidad	Gaussianas condicionales por clase[a], flujos	—
Distancia	Medir la distancia a prototipos o muestras ID en el espacio de características	Mahalanobis[a], KNN, coseno, ViM	MDS, RMDS[a], KNN, ViM (apartado 5.3); STOOD-X (apartado 5.4)
Reconstrucción	Comparar la reconstrucción de un codificador-decodificador	Autocodificadores, MoodCat, READ	—

[a]MDS y RMDS modelan cada clase con una gaussiana en el espacio de características; Yang et al. citan este modelado tanto entre los métodos basados en densidad como entre los basados en distancia.

ID de las OOD [78, 38]; la puntuación de energía tiene una interpretación en términos de verosimilitud [78, 40]; y SHE mide la discrepancia con patrones almacenados que representan cada clase [78, 82]. Otra línea modifica las activaciones o los pesos del modelo antes de calcular la puntuación: ReAct trunca las activaciones anormalmente altas, que relaciona con aplicar a datos OOD estadísticas de normalización por lotes estimadas con datos ID [78, 67]; DICE usa solo los pesos que más contribuyen a la salida [78, 68]; y ASH elimina gran parte de las activaciones de una capa tardía y ajusta las restantes [78, 14]. Sus definiciones se dan en el capítulo 5.

Los métodos anteriores son *post hoc*: se aplican a un modelo ya entrenado, sin modificar su entrenamiento. Yang et al. destacan que esta propiedad es importante para su adopción en entornos reales, donde el coste de reentrenar puede ser prohibitivo [78, 62]. Los métodos *con entrenamiento*, en cambio, imponen restricciones durante el entrenamiento para que el modelo resultante detecte mejor las muestras OOD [62]. Por ejemplo, DeVries y Taylor entrenan una rama adicional que estima la confianza del modelo como un valor entre 0 y 1 [62, 78]; LogitNorm modifica la entropía cruzada para fijar la norma de los *logits* [78]; y los métodos de *exposición a datos atípicos* (*outlier exposure*) usan muestras OOD reales durante el entrenamiento, como MCD, que entrena dos ramas cuya discrepancia se amplía ante esos datos [78, 79]. Estos últimos pueden mejorar mucho el rendimiento, pero dependen de que los datos atípicos de entrenamiento se parezcan a los que aparecerán en la prueba [78]. Por último, los métodos basados en gradientes, como GradNorm, obtienen la puntuación a partir del gradiente [78, 27].

Los *métodos basados en densidad* modelan explícitamente la distribución ID con un modelo probabilístico y consideran OOD las muestras de regiones de baja densidad [78]. Cuando hay varias clases, la distribución puede modelarse con gaussianas condicionales por clase [78, 36]; también se usan modelos basados en flujos. Sin embargo, los modelos probabilísticos

a veces asignan más verosimilitud a muestras OOD que a las ID, su verosimilitud presenta un sesgo hacia la complejidad de la entrada [78, 60], y en general son difíciles de entrenar y quedan por detrás de los métodos basados en clasificación [78].

Los *métodos basados en distancia* parten de que las muestras OOD deberían estar lejos de los centroides o prototipos de las clases ID [78]. El espacio de características que aprende el modelo separa las clases ID, mientras que una muestra OOD puede compartir solo algunas características con ellas, sin llegar a parecerse a ninguna [62]. Entre estos métodos hay enfoques paramétricos, como la distancia de Mahalanobis mínima a los centroides de clase (MDS) o su variante relativa (RMDS), que suponen características gaussianas, y no paramétricos, como la distancia al k-ésimo vecino más cercano (KNN), que no hace ninguna hipótesis sobre su distribución [62, 78, 36, 58, 69]. También se han usado la similitud coseno y la norma de la componente de las características fuera de su subespacio principal, en la que se basa ViM [78, 75]. Sevillano-García et al. señalan que estos métodos fijan empíricamente el umbral de decisión, sin una justificación teórica que lo respalde [62]. STOOD-X, también basado en distancias en el espacio de características y no paramétrico como KNN, sustituye la distancia al vecino por un contraste de hipótesis: compara las distancias de la muestra a sus vecinos de la clase predicha con las distancias entre esos vecinos, y usa el p-valor del test de Wilcoxon-Mann-Whitney como puntuación, sin suponer una distribución concreta de las características, a diferencia de MDS [62]. Se describe en la apartado 5.4.

Por último, los *métodos basados en reconstrucción* usan un esquema de codificador y decodificador entrenado con datos ID, que reconstruye peor las muestras OOD; reconstruir píxeles tiene un coste de entrenamiento alto, por lo que trabajos más recientes reconstruyen características ocultas o partes enmascaradas de la imagen [78].

2.2.5. Métodos excluidos

No se han incluido métodos basados en gradientes, como ODIN (Liang et al. [38]) o GradNorm (Huang et al. [27]), por dos motivos. En primer lugar, requieren una pasada hacia atrás por cada imagen, lo que incrementa notablemente el coste de inferencia y dificulta su despliegue en un entorno clínico. En segundo lugar, Igoe et al. [29] indican que la eficacia de estos métodos no se debe tanto a la información del gradiente como a la magnitud de las características y a la distribución de salida [78], aspectos que ya quedan cubiertos por los métodos basados en características y en logits evaluados en este trabajo.

Entre los métodos que modelan la distribución ID se distinguen dos enfoques. El modelado mediante gaussianas condicionales por clase en el espacio de características (Lee et al. [36]) se ha incluido en la evaluación a través de MDS y RMDS, que aquí se agrupan con los métodos basados en distancia (cuadro 2.2). En cambio, no se han considerado los modelos generativos sobre el espacio de entrada, como los basados en flujos, por tres motivos: su entrenamiento resulta costoso y difícil de optimizar sobre imágenes de alta resolución; su verosimilitud presenta un fuerte sesgo hacia la complejidad de la entrada (Serrà et al. [60]), lo que en histopatología podría favorecer parches de baja complejidad, como regiones de fondo o estroma; y su rendimiento suele quedar por detrás de los enfoques basados en clasificación (Yang et al. [78]). OpenOOD tampoco incluye métodos generativos, que según sus autores no han demostrado escalar a datos del tamaño de ImageNet [81].

2.2.6. Evaluación: OpenOOD, near-OOD y far-OOD

Zhang et al. señalan que el progreso en detección OOD ha sido difícil de seguir por tres problemas de evaluación: una terminología confusa, conjuntos de datos inconsistentes y prácticas erróneas [81]. OpenOOD nació como plataforma y benchmark unificado para evaluar con el mismo protocolo los métodos existentes y futuros [77, 81]; su versión 1.5 amplía la evaluación a ImageNet, a modelos fundacionales y a la detección del espectro completo, e incluye alrededor de 40 métodos [81]. Yang et al. recogen en su revisión una comparación de métodos hecha con esta plataforma [78]. Los métodos post hoc de este trabajo se han evaluado con la implementación de OpenOOD (capítulo 5).

El protocolo de OpenOOD toma como ID el conjunto que define la tarea de clasificación y como OOD varios conjuntos públicos cuyas categorías no se solapan con las ID, en lugar de uno solo [81]. Los conjuntos OOD se agrupan en *near-OOD*, más difíciles, y *far-OOD*, más fáciles, con un criterio semántico o empírico: en los benchmarks de CIFAR, las imágenes near-OOD contienen objetos parecidos a los ID, mientras que las far-OOD (dígitos, texturas o escenas) se alejan de ellas tanto en significado como en estadísticas de bajo nivel; en ImageNet, donde es difícil definir la cercanía semántica, se agrupan según el rendimiento empírico de los detectores [81]. En la revisión de Yang et al., los conjuntos near-OOD solo presentan cambio semántico respecto a los ID, mientras que los far-OOD añaden un desplazamiento de dominio evidente [78]. Además, OpenOOD reserva conjuntos de validación ID y OOD para ajustar los hiperparámetros, en lugar de hacerlo con los datos de prueba, para no obtener resultados demasiado optimistas [81]. En este trabajo, NCT-CRC desempeña el papel de near-OOD y DTD el de far-OOD (cuadro 8.3); en patología digital, Linmans et al. aplican la misma distinción con el linfoma y el tejido de colon (apartado 2.1.3).

La evaluación es binaria, con las muestras OOD como clase positiva, y usa métricas independientes del umbral, como el AUROC y el AUPR, y el FPR@95, que fija un punto de operación [81]; se definen en la apartado 4.3. OpenOOD v1.5 evalúa también la *detección del espectro completo*, que añade a las muestras ID de prueba otras con desplazamiento de covariables (csID) y las sigue considerando ID, porque su etiqueta pertenece a las clases conocidas [81]. En este escenario, el AUROC near-OOD de la mayoría de los métodos cae más de un 10 % en ImageNet-1K, lo que indica que los detectores actuales son sensibles al desplazamiento de covariables y tienden a marcar como OOD muestras ID con ese desplazamiento [81, 78]. Este trabajo adopta el criterio contrario, pues considera OOD el desplazamiento de covariables de PANDA (apartado 2.2.3); la definición se da en la definición 4.6.

De los resultados de OpenOOD v1.5, varios afectan directamente a este trabajo [81]:

- *No hay un método ganador.* Ningún método supera a los demás en todos los benchmarks, y la clasificación puede cambiar mucho de un conjunto de datos a otro. Por eso se comparan aquí varios métodos de distintas familias, y no uno solo.

- *El near-OOD es más difícil.* En ImageNet-1K, el AUROC near-OOD crece aproximadamente en proporción al far-OOD, pero más despacio; los autores lo atribuyen a la mayor dificultad del problema y a que los trabajos previos se centraron en conjuntos far-OOD.

- *El aumento de datos ayuda.* Varias técnicas de aumento de datos, aunque no se diseñaron para la detección OOD, la mejoran en muchos casos, y la mejora es mayor al combinarlas con métodos post hoc. Los autores proponen como posible explicación que unas muestras de entrenamiento más variadas llevan al modelo a apoyarse en características

relacionadas con el significado de las clases y no en *características espurias*, correlacionadas con la etiqueta pero sin relación semántica con ella. Un modelo que depende de estas últimas puede activarse con fuerza ante una muestra OOD que las contenga, mientras que uno entrenado con aumento de datos responde sobre todo a los rasgos semánticos de las clases ID y separa mejor ambos tipos de datos.

- *Los transformers no superan a las ResNet.* Con ResNet-50, ViT-B/16 y Swin-T preentrenados en ImageNet-1K, los transformers no mejoran de forma apreciable la detección OOD. Además, cada método favorece una arquitectura: ASH y ReAct, los dos mejores con ResNet-50, empeoran notablemente con transformers, mientras que RMDS se adapta mucho mejor a ellos que a las ResNet. Los autores sugieren que la mayoría de los métodos post hoc están diseñados para redes convolucionales. Este resultado es relevante aquí, porque el clasificador principal es un Swin-S.

Entre el resto de observaciones, los métodos post hoc aplicados a un modelo entrenado con la entropía cruzada estándar son los mejores en ImageNet-1K; los datos atípicos de entrenamiento solo ayudan cuando se parecen a los de prueba; y algunos métodos, como MDS o KNN, tienen un coste de memoria alto porque necesitan las características de los datos ID [81]. La revisión de Yang et al. llega a conclusiones parecidas sobre CIFAR: los métodos solo de inferencia superan en general a los que requieren entrenamiento, y los datos adicionales no parecen imprescindibles [78].

2.2.7. Retos abiertos

Yang et al. cierran su revisión con varios retos [78]: especificar con claridad qué tipo de cambio de distribución se quiere detectar y por qué, sobre todo cuando se trata de desplazamiento de covariables; construir con cuidado los benchmarks, evitando que los conjuntos OOD contengan imágenes de clases ID; desarrollar métodos que no dependan de datos atípicos de entrenamiento; equilibrar la clasificación ID y la detección OOD cuando ambas comparten la red; y evaluar en conjuntos grandes y realistas, porque las estrategias que funcionan en CIFAR no siempre lo hacen en ImageNet. Entre las líneas futuras destacan la relación entre detección y generalización OOD, en la que señalan que las características espurias del entorno presentes en los datos de entrenamiento pueden afectar mucho a la detección, y la extensión de la detección OOD a más tareas [78]. Zhang et al. añaden que la detección del espectro completo sigue siendo un problema abierto y que arquitecturas como los vision transformers pueden necesitar detectores específicos [81].

2.3. Explicabilidad

Sevillano-García et al. señalan que muchos métodos de detección OOD carecen de explicabilidad, lo que dificulta entender cómo y por qué una muestra se considera OOD [62], y Yang et al. mencionan la explicabilidad de estos modelos entre los aspectos en los que se espera más investigación [78]. Este trabajo aborda dicho aspecto desde dos perspectivas complementarias: mediante STOOD-X, que proporciona explicaciones de las decisiones de detección, y mediante técnicas de relevancia por conceptos (CRP), que permiten identificar y eliminar características sesgadas del clasificador y analizar su efecto sobre la fiabilidad del sistema.

2.3.1. Conceptos básicos y transparencia

La adopción de sistemas de inteligencia artificial en ámbitos de alto impacto, como la salud, ha impulsado el campo de la *inteligencia artificial explicable* (*explainable artificial intelligence*, XAI) [61]. Barredo Arrieta et al. señalan que la imposibilidad de explicar el funcionamiento de los modelos es una de las principales barreras para su implantación, sobre todo en sectores muy regulados y reacios a técnicas que puedan poner en riesgo sus activos, como la banca, la seguridad o la salud [7].

En la literatura se usan a menudo como sinónimos términos con matices distintos [7]. La *interpretabilidad* es una característica pasiva del modelo, el grado en que tiene sentido para un observador humano, y se expresa también como *transparencia*: un modelo es transparente si es comprensible por sí mismo. La *explicabilidad*, en cambio, es una característica activa: cualquier acción o procedimiento del modelo para aclarar su funcionamiento interno. La *inteligibilidad* es la capacidad del modelo de hacer entender a una persona cómo funciona sin explicar su estructura interna, y la *comprensibilidad*, la capacidad de un algoritmo de aprendizaje de representar lo aprendido de forma comprensible [7]. Como todas dependen de quién recibe la explicación, Barredo Arrieta et al. definen la XAI en función de la audiencia: dada una audiencia, una inteligencia artificial explicable es la que produce detalles o razones que hacen claro o fácil de entender su funcionamiento [7]. Esta es la definición que adopta el artículo de STOOD-X [62]. Distintas audiencias persiguen objetivos distintos: para los expertos del dominio, por ejemplo, la confianza o la causalidad; para los usuarios afectados por las decisiones, la equidad; y para los organismos reguladores, entre otros, la equidad o la privacidad [7].

Los primeros sistemas de inteligencia artificial, como las regresiones lineales, los árboles de decisión o los sistemas de reglas, eran *cajas blancas*: transparentes para una persona, aunque incapaces de capturar toda la complejidad de los datos [61]. Las redes neuronales profundas mejoraron las predicciones a costa de la transparencia y se consideran *cajas negras*, porque es muy difícil seguir paso a paso su razonamiento [61]. La frontera entre ambas no es binaria, y entre los dos extremos puede hablarse de *cajas grises* [61]. Barredo Arrieta et al. distinguen tres niveles de transparencia, de modo que un modelo simulable es también descomponible y algorítmicamente transparente: la *transparencia algorítmica*, que permite entender cómo el modelo produce cada salida a partir de la entrada; la *descomponibilidad*, que permite explicar cada una de sus partes; y la *simulabilidad*, que permite a una persona razonar sobre el modelo completo [7]. Las redes profundas no son algorítmicamente transparentes, porque su superficie de pérdida no puede observarse por completo y su solución se aproxima mediante optimización heurística [7]. Los autores matizan la idea de que la interpretabilidad se pierde necesariamente al ganar rendimiento: los modelos más complejos son más flexibles, pero no siempre más precisos, y el compromiso entre interpretabilidad y rendimiento solo aparece cuando la función que se aproxima es compleja y hay datos suficientes y variados; las técnicas de XAI buscan reducirlo [7].

2.3.2. Tipos de métodos y de explicaciones

Según el momento en que se introduce la explicabilidad, los métodos se dividen en *ante hoc*, cuyos modelos son interpretables desde su construcción, y *post hoc*, que explican un modelo ya construido, sea cual sea su complejidad [61]. Barredo Arrieta et al. hablan, respectivamente, de modelos transparentes y de explicabilidad post hoc, y clasifican las técnicas post hoc en explicaciones textuales, visuales, locales, por ejemplos, por simplificación y por relevan-

cia de características [7]. Los métodos post hoc permiten explicar redes profundas con buen rendimiento, aunque al simplificar su funcionamiento pueden perder información [61].

Según la información del modelo que usan, los métodos son *dependientes del modelo*, que aprovechan su estructura interna, como las capas o las funciones de activación, o *agnósticos*, que solo necesitan las entradas y las predicciones [61, 7]. Los primeros pueden dar explicaciones más precisas, pero no se trasladan directamente a otros modelos; los segundos sirven para cualquier modelo, pero necesitan evaluarlo en muchos puntos de su espacio de entrada, lo que resulta costoso [61]. Sevillano-García et al. describen esta diferencia como explicaciones de caja negra y de caja blanca: las de caja negra no usan la estructura interna y no quedan condicionadas por ella, pero necesitan muchas evaluaciones del modelo; las de caja blanca, como la propagación de la relevancia por capas (LRP), conservan la importancia de la decisión a lo largo de las capas del modelo y se obtienen con un coste razonable [62].

Biecek y Samek distinguen dos enfoques de la XAI, recogidos en el artículo de STOOD-X [62]. La *RED XAI* (*Research, Explore, Debug*) se orienta a investigar y mejorar los modelos y está dirigida a desarrolladores con conocimientos técnicos, que pueden usar explicaciones complejas para encontrar fallos o auditar el modelo. La *BLUE XAI* (*responsiBle, Legal, trUst, Ethics*) se orienta a explicar las decisiones al usuario final, con explicaciones sencillas que le permitan decidir si confía en el modelo [62, 61]. La tesis de Sevillano García recoge además varias ideas que Biecek y Samek ponen en cuestión, como que la interpretabilidad sea binaria, que deba existir un único método de explicación válido para todo o que el único objetivo de las explicaciones sea aumentar la confianza del usuario [61]. En el ámbito clínico, Ayensa-Jiménez et al. consideran prioritario el enfoque BLUE XAI, porque los clínicos adoptan con más facilidad las decisiones asistidas cuyo razonamiento entienden [4].

En cuanto a la forma de la explicación, el artículo de STOOD-X distingue entre explicaciones *por importancia de características* y explicaciones *por ejemplos* [62]. Las primeras asignan a cada parte de la entrada un grado de influencia en la decisión y se muestran como mapas de calor. Las segundas muestran muestras parecidas a la que se explica, ya sea para respaldar la decisión, con *prototipos*, o para indicar qué tendría que cambiar para que la decisión fuera otra, con *contrafactuales* [62]. Las explicaciones prototípicas tienen un carácter descriptivo, porque muestran lo que la muestra comparte con ejemplos ya validados, mientras que las contrafactuales son prescriptivas, porque señalan qué la separa de otra decisión [61].

2.3.3. El efecto Clever Hans y las correlaciones espurias

En psicología se llama fenómeno *Clever Hans* a resolver un problema apoyándose en una correlación espuria, en lugar de en el problema [35]. Lapuschkin et al. muestran que los modelos de aprendizaje automático pueden comportarse así y que las métricas habituales, como el error en el conjunto de prueba, no lo detectan [35]. Con mapas de relevancia obtenidos mediante LRP encuentran varios casos: un clasificador de PASCAL VOC que reconocía los caballos por una etiqueta de procedencia presente en una parte de sus imágenes, de modo que añadirla a la foto de un coche la convertía en «caballo»; un agente de Atari Pinball que puntuaba moviendo la mesa en lugar de usar las palancas; y una red que reconocía los aviones por el relleno añadido en los bordes de la imagen [35]. Para analizar conjuntos de datos completos proponen SpRAy (*Spectral Relevance Analysis*), que agrupa los mapas de relevancia para identificar de forma semiautomática las distintas estrategias de predicción del modelo [35].

Achtibat et al. identifican con CRP un caso análogo en ImageNet: un modelo VGG-16 usaba filtros que detectan una marca de agua para reconocer la clase «caja fuerte», y la mis-

ma marca contaminaba otras clases [1]. Al anular esos filtros, la clasificación de la muestra seguía siendo correcta, y como el mismo filtro se usaba de forma legítima en otras clases, los autores proponen corregir el comportamiento por clase en lugar de eliminar el filtro [1]. En el ámbito médico, Storås et al. recuerdan que los modelos pueden aprender correlaciones espurias, y en un modelo de endoscopia gastrointestinal encuentran que el instrumental se asociaba a la clase «normal»: al insertar instrumentos en imágenes que no los tenían, la exactitud en la clase «anormal» bajaba de 0,943 a 0,783 [66].

En histopatología, Howard et al. muestran que una red profunda identifica con gran exactitud el centro que envió una lámina de TCGA, que esa capacidad persiste tras la normalización del color y el aumento de datos habituales, y que la firma del centro sesga la predicción de características como la supervivencia, las mutaciones o el estadio tumoral cuando está correlacionada con ellas [26]. Lo comparan con el ejemplo del husky y el lobo, en el que un modelo distingue a ambos animales por la nieve del fondo, y advierten de que estas firmas pueden dar estimaciones del rendimiento demasiado optimistas [26]. El capítulo 7 retoma el problema de las correlaciones espurias, y en la apartado 10.2 se analiza si los detectores responden al tipo de tejido o a las condiciones de adquisición.

2.3.4. Explicaciones locales, globales y glocales: de LRP a CRP

Achtibat et al. dividen los métodos de XAI en locales y globales [1]. Los *locales* explican predicciones individuales mediante mapas de atribución que indican *dónde* están las características importantes, pero no *qué* representan; además, cada mapa superpone muchos subprocesos de decisión internos del modelo. Los *globales* muestran qué conceptos ha aprendido el modelo en general, pero no cuáles usa en una predicción concreta. Ambos tipos dejan al usuario la tarea de interpretar el razonamiento del modelo [1].

LRP explica la predicción de una red propagando la relevancia hacia atrás, desde la salida hasta la entrada, y asigna así un valor de relevancia a cada píxel y a cada elemento intermedio del modelo [1, 5]; Barredo Arrieta et al. la sitúan entre las técnicas de visualización de redes convolucionales [7]. La *Concept Relevance Propagation* (CRP) extiende LRP condicionando la propagación a conceptos codificados en canales de capas intermedias: así obtiene mapas de relevancia por concepto, que indican dónde aparece cada concepto en la imagen y cuánto contribuye a la predicción [1]. Para dar significado a cada concepto, los autores proponen la *maximización de la relevancia* (RelMax), que selecciona como ejemplos de referencia las muestras en las que el concepto fue más relevante para la predicción, y no aquellas en las que más se activó, porque la activación no siempre refleja su utilidad para el modelo [1]. La combinación de ambas perspectivas da lugar a explicaciones *glocales*, término que introducen Achtibat et al. [1, 61]: responden a la vez dónde mira el modelo y qué reconoce, con un coste del orden de una pasada hacia atrás, y en un estudio con usuarios resultaron más útiles que los mapas de atribución tradicionales [1]. LRP y CRP se formalizan en las apartados 7.1 y 7.2.

Storås et al. estudiaron el valor clínico de este tipo de explicaciones en un modelo de detección de anomalías en endoscopia gastrointestinal, no en histopatología [66]. Mostraron a cinco gastroenterólogos explicaciones de GradCAM, TCAV, CRP y PCX: los mapas de GradCAM resultaron fáciles de interpretar, mientras que los de CRP contenían más información y, por eso, parecían más difíciles de usar durante un procedimiento; los mapas de prototipos de PCX no resultaron intuitivos. La mayoría prefería recibir un solo tipo de explicación, sin acuerdo sobre cuál [66]. Los autores concluyen que estos métodos aún no cumplen los

requisitos para el uso clínico, pero que aportan información valiosa a investigadores y desarrolladores, por ejemplo para detectar correlaciones espurias [66].

2.3.5. Explicabilidad en la detección OOD: PCX y STOOD-X

Un detector OOD indica que una muestra no debe procesarse, pero para que el usuario confíe en esa decisión hace falta explicarle por qué se ha rechazado [62]. Las *explicaciones prototípicas basadas en conceptos* (PCX), de Dreyer et al., se apoyan en CRP y en prototipos extraídos del conjunto de entrenamiento: muestran ejemplos prototípicos que ha identificado el modelo, resaltando las características que comparten con la muestra y dónde aparecen [62, 61]. Como detector OOD, PCX es un método paramétrico basado en la distancia a prototipos de clase, y su umbral se busca empíricamente [62, 61]. Sevillano-García et al. observan que esa forma de explicar está ligada al uso de prototipos y que un detector que no los usa necesita adaptar la explicación a su propio funcionamiento [62].

STOOD-X, propuesto por Sevillano-García, Luengo y Herrera, es una metodología post hoc en dos etapas [62]. Parte de tres limitaciones que los autores señalan en los métodos existentes: hipótesis fuertes sobre la distribución de los datos, como la normalidad; falta de explicabilidad; y puntuaciones sin un significado teórico, como el de un test estadístico [62]. En la primera etapa, la decisión se toma con un test no paramétrico sobre distancias en el espacio de características, restringido a la clase predicha por el modelo, y el p-valor se usa como puntuación. En la segunda, siguiendo el enfoque BLUE XAI, la metodología muestra al usuario los vecinos más cercanos de la muestra en el conjunto de entrenamiento y la localización de las características más presentes en ellos y en la muestra, de modo que pueda comprobar si el modelo se apoya en rasgos válidos o en sesgos [62]. Los autores destacan que esta explicación es útil también cuando la muestra se acepta como ID, y que en el caso OOD convierte la incertidumbre del modelo en una pregunta al usuario: si debe procesarse una muestra para la que no hay ejemplos parecidos validados [62]. La metodología se describe en la apartado 5.4 y su aplicación a este trabajo, en el capítulo 11.

2.4. Síntesis

La literatura revisada deja varias cuestiones abiertas que enmarcan este trabajo. En patología digital, la detección OOD está poco explorada, sobre todo en el caso near-OOD, y las conclusiones de los benchmarks de visión por computador no se trasladan directamente [39]. Los propios autores del conjunto de datos ID y del reto PANDA señalan la necesidad de validar los modelos fuera de las condiciones en que se desarrollaron [4, 8], y las firmas de centro muestran que esas condiciones pueden influir en lo que aprende un modelo [26]. En detección OOD no hay un método que gane en todos los escenarios, los métodos post hoc pueden comportarse de forma distinta con transformers y la detección del desplazamiento de covariables sigue siendo una cuestión discutida, salvo en aplicaciones de alto riesgo como la medicina [81, 78]. Por último, la explicabilidad de las decisiones de detección y la identificación de correlaciones espurias siguen siendo retos abiertos [78, 62, 1].

Este trabajo se sitúa en ese contexto. Sobre el conjunto de datos de próstata de Ayensa-Jiménez et al., compara varios clasificadores (capítulo 9) y evalúa sobre el elegido métodos de detección OOD post hoc de distintas familias, con conjuntos near-OOD, far-OOD y de cambio de centro y resolución (capítulo 10). Aplica STOOD-X como detector explicable (capítulo 11), estudia la predicción conforme como forma complementaria de expresar

la incertidumbre (capítulo 12), estudia la fuga por lámina (capítulo 13) y usa explicaciones conceptuales para identificar y corregir sesgos del clasificador (capítulo 14).

Parte II.

Fundamentos matemáticos

3. Aprendizaje supervisado y redes profundas

3.1. El problema de clasificación supervisada

Definición 3.1 (Problema de clasificación)**.** **[PENDIENTE: definición formal]**

Proposición 3.2 (Optimalidad del clasificador de Bayes)**.** ***[PENDIENTE: enunciado]***

Demostración. **[PENDIENTE: demostración]** □

3.2. Redes neuronales

3.2.1. Neuronas y funciones de activación

Según la Enciclopedia Británica [11] se define el conexionismo como una aproximación hacia la IA que surgió en el desarrollo de tratar de entender como funcionaba el cerebro a nivel neurológico. En 1943, el neurofisiólogo Warren McCulloch, de la Universidad de Illinois, y el matemático Walter Pitts, de la Universidad de Chicago, publicaron un tratado sobre redes neuronales y autómatas, en el que definían cada neurona del cerebro como un simple procesador digital y el cerebro en su conjunto es una especie de máquina de cálculo. De aquí nace el concepto de neurona artificial, en similitud con el concepto de neurona biológica. Este concepto consta de un conjunto de datos de entrada, lo que equivaldría a las dendritas biológicas. Cada entrada se multiplica por un factor de peso que determina su importancia. Estos pesos son los que el modelo ajusta en el proceso de entrenamiento. Finalmente, se suman las entradas multiplicadas por sus pesos (normalmente también se suele añadir un término de sesgo) y una función matemática no lineal decide, en base al valor final, si la neurona se activa y qué valor transmite a la siguiente capa (figura 3.1).

Definición 3.3 (Neurona artificial)**.** Sea $\sigma\colon \mathbb{R} \to \mathbb{R}$ una función, llamada *función de activación*. Una *neurona* con entrada $x \in \mathbb{R}^D$ calcula

$$h = \sigma\big(\beta + \omega^\top x\big),$$

donde $\omega \in \mathbb{R}^D$ son los *pesos* y $\beta \in \mathbb{R}$ es el *sesgo*. La cantidad $\beta + \omega^\top x$ se llama *preactivación* y h, *activación* [54, cap. 3].

Definición 3.4 (ReLU)**.** Sea $x \in \mathbb{R}$. La función de activación *rectificada lineal* (ReLU) se define como $\mathrm{ReLU}(x) = \max\{0, x\}$.

La función GELU (*Gaussian Error Linear Unit*) fue propuesta por Hendrycks y Gimpel [23]. Su idea de partida es combinar dos mecanismos que, hasta entonces, se trataban por separado: la función de activación y la regularización estocástica (como el *dropout*). En una ReLU, la entrada x se multiplica por 0 o por 1 según su signo, de forma determinista; en el *dropout*, se multiplica por 0 o por 1 al azar, sin tener en cuenta su valor. La GELU une ambas ideas: la entrada se multiplica por una máscara aleatoria $m \sim \mathrm{Bernoulli}(\Phi(x))$, de modo que la

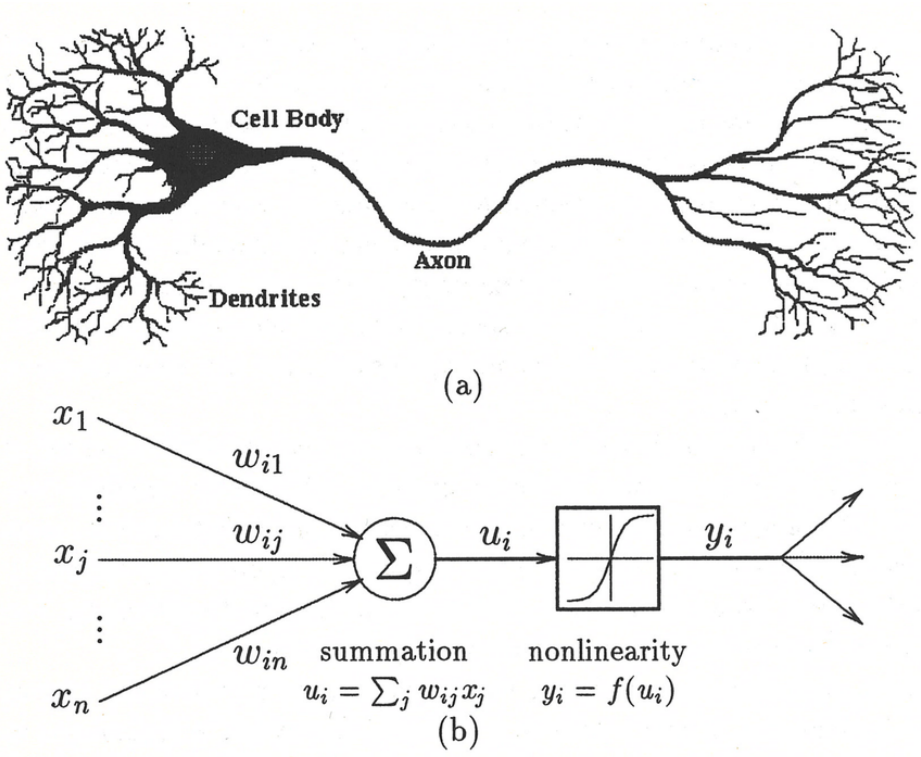

Figura 3.1.: (a) Neurona biológica. (b) Neurona artificial: las entradas x_j se ponderan con los pesos w_{ij}, se suman y el resultado u_i pasa por una función no lineal f. Fuente: [71, fig. 2.1], a partir de [57].

probabilidad de anularla es mayor cuanto menor es x. Como en la práctica se busca una salida determinista, la activación se define como el valor esperado de esta transformación:

$$\mathbb{E}[m\,x] = \Phi(x)\cdot x + \big(1-\Phi(x)\big)\cdot 0 = x\,\Phi(x).$$

Se elige la distribución normal estándar porque las entradas de las neuronas suelen tener una distribución aproximadamente normal, sobre todo cuando se usa normalización por lotes.

Definición 3.5 (GELU)**.** Sea Φ la función de distribución de una variable aleatoria $X \sim \mathcal{N}(0,1)$. La *unidad lineal de error gaussiano* (GELU) es la función $\mathrm{GELU}\colon \mathbb{R}\to\mathbb{R}$ dada por

$$\mathrm{GELU}(x) = x\,\mathbb{P}(X\le x) = x\,\Phi(x) = \frac{x}{2}\left[1+\operatorname{erf}\!\left(\frac{x}{\sqrt{2}}\right)\right],$$

donde $\operatorname{erf}(t) = \frac{2}{\sqrt{\pi}}\int_0^t e^{-s^2}\,ds$ es la función error.

Dicho de otro modo, la GELU pondera cada entrada por la probabilidad de que una normal estándar no la supere: escala x según lo grande que es en comparación con el resto de entradas. Así, mientras que la ReLU, $\mathrm{ReLU}(x) = x\,\mathbf{1}_{\{x>0\}}$, *filtra* las entradas por su signo, la GELU las *pondera* por su valor.

Observación 3.6.

1. La GELU es una versión suavizada de la ReLU: basta sustituir la función indicadora $\mathbf{1}_{\{x>0\}}$ por $\Phi(x)$. Si en lugar de $\mathcal{N}(0,1)$ se toma $\mathcal{N}(0,s^2)$, la GELU tiende a la ReLU cuando $s\to 0$. Además, ambas funciones son asintóticamente iguales cuando $|x|\to\infty$.
2. A diferencia de la ReLU, la GELU no es monótona ni convexa, y toma valores negativos (pequeños) para $x<0$.
3. Cuando se prioriza la velocidad sobre la exactitud, se puede aproximar por

$$\mathrm{GELU}(x) \approx \tfrac{1}{2}\,x\left(1+\tanh\!\left[\sqrt{2/\pi}\,\left(x+0{,}044715\,x^3\right)\right]\right)$$

o

$$\mathrm{GELU}(x) \approx x\ \mathrm{sigm}(1{,}702\,x),$$

donde $\mathrm{sigm}(x) = 1/(1+e^{-x})$ es la función sigmoide.

Definición 3.7 (SiLU)**.** La SiLU, $\mathrm{SiLU}(x) = x\ \mathrm{sigm}(x)$, se obtiene al sustituir Φ por la función de distribución logística, sigm, en la definición de la GELU [23].

Estas funciones de activación han sido definidas en concreto pues son las que han sido usadas en los modelos de la fase de experimentación. En concreto ResNet-50 usó ReLU, ViT-B/16, ConvNeXt-S y Swin-S usaron GELU, y únicamente EfficientNetV2-S empleó SiLU.

3.2.2. Redes neuronales profundas

Las neuronas de la definición 3.3 se agrupan en *capas*: todas las neuronas de una capa reciben la misma entrada, y la salida de una capa es la entrada de la siguiente. Si cada neurona de una capa está conectada a todas las salidas de la capa anterior, la red se llama *totalmente conectada*. Seguimos la notación de Prince [54, sec. 4.4.1].

Definición 3.8 (Red neuronal profunda [54, sec. 4.4.1])**.** Sea σ una función de activación, que se aplica componente a componente a los vectores. Una *red neuronal profunda* con entrada $x \in \mathbb{R}^{D_i}$, salida $y \in \mathbb{R}^{D_o}$ y K capas ocultas con $D_1, \dots, D_K$ neuronas es la función $y = f(x; \phi)$ dada por

$$\begin{aligned} h_1 &= \sigma\big(\beta_0 + \Omega_0 x\big), \\ h_k &= \sigma\big(\beta_{k-1} + \Omega_{k-1} h_{k-1}\big), \qquad k = 2, \dots, K, \\ y &= \beta_K + \Omega_K h_K, \end{aligned}$$

donde $h_k \in \mathbb{R}^{D_k}$ es el vector de *unidades ocultas* de la capa k, β_k son los vectores de sesgos y Ω_k las matrices de pesos, con $\Omega_0 \in \mathbb{R}^{D_1 \times D_i}$, $\Omega_k \in \mathbb{R}^{D_{k+1} \times D_k}$ para $k = 1, \dots, K-1$ y $\Omega_K \in \mathbb{R}^{D_o \times D_K}$. Los parámetros de la red son $\phi = \{\beta_k, \Omega_k\}_{k=0}^{K}$.

Cada componente de h_k es una neurona en el sentido de la definición 3.3, cuyos pesos son una fila de Ω_{k-1}. Equivalentemente, la red es la composición

$$y = \beta_K + \Omega_K\, \sigma\Big(\beta_{K-1} + \Omega_{K-1}\, \sigma\big(\cdots \sigma(\beta_0 + \Omega_0 x) \cdots\big)\Big).$$

Estas redes también se denominan *redes prealimentadas* (*feedforward*) o *perceptrones multicapa* (*multilayer perceptron*, MLP) [19, cap. 6].

Para la pregunta de por qué la no linealidad es necesaria se justifica con la siguiente proposición:

Proposición 3.9. *Sean $f_\ell(x) = \beta_\ell + \Omega_\ell x$, con $\Omega_\ell \in \mathbb{R}^{D_\ell \times D_{\ell-1}}$ y $\beta_\ell \in \mathbb{R}^{D_\ell}$, para $\ell = 1, \dots, L$. Entonces la composición $f = f_L \circ \cdots \circ f_1$ es también afín: existen $\Omega \in \mathbb{R}^{D_L \times D_0}$ y $\beta \in \mathbb{R}^{D_L}$ tales que $f(x) = \beta + \Omega x$ para todo $x \in \mathbb{R}^{D_0}$.*

Demostración. Por inducción sobre L. Para $L = 1$ no hay nada que probar. Supongamos que $g = f_{L-1} \circ \cdots \circ f_1$ cumple $g(x) = \widetilde{\beta} + \widetilde{\Omega} x$. Entonces

$$f(x) = \beta_L + \Omega_L\big(\widetilde{\beta} + \widetilde{\Omega} x\big) = \big(\beta_L + \Omega_L \widetilde{\beta}\big) + \big(\Omega_L \widetilde{\Omega}\big) x,$$

que es afín con $\Omega = \Omega_L \widetilde{\Omega}$ y $\beta = \beta_L + \Omega_L \widetilde{\beta}$. □

Observación 3.10. Por tanto, una red sin funciones de activación, por muchas capas que tenga, solo puede representar funciones afines; en clasificación, sus fronteras de decisión están formadas por hiperplanos [19, cap. 6]. Las funciones de activación no lineales son las que permiten que la red aproxime funciones más complejas.

3.2.3. Teorema de aproximación universal

La proposición 3.9 muestra que la no linealidad de σ es necesaria para que la red pueda representar algo más que funciones afines. Cabe preguntarse si también es suficiente, es decir, qué condición debe cumplir σ para que una red pueda aproximar cualquier función continua. Para redes con una capa oculta, la respuesta la da el siguiente teorema: la condición exacta no es que σ sea no lineal, sino que no sea un polinomio.

Dada una función de activación $\sigma\colon \mathbb{R} \to \mathbb{R}$, una red neuronal con una capa oculta de r

neuronas y una salida escalar calcula funciones de la forma

$$N(x) = \sum_{i=1}^{r} c_i\, \sigma(w_i \cdot x + b_i), \qquad w_i \in \mathbb{R}^n,\ b_i, c_i \in \mathbb{R}.$$

Denotamos por $\mathcal{M}(\sigma) = \operatorname{span}\{\sigma(w \cdot x + b) : w \in \mathbb{R}^n,\ b \in \mathbb{R}\}$ el conjunto de todas ellas. En $C(\mathbb{R}^n)$ consideramos la topología de la convergencia uniforme sobre compactos: decimos que $\mathcal{M}(\sigma)$ es *denso* en $C(\mathbb{R}^n)$ si para toda $f \in C(\mathbb{R}^n)$, todo compacto $K \subset \mathbb{R}^n$ y todo $\varepsilon > 0$ existe $N \in \mathcal{M}(\sigma)$ con $\sup_{x \in K} |f(x) - N(x)| < \varepsilon$. Escribimos $\overline{\mathcal{M}(\sigma)}$ para su clausura, que es un subespacio vectorial cerrado.

Teorema 3.11 (Aproximación universal, Leshno et al. [37])**.** *Sea $\sigma \in C(\mathbb{R})$. Entonces $\mathcal{M}(\sigma)$ es denso en $C(\mathbb{R}^n)$ si y solo si σ no es un polinomio.*

Seguimos la demostración de Pinkus [53, teorema 3.1], que se divide en tres pasos: primero se reduce el problema a dimensión $n = 1$ (lema 3.13); después se prueba para activaciones de clase C^∞ (lema 3.14); y, por último, se extiende a activaciones continuas mediante convolución.

Lema 3.12. *Sea H_k el espacio de los polinomios homogéneos de grado k en n variables. Entonces $H_k = \operatorname{span}\{(a \cdot x)^k : a \in \mathbb{R}^n\}$.*

Demostración. Los monomios $x^\alpha = x_1^{\alpha_1} \cdots x_n^{\alpha_n}$ con $|\alpha| = k$ forman una base de H_k. Para $p = \sum_\alpha p_\alpha x^\alpha$ y $q = \sum_\alpha q_\alpha x^\alpha$ definimos el producto escalar $\langle p, q \rangle = \sum_{|\alpha|=k} \alpha!\, p_\alpha q_\alpha$, donde $\alpha! = \alpha_1! \cdots \alpha_n!$. Por la fórmula multinomial,

$$(a \cdot x)^k = \sum_{|\alpha|=k} \frac{k!}{\alpha!}\, a^\alpha x^\alpha, \qquad \text{luego} \qquad \big\langle (a \cdot x)^k, q \big\rangle = \sum_{|\alpha|=k} k!\, a^\alpha q_\alpha = k!\, q(a).$$

Si $q \in H_k$ es ortogonal a todos los $(a \cdot x)^k$, entonces $q(a) = 0$ para todo $a \in \mathbb{R}^n$, y por tanto $q = 0$. Como H_k tiene dimensión finita, el complemento ortogonal del subespacio generado es trivial y se tiene la igualdad. □

Lema 3.13 (Reducción a dimensión uno)**.** *Si $\mathcal{M}(\sigma)$ es denso en $C(\mathbb{R})$, entonces es denso en $C(\mathbb{R}^n)$ para todo $n \geq 1$.*

Demostración. Sean $g \in C(\mathbb{R})$, $a \in \mathbb{R}^n$, $K \subset \mathbb{R}^n$ compacto y $\varepsilon > 0$. Existe $R > 0$ con $a \cdot K \subset [-R, R]$. Por hipótesis hay $c_i, w_i, b_i \in \mathbb{R}$ tales que $|g(t) - \sum_i c_i \sigma(w_i t + b_i)| < \varepsilon$ para $t \in [-R, R]$. Tomando $t = a \cdot x$,

$$\sup_{x \in K} \Big| g(a \cdot x) - \sum_i c_i\, \sigma\big((w_i a) \cdot x + b_i\big) \Big| < \varepsilon,$$

luego $g(a \cdot x) \in \overline{\mathcal{M}(\sigma)}$. En particular, $(a \cdot x)^k \in \overline{\mathcal{M}(\sigma)}$ para todo a y todo k, y por el lema 3.12 la clausura contiene todos los polinomios en n variables. Por el teorema de Stone–Weierstrass, los polinomios son densos en $C(K)$ para todo compacto K, así que $\overline{\mathcal{M}(\sigma)} = C(\mathbb{R}^n)$. □

Lema 3.14 (Caso suave [53, prop. 3.4])**.** *Sea $\sigma \in C^\infty(\mathbb{R})$. Entonces:*

(a) $x^k \sigma^{(k)}(b) \in \overline{\mathcal{M}(\sigma)}$ para todo $k \geq 0$ y todo $b \in \mathbb{R}$;

(b) si σ no es un polinomio, $\mathcal{M}(\sigma)$ es denso en $C(\mathbb{R})$.

Demostración. (a) Para $k = 0$ basta tomar $w = 0$. Sea $k \geq 1$ y, fijado b, sea $f(w) = \sigma(wx + b)$, con $f^{(k)}(w) = x^k \sigma^{(k)}(wx + b)$. La diferencia finita de orden k,

$$D_h(x) = \frac{1}{h^k} \sum_{j=0}^{k} (-1)^{k-j} \binom{k}{j} \sigma\big((w + jh)x + b\big),$$

pertenece a $\mathcal{M}(\sigma)$ y, por el teorema del valor medio para diferencias finitas, $D_h(x) = x^k \sigma^{(k)}(\xi x + b)$ para algún $\xi \in (w, w + kh)$ que depende de x. Así, para $|x| \leq R$,

$$\big|D_h(x) - x^k \sigma^{(k)}(wx + b)\big| \leq R^k \sup_{|\xi - w| \leq kh,\ |x| \leq R} \big|\sigma^{(k)}(\xi x + b) - \sigma^{(k)}(wx + b)\big|,$$

que tiende a 0 cuando $h \to 0$ por la continuidad uniforme de $\sigma^{(k)}$ en compactos. Luego $x^k \sigma^{(k)}(wx + b) \in \overline{\mathcal{M}(\sigma)}$, y basta tomar $w = 0$.

(b) Si σ no es un polinomio, ninguna $\sigma^{(k)}$ es idénticamente nula, así que para cada k existe b_k con $\sigma^{(k)}(b_k) \neq 0$. Por (a), $x^k \in \overline{\mathcal{M}(\sigma)}$ para todo k. La clausura contiene todos los polinomios y, por el teorema de Weierstrass, es todo $C(\mathbb{R})$. □

Demostración del teorema 3.11. Necesidad. Si σ es un polinomio de grado m, cada $\sigma(w \cdot x + b)$ es un polinomio de grado a lo sumo m, de modo que $\mathcal{M}(\sigma)$ está contenido en el espacio $\mathcal{P}_m$ de los polinomios de grado $\leq m$. Este espacio tiene dimensión finita, luego es cerrado, y no coincide con $C(\mathbb{R}^n)$. Por tanto, $\mathcal{M}(\sigma)$ no es denso.

Suficiencia [53, prop. 3.7]. Por el lema 3.13 basta el caso $n = 1$. Para $\varphi \in C_c^\infty(\mathbb{R})$ con soporte en $[-\alpha, \alpha]$, la convolución $\sigma_\varphi = \sigma * \varphi$ es de clase C^∞, y

$$\sigma_\varphi(wx + b) = \int_{-\alpha}^{\alpha} \sigma(wx + b - y)\, \varphi(y)\, dy.$$

Las sumas de Riemann $\sum_j \sigma(wx + b - y_j)\varphi(y_j)\Delta y$ pertenecen a $\mathcal{M}(\sigma)$ y, por la continuidad uniforme de $(t, y) \mapsto \sigma(t - y)\varphi(y)$ en compactos, convergen a $\sigma_\varphi(wx + b)$ uniformemente para x en compactos. Luego $\mathcal{M}(\sigma_\varphi) \subset \overline{\mathcal{M}(\sigma)}$ y, como la clausura es cerrada, también $\overline{\mathcal{M}(\sigma_\varphi)} \subset \overline{\mathcal{M}(\sigma)}$.

Supongamos, por reducción al absurdo, que $\mathcal{M}(\sigma)$ no es denso en $C(\mathbb{R})$. Por el teorema de Weierstrass, existe k tal que $x^k \notin \overline{\mathcal{M}(\sigma)}$. Por el lema 3.14(a), $x^k \sigma_\varphi^{(k)}(b) \in \overline{\mathcal{M}(\sigma_\varphi)} \subset \overline{\mathcal{M}(\sigma)}$ para todo $b \in \mathbb{R}$, así que necesariamente $\sigma_\varphi^{(k)}(b) = 0$ para todo b. Es decir, $\sigma_\varphi \in \mathcal{P}_{k-1}$ para toda $\varphi \in C_c^\infty(\mathbb{R})$, con el mismo k.

Tomemos ahora una aproximación de la identidad (*mollifiers*): $\varphi_m \in C_c^\infty(\mathbb{R})$, $\varphi_m \geq 0$, $\int \varphi_m = 1$ y soporte en $[-1/m, 1/m]$. Por la continuidad uniforme de σ en compactos, $\sigma * \varphi_m \to \sigma$ uniformemente en compactos. Como $\sigma * \varphi_m \in \mathcal{P}_{k-1}$ y este subespacio es cerrado por tener dimensión finita, $\sigma \in \mathcal{P}_{k-1}$, lo que contradice que σ no es un polinomio. □

Observación 3.15.

1. Las activaciones ReLU, GELU y SiLU son continuas y no son polinomios, así que el teorema 3.11 se aplica a todas ellas. La identidad es un polinomio de grado 1, lo que es coherente con la proposición 3.9.

2. El resultado es de existencia: garantiza que *existe* una red con una capa oculta suficientemente ancha que aproxima f, pero no dice cuántas neuronas hacen falta ni cómo

encontrar los pesos mediante el entrenamiento.

Observación 3.16. Los dos resultados anteriores se complementan. Una activación afín no aporta nada (proposición 3.9), y una activación polinómica, aunque sea no lineal, tampoco basta con una capa oculta: si σ es un polinomio de grado m, la red solo genera polinomios de grado a lo sumo m. Las activaciones que usamos en este trabajo (ReLU, GELU y SiLU) son continuas y no polinómicas, de modo que el teorema 3.11 garantiza que las redes con una capa oculta suficientemente ancha pueden aproximar cualquier función continua sobre un compacto.

Este resultado, junto con otros análogos con hipótesis distintas sobre σ [12, 25], se conoce en la literatura como *teorema de aproximación universal*; la expresión procede de Hornik et al. [25], que llamaron *aproximadores universales* a las redes con esta propiedad. Pinkus [53] lo formula como un problema de *densidad*. Aquí presentamos la versión de Leshno et al. [37], que caracteriza exactamente las activaciones continuas que tienen esta propiedad.

3.3. Función de pérdida: entropía cruzada y *label smoothing*

En la clasificación multiclase, la etiqueta toma valores en $\{1, \dots, K\}$ y se modeliza con una distribución categórica, de parámetros $\lambda_1, \dots, \lambda_K$, que determinan la probabilidad de cada clase: $\mathbb{P}(y = k) = \lambda_k$. Estos parámetros deben estar entre cero y uno y sumar uno. Una red $f(x; \phi)$ con K salidas no cumple estas restricciones, así que sus salidas se transforman con una función que sí las cumple [54, sec. 5.5].

Definición 3.17 (Función softmax [54, sec. 5.5])**.** La *función softmax*, $\mathrm{softmax}\colon \mathbb{R}^K \to \mathbb{R}^K$, es la función cuya componente k-ésima es

$$\mathrm{softmax}_k(z) = \frac{\exp(z_k)}{\sum_{k'=1}^{K} \exp(z_{k'})}, \qquad k = 1, \dots, K.$$

Las exponenciales garantizan que todas las componentes son positivas, y el denominador, que suman uno. Así, para cada entrada x, el modelo asigna a cada clase la probabilidad

$$\mathbb{P}(y = k \mid x) = \mathrm{softmax}_k\big(f(x; \phi)\big),$$

y, si se necesita una única predicción, se toma la clase más probable, $\widehat{y} = \arg\max_k \mathbb{P}(y = k \mid x)$ [54, sec. 5.5]. Las componentes de $f(x; \phi)$ se llaman *logits*. **[REVISAR: Prince no usa el término *logits* en la sec. 5.5; se ha añadido porque se usa en el resto de la memoria (por ejemplo, en los métodos de detección basados en logits)]**

Definición 3.18 (Entropía cruzada [54, sec. 5.5])**.** Sea $\{(x_i, y_i)\}_{i=1}^{I}$ un conjunto de entrenamiento con $y_i \in \{1, \dots, K\}$ y sea $f(x; \phi)$ una red con K salidas. La *pérdida de entropía cruzada multiclase* es la log-verosimilitud negativa de los datos de entrenamiento bajo el modelo de la definición 3.17:

$$L(\phi) = -\sum_{i=1}^{I} \log\Big(\mathrm{softmax}_{y_i}\big(f(x_i; \phi)\big)\Big) = -\sum_{i=1}^{I} \left(f_{y_i}(x_i; \phi) - \log\left(\sum_{k'=1}^{K} \exp\big(f_{k'}(x_i; \phi)\big) \right) \right),$$

donde $f_k(x; \phi)$ es la k-ésima salida de la red.

El nombre de entropía cruzada se explica porque minimizar esta pérdida equivale a minimizar la divergencia de Kullback-Leibler entre la distribución empírica de los datos observados y la distribución del modelo [54, sec. 5.7].

Para dos distribuciones q y p sobre $\{1, \dots, K\}$ con $p_k > 0$ para todo k, la *divergencia de Kullback-Leibler* es

$$D_{\mathrm{KL}}(q \,\|\, p) = \sum_{k=1}^{K} q_k \log q_k - \sum_{k=1}^{K} q_k \log p_k,$$

con el convenio $0 \log 0 = 0$. Mide la distancia entre las dos distribuciones. El segundo sumando, cambiado de signo, $H(q, p) = -\sum_k q_k \log p_k$, es la *entropía cruzada* entre q y p [54, sec. 5.7].

Proposición 3.19 (Entropía cruzada y divergencia KL [54, sec. 5.7])**.** *En las condiciones de la definición 3.18, sean, para cada $i = 1, \dots, I$, q_i la distribución empírica de la etiqueta del ejemplo i, $q_{i,k} = 1$ si $k = y_i$ y $q_{i,k} = 0$ en otro caso, y $p_i(\phi) = \operatorname{softmax}\big(f(x_i; \phi)\big)$ la distribución del modelo. Entonces, para todo ϕ,*

$$\sum_{i=1}^{I} D_{\mathrm{KL}}\big(q_i \,\|\, p_i(\phi)\big) = \sum_{i=1}^{I} H\big(q_i, p_i(\phi)\big) = L(\phi).$$

En consecuencia, minimizar la divergencia KL entre la distribución empírica y la del modelo, minimizar la entropía cruzada y maximizar la log-verosimilitud de los datos de entrenamiento son el mismo problema.

Demostración. Las componentes de $p_i(\phi)$ son positivas por la definición 3.17, así que los logaritmos están definidos. El primer sumando de $D_{\mathrm{KL}}(q_i \,\|\, p_i(\phi))$ es nulo, porque cada $q_{i,k}$ vale 0 o 1 y $0 \log 0 = 1 \log 1 = 0$; en particular, no depende de ϕ. Queda la entropía cruzada, en la que solo sobrevive el sumando $k = y_i$:

$$H\big(q_i, p_i(\phi)\big) = -\sum_{k=1}^{K} q_{i,k} \log p_{i,k}(\phi) = -\log\Big(\operatorname{softmax}_{y_i}\big(f(x_i; \phi)\big)\Big).$$

Sumando sobre i se obtiene $L(\phi)$ por la definición 3.18, que es la log-verosimilitud negativa de los datos. □

Prince razona de forma más general: para cualquier distribución empírica, el primer sumando de la divergencia no depende de los parámetros y desaparece del problema de minimización, de modo que minimizar la divergencia KL equivale a minimizar la entropía cruzada [54, sec. 5.7].

Müller et al. describen el *label smoothing* como el uso de objetivos *suavizados*, que son una media ponderada de los objetivos exactos y de la distribución uniforme sobre las clases. Suavizar así las etiquetas evita que la red se vuelva demasiado confiada [51].

Definición 3.20 (*Label smoothing* [51, sec. 1])**.** Sea x una entrada con etiqueta y y sea $p = (p_1, \dots, p_K)$ la distribución que le asigna la red,

$$p_k = \operatorname{softmax}_k\big(f(x; \phi)\big), \qquad k = 1, \dots, K.$$

Sean $y_k = 1$ si $k = y$ e $y_k = 0$ en otro caso los *objetivos exactos*. La entropía cruzada entre los

objetivos y la predicción es

$$H(y,p) = \sum_{k=1}^{K} -y_k \log p_k.$$

Con *label smoothing* de parámetro $\varepsilon \in [0,1]$, se minimiza en su lugar la entropía cruzada $H(y^{LS}, p)$ entre la predicción y los objetivos modificados

$$y_k^{LS} = y_k\,(1-\varepsilon) + \frac{\varepsilon}{K}, \qquad k = 1,\dots,K.$$

Con objetivos exactos, $H(y,p) = -\log p_y$ es el sumando correspondiente a (x,y) en la definición 3.18, de modo que $\varepsilon = 0$ recupera la pérdida habitual. Con $\varepsilon > 0$, el objetivo de la clase verdadera es $1-\varepsilon+\varepsilon/K$ y el de cada una de las demás, ε/K. Desarrollando la suma,

$$H(y^{LS},p) = (1-\varepsilon)\,(-\log p_y) + \frac{\varepsilon}{K}\sum_{k=1}^{K}(-\log p_k).$$

Para obtener el mínimo de la pérdida con *label smoothing* basta una propiedad de la divergencia de Kullback-Leibler.

Lema 3.21 (No negatividad de la divergencia KL [54, ap. C.5.1], [19, sec. 3.13])**.** *Sean q y p dos distribuciones sobre $\{1,\dots,K\}$ con $p_k > 0$ para todo k. Entonces $D_{\mathrm{KL}}(q \,\|\, p) \geq 0$. Si además $q_k > 0$ para todo k, la igualdad se da si y solo si $p = q$.*

Demostración. Sea $g(t) = -\log t - (1-t)$ para $t > 0$. Como $g'(t) = 1 - 1/t$ es negativa en $(0,1)$ y positiva en $(1,\infty)$, g alcanza su mínimo únicamente en $t = 1$, donde $g(1) = 0$. Por tanto, $-\log t \geq 1 - t$, con igualdad si y solo si $t = 1$ [54, ap. C.5.1]. Sea $S = \{k : q_k > 0\}$. Aplicando la desigualdad con $t = p_k/q_k$,

$$D_{\mathrm{KL}}(q \,\|\, p) = \sum_{k\in S} q_k\Big(-\log\frac{p_k}{q_k}\Big) \geq \sum_{k\in S} q_k\Big(1-\frac{p_k}{q_k}\Big) = \sum_{k\in S} q_k - \sum_{k\in S} p_k = 1 - \sum_{k\in S} p_k \geq 0.$$

Si $q_k > 0$ para todo k, entonces $S = \{1,\dots,K\}$, la última desigualdad es una igualdad y la primera lo es si y solo si $p_k/q_k = 1$ para todo k, es decir, si y solo si $p = q$. □

Proposición 3.22 (Óptimo de la pérdida con *label smoothing*)**.** *Sean $\varepsilon \in (0,1]$, $y \in \{1,\dots,K\}$ la etiqueta de una entrada e y^{LS} los objetivos suavizados de la definición 3.20. Entre todas las distribuciones p sobre $\{1,\dots,K\}$ con componentes positivas, la pérdida $H(y^{LS},p)$ alcanza su mínimo en un único punto, $p = y^{LS}$:*

$$p_y = 1 - \varepsilon + \frac{\varepsilon}{K}, \qquad p_k = \frac{\varepsilon}{K} \quad (k \neq y).$$

Además, este mínimo lo alcanza la red: es la softmax de cualquier vector de logits z con $z_k = \log y_k^{LS} + c$, $c \in \mathbb{R}$, y en él la diferencia entre el logit de la clase verdadera y el de cualquier otra clase es

$$z_y - z_k = \log\Big(1 + \frac{K(1-\varepsilon)}{\varepsilon}\Big), \qquad k \neq y.$$

Demostración. Como $\varepsilon > 0$, todas las componentes de y^{LS} son positivas. Sumando y restando

$\sum_k y_k^{LS} \log y_k^{LS}$,

$$H(y^{LS}, p) = -\sum_{k=1}^{K} y_k^{LS} \log y_k^{LS} + \sum_{k=1}^{K} y_k^{LS} \log \frac{y_k^{LS}}{p_k} = H(y^{LS}, y^{LS}) + D_{\mathrm{KL}}(y^{LS} \,\|\, p).$$

El primer sumando no depende de p, y por el lema 3.21 el segundo es no negativo y se anula si y solo si $p = y^{LS}$. Luego el mínimo es único y se alcanza en $p = y^{LS}$.

Si $z_k = \log y_k^{LS} + c$, entonces $\mathrm{softmax}_k(z) = e^c y_k^{LS} / \left(e^c \sum_{k'} y_{k'}^{LS}\right) = y_k^{LS}$, porque los objetivos suman uno. Por último, para $k \neq y$,

$$z_y - z_k = \log \frac{1 - \varepsilon + \varepsilon/K}{\varepsilon/K} = \log\Big(1 + \frac{K(1-\varepsilon)}{\varepsilon}\Big). \qquad \square$$

Observación 3.23. Con $\varepsilon = 0$ (objetivos exactos), $H(y, p) = -\log p_y$ no tiene mínimo sobre las distribuciones con componentes positivas: tiende a cero cuando $p_y \to 1$, lo que exige que la diferencia entre logits crezca sin límite. Con $\varepsilon > 0$, en cambio, el óptimo es una distribución con un «suelo» ε/K en todas las clases y una diferencia de logits finita, que solo depende de ε y K. Esto concuerda con la observación de Müller et al. de que el *label smoothing* lleva a que la diferencia entre el logit de la clase correcta y los de las incorrectas sea una constante que depende del parámetro [51, sec. 2]. En el entrenamiento de este trabajo, con $\varepsilon = 0{,}1$ y $K = 14$, el óptimo asigna 0,907 a la clase verdadera y $\varepsilon/K \approx 0{,}00714$ a cada una de las demás, con una diferencia de logits de $\log 127 \approx 4{,}84$. Este suelo se usa en el capítulo 12.

3.4. Optimización: Adam y AdamW

Sea $f(\theta)$ la función de pérdida, que depende de los parámetros $\theta \in \mathbb{R}^n$ de la red. En la práctica no se minimiza directamente f, sino una sucesión de realizaciones estocásticas $f_1, f_2, \ldots$, cada una evaluada sobre un minilote distinto de datos de entrenamiento. Se denota por

$$g_t = \nabla_\theta f_t(\theta_{t-1})$$

el gradiente del minilote t evaluado en los parámetros de la iteración anterior. El método más sencillo es el descenso de gradiente estocástico (SGD), que actualiza $\theta_t = \theta_{t-1} - \alpha\, g_t$ con una tasa de aprendizaje $\alpha > 0$ común a todos los parámetros.

3.4.1. Adam

Adam [33] (*adaptive moment estimation*) asigna a cada parámetro una tasa de aprendizaje propia y adaptativa, calculada a partir de estimaciones del primer y del segundo momento del gradiente. Combina las ideas de AdaGrad, adecuado para gradientes dispersos, y de RMSProp, adecuado para objetivos no estacionarios [33].

Definición 3.24 (Adam [33])**.** Sean $\alpha > 0$ la tasa de aprendizaje, $\beta_1, \beta_2 \in [0, 1)$ las tasas de decaimiento de las medias móviles y $\varepsilon > 0$ una constante de estabilidad numérica. Partiendo

de θ_0, $m_0 = 0$ y $v_0 = 0$, en cada iteración $t \geq 1$ Adam calcula

$$\begin{aligned} m_t &= \beta_1\, m_{t-1} + (1-\beta_1)\, g_t, \\ v_t &= \beta_2\, v_{t-1} + (1-\beta_2)\, g_t^2, \\ \widehat{m}_t &= \frac{m_t}{1-\beta_1^t}, \qquad \widehat{v}_t = \frac{v_t}{1-\beta_2^t}, \\ \theta_t &= \theta_{t-1} - \alpha\, \frac{\widehat{m}_t}{\sqrt{\widehat{v}_t} + \varepsilon}, \end{aligned}$$

donde g_t^2, la raíz cuadrada y el cociente se entienden componente a componente, y β_1^t, β_2^t denotan potencias. Los valores propuestos por defecto son $\alpha = 10^{-3}$, $\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$ y $\varepsilon = 10^{-8}$.

Las sucesiones m_t y v_t son medias móviles exponenciales del gradiente y de su cuadrado, es decir, estimaciones de su media y de su momento de segundo orden no centrado. Como se inicializan en cero, están sesgadas hacia cero en las primeras iteraciones. Los cocientes de la definición 3.24 corrigen ese sesgo, como muestra el siguiente resultado.

Proposición 3.25 (Corrección del sesgo de inicialización [33])**.** *Supongamos que los gradientes $g_1, g_2, \ldots$ tienen el mismo momento de segundo orden, $\mathbb{E}[g_i^2] = \mathbb{E}[g^2]$ para todo i. Entonces, para todo $t \geq 1$,*

$$\mathbb{E}[v_t] = \left(1-\beta_2^t\right)\, \mathbb{E}[g^2], \qquad \text{y por tanto} \qquad \mathbb{E}[\widehat{v}_t] = \mathbb{E}[g^2].$$

El resultado análogo se cumple para m_t y $\widehat{m}_t$ si $\mathbb{E}[g_i] = \mathbb{E}[g]$ para todo i.

Demostración. Desarrollando la recurrencia de la definición 3.24 a partir de $v_0 = 0$ se obtiene, por inducción sobre t,

$$v_t = (1-\beta_2) \sum_{i=1}^{t} \beta_2^{\,t-i}\, g_i^2.$$

Tomando esperanzas, por linealidad y por la hipótesis,

$$\mathbb{E}[v_t] = \mathbb{E}[g^2]\,(1-\beta_2) \sum_{i=1}^{t} \beta_2^{\,t-i} = \mathbb{E}[g^2]\,(1-\beta_2)\,\frac{1-\beta_2^t}{1-\beta_2} = \left(1-\beta_2^t\right)\, \mathbb{E}[g^2],$$

donde se ha usado la suma de la progresión geométrica $\sum_{i=1}^{t} \beta_2^{\,t-i} = \sum_{k=0}^{t-1} \beta_2^k$, válida porque $\beta_2 < 1$. Dividiendo entre $1-\beta_2^t > 0$ se obtiene $\mathbb{E}[\widehat{v}_t] = \mathbb{E}[g^2]$. El caso de m_t es idéntico, sustituyendo g_i^2 por g_i y β_2 por β_1. □

Observación 3.26. Si el momento de segundo orden no es constante, aparece un término adicional ζ en la expresión de $\mathbb{E}[v_t]$. Kingma y Ba [33] argumentan que ζ es pequeño, porque β_2 puede elegirse de modo que la media móvil asigne pesos muy pequeños a los gradientes lejanos en el tiempo.

El paso efectivo de Adam, $\Delta_t = \alpha\, \widehat{m}_t / \sqrt{\widehat{v}_t}$ (tomando $\varepsilon = 0$), tiene dos propiedades que explican su uso extendido:

- *Es invariante frente a reescalados del gradiente.* Si los gradientes se multiplican por $c > 0$, $\widehat{m}_t$ se multiplica por c y $\widehat{v}_t$ por c^2, de modo que el cociente $c\,\widehat{m}_t / \sqrt{c^2\,\widehat{v}_t}$ no cambia.

- *Está aproximadamente acotado por α.* En los casos habituales $|\widehat{m}_t/\sqrt{\widehat{v}_t}| \lesssim 1$, lo que actúa como una región de confianza alrededor de los parámetros actuales y facilita elegir el orden de magnitud de α [33].

3.4.2. Regularización L_2 y decaimiento de pesos

Para reducir el sobreajuste es habitual penalizar los pesos grandes. Hay dos formas de hacerlo que suelen confundirse:

- La *regularización L_2* añade un término a la pérdida,

$$f_t^{\text{reg}}(\theta) = f_t(\theta) + \frac{\lambda'}{2}\,\|\theta\|_2^2,$$

  y aplica el optimizador a f_t^{reg}.

- El *decaimiento de pesos* (*weight decay*) reduce los pesos directamente en cada paso, de forma separada del gradiente de la pérdida:

$$\theta_t = (1-\lambda)\,\theta_{t-1} - \alpha\,\nabla f_t(\theta_{t-1}),$$

  donde λ es la tasa de decaimiento por paso.

Loshchilov y Hutter [43] muestran que ambas formas coinciden para SGD, pero no para métodos adaptativos como Adam.

Proposición 3.27 (Equivalencia para SGD [43])**.** *SGD con tasa de aprendizaje α y decaimiento de pesos λ sobre f_t produce los mismos iterados que SGD sin decaimiento sobre f_t^{reg} con $\lambda' = \lambda/\alpha$.*

Demostración. Como $\nabla f_t^{\text{reg}}(\theta) = \nabla f_t(\theta) + \lambda'\theta$, SGD sobre f_t^{reg} da

$$\theta_t = \theta_{t-1} - \alpha\nabla f_t(\theta_{t-1}) - \alpha\lambda'\,\theta_{t-1} = (1-\alpha\lambda')\,\theta_{t-1} - \alpha\nabla f_t(\theta_{t-1}),$$

que coincide con la regla del decaimiento de pesos si y solo si $\alpha\lambda' = \lambda$. □

La equivalencia exige $\lambda' = \lambda/\alpha$: el mejor valor de la regularización L_2 depende de la tasa de aprendizaje, y ambos hiperparámetros quedan acoplados.

Proposición 3.28 (No equivalencia para métodos adaptativos [43])**.** *Sea un optimizador cuyos iterados sin regularización son $\theta_t = \theta_{t-1} - \alpha M_t \nabla f_t(\theta_{t-1})$, con una matriz de precondicionamiento M_t que no es múltiplo de la identidad, y que con decaimiento de pesos $\lambda > 0$ son $\theta_t = (1-\lambda)\theta_{t-1} - \alpha M_t \nabla f_t(\theta_{t-1})$. Entonces no existe ningún $\lambda' \in \mathbb{R}$ tal que aplicar el optimizador sin decaimiento a f_t^{reg} produzca los mismos iterados que aplicarlo con decaimiento λ a f_t.*

Demostración. Sobre f_t^{reg}, los iterados son

$$\theta_t = \theta_{t-1} - \alpha\lambda' M_t\,\theta_{t-1} - \alpha M_t \nabla f_t(\theta_{t-1}).$$

Restando la regla con decaimiento de pesos, ambos iterados coinciden para todo θ_{t-1} si y solo si $\lambda\,\theta_{t-1} = \alpha\lambda' M_t\,\theta_{t-1}$ para todo θ_{t-1}, es decir, si $\alpha\lambda' M_t = \lambda I$. Como $\lambda > 0$, esto exige que M_t sea un múltiplo de la identidad, en contradicción con la hipótesis. □

En Adam, el precondicionador es diagonal y depende de cada parámetro,

$$M_t = \operatorname{diag}\big(\sqrt{\widehat{v}_t} + \varepsilon\big)^{-1},$$

así que la proposición 3.28 se aplica. Intuitivamente, con regularización L_2 el gradiente del término de penalización también se divide por $\sqrt{\widehat{v}_t}$, de modo que los pesos con gradientes históricamente grandes se regularizan menos que con el decaimiento de pesos, que los reduce a todos a la misma tasa λ [43].

3.4.3. AdamW

Definición 3.29 (AdamW [43])**.** AdamW es Adam con decaimiento de pesos desacoplado: los momentos $m_t, v_t, \widehat{m}_t, \widehat{v}_t$ se calculan como en la definición 3.24, a partir del gradiente de la pérdida sin término de regularización, y la actualización de la definición 3.24 se sustituye por

$$\theta_t = \theta_{t-1} - \eta_t \left(\alpha \, \frac{\widehat{m}_t}{\sqrt{\widehat{v}_t} + \varepsilon} + \lambda \, \theta_{t-1} \right),$$

donde $\lambda \geq 0$ es la tasa de decaimiento de pesos y $\eta_t > 0$ es un multiplicador que permite modificar la tasa de aprendizaje a lo largo del entrenamiento (fijo, decreciente, con reinicios…).

Así, el decaimiento de pesos actúa fuera del mecanismo adaptativo y todos los pesos se reducen a la misma tasa. Loshchilov y Hutter [43] muestran empíricamente que este cambio mejora la generalización de Adam en clasificación de imágenes y que hace más independientes los valores óptimos de α y λ, lo que facilita ajustar ambos hiperparámetros.

Observación 3.30. Los modelos de este trabajo se entrenaron con la implementación de Adam de fastai, que por defecto aplica el decaimiento de pesos de forma desacoplada y es, por tanto, AdamW. Esta implementación aplica el decaimiento como $\theta \leftarrow (1 - \mathrm{lr}_t \, \mathrm{wd})\, \theta$, donde lr_t es la tasa de aprendizaje vigente; equivale a la definición 3.29 con $\lambda = \alpha \, \mathrm{wd}$. Además, no aplica decaimiento a los sesgos ni a los parámetros de las capas de normalización. Se usaron $\mathrm{wd} = 0{,}1$, $\beta_2 = 0{,}99$ y $\varepsilon = 10^{-5}$, y β_1 varió entre 0,95 y 0,85 según la política de un ciclo, por lo que la corrección de la proposición 3.25, que supone β_1 fijo, es solo aproximada. La configuración completa se detalla en el capítulo 8.

3.5. Arquitecturas para clasificación de imágenes

3.5.1. Redes neuronales convolucionales

Las redes neuronales convolucionales (CNN) son redes especializadas en datos con estructura de rejilla, como las imágenes, que pueden verse como rejillas bidimensionales de píxeles. Seguimos la presentación de Goodfellow et al. [19, cap. 9].

3.5.1.1. La operación de convolución

Definición 3.31 (Convolución)**.** Sean $x, w\colon \mathbb{R} \to \mathbb{R}$ dos funciones integrables, en particular se exigirá que $x, w \in L^1(\mathbb{R})$. Se define su *convolución* como

$$s(t) = (x * w)(t) = \int_{-\infty}^{\infty} x(a)\, w(t-a)\, da.$$

Si $x, w\colon \mathbb{Z} \to \mathbb{R}$ son discretas, la convolución es

$$s(t) = (x * w)(t) = \sum_{a=-\infty}^{\infty} x(a)\, w(t-a).$$

En el contexto de las redes convolucionales, x recibe el nombre de *entrada*, w el de *núcleo* (*kernel*) y la salida s el de *mapa de características* (*feature map*) [19, sec. 9.1].

En la práctica, la entrada y el núcleo son tensores de valores finitos y se suponen nulos fuera de las posiciones almacenadas, de modo que la suma infinita de definición 3.31 se reduce a una suma finita, siempre y cuando la entrada o el núcleo tengan soporte finito. Para una imagen bidimensional I y un núcleo bidimensional K, la convolución es

$$S(i,j) = (I * K)(i,j) = \sum_m \sum_n I(m,n)\, K(i-m,\, j-n),$$

y, por ser conmutativa,

$$S(i,j) = (K * I)(i,j) = \sum_m \sum_n I(i-m,\, j-n)\, K(m,n).$$

La conmutatividad se debe a que el núcleo aparece *volteado (flipped)* respecto de la entrada: al crecer m, el índice de la entrada crece y el del núcleo decrece. Esta propiedad es útil en las demostraciones, pero no es relevante para la implementación de una red [19, sec. 9.1].

Definición 3.32 (Correlación cruzada)**.** La *correlación cruzada* de una imagen I con un núcleo K es

$$S(i,j) = (K \star I)(i,j) = \sum_m \sum_n I(i+m,\, j+n)\, K(m,n).$$

Observación 3.33. La correlación cruzada coincide con la convolución salvo por el volteo del núcleo. Muchas bibliotecas de aprendizaje automático implementan en realidad definición 3.32 pero la llaman convolución, y Goodfellow et al. [19, sec. 9.1] adoptan ese mismo convenio. Como el núcleo se aprende, ambas operaciones son equivalentes a efectos del modelo: la red aprendería simplemente el núcleo volteado. En lo que sigue llamaremos convolución a definición 3.32, como es habitual.

Definición 3.34 (Red neuronal convolucional)**.** Una *red neuronal convolucional* es una red neuronal que, en al menos una de sus capas, sustituye la multiplicación por una matriz general por una convolución [19, cap. 9].

3.5.1.2. Convolución con varios canales, paso y relleno

Las imágenes tienen varios canales (por ejemplo, RGB) y cada capa calcula varios mapas de características en paralelo. Sea V la entrada, con $V_{l,j,k}$ el valor del canal l en la fila j y

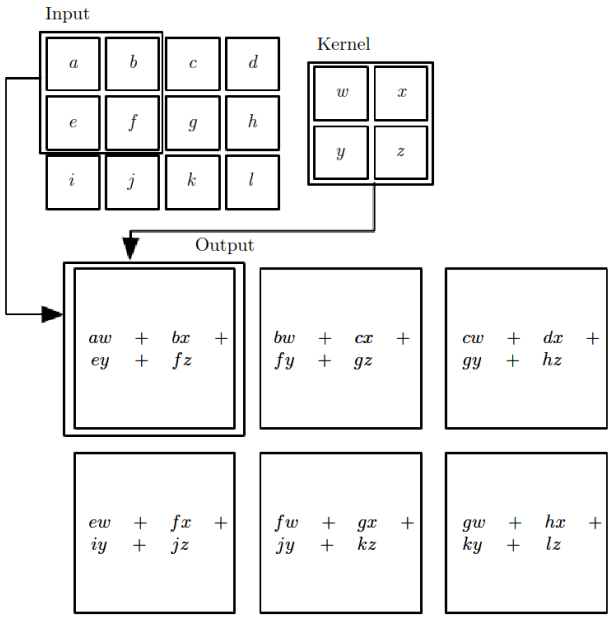

Figura 3.2.: Correlación cruzada bidimensional de una entrada de 3×4 con un núcleo de 2×2, sin volteo del núcleo: cada salida es la suma de los productos de una región de la entrada por el núcleo. Fuente: Goodfellow et al. [19, fig. 9.1].

la columna k, y sea K un núcleo de orden cuatro, donde $\mathsf{K}_{i,l,m,n}$ es el peso que conecta la unidad del canal de salida i con la del canal de entrada l cuando hay un desplazamiento de m filas y n columnas. La salida Z es

$$\mathsf{Z}_{i,j,k} = \sum_{l,m,n} \mathsf{V}_{l,\, j+m-1,\, k+n-1}\, \mathsf{K}_{i,l,m,n},$$

donde la suma recorre los índices para los que los tensores están definidos y el -1 se debe a que los índices empiezan en 1 [19, sec. 9.5].

Para reducir el coste se puede evaluar la salida solo cada s píxeles en cada dirección. La *convolución con paso* (*stride*) s es

$$\mathsf{Z}_{i,j,k} = c(\mathsf{K}, \mathsf{V}, s)_{i,j,k} = \sum_{l,m,n} \mathsf{V}_{l,\,(j-1)s+m,\,(k-1)s+n}\, \mathsf{K}_{i,l,m,n},$$

lo que equivale a una convolución con paso unidad seguida de un submuestreo, pero sin calcular los valores que se descartarían [19, sec. 9.5].

Por último, el *relleno con ceros* (*zero padding*) de la entrada permite controlar el tamaño de la salida con independencia del tamaño del núcleo. Si la entrada tiene anchura m y el núcleo anchura k, hay tres casos habituales [19, sec. 9.5]:

- *Válida* (*valid*): sin relleno; el núcleo solo se aplica donde cabe entero y la salida tiene anchura $m - k + 1$.
- *Misma* (*same*): se rellena lo justo para que la salida tenga la misma anchura m que la entrada.

- *Completa* (*full*): se rellena lo suficiente para que cada píxel se visite k veces en cada dirección; la salida tiene anchura $m + k - 1$.

3.5.1.3. Motivación: interacciones dispersas, parámetros compartidos y equivarianza

La convolución aporta tres propiedades frente a una capa densa [19, sec. 9.2]:

1. *Interacciones dispersas*. El núcleo es mucho más pequeño que la entrada, así que cada unidad de salida depende solo de una región local. Con m entradas y n salidas, una capa densa necesita $m \times n$ parámetros y un coste $O(m \times n)$; si cada salida se conecta como mucho a $k \ll m$ entradas, bastan $k \times n$ parámetros y un coste $O(k \times n)$.

2. *Parámetros compartidos*. Cada peso del núcleo se usa en todas las posiciones de la entrada, de modo que se aprende un único conjunto de k parámetros en lugar de uno por posición.

3. *Equivarianza a traslaciones*, que precisamos a continuación.

Definición 3.35 (Equivarianza)**.** Una función f es *equivariante* respecto de una transformación g si $f(g(x)) = g(f(x))$ para toda entrada x [19, sec. 9.2].

Proposición 3.36 (Equivarianza de la convolución a traslaciones)**.** *Sean $I, K \colon \mathbb{Z}^2 \to \mathbb{R}$ con K de soporte finito y, para $\tau = (\tau_1, \tau_2) \in \mathbb{Z}^2$, sea T_τ el operador de traslación $(T_\tau I)(m, n) = I(m - \tau_1,\, n - \tau_2)$. Entonces*

$$K \star (T_\tau I) = T_\tau (K \star I).$$

Demostración. Para todo $(i, j) \in \mathbb{Z}^2$, por la definición definición 3.32,

$$\begin{aligned}\big(K \star T_\tau I\big)(i,j) &= \sum_m \sum_n I\big(i + m - \tau_1,\, j + n - \tau_2\big)\, K(m,n) \\ &= (K \star I)(i - \tau_1,\, j - \tau_2) = \big(T_\tau (K \star I)\big)(i,j).\end{aligned}$$

Las sumas son finitas porque K tiene soporte finito. □

Observación 3.37. En una imagen finita la igualdad solo se cumple lejos de los bordes, donde el relleno con ceros rompe la equivarianza. Además, la convolución *no* es equivariante a otras transformaciones, como los cambios de escala o las rotaciones [19, sec. 9.2].

3.5.1.4. Estructura de una capa convolucional y *pooling*

Una capa convolucional típica consta de tres etapas [19, sec. 9.3]:

1. *Etapa de convolución*: se calculan varias convoluciones en paralelo, que dan un conjunto de activaciones lineales (afines, si se suma un sesgo).

2. *Etapa de detección*: a cada activación se le aplica una función no lineal, como la rectificada lineal $\mathrm{ReLU}(z) = \max\{0, z\}$.

3. *Etapa de agregación* (*pooling*): se modifica la salida sustituyéndola, en cada posición, por un resumen estadístico de las salidas cercanas.

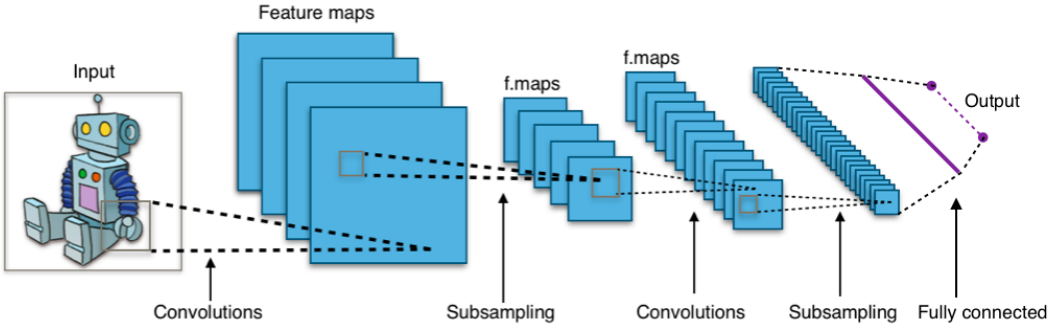

Figura 3.3.: Arquitectura típica de una red neuronal convolucional para clasificación de imágenes: capas de convolución que producen mapas de características, alternadas con capas de submuestreo (*pooling*), y capas totalmente conectadas al final que producen la salida. Fuente: Aphex34, *Typical cnn.png*, Wikimedia Commons, licencia CC BY-SA 4.0 (https://commons.wikimedia.org/w/index.php?curid=45679374).

Definición 3.38 (*Max pooling*)**.** Dada una vecindad rectangular $\mathcal{N}(i,j)$ de la posición (i,j), el *max pooling* devuelve

$$P(i,j) = \max_{(m,n)\in\mathcal{N}(i,j)} S(m,n).$$

Otras funciones de agregación habituales son la media en la vecindad, la norma L^2 o una media ponderada por la distancia al píxel central [19, sec. 9.3].

El *pooling* hace que la representación sea aproximadamente *invariante* a traslaciones pequeñas de la entrada: si la entrada se desplaza ligeramente, la mayoría de las salidas agregadas no cambian [19, sec. 9.3].

La figura 3.3 muestra cómo se combinan estos elementos en una arquitectura convolucional típica: varias capas convolucionales, cada una seguida de una no linealidad y de una etapa de *pooling*, que reducen progresivamente la resolución espacial y aumentan el número de mapas de características, y unas capas totalmente conectadas finales que proporcionan la predicción.

3.5.2. Redes residuales y normalización

ResNet-50, los transformers, Swin y ConvNeXt, que se estudian en el resto de esta sección, comparten dos componentes que no aparecen en la red de la definición 3.8: las conexiones residuales y las capas de normalización. Al aumentar el número de capas, entrenar una red se vuelve más difícil; una de las causas que señala Prince [54, sec. 11.1] es que los cambios en las primeras capas modifican la salida de forma cada vez más compleja a medida que la red es más profunda, de modo que el gradiente cambia mucho de un ejemplo a otro (*shattered gradients*).

Definición 3.39 (Conexión residual [54, sec. 11.2])**.** Sean $f_1, \ldots, f_K$ funciones con parámetros

$\phi_1, \dots, \phi_K$ cuya salida tiene el mismo tamaño que su entrada. La *red residual* asociada es

$$\begin{aligned} h_1 &= x + f_1(x; \phi_1), \\ h_k &= h_{k-1} + f_k(h_{k-1}; \phi_k), \qquad k = 2, \dots, K-1, \\ y &= h_{K-1} + f_K(h_{K-1}; \phi_K). \end{aligned}$$

El primer sumando de cada igualdad es la *conexión residual* (*residual* o *skip connection*), y cada combinación aditiva de la entrada y de su transformación se llama *bloque residual*.

Cada f_k aprende, por tanto, un cambio aditivo sobre la representación actual. Sustituyendo las expresiones intermedias, la salida es la suma de la entrada y de varias redes más pequeñas; con K bloques, la red puede verse como la combinación de 2^K caminos distintos desde la entrada hasta la salida [54, sec. 11.2, fig. 11.4].

Definición 3.40 (Normalización por lotes [54, sec. 11.4])**.** Sea h una activación y sean h_i, $i \in \mathcal{B}$, sus valores en los ejemplos de un lote $\mathcal{B}$. La *normalización por lotes* (*batch normalization*, BatchNorm) calcula la media y la desviación típica empíricas

$$m_h = \frac{1}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} h_i, \qquad s_h = \sqrt{\frac{1}{|\mathcal{B}|} \sum_{i \in \mathcal{B}} (h_i - m_h)^2},$$

estandariza los valores y después los escala y desplaza:

$$h_i \leftarrow \frac{h_i - m_h}{s_h + \varepsilon}, \qquad h_i \leftarrow \gamma\, h_i + \delta, \qquad i \in \mathcal{B},$$

donde $\varepsilon > 0$ evita la división por cero y γ y δ son parámetros que se aprenden durante el entrenamiento.

Tras esta operación, las activaciones tienen, en el lote, media δ y desviación típica γ. La normalización se aplica a cada unidad oculta por separado; en una red convolucional, los estadísticos se calculan sobre el lote y sobre todas las posiciones espaciales, con un par (γ, δ) por canal. En la fase de prueba no se dispone de un lote, así que m_h y s_h se calculan sobre el conjunto de entrenamiento y se congelan [54, sec. 11.4]. Entre sus ventajas, Prince señala que estabiliza la propagación hacia delante, permite usar tasas de aprendizaje más altas y actúa como regularizador [54, sec. 11.4.1].

Definición 3.41 (Normalización por capa [54, sec. 11.4])**.** La *normalización por capa* (*layer normalization*, LayerNorm) no usa estadísticos del lote: normaliza cada ejemplo por separado. Para un vector $x \in \mathbb{R}^D$,

$$\mathrm{LN}(x)_d = \gamma_d \frac{x_d - m}{s + \varepsilon} + \delta_d, \qquad m = \frac{1}{D} \sum_{d=1}^{D} x_d, \quad s = \sqrt{\frac{1}{D} \sum_{d=1}^{D} (x_d - m)^2},$$

con parámetros aprendidos $\gamma, \delta \in \mathbb{R}^D$, uno por canal.

[REVISAR: Prince describe la LayerNorm con estadísticos sobre los canales y las posiciones espaciales (sec. 11.4) y, en los transformers, sobre los tokens de la secuencia (sec. 12.4). En las implementaciones de ViT, Swin y ConvNeXt usadas (`timm`) se normaliza cada token, o cada posición espacial, sobre sus D canales, que es lo que recoge la definición; comprobar cuál se prefiere citar.]

A diferencia de BatchNorm, la salida de LayerNorm para un ejemplo no depende del resto del lote. Vaswani et al. la usaron en el transformer original porque los estadísticos del lenguaje varían mucho de un lote a otro [54, cap. 12, notas].

3.5.2.1. ResNet-50

Las conexiones residuales se usaron por primera vez en redes convolucionales para clasificación de imágenes, en las llamadas *redes residuales* o ResNet [21]. Para redes muy profundas, Prince [54, sec. 11.5.1] describe el *bloque residual con cuello de botella* (*bottleneck*), que usa tres convoluciones: la primera, de 1×1, reduce el número de canales; la segunda es una convolución habitual de 3×3; y la tercera, de nuevo de 1×1, recupera el número de canales original para poder sumar la entrada. Así se integra la información de una región de 3×3 píxeles con menos parámetros. Como en otras arquitecturas convolucionales, la resolución espacial se reduce periódicamente mientras aumenta el número de canales.

La ResNet-50 usada en este trabajo tiene esta estructura: una convolución inicial de 7×7 con paso 2 seguida de *max pooling*, cuatro etapas de 3, 4, 6 y 3 bloques con cuello de botella cuyas salidas tienen 256, 512, 1024 y 2048 canales, y BatchNorm y ReLU en cada bloque.

Observación 3.42. Prince indica que, en cada bloque, el orden de las operaciones es BatchNorm, ReLU y convolución [54, sec. 11.5.1, fig. 11.7]. En la ResNet-50 usada en este trabajo, cada convolución va seguida de BatchNorm y ReLU, y la última ReLU del bloque se aplica después de sumar la conexión residual, según el resumen de capas del entrenamiento. **[REVISAR: comprobar el orden del bloque en He et al. (2016); el orden de Prince corresponde a otra variante de ResNet]**

3.5.3. Transformers

Los transformers presentan su origen en los NLP, en donde es fundamental el contexto de las palabras para poder entender su significado. Por ejemplo, sea la siguiente frase, similar a la ofrecida por Prince [54, sec. 12.1]:

El restaurante se negó a servirme un sándwich de jamón porque ellos solo ofrecían platos veganos. Al final, ellos solo me dieron dos rebanadas de pan. Su ambiente fue igual de bueno que la comida y el servicio.

En el procesamiento de lenguajes naturales se trabaja para ofrecer una representación adaptable del texto para diversos objetivos, que puede ser por ejemplo calificar esta reseña como positiva o negativa. En este contexto existen diversas dificultades. La primera es que las entradas pueden ser inmensamente largas de forma que las redes neuronales totalmente conectadas son imprácticas. Segundo, cada entrada es de una longitud distinta de forma que no sería obvio cómo aplicar una red totalmente conectada. Finalmente, el lenguaje es ambiguo, por ejemplo la palabra «ellos» se refiere al restaurante y no al sándwich de jamón. Para entender el texto, la palabra debería estar relacionada de alguna manera con la palabra «restaurante». En la jerga de los transformadores, la primera palabra debería tener en cuenta a la segunda. Esto implica que debe haber conexiones entre las palabras y que la fuerza de estas conexiones dependerá de las propias palabras. Además, estas conexiones deben extenderse a lo largo de amplios fragmentos de texto. Por ejemplo, la palabra «su» de la última frase también se refiere al restaurante.

Las dificultades anteriores sugieren dos requisitos para un modelo que procese texto. Por un lado, debe *compartir parámetros* entre las distintas posiciones de la entrada, de forma análoga a como las redes convolucionales comparten los pesos de sus filtros entre las distintas

posiciones de una imagen; así, el número de parámetros no crece con la longitud del texto y el mismo modelo puede aplicarse a entradas de cualquier tamaño. Por otro lado, debe establecer *conexiones entre las representaciones de las palabras* cuya intensidad dependa de las propias palabras, y no de unos pesos fijos. Una capa totalmente conectada no cumple ninguno de los dos: calcula $f(x) = \mathrm{ReLU}(\beta + \Omega x)$ para una entrada x de tamaño fijo, y la influencia de cada componente de x sobre la salida queda determinada por los pesos Ω, sea cual sea el texto. Los transformers satisfacen ambos requisitos gracias al mecanismo de *autoatención por producto escalar* [54, sec. 12.2], que describimos a continuación.

Un bloque de autoatención recibe N vectores de entrada $x_1, \ldots, x_N \in \mathbb{R}^D$ y devuelve N vectores de salida de la misma dimensión. En procesamiento del lenguaje, cada entrada representa una palabra o un fragmento de palabra; en visión, un fragmento (*patch*) de la imagen. La idea es que cada salida sea una combinación de todas las entradas, en la que el peso de cada una dependa de su parecido con la entrada correspondiente a esa salida.

Definición 3.43 (Autoatención por producto escalar [54, sec. 12.2])**.** Sean $x_1, \ldots, x_N \in \mathbb{R}^D$. Para cada $n = 1, \ldots, N$ se calculan, mediante tres transformaciones afines con parámetros compartidos por todas las entradas, los vectores

$$v_n = \beta_v + \Omega_v x_n, \qquad q_n = \beta_q + \Omega_q x_n, \qquad k_n = \beta_k + \Omega_k x_n,$$

llamados respectivamente *valor*, *consulta* (*query*) y *clave* (*key*), donde $\Omega_v \in \mathbb{R}^{D\times D}$, $\beta_v \in \mathbb{R}^D$, $\Omega_q, \Omega_k \in \mathbb{R}^{D_q \times D}$ y $\beta_q, \beta_k \in \mathbb{R}^{D_q}$. Brevemente explicado q_n representa lo que busca cada parche en un momento dado, k_n actúa como un identificativo de cada parche y v_n contiene la información real que será transmitida si el parche resulta ser relevante. Los *pesos de atención* de la salida n-ésima sobre cada entrada x_m se definen como

$$a(x_m, x_n) = \mathrm{softmax}_m\left(k_\bullet^\top q_n\right) = \frac{\exp\left(k_m^\top q_n\right)}{\sum_{m'=1}^N \exp\left(k_{m'}^\top q_n\right)}, \qquad m = 1, \ldots, N,$$

y la salida n-ésima del bloque es la media ponderada de los valores:

$$\mathrm{sa}_n(x_1, \ldots, x_N) = \sum_{m=1}^N a(x_m, x_n)\, v_m.$$

Para cada n, los pesos $a(x_1, x_n), \ldots, a(x_N, x_n)$ son positivos y suman 1, de modo que cada salida es una combinación convexa de los valores. El producto escalar $k_m^\top q_n$ mide la compatibilidad entre la consulta de la entrada n-ésima y la clave de la entrada m-ésima. Como las consultas y las claves se obtienen con proyecciones distintas y aprendidas, Ω_q y Ω_k, esta compatibilidad no es un simple parecido entre x_n y x_m: el modelo aprende durante el entrenamiento qué entradas son relevantes para cada una. Así, cada salida da más peso a las entradas más relevantes para ella. Además, como la función *softmax* normaliza los pesos para que sumen uno, las claves *compiten* entre sí: aumentar el peso de una entrada reduce necesariamente el de las demás. Los nombres de consulta y clave proceden del campo de la recuperación de información. Las consultas y las claves deben tener la misma dimensión D_q, que puede ser distinta de la de los valores; estos suelen tener la dimensión D de la entrada, para que la representación no cambie de tamaño.

Observación 3.44 (Forma matricial). Si se colocan las entradas como columnas de una matriz $X \in \mathbb{R}^{D\times N}$ donde N es el número total de tokens y D es la dimensión del espacio latente,

los valores, las consultas y las claves se calculan a la vez como

$$V = \beta_v \mathbf{1}^\top + \Omega_v X, \qquad Q = \beta_q \mathbf{1}^\top + \Omega_q X, \qquad K = \beta_k \mathbf{1}^\top + \Omega_k X,$$

donde $\mathbf{1} \in \mathbb{R}^N$ es el vector de unos, y la salida del bloque es

$$\text{Sa}(X) = V \ \text{Softmax}\big(K^\top Q\big),$$

donde Softmax aplica la función *softmax* a cada columna de la matriz por separado [54, sec. 12.2.4].

Observación 3.45.

1. El número de parámetros, $\{\beta_v, \Omega_v, \beta_q, \Omega_q, \beta_k, \Omega_k\}$, no depende de N, de modo que el mismo bloque puede aplicarse a secuencias de cualquier longitud. En cambio, el número de pesos de atención es N^2.

2. Aunque el bloque no tiene función de activación, no es lineal en la entrada. Los valores v_m son funciones afines de x_m, y si los pesos de atención fueran constantes la salida sería también afín. Sin embargo, los pesos $a(x_m, x_n)$ dependen de la propia entrada: el producto escalar $k_m^\top q_n$ es cuadrático en X y la función *softmax* introduce exponenciales. Por tanto, la salida es el producto de una función no lineal de X por una función afín de X. En términos de Prince [54, sec. 12.2.2], se trata de una *hiperred*: una rama de la red calcula los pesos que utiliza la otra. En un perceptrón multicapa la no linealidad la aporta la función de activación; en la autoatención, los pesos de atención.

3. En la práctica, los productos escalares se dividen por $\sqrt{D_q}$, lo que se conoce como *autoatención por producto escalar escalado* [54, sec. 12.3.2]:

$$\text{Sa}(X) = V \ \text{Softmax}\left(\frac{K^\top Q}{\sqrt{D_q}}\right).$$

   Así se evita que los productos escalares sean tan grandes que el mayor de ellos domine la función *softmax*; en esa situación, los gradientes son muy pequeños y el modelo es difícil de entrenar. Por otro lado, al multiplicar la matriz resultante por los valores (V) se obtiene una nueva representación de los parches donde cada uno se ha actualizado incorporando el contexto global ponderado de toda la imagen.

3.5.3.1. Atención multicabeza

En la práctica, no se usa un único mecanismo de autoatención, sino varios en paralelo; esto se conoce como *autoatención multicabeza* (*multi-head self-attention*). Cada uno de estos mecanismos, llamado *cabeza*, tiene sus propios parámetros y calcula sus propios valores, consultas y claves.

Definición 3.46 (Autoatención multicabeza [54, sec. 12.3.3])**.** Sea $X \in \mathbb{R}^{D \times N}$ la matriz de entradas y sea $H \geq 1$ el número de cabezas. Para cada $h = 1, \ldots, H$ se calculan

$$V_h = \beta_{v_h} \mathbf{1}^\top + \Omega_{v_h} X, \qquad Q_h = \beta_{q_h} \mathbf{1}^\top + \Omega_{q_h} X, \qquad K_h = \beta_{k_h} \mathbf{1}^\top + \Omega_{k_h} X,$$

con parámetros $\{\beta_{v_h}, \Omega_{v_h}\}$, $\{\beta_{q_h}, \Omega_{q_h}\}$ y $\{\beta_{k_h}, \Omega_{k_h}\}$ distintos para cada cabeza, y la salida de

la cabeza h-ésima es

$$\mathrm{Sa}_h(X) = V_h \,\mathrm{Softmax}\left(\frac{K_h^\top Q_h}{\sqrt{D_q}}\right),$$

donde D_q es la dimensión de las consultas y las claves. La salida del bloque se obtiene concatenando verticalmente las salidas de todas las cabezas y combinándolas mediante una transformación lineal Ω_c:

$$\mathrm{MhSa}(X) = \Omega_c \begin{bmatrix} \mathrm{Sa}_1(X) \\ \vdots \\ \mathrm{Sa}_H(X) \end{bmatrix}.$$

Habitualmente, si las entradas tienen dimensión D, los valores, las consultas y las claves de cada cabeza tienen dimensión D/H, lo que permite una implementación eficiente: el coste total es similar al de una única cabeza de dimensión D. Según Prince [54, sec. 12.3.3], el uso de varias cabezas parece necesario para que el transformer funcione bien, y se ha conjeturado que hace la red más robusta frente a malas inicializaciones.

3.5.3.2. Codificación posicional

El mecanismo de autoatención descarta una información importante: el cálculo es el mismo sea cual sea el orden de las entradas x_n. Más precisamente, es equivariante respecto de las permutaciones de las entradas [54, sec. 12.3.1].

Proposición 3.47 (Equivarianza a permutaciones [54, problema 12.3])**.** *Sean $X \in \mathbb{R}^{D\times N}$, π una permutación de $\{1,\dots,N\}$ y $P = [\,e_{\pi(1)} \;\cdots\; e_{\pi(N)}\,] \in \mathbb{R}^{N\times N}$ su matriz de permutación, de modo que XP tiene por columnas $x_{\pi(1)},\dots,x_{\pi(N)}$. Entonces*

$$\mathrm{Sa}(XP) = \mathrm{Sa}(X)\,P,$$

y lo mismo ocurre con la autoatención escalada y con la autoatención multicabeza.

Demostración. Cada columna de P tiene un único uno, así que $\mathbf{1}^\top P = \mathbf{1}^\top$. Por tanto, los valores calculados a partir de XP son

$$\beta_v \mathbf{1}^\top + \Omega_v XP = \big(\beta_v \mathbf{1}^\top + \Omega_v X\big)P = VP,$$

y del mismo modo las consultas y las claves son QP y KP. La matriz de compatibilidades pasa a ser $(KP)^\top QP = P^\top AP$, con $A = K^\top Q$.

Veamos que $\mathrm{Softmax}(P^\top AP) = P^\top \mathrm{Softmax}(A)P$. Para un vector $z \in \mathbb{R}^N$ se tiene

$$(P^\top z)_m = e_{\pi(m)}^\top z = z_{\pi(m)}, \qquad m = 1,\dots,N,$$

es decir, $P^\top z$ reordena las componentes de z. Como el denominador de la función *softmax* no depende del orden,

$$\sum_{m=1}^{N} \exp(z_{\pi(m)}) = \sum_{m=1}^{N} \exp(z_m), \qquad \text{luego} \qquad \mathrm{softmax}(P^\top z) = P^\top \mathrm{softmax}(z).$$

La columna n-ésima de AP es la columna $\pi(n)$-ésima de A, que denotamos $a_{\pi(n)}$, así que la

columna n-ésima de $\mathrm{Softmax}(P^\top AP)$ es

$$\mathrm{softmax}\big(P^\top a_{\pi(n)}\big) = P^\top \mathrm{softmax}\big(a_{\pi(n)}\big),$$

que es la columna n-ésima de $P^\top \mathrm{Softmax}(A)P$.

Finalmente, como $PP^\top = I$,

$$\mathrm{Sa}(XP) = VP\,P^\top \mathrm{Softmax}(A)\,P = V\,\mathrm{Softmax}(A)\,P = \mathrm{Sa}(X)\,P.$$

Dividir A entre $\sqrt{D_q}$ no afecta al argumento. En la autoatención multicabeza, cada cabeza cumple $\mathrm{Sa}_h(XP) = \mathrm{Sa}_h(X)P$, de modo que la concatenación vertical de las cabezas queda multiplicada por P por la derecha, y también su producto por Ω_c. □

Es decir, si se reordenan las entradas, las salidas se reordenan de la misma manera: el bloque no sabe en qué posición está cada entrada. Sin embargo, el orden importa: en una frase, cambiar el orden de las palabras cambia su significado y, en una imagen, cada parche ocupa una posición concreta. Prince [54, sec. 12.3.1] distingue dos formas principales de incorporar la posición:

- *Codificaciones posicionales absolutas*. Se suma a la entrada X una matriz Π que codifica la posición. Cada columna de Π es distinta, así que contiene información sobre la posición absoluta en la secuencia. La matriz puede elegirse a mano o aprenderse, y sumarse a la entrada de la red o en cada capa.
- *Codificaciones posicionales relativas*. Lo relevante suele ser la posición relativa entre dos entradas, más que la absoluta. Cada elemento de la matriz de atención corresponde a un desplazamiento concreto entre la posición a de la consulta y la posición b de la clave; se aprende un parámetro $\pi_{a,b}$ para cada desplazamiento, que modifica la matriz de atención, por ejemplo sumándose a ella.

ViT usa una codificación absoluta aprendida (apartado 3.5.4) y Swin, una relativa (apartado 3.5.5).

3.5.3.3. La capa transformer

La autoatención es solo una parte de una capa transformer, que consta de una unidad de autoatención multicabeza, que permite que las representaciones de las entradas interactúen entre sí, seguida de una red totalmente conectada mlp que actúa por separado sobre cada entrada. Ambas unidades son bloques residuales (definición 3.39) y van seguidas de una LayerNorm (definición 3.41).

Definición 3.48 (Capa transformer [54, sec. 12.4])**.** Dada $X \in \mathbb{R}^{D\times N}$ con columnas $x_1, \ldots, x_N$, una *capa transformer* realiza las operaciones

$$\begin{aligned} X &\leftarrow X + \mathrm{MhSa}(X), \\ X &\leftarrow \mathrm{LN}(X), \\ x_n &\leftarrow x_n + \mathrm{mlp}(x_n), \qquad n = 1, \ldots, N, \\ X &\leftarrow \mathrm{LN}(X), \end{aligned}$$

donde LN se aplica a cada columna y mlp es la misma red totalmente conectada para todas las columnas.

Una red transformer aplica varias de estas capas consecutivas. La salida de cada capa tiene el mismo tamaño $D \times N$ que su entrada, y el número de parámetros no depende de N.

Observación 3.49. En la definición 3.48 la LayerNorm se aplica después de cada suma residual. ViT y Swin, en cambio, aplican la LayerNorm *antes* de cada unidad y la conexión residual después [15, ecs. (2)–(3)], [41, ec. (3)]:

$$X \leftarrow X + \mathrm{MhSa}\big(\mathrm{LN}(X)\big), \qquad x_n \leftarrow x_n + \mathrm{mlp}\big(\mathrm{LN}(x_n)\big).$$

Prince señala que colocar la LayerNorm fuera del bloque residual hace que los gradientes se reduzcan al propagarse hacia atrás por la red, y que cambiar la posición de la LayerNorm es una de las propuestas para estabilizar el entrenamiento de los transformers [54, cap. 12, notas].

3.5.4. Vision Transformer

El *Vision Transformer* (ViT) de Dosovitskiy et al. [15] aplica a imágenes un transformer que sigue lo más fielmente posible el transformer original del procesamiento del lenguaje. La ventaja de esta elección es que las arquitecturas escalables de procesamiento del lenguaje, y sus implementaciones eficientes, pueden usarse casi directamente [15, sec. 3]. Adaptamos la notación del artículo a la de Prince, con los tokens en columnas.

El transformer recibe una secuencia de vectores. Para aplicarlo a una imagen $x \in \mathbb{R}^{H\times W\times C}$, donde (H, W) es la resolución y C el número de canales, la imagen se divide en $N = HW/P^2$ parches de $P \times P$ píxeles, que se aplanan en vectores $x_p^1, \ldots, x_p^N \in \mathbb{R}^{P^2C}$. N es la longitud de la secuencia que recibe el transformer. Como el transformer usa la misma dimensión D en todas sus capas, cada parche se proyecta a $\mathbb{R}^D$ con una matriz aprendida E; el resultado se llama *embedding* del parche [15, sec. 3.1].

Definición 3.50 (Vision Transformer [15, sec. 3.1])**.** Sean $E \in \mathbb{R}^{D\times P^2C}$ la proyección de los parches, $x_{\text{class}} \in \mathbb{R}^D$ un vector aprendido (el *token de clase*) y $E_{\text{pos}} \in \mathbb{R}^{D\times(N+1)}$ una matriz de embeddings de posición aprendidos. El ViT con L capas calcula

$$\begin{aligned}
Z_0 &= \big[\, x_{\text{class}} \;\; Ex_p^1 \;\; Ex_p^2 \;\; \cdots \;\; Ex_p^N \,\big] + E_{\text{pos}}, \\
Z'_\ell &= Z_{\ell-1} + \mathrm{MhSa}\big(\mathrm{LN}(Z_{\ell-1})\big), && \ell = 1, \ldots, L, \\
Z_\ell &= Z'_\ell + \mathrm{MLP}\big(\mathrm{LN}(Z'_\ell)\big), && \ell = 1, \ldots, L, \\
y &= \mathrm{LN}\big(z_L^0\big),
\end{aligned}$$

donde LN y MLP se aplican a cada columna por separado, MLP es una red con dos capas y activación GELU (definición 3.5) y z_L^0 es la primera columna de Z_L, la que corresponde al token de clase.

Las capas de la definición 3.50 son capas transformer con la LayerNorm antes de cada unidad (observación 3.49). Igual que el token `[class]` de BERT, el token de clase no corresponde a ningún parche: su estado a la salida del transformer, y, es la representación de la imagen, y a él se conecta la cabeza de clasificación. En el artículo, esta cabeza es un MLP con una capa oculta durante el preentrenamiento y una única capa lineal durante el ajuste fino [15, sec. 3.1].

Observación 3.51. Los embeddings de posición son una codificación posicional absoluta y aprendida (apartado 3.5.3.2). Dosovitskiy et al. usan embeddings unidimensionales, que tra-

tan los parches como una secuencia en orden de lectura, porque no observaron mejoras significativas con embeddings bidimensionales. En sus experimentos hay una gran diferencia entre no usar información posicional y usarla, pero apenas hay diferencias entre las distintas formas de codificarla (unidimensional, bidimensional o relativa). Los autores lo atribuyen a que el transformer trabaja con parches y no con píxeles, de modo que la forma de codificar la información espacial es menos importante [15, ap. D.4].

Para adaptar a una tarea concreta un modelo preentrenado, se elimina la cabeza de predicción y se añade una capa de $D \times K$ inicializada a cero, donde K es el número de clases. Si las imágenes del ajuste fino tienen mayor resolución que las del preentrenamiento, se mantiene el tamaño de los parches, de modo que la secuencia es más larga; como los embeddings de posición preentrenados pueden dejar de tener sentido, se interpolan en dos dimensiones según su posición en la imagen original [15, sec. 3.2].

Dosovitskiy et al. definen tres variantes a partir de las de BERT, y la notación ViT-B/16 indica la variante *Base* con parches de 16×16. ViT-B tiene $L = 12$ capas, dimensión $D = 768$, MLP de dimensión 3072, 12 cabezas y 86 millones de parámetros [15, tabla 1]. Como la longitud de la secuencia es inversamente proporcional al cuadrado del tamaño de los parches, los modelos con parches más pequeños son más costosos [15, sec. 4.1]. En el ViT-B/16 usado en este trabajo, con imágenes de 224×224, la secuencia tiene $N = 224^2/16^2 = 196$ parches, más el token de clase. La cabeza de clasificación no es la del artículo, sino la que añade fastai (apartado 8.5.2).

3.5.4.1. Sesgo inductivo: transformers frente a redes convolucionales

Se llama *sesgo inductivo* de un modelo a su tendencia a preferir unas soluciones frente a otras al extrapolar entre los datos de entrenamiento [54, sec. 8.4]; viene determinado, en gran medida, por la arquitectura. Las redes convolucionales tienen un sesgo inductivo muy adecuado para las imágenes: cada capa es equivariante por traslaciones y solo relaciona píxeles cercanos, de modo que la estructura bidimensional de la imagen está incorporada en la propia arquitectura. La autoatención, en cambio, no hace ninguna de estas suposiciones: cada parche puede relacionarse con cualquier otro desde la primera capa, y la intensidad de esas relaciones se aprende a partir de los datos. Esto permite modelar relaciones de largo alcance en la imagen, pero obliga al modelo a aprender la estructura espacial que una red convolucional tiene de partida. Por eso, como señala Prince [54, sec. 12.10], los transformers solo superan a las redes convolucionales cuando se entrenan con cantidades muy grandes de datos, habitualmente mediante un preentrenamiento a gran escala.

Dosovitskiy et al. precisan este argumento para ViT. En una red convolucional, la localidad, la estructura bidimensional de vecindad y la equivarianza a traslaciones están incorporadas en cada capa. En ViT, solo las capas MLP son locales y equivariantes a traslaciones, mientras que las capas de autoatención son globales. La estructura bidimensional se usa muy poco: al principio, al dividir la imagen en parches, y en el ajuste fino, al interpolar los embeddings de posición para imágenes de otra resolución. Por lo demás, los embeddings de posición no contienen al inicializarse información sobre la posición bidimensional de los parches, y todas las relaciones espaciales entre ellos tienen que aprenderse desde cero [15, sec. 3.1]. En consecuencia, cuando se entrenan en conjuntos de tamaño medio como ImageNet sin una regularización fuerte, los ViT obtienen exactitudes unos puntos porcentuales por debajo de las de ResNet de tamaño comparable [15, sec. 1]. Con preentrenamiento en ImageNet, ViT-Large rinde peor que ViT-Base, y solo con el preentrenamiento en JFT-300M, con

unos 303 millones de imágenes, se aprecia todo el beneficio de los modelos más grandes [15, secs. 4.1 y 4.3].

3.5.5. Swin Transformer

ViT trabaja a una única escala: todas sus capas operan sobre la misma rejilla de parches. Se han propuesto transformers que procesan la imagen a varias escalas y que, como las redes convolucionales, empiezan con parches de alta resolución y pocos canales y van reduciendo la resolución a la vez que aumentan el número de canales [54, sec. 12.10.3]. Un ejemplo representativo es el *Swin Transformer* (*shifted window transformer*) de Liu et al. [41].

Liu et al. explican las dificultades de trasladar el transformer del lenguaje a la visión por dos diferencias entre ambos dominios: los objetos de una imagen pueden aparecer a escalas muy distintas, mientras que en los transformers existentes todos los tokens tienen una escala fija; y la resolución de los píxeles de una imagen es mucho mayor que la de las palabras de un texto, mientras que el coste de la autoatención es cuadrático en el tamaño de la imagen [41, sec. 1]. Swin responde a ambas con una representación jerárquica y con autoatención calculada dentro de ventanas locales.

3.5.5.1. Arquitectura

La imagen se divide en parches de 4×4 píxeles que no se solapan, como en ViT. Cada parche es un token cuyo vector de características es la concatenación de sus valores RGB, de dimensión $4 \times 4 \times 3 = 48$, y una capa lineal lo proyecta a una dimensión C. Sobre estos $\frac{H}{4} \times \frac{W}{4}$ tokens se aplican varios bloques Swin, que mantienen el número de tokens; todo ello forma la *etapa 1*. Para obtener una representación jerárquica, una capa de *fusión de parches* (*patch merging*) concatena las características de cada grupo de 2×2 parches vecinos, de dimensión $4C$, y les aplica una capa lineal con salida de dimensión $2C$. Así, el número de tokens se divide entre 4, la resolución entre 2 y el número de canales se duplica. Siguen nuevos bloques Swin, que forman la *etapa 2*, con resolución $\frac{H}{8} \times \frac{W}{8}$. El proceso se repite en las etapas 3 y 4, con resoluciones $\frac{H}{16} \times \frac{W}{16}$ y $\frac{H}{32} \times \frac{W}{32}$: las mismas que las de redes convolucionales típicas como ResNet [41, sec. 3.1]. La fusión de parches desempeña así un papel análogo al del *pooling* en una red convolucional.

Un *bloque Swin* es una capa transformer con LayerNorm antes de cada unidad (observación 3.49) en la que la autoatención multicabeza se sustituye por una autoatención por ventanas; el MLP tiene dos capas con GELU. Los bloques consecutivos alternan dos particiones en ventanas, la regular (W-MSA) y la desplazada (SW-MSA), que se describen a continuación:

$$\widehat{Z}_\ell = Z_{\ell-1} + \text{W-MSA}\big(\text{LN}(Z_{\ell-1})\big), \qquad Z_\ell = \widehat{Z}_\ell + \text{MLP}\big(\text{LN}(\widehat{Z}_\ell)\big),$$
$$\widehat{Z}_{\ell+1} = Z_\ell + \text{SW-MSA}\big(\text{LN}(Z_\ell)\big), \qquad Z_{\ell+1} = \widehat{Z}_{\ell+1} + \text{MLP}\big(\text{LN}(\widehat{Z}_{\ell+1})\big),$$

donde $\widehat{Z}_\ell$ y Z_ℓ son las salidas de la autoatención y del MLP del bloque ℓ [41, ec. (3)].

Swin no tiene token de clase: las características de la última capa se promedian sobre todos los tokens y una capa lineal las transforma en las puntuaciones de las clases [54, sec. 12.10.3].

3.5.5.2. Autoatención por ventanas

La autoatención global de ViT relaciona cada token con todos los demás, lo que tiene un coste cuadrático en el número de tokens. Para reducirlo, Swin calcula la autoatención dentro de *ventanas* locales de $M \times M$ parches que dividen la imagen sin solaparse [41, sec. 3.2]. El siguiente resultado cuantifica la diferencia.

Proposición 3.52 (Coste de la atención por ventanas [41, ecs. (1)–(2)])**.** *Sea un mapa de $h \times w$ parches con C canales y sea M un divisor de h y de w. Contando las multiplicaciones de los productos de matrices y omitiendo el cálculo de la función* softmax*, el coste de la autoatención multicabeza global (MSA) y el de la autoatención por ventanas de $M \times M$ parches (W-MSA) son*

$$\Omega(\text{MSA}) = 4hwC^2 + 2(hw)^2C,$$
$$\Omega(\textit{W-MSA}) = 4hwC^2 + 2M^2hwC.$$

El primero es cuadrático en el número de parches hw y el segundo es lineal en hw para M fijo.

Demostración. Sean $T = hw$ el número de tokens, $X \in \mathbb{R}^{C\times T}$ la matriz de entrada y H el número de cabezas, cada una con consultas, claves y valores de dimensión C/H.

Proyecciones. Para cada cabeza, calcular $\Omega_{v_h} X$, con $\Omega_{v_h} \in \mathbb{R}^{(C/H)\times C}$, requiere $(C/H) \cdot C \cdot T$ multiplicaciones; para las H cabezas, C^2T. Lo mismo ocurre con las consultas y las claves, y con la proyección final $\Omega_c \in \mathbb{R}^{C\times C}$ de la definición 3.46. En total, $4C^2T = 4hwC^2$ multiplicaciones. Estas operaciones actúan sobre cada token por separado, así que su coste es el mismo en MSA y en W-MSA.

Atención global. Para cada cabeza, $K_h^\top Q_h$ es el producto de una matriz $T \times (C/H)$ por otra $(C/H) \times T$, con $T^2\, C/H$ multiplicaciones, y $V_h\,\text{Softmax}(\cdot)$ es el producto de una matriz $(C/H) \times T$ por otra $T \times T$, con otras $T^2\, C/H$. Para las H cabezas, $2T^2C = 2(hw)^2C$. Sumando, se obtiene $\Omega(\text{MSA})$.

Atención por ventanas. Cada ventana contiene M^2 tokens y se procesa igual que en el caso global con $T = M^2$, con un coste de $2(M^2)^2C$. Como hay hw/M^2 ventanas, el coste total de la atención es $\frac{hw}{M^2} \cdot 2M^4C = 2M^2hwC$. Sumando las proyecciones, se obtiene $\Omega(\text{W-MSA})$. □

Liu et al. fijan $M = 7$ por defecto. En la primera etapa de Swin-S, con imágenes de 224×224, el mapa tiene $h = w = 56$; la parte de atención del coste se reduce en un factor $hw/M^2 = 3136/49 = 64$. Liu et al. indican que la atención global es inabordable para hw grande, mientras que la atención por ventanas es escalable [41, sec. 3.2]. Si M no divide a h o a w, el mapa se rellena por la parte inferior derecha [41, sec. 3.2].

3.5.5.3. Ventanas desplazadas

La autoatención por ventanas no relaciona parches de ventanas distintas, lo que limita la capacidad del modelo. Para introducir conexiones entre ventanas sin perder la eficiencia, los bloques consecutivos alternan dos particiones. La primera es la partición regular, que empieza en el píxel superior izquierdo; la segunda desplaza las ventanas $(\lfloor M/2 \rfloor, \lfloor M/2 \rfloor)$ parches respecto de la regular. Así, las nuevas ventanas cruzan los bordes de las de la capa anterior y las conectan [41, sec. 3.2]. Prince lo resume diciendo que, tras varias capas, la información puede propagarse por toda la imagen [54, fig. 12.18].

La partición desplazada da lugar a más ventanas, de $\lceil h/M \rceil \times \lceil w/M \rceil$ a $(\lceil h/M \rceil + 1) \times (\lceil w/M \rceil + 1)$, y algunas son más pequeñas que $M \times M$. Para no aumentar el coste, Liu et al. desplazan cíclicamente el mapa hacia la esquina superior izquierda. Tras el desplazamiento,

Tabla 3.1.: Etapas del Swin-S usado en este trabajo, con imágenes de entrada de 224×224: resolución del mapa de tokens, número de canales, número de bloques Swin y número de cabezas.

Etapa	Resolución	Canales	Bloques	Cabezas
1	56×56	96	2	3
2	28×28	192	2	6
3	14×14	384	18	12
4	7×7	768	2	24

una ventana puede estar formada por varias subventanas que no son adyacentes en el mapa original, así que se aplica una máscara que limita la autoatención al interior de cada subventana. De este modo, el número de ventanas es el mismo que con la partición regular [41, sec. 3.2, fig. 4].

3.5.5.4. Sesgo de posición relativa

Swin no suma embeddings de posición a la entrada, sino que usa una codificación posicional relativa (apartado 3.5.3.2): dentro de cada ventana y para cada cabeza, suma un *sesgo de posición relativa* $B \in \mathbb{R}^{M^2 \times M^2}$ a las compatibilidades antes de la función *softmax*,

$$\mathrm{Sa}(X) = V\ \mathrm{Softmax}\left(\frac{K^\top Q}{\sqrt{d}} + B\right),$$

donde d es la dimensión de las consultas y las claves, y el elemento de B correspondiente a dos parches de la ventana depende solo de su desplazamiento relativo [41, ec. (4)]. Como el desplazamiento en cada eje está en $[-M+1, M-1]$, basta aprender una matriz $\widehat{B} \in \mathbb{R}^{(2M-1)\times(2M-1)}$ de la que se toman los valores de B. Liu et al. observan mejoras significativas frente a no usar este sesgo o frente a usar embeddings de posición absolutos, y que añadir además embeddings absolutos a la entrada, como en ViT, empeora ligeramente el rendimiento [41, sec. 3.2].

3.5.5.5. Swin-S

Liu et al. definen cuatro variantes, Swin-T, Swin-S, Swin-B y Swin-L. En todas, $M = 7$, la dimensión de las consultas de cada cabeza es $d = 32$ y la capa oculta del MLP tiene 4 veces la dimensión de la entrada. Swin-S tiene $C = 96$ y $\{2, 2, 18, 2\}$ bloques en sus cuatro etapas, y su complejidad es similar a la de ResNet-101 [41, sec. 3.3]. La cuadro 3.1 resume el Swin-S usado en este trabajo. Su salida, tras el promedio, tiene 768 características.

[REVISAR: el número de cabezas no aparece en el resumen de capas: se ha obtenido como canales/d con $d = 32$ (Liu et al., sec. 3.3)]

3.5.6. ConvNeXt

En 2020 las redes neuronales convulcionales parecían estancadas ante la superioridad de los transformers. ¿Y si realmente, no es que fueran peores, y sólo es que estaban desactualizadas? Esta pregunta fue respondida en 2022, cuando unos investigadores de Facebook

presentaron una familia de redes convolucionales, llamada ConvNeXt, que superó a los vision transformers en clasificación de imágenes [42, 72]. Para construirla, partieron de una ResNet y la adaptaron para que se pareciera más a un vision transformer. Para esto aplicaron diversas implementaciones como pasar de entrenar con 90 épocas a 300, utilizar como optimizador AdamW en vez SGD, nuevas técnicas de data augmentation, stochasthic depth y label smoothing que evitó que el modelo fuese demasiado confiado. También empleó en cada una de las cuatro etapas principales de la red neuronal una distribución de bloques residuales en donde se dedica mucha más capacidad de procesamiento a extraer características complejas en una resolución intermedia. Estó último permitió que el modelo fuera capaz de adquirir características más complejas. Entre otras implementaciones como utilizar como función de activación GELU en vez de RELU la estructura final del bloque ConvNext es la siguiente:

Input → *7x7 DWConv* → *Capa de normalización* → *1x1 Conv* → *Función de activación Gelu* → *1x1 Conv* [42] El el modelo resultante se entrenó y evaluó en ImageNet-1k e ImageNet-22k y tiene varias variantes [72]. ConvNeXt es, por tanto, una red puramente convolucional que incorpora decisiones de diseño de los transformers [72].

3.5.6.1. Convoluciones por canal y puntuales

El bloque ConvNeXt combina dos tipos de convolución [72]. En la *convolución por canal* (*depthwise convolution*), cada canal de entrada se convoluciona con su propio filtro, y en la *convolución puntual* (*pointwise convolution*) cada canal de salida combina todos los canales de entrada. Con la notación de la apartado 3.5.1.2, y para un núcleo espacial de $k \times k$:

Definición 3.53 (Convolución por canal y convolución puntual)**.** Sea V una entrada con C canales. La *convolución por canal* con núcleo $\mathsf{K} \in \mathbb{R}^{C\times k\times k}$ da una salida con C canales,

$$\mathsf{Z}_{i,j,l} = \sum_{m,n} \mathsf{V}_{i,\, j+m-1,\, l+n-1}\, \mathsf{K}_{i,m,n},$$

y la *convolución puntual* con núcleo $\mathsf{K} \in \mathbb{R}^{C'\times C}$ da una salida con C' canales,

$$\mathsf{Z}_{i,j,l} = \sum_{c=1}^{C} \mathsf{V}_{c,j,l}\, \mathsf{K}_{i,c}.$$

La convolución puntual es una convolución de 1×1: en cada posición espacial aplica la misma transformación lineal $\mathbb{R}^C \to \mathbb{R}^{C'}$ al vector de canales. Es, por tanto, equivalente a una capa totalmente conectada aplicada a cada posición por separado, como el MLP de una capa transformer a cada token.

Proposición 3.54. *Sin contar los sesgos, una convolución de $k \times k$ de C a C' canales tiene $C\,C'\,k^2$ parámetros, mientras que una convolución por canal de $k \times k$ seguida de una convolución puntual de C a C' canales tiene $C\,k^2 + C\,C'$.*

Demostración. Basta contar los elementos de los núcleos: el de la convolución de la apartado 3.5.1.2 tiene un peso $\mathsf{K}_{i,c,m,n}$ por cada canal de salida i, canal de entrada c y posición (m, n) del núcleo, es decir, $C'\,C\,k^2$; los de la definición 3.53 tienen $C\,k^2$ y $C'\,C$ elementos. □

Por ejemplo, en la primera etapa del ConvNeXt-S usado en este trabajo, con $C = C' = 96$ y $k = 7$, una convolución completa tendría $96^2 \cdot 49 = 451\,584$ pesos, mientras que la convolución por canal tiene $96 \cdot 49 = 4704$.

3.5.6.2. El bloque ConvNeXt

Según Todi et al., un bloque ConvNeXt consta de una convolución por canal, una convolución puntual, una conexión residual, una LayerNorm y una activación GELU [72]. En la implementación usada en este trabajo, el bloque con C canales calcula

$$x \leftarrow x + \mathrm{PW}_2\Big(\mathrm{GELU}\big(\mathrm{PW}_1\big(\mathrm{LN}(\mathrm{DW}_{7\times7}(x))\big)\big)\Big),$$

donde $\mathrm{DW}_{7\times7}$ es una convolución por canal de 7×7, LN normaliza los C canales en cada posición espacial, PW_1 es una convolución puntual de C a $4C$ canales y PW_2 otra de $4C$ a C. Es el bloque de la figura 4 de Liu et al. [42, fig. 4]. Liu et al. aplican además el escalado por capa (*layer scale*) de Touvron et al., con valor inicial 10^{-6} [42, sec. 3]. El modelo usado en este trabajo lo incluye: cada uno de sus 36 bloques tiene un parámetro `gamma`, que no aparece en el resumen de capas porque no es una capa. **[PENDIENTE: definir el escalado por capa y añadirlo a la ecuación del bloque: requiere Touvron et al. (2021), *Going deeper with image transformers*, ICCV (ref. [74] de Liu et al.), que no está en tfg-referencias/papers]**

Liu et al. parten de una ResNet-50 y la modifican paso a paso siguiendo el diseño de Swin, comprobando en ImageNet-1K el efecto de cada cambio [42, sec. 2]. La comparación con las arquitecturas anteriores muestra qué se ha tomado de cada una:

- *Diseño por etapas.* De ResNet-50 (apartado 3.5.2.1) conserva la estructura convolucional en cuatro etapas con conexiones residuales, que reducen la resolución y aumentan los canales. El número de bloques por etapa pasa de $(3, 4, 6, 3)$ en ResNet-50 a $(3, 3, 9, 3)$, siguiendo la proporción $1 : 1 : 3 : 1$ de Swin-T [42, sec. 2.2]. El ConvNeXt-S usado en este trabajo tiene $(3, 3, 27, 3)$ bloques [42, sec. 3].

- *Entrada por parches.* ResNet empieza con una convolución de 7×7 con paso 2 seguida de *max pooling*, que reduce la resolución a la cuarta parte. ConvNeXt la sustituye por una convolución de 4×4 con paso 4, que divide la imagen en parches de 4×4 que no se solapan, como la división en parches de ViT y de Swin [42, sec. 2.2].

- *Convolución por canal.* Liu et al. señalan que la convolución por canal se parece a la suma ponderada de la autoatención, que actúa canal a canal y solo mezcla información en la dimensión espacial. Combinada con las convoluciones de 1×1, separa la mezcla espacial de la mezcla entre canales, como en los vision transformers. Para compensar la pérdida de capacidad, la anchura de la primera etapa pasa de 64 a 96 canales, como en Swin-T [42, sec. 2.3].

- *Cuello de botella invertido.* En cada bloque transformer, la capa oculta del MLP tiene cuatro veces la dimensión de la entrada. Del mismo modo, PW_1 y PW_2 expanden los canales a $4C$ y los reducen de nuevo a C, al contrario que el cuello de botella de ResNet, que los reduce en la capa intermedia [42, sec. 2.4]. Además, la convolución por canal se coloca al principio del bloque, igual que en un transformer la autoatención va antes del MLP [42, sec. 2.5].

- *Núcleos grandes.* Las ventanas de Swin son de al menos 7×7, mucho mayores que los núcleos de 3×3 de ResNet. Liu et al. prueban núcleos de 3, 5, 7, 9 y 11: la exactitud mejora hasta 7×7 y a partir de ahí se satura [42, sec. 2.5]. Así, la convolución por canal mezcla la información de una vecindad del mismo tamaño que las ventanas de Swin ($M = 7$), pero con pesos que no dependen de la entrada.

- *Microdiseño.* La ReLU se sustituye por la GELU, se deja una sola activación por bloque, entre las dos convoluciones de 1×1, como en el MLP de un transformer, y una sola normalización, que pasa de BatchNorm a LayerNorm. El bloque con cuello de botella de ResNet tiene, en cambio, tres de cada tipo [42, sec. 2.6, fig. 4].
- *Capas de reducción separadas.* ResNet reduce la resolución en el primer bloque de cada etapa con una convolución de 3×3 y paso 2. Como Swin, ConvNeXt usa capas separadas: convoluciones de 2×2 con paso 2, que reducen la resolución a la mitad y duplican los canales, igual que la fusión de parches. Con ellas el entrenamiento divergía, y se estabilizó añadiendo LayerNorm donde cambia la resolución: antes de cada capa de reducción, después de la primera capa y después del promedio global final [42, sec. 2.6].

Con todos estos cambios, ConvNeXt supera a Swin-T en ImageNet-1K con un coste similar y sin módulos especializados como la atención por ventanas desplazadas o el sesgo de posición relativa. Liu et al. señalan que ninguna de estas decisiones es nueva en la literatura de redes convolucionales: se habían estudiado por separado, pero no conjuntamente [42, sec. 2].

El ConvNeXt-S usado en este trabajo tiene cuatro etapas de 3, 3, 27 y 3 bloques con 96, 192, 384 y 768 canales. Con las imágenes de 256×256 con las que se entrenó, los mapas de características de las etapas tienen resoluciones de 64×64, 32×32, 16×16 y 8×8, de modo que su salida es un mapa de $768 \times 8 \times 8$. Como en los demás modelos entrenados con fastai, la cabeza de clasificación es la de fastai (apartado 8.5.2). Las capas `conv_dw`, `fc1` y `fc2` del bloque son, respectivamente, $\mathrm{DW}_{7\times7}$, PW_1 y PW_2; son los nombres que se usan en la configuración de LRP del capítulo 7.

4. Formalización de la detección OOD y métricas

Para comenzar con una formalización matemática del problema OOD se debe esclarecer que se considerará como ID (dentro de la distribución, In-Distribution).

Definición 4.1 (ID)**.** Se determinará ID como nuestra distribución de referencia $\mathcal{D}_{\text{ID}}$, en donde $(x, y) \sim \mathcal{D}_{\text{ID}}$, considerando x como la entrada e y como su etiqueta correspondiente dentro de la distribución.Se denotará como p la función de densidad de probabilidad. Entonces, dada una distribución $\mathcal{D}_{\text{ID}}$ como referencia se considerará una distribución $\mathcal{D}_{\text{OOD}}$ como fuera de la distribución si $\forall \delta \in (0, 1) \exists$ una región $\mathcal{D}$ tal que:

- $\int\int_{\mathcal{D}} p_{\mathcal{D}_{\text{OOD}}}(x, y) dx dy > \delta$
- $\forall \epsilon > 0$, $\int\int_{\mathcal{D}} p_{\mathcal{D}_{\text{ID}}}(x, y)\, dx\, dy < \epsilon$ [81].

A continuación bajo la Definición 1 procedemos a definir el objetivo forma de la detección OOD el cual originalmente en (Scheirer et al., 2012) se definió solo para la clasificación pero en el OpenOOD v1.5: Enhanced Benchmark for Out-of-Distribution Detection se generalizó:

Definición 4.2. Dada una distribución de referencia $\mathcal{D}_{\text{ID}}$ y una distribución $\mathcal{D}_{\text{OOD}}$ que está fuera de distribución con respecto a ella. Sea una función de detección f definida como:

$$f(x) = \begin{cases} 0 & \text{si } x \in \mathcal{D}_{\text{OOD}} \\ 1 & \text{si } x \in \mathcal{D}_{\text{ID}} \end{cases}$$

Así pues el objetivo de la detección OOD se definde mediante la búsqueda de una función de detección f que minimice el riegso de espacio abierto:

$$\arg\min_{f} R_{\mathcal{O}}(f)$$

donde:

$$R_{\mathcal{O}}(f) = \frac{\int\int f(x) p_{\mathcal{D}_{OOD}}(x, y)\, dx\, dy}{\int\int f(x) p_{\mathcal{D}_{OOD}}(x, y)\, dx\, dy + \int\int f(x) p_{\mathcal{D}_{ID}}(x, y)\, dx\, dy}$$

[81]

Así pues el riesgo de espacio abierto es una medida cuantitativa del error en el que incunbe un modelo al clasificar una muestra fuera de la distribución $\mathcal{D}_{\text{OOD}}$ como si perteneciera a la distribución interna $\mathcal{D}_{\text{ID}]}$. De esta forma el objetivo de la detección *OOD* va a ser minimizar dicha función.

La definición propuesta a nivel matemático presenta algunos matices en práctica. Primero, la detecciónn OOD se suele asentar en una tarea base cuyo objetivo debe ser considerado también. Segundo, como tarea de clasificación binaria como es nuestro objetivo, existen hoy en día métricas asentadas que se usan preferiblemente antes que el riesgo de espacio abierto como AUROC (estas métricas se discutirán más adelante).**[REVISAR: Iván]**

A continuación se procede a describir nuestro problema especificamente en el escenario de clasificación de imágenes:

Definición 4.3 (Detección OOD estándar)**.** def:deteccionOODestandar

Dado un problema de clasificación de imágenes existe un conjunto de categorías semánticas que se considera dentro de la distribución $\mathcal{Y}_{ID}$, y por tratarse un problema de mundo abierto existe un conjunto infinito de categorías semánticas que no pertenecen a la distribución (OOD) $\mathcal{Y}_{OOD} = \{y | y \notin \mathcal{Y}_{ID}\}$. En el caso de este estudio las 14 clases de prostatectomía radical conformarían nuestro conjunto ID y cualquier categoría semántica ajena como árbol, perro, reloj..., será considerada OOD. En el momento de la inferencia para cualquier imagen x con una etiqueta de referencia y, el clasificador ideal tendría la capacidad de comportarse la siguiente forma: 1) identifica si $y \in \mathcal{Y}_{ID}$ o $y \in \mathcal{Y}_{OOD}$, y 2) si $y \in \mathcal{Y}_{ID}$ lo clasifica en una de sus categorías ID correctamente.

Para que un clasificador de imágenes f se capaz de detectar muestras OOD, un detector OOD denominado G es necesario sobre f, el cual es forumalado de la siguiente forma

$$G(x; f) = \begin{cases} 1 \text{ (OOD)}, & S(x; f) \geq \lambda, \\ 0 \text{ (ID)}, & S(x; f) < \lambda. \end{cases}$$

siendo $S(\cdot)$ la función de puntuación que califica el grado de *"OOD-ness"* que tiene cada muestra, y λ es el umbral asociado a cada caso.

4.1. Distribución de los datos y cambios de distribución

Sea el espacio de entrada X(observaciones sensoriales) y sea de forma independiente el espacio de etiquetas Y (categorías semánticas). La distribución de los datos es representada por la distribución conjunta $P(X, Y) \in X \times Y$. Un cambio en la distribución puede ocurrir tanto en la distribución marginal $P(X)$ o en ambas $P(X)$ y $P(Y)$.

Definición 4.4 (Desplazamiento de covariables)**.** Ocurre cuando hay una alteración en la distribución marginal $P(X)$ afectando al espacio de entrada, mientras que el espacio de etiquetas Y se mantiene constante.

Definición 4.5 (Cambio semántico)**.** Envuelve cambios en ambos, en $P(Y)$ e indirectamente en $P(X)$. Un cambio en espacio de etiquetas $P(Y)$ implica la introducción de nuevas categorias o la alteración de las ya existentes. Esto suele cambiar el espacio de entrada $P(X)$ ya que ahora la naturaleza de los datos observados es diferente.

Definición 4.6 (Detección OOD del espectro completo)**.** La detección estándar OOD estudia el desplazamiento de la distribución semántica (semantic distribution shift), entre $\mathcal{Y}_{ID}$ y $\mathcal{Y}_{OOD}$, ignorando otro tipo de desplazamiento de distribución igualmente importante en el munto real, el desplazamiento de covariables (covariate shift). Bajo este contexto nace la detección OOD del especto completo, en donde se estudia por primera vez ambos tipos de alteraciones. Cabe recalcar que en el contexto de la detección OOD, aquellas imágenes con covariate shift son consideras como in-distribution (csID) ya que sus etiquetas siguen perteneciendo a $\mathcal{Y}_{OOD}$.

Clasificación de los conjuntos de muestras Llamamos conjunto *en distribución* (ID), $\mathcal{D}_{\text{ID}}$, al conjunto de datos que define la tarea de clasificación de imágenes, con espacio de etiquetas $\mathcal{Y}_{\text{ID}}$. Como es habitual en la literatura, las muestras *fuera de distribución* (OOD), $\mathcal{D}_{\text{OOD}}$, se toman de conjuntos de datos públicos cuyas categorías no pertenecen a $\mathcal{Y}_{\text{ID}}$.

El clasificador se entrena únicamente con imágenes ID, $\mathcal{D}_{\text{ID}}^{\text{train}}$. La evaluación se hace con dos conjuntos de prueba: imágenes ID, $\mathcal{D}_{\text{ID}}^{\text{test}}$, e imágenes OOD, $\mathcal{D}_{\text{OOD}}^{\text{test}}$. Para que la evaluación sea más completa, cada conjunto ID se enfrenta a varios conjuntos OOD distintos, y no a uno solo.

Además, los conjuntos OOD se clasifican en dos grupos según su dificultad: *near-OOD* (OOD cercano) y *far-OOD* (OOD lejano). El criterio puede ser semántico (cuánto se parecen las imágenes a las de la tarea ID) o empírico (lo difícil que resulta detectarlas en la práctica). Esta división permite analizar con más detalle el comportamiento de los detectores ante distintos tipos de muestras OOD.

Como se mencionó en 4.6 la detección del espectro completo considera también muestras con covariate shift (csID). En la práctica esto se realiza mediante incorporar muestras csID $\mathcal{D}_{\text{csID}}^{\text{test}}$, juntas con $\mathcal{D}_{\text{ID}}^{\text{test}}$, para que sirva como datos ID de test. **[PENDIENTE: aprendibilidad de la detección OOD (Fang et al. [17])]**

4.2. Regla de decisión por umbral

Definición 4.7 (Detector OOD por umbral)**.** **[PENDIENTE: definición]**

4.3. Métricas de evaluación

Debido a que la detección se trata de un problema de clasificación binaria según definición 4.1 se utilizarán las siguintes métricas: área bajo la curva característica de funcionamiento del receptor (AUROC), area bajo la curva precisión-recuperación (AUPR) y tasa falsos positivos al 95 % de tasa de verdaderos positivos (FPR@95). El inconveniente de estas métricas está en que no miden si la clasificación de las 14 clases es correcta. Para ello se ha considerado añadir en este trabajo la mejor CCR@FPRx. Debido al potencial de esta métrica como evolución de la métrica FPR@95 y su capacidad para medir tanto covariate shift como semantic shift distribution se considerará como un indicador de la detección full-spectrum. **[REVISAR: Iván]**[No sé si la afirmaciónd de CCR@FPRx de indicador full spectrum es apropiada]. Además siguiendo la convención en aprendizaje automático [55] y la obra fundamental de detección OOD [24] se tratarán las muestras .ªnómalas.ºOD como *positivas* y las muestras "normalesÏD como negativas [81].

Evaluación. Además de las puntuaciones F, AUROC y AUPR, otra métrica comúnmente utilizada es FPR@TPRx, que mide la FPR cuando la TPR es x (por ejemplo, 0,95). Algunos trabajos también utilizan una métrica alternativa, TNR@TPRx, que es equivalente a $1 -$ FPR@TPRx. La detección de OOD también afecta al rendimiento de la clasificación de ID. **[REVISAR: traducción casi literal; parafrasear y citar]**

4.3.1. Curva ROC y AUROC

AUROC: representa la probabilidad de que el modelo asigne una puntuación o probabilidad más alta a un ejemplo positivo elegido al azar que a uno negativo. Puede ser interpretado como la probabilidad de que el detector separe correctamente muestras ID y OOD [81]. **Rango de valores:** va de 0 a 1; 0,5 representa que el modelo no tiene capacidad discriminatoria (equivale a adivinar al azar), 1 que el modelo tiene una clasificación perfecta, y los

valores inferiores a 0,5 indican que el modelo invierte las clases (si se invierte la predicción, el valor pasa a ser 1 − valor). En este caso también la clase positiva es la OOD.
[PENDIENTE: citar a Fawcett [18] para la curva ROC]

Definición 4.8 (Curva ROC)**.** **[PENDIENTE: definición]**

Teorema 4.9 (Interpretación probabilística del AUROC)**.** ***[PENDIENTE: enunciado]***

Demostración. **[PENDIENTE: demostración]** □

Corolario 4.10 (AUROC empírico y estadístico U)**.** ***[PENDIENTE: enunciado]***

Demostración. **[PENDIENTE: demostración]** □

4.3.2. FPR@95

FPR@95: consiste en ajustar el umbral que delimita un caso como ID de forma que dicho umbral detecte el 95 % de las OOD. **[PENDIENTE: completar qué se mide con ese umbral (la proporción de ID rechazadas como OOD; más bajo es mejor)]**

Definición 4.11 (FPR@TPRx)**.** **[PENDIENTE: definición]**

4.3.3. AUPR-In y AUPR-Out

AUPR: esta métrica va acompañada de AUROC, ya que AUROC no es sensible a desbalance entre clases mientras que AUPR sí. Principalmente se basa en dos conceptos: precisión y exhaustividad (*recall*). De esta métrica obtenemos dos versiones: AUPR-In (mide lo bien que se recuperan imágenes de próstata sin que se cuelen OOD) y AUPR-Out (mide lo bien que se encuentran las OOD sin falsas alarmas sobre las de próstata). En el primer caso el caso positivo es ID y por eso mismo nos interesa un valor alto, y en el segundo el caso positivo es el OOD, por lo que también interesa un valor alto. **[REVISAR: las notas decían que en AUPR-Out interesa un valor «más bajo»; es incorrecto: en ambas versiones interesa un valor alto]**

Definición 4.12 (Precisión, exhaustividad y AUPR)**.** **[PENDIENTE: definición]**

4.3.4. CCR@FPRx

CCR@FPRx: se fija el umbral de modo que solo se acepte un x % de las imágenes OOD, y se mide la proporción de imágenes del test ID que son aceptadas y además correctamente clasificadas. Se calcula solo sobre el test ID; su máximo es la exactitud del clasificador.

Definición 4.13 (CCR@FPRx)**.** **[PENDIENTE: definición]**

5. Métodos de detección post hoc

[PENDIENTE: introducción del capítulo y notación común]

Esto equivale a usar la función mencionada en 4.2 en el clasificador base para generar el .ºOD-score". Estos métodos solo toman efecto en la fase de inferencia y por defecto asume que el clasificado es entrenado con el estándar de perdida de entropía cruzada.

5.1. Métodos basados en logits

Grupo de los logits (números producidos por la red justo al final, antes de convertirlos en probabilidades):

- **MSP** (*Maximum Softmax Probability*) [24]: la probabilidad de la clase ganadora tras el softmax.
- **MLS** (*MaxLogit*) [22]: lo mismo que MSP, pero con el logit máximo sin pasar por softmax. La ventaja que ofrece este método es que el softmax normaliza y pierde información sobre la magnitud absoluta; el logit bruto la conserva.
- **EBO** (*Energy-Based OOD*) [40]: el logaritmo de la suma de las exponenciales de todos los logits. Funciona como una versión «suave» y diferenciable de la función $\max(x)$.

[REVISAR: añadidas las citas a los artículos originales de MSP, MaxLogit y Energy] [REVISAR: en EBO, «de las exponenciales de los argumentos de todos los logits» se ha simplificado a «de las exponenciales de todos los logits»]

Definición 5.1 (Puntuaciones MSP, MaxLogit y Energy)**.** **[PENDIENTE: definición formal]**

Proposición 5.2 (LogSumExp como cota suave del máximo)**.** ***[PENDIENTE: enunciado]***

Demostración. **[PENDIENTE: demostración]** □

Observación 5.3 (Efecto del *label smoothing* sobre los logits). **[PENDIENTE: desarrollo]**

5.2. Métodos basados en la modificación de activaciones

Estos métodos modifican las activaciones o los pesos de la última capa del modelo antes de calcular la puntuación, con el objetivo de atenuar las señales anómalas que producen las imágenes OOD. Los tres calculan finalmente una puntuación de tipo Energy sobre los logits resultantes y fueron diseñados y evaluados originalmente sobre redes convolucionales con activaciones ReLU.

- **ReAct** (*Rectified Activations*) (Sun et al. [67]): parte de la observación de que las imágenes OOD tienden a producir activaciones anormalmente altas en algunas unidades de la penúltima capa, lo que sus autores atribuyen al uso de estadísticas de BatchNorm

estimadas con datos ID y aplicadas sin cambios a datos OOD. Para atenuarlo, recorta cada activación del vector de características por encima de un umbral c, $\tilde{h} = \min(h, c)$, y calcula la puntuación Energy sobre los logits obtenidos a partir de las características recortadas. El umbral c se fija como el percentil 90 de las activaciones en el conjunto de validación ID.

- **ASH** (*Activation Shaping*) (Djurisic et al. [14]): actúa sobre el vector de características de cada imagen de forma individual. Conserva solo el 10 % de las activaciones de mayor valor (percentil 90), pone a cero el resto y ajusta las conservadas para compensar la información eliminada. En la variante empleada (ASH-B), todas las activaciones conservadas toman el mismo valor, igual a la suma total de las activaciones de la imagen dividida entre el número de activaciones conservadas. Después se calcula la puntuación Energy. Se aplica sobre las 768 características agregadas tras el *pooling*, como en la implementación de OpenOOD.
- **DICE** (*Directed Sparsification*) (Sun y Li [68]): actúa sobre los pesos de la última capa lineal en lugar de sobre las activaciones. Para cada conexión entre una característica y una clase, calcula su contribución media en el conjunto de entrenamiento ID (el peso multiplicado por la activación media de esa característica), conserva solo las conexiones de mayor contribución y pone a cero el resto (esparsidad del 90 %). Al eliminar las conexiones poco relevantes para los datos ID, reduce la varianza de la salida en las imágenes OOD y mejora su separación. La puntuación es la Energy de los logits calculados con la capa podada.

Definición 5.4 (ReAct, ASH-B y DICE)**. [PENDIENTE: definición formal]**

Observación 5.5 (Supuestos sobre el signo de las activaciones). **[PENDIENTE: desarrollo]**

5.3. Métodos basados en características y distancias

Grupo de métodos que comparan con la información de las características (*features*) de entrenamiento:

- **KNN** [69]: normaliza el vector de características de cada imagen y mide su distancia al k-ésimo vecino más cercano entre las características de entrenamiento. Si esa distancia es grande, la imagen está lejos de todo lo visto en entrenamiento y se considera OOD. No supone ninguna forma concreta (por ejemplo, gaussiana) para la distribución de las características.
- **MDS** (Mahalanobis) [36]: calcula la media de las características de cada clase y una covarianza compartida. La puntuación es la distancia de Mahalanobis a la media de la clase más cercana.
- **RMDS** (*Relative Mahalanobis*) [58]: igual que MDS, pero resta la distancia a una gaussiana global de todo el conjunto de datos. Así corrige el hecho de que algunas direcciones del espacio de características son «fondo» común a todas las imágenes y no información de clase. Suele funcionar mejor en near-OOD.
- **ViM** (*Virtual-logit Matching*) [75]: busca las direcciones principales del espacio de características de entrenamiento (análisis de componentes principales). Lo que queda fuera

de ese subespacio principal (el residuo) se considera señal de OOD. Combina la norma de ese residuo con la energía de los logits.

- **SHE** (*Simplified Hopfield Energy*) [82]: en la preparación (`setup()`) pasa el conjunto de entrenamiento por la red y, para cada clase, calcula la media de las características solo de las imágenes que el modelo clasifica correctamente (etiqueta real igual a la predicción). Eso le da 14 «patrones» de referencia. En test, mira qué clase predice el modelo para la imagen y compara su característica con el patrón de esa clase (por producto escalar, distancia euclídea o coseno, según la configuración).

[REVISAR: añadidas las citas a los artículos originales de KNN, MDS, RMDS, ViM y SHE]

Definición 5.6 (Puntuación KNN)**.** Sea $h(x) \in \mathbb{R}^D$ el vector de características de una imagen x y sea $z(x) = h(x)/\|h(x)\|$ su normalización. Sea $\mathcal{Z} = \{z(x_1), \ldots, z(x_N)\}$ el conjunto de características normalizadas del conjunto de entrenamiento. Para un entero $k \geq 1$, se denota $z_{(k)}(x)$ el k-ésimo elemento de $\mathcal{Z}$ más cercano a $z(x)$ en distancia euclídea. La puntuación KNN de x es

$$s_{\mathrm{KNN}}(x) = -\|z(x) - z_{(k)}(x)\|_2.$$

Valores altos indican que x tiene al menos k imágenes de entrenamiento cercanas («más ID»). La imagen se considera OOD si $s_{\mathrm{KNN}}(x) < \lambda$, donde el umbral λ se elige para que se acepte una proporción prefijada de las imágenes ID (por ejemplo, el 95 %).

Para vectores con norma uno se cumple $\|z - z'\|^2 = 2 - 2\langle z, z' \rangle$ de forma que la distancia euclídea entre caracteristicas normalizadas equivale a la similitud coseno.

Definición 5.7 (Puntuación de Mahalanobis)**.** Medida de distancia basada en cuanta desviación estándar una muestra de test x se encuentra de la media de una distribución multivariante gaussiana. Es definida como:

$$D_M(x) = \sqrt{(x - \hat{\mu})^T \hat{\Sigma}^{-1} (x - \hat{\mu})}$$

Se denota por $\hat{\mu}$ el vector de medias, $\hat{\Sigma}^{-1}$ la inversa de la matriz de covarianza de la distribución. Esta medida es invariante a cambios de escala y considera además las correlaciones entre las dimensiones de los datos utilizados para estimar la distribución.[36]

Proposición 5.8 (Relación con el análisis discriminante lineal)**.** ***[PENDIENTE: enunciado]***

Demostración. **[PENDIENTE: demostración]** □

Definición 5.9 (Mahalanobis relativo)**.** **[PENDIENTE: definición]**

Definición 5.10 (ViM)**.** **[PENDIENTE: definición]**

Proposición 5.11 (Residuo de PCA como proyección ortogonal)**.** ***[PENDIENTE: enunciado]***

Definición 5.12 (SHE)**.** Sea $\mathcal{D}_{\mathrm{train}} = \{(x_n, y_n)\}_{n=1}^N$ el conjunto de entrenamiento y $\hat{y}(x) = \arg\max_k f_k(x)$ la clase predicha por el modelo. Para cada clase c, se considera el conjunto de *patrones almacenados* formado por las características de las imágenes de entrenamiento de esa clase que el modelo clasifica correctamente,

$$S_c = \{\, h(x_n) : y_n = c,\ \hat{y}(x_n) = c \,\}, \qquad N_c = |S_c|,$$

y su *patrón medio*

$$\bar{s}_c = \frac{1}{N_c} \sum_{h \in S_c} h.$$

La puntuación SHE de una imagen x es el producto escalar entre sus características y el patrón medio de la clase predicha:

$$s_{\mathrm{SHE}}(x) = h(x)^\top \bar{s}_{\hat{y}(x)}.$$

Valores altos indican mayor parecido con los patrones de entrenamiento de la clase predicha («más ID»).

El método sigue un esquema de *almacenar y comparar*: durante la preparación se guardan representaciones de los datos ID de cada clase y, en test, se mide la discrepancia entre la representación de la imagen y los patrones almacenados de la clase que el modelo le asigna. La idea de fondo, ilustrada por los autores con visualizaciones t-SNE, es que el entrenamiento agrupa las representaciones de las imágenes ID de una misma clase en torno a un patrón común, mientras que las de las imágenes OOD no se ajustan a ninguno de esos patrones [82]. A diferencia de la mayoría de los métodos basados en logits, la puntuación no depende solo de la imagen de test, sino también de la información de todas las imágenes de entrenamiento de la clase predicha. Además, no tiene hiperparámetros y solo requiere almacenar C vectores.

Observación 5.13 (Origen en la energía de las redes de Hopfield modernas). Las redes de Hopfield modernas [56] almacenan un conjunto de patrones $S = [s_1, \ldots, s_N] \in \mathbb{R}^{D \times N}$ y recuperan, a partir de un patrón de entrada $\xi \in \mathbb{R}^D$, el patrón almacenado más parecido minimizando la energía

$$E(\xi) = -\operatorname{lse}\big(\beta, \xi^\top S\big) + \tfrac{1}{2}\,\xi^\top \xi + c, \qquad \operatorname{lse}(\beta, e) = \frac{1}{\beta} \log \sum_{j=1}^{N} \exp(\beta e_j),$$

donde $\beta > 0$ y c son constantes y $e_j = \xi^\top s_j$. Cuanto más se parece ξ a los patrones almacenados, menor es la energía. Zhang et al. [82] proponen usar el primer término como puntuación de similitud (método HE): con $\xi = h(x)$ y los patrones S_i de la clase predicha $i = \hat{y}(x)$,

$$\mathrm{HE}(x) = \operatorname{lse}\big(\beta, h(x)^\top S_i\big).$$

Prescinden del término $\frac{1}{2}\xi^\top \xi$, que en la red de Hopfield solo evita que el patrón crezca durante las actualizaciones, porque la magnitud de las características también aporta información para distinguir ID de OOD, y de la constante c, que no altera el orden de las puntuaciones.

SHE se obtiene de HE para β pequeño. Con las aproximaciones de Taylor $e^t \approx 1 + t$ y $\log(1 + t) \approx t$,

$$\operatorname{lse}(\beta, e_i) \approx \frac{1}{\beta} \log \sum_{j=1}^{N_i} (1 + \beta e_{ij}) = \frac{1}{\beta} \log N_i + \frac{1}{\beta} \log\big(1 + \beta\, h(x)^\top \bar{s}_i\big) \approx \frac{1}{\beta} \log N_i + h(x)^\top \bar{s}_i.$$

El primer sumando es igual para todas las imágenes con la misma clase predicha, y los autores lo descartan para quedarse con s_{SHE}. Así, cada conjunto de patrones S_i se reduce a su media $\bar{s}_i$ y desaparece el hiperparámetro β. En sentido contrario, por la proposición 5.2

aplicada a βe_i, cuando $\beta \to \infty$ la puntuación HE tiende al máximo producto escalar con un patrón almacenado. HE se sitúa por tanto entre dos extremos: la comparación con el patrón más parecido (β grande) y la comparación con el patrón medio (β pequeño, SHE).

Observación 5.14 (Elección de la capa y de la medida de similitud). Los autores justifican el uso de la penúltima capa en lugar de los logits como patrones con un argumento que llaman *alineación de picos*: si se usaran los logits, el patrón medio de la clase predicha i tendría su máximo precisamente en la componente i, la misma en la que lo tiene el logit de cualquier imagen clasificada en esa clase, sea ID u OOD. El producto escalar sería alto también para las imágenes OOD. Las características de la penúltima capa no concentran su valor en una sola componente, y la puntuación separa mejor ambos tipos de imágenes. Lo respaldan con un análisis bajo hipótesis de normalidad e independencia (apéndice B del artículo) y, empíricamente, con una reducción del FPR@95 medio sobre nueve conjuntos OOD, por ejemplo de 31,70 % a 11,74 % con ResNet-18 y CIFAR-10 como datos ID [82]. En el mismo trabajo, el producto escalar supera a la distancia euclídea y a la similitud coseno como medida de similitud, lo que sugiere que la norma de las características, que el coseno descarta, contiene información útil para la detección.

5.4. STOOD-X

Se trata de una metodología post hoc de detección OOD en dos etapas [62]: una primera de detección, basada en un test estadístico no paramétrico sobre distancias en el espacio de características, y una segunda de explicación, que muestra al usuario los vecinos más cercanos y las características más relevantes compartidas con ellos.

Sea x una imagen cuya clase predicha por el modelo es c, y sea X_{set} el conjunto de características de entrenamiento de esa clase. Se denota $X_k = \{x_1, \dots, x_K\}$ el conjunto de los K vecinos más cercanos de x en X_{set} según una distancia d y, para cada vecino x_i, X_k^i el conjunto de sus K vecinos más cercanos en $X_{\text{set}} \setminus \{x_i\}$. La hipótesis del método es que, si x pertenece a la distribución de entrenamiento, las distancias $D(x, X_k)$ y $D(x_i, X_k^i)$ siguen la misma distribución; si x es OOD, las primeras serán mayores. Para contrastarlo se aplica el test unilateral de Wilcoxon-Mann-Whitney (apartado 6.2) entre ambos conjuntos de distancias, con un total de $M = K + K^2$ distancias, y el p-valor resultante se utiliza como puntuación: valores altos indican pertenencia a la distribución.

Definición 5.15 (Puntuación de STOOD-X)**.** Sea x una imagen de test con clase predicha $c = \hat{y}(x)$ y sea $X_{\text{set}} = \{h(x_n) : y_n = c\}$ el conjunto de características de entrenamiento de la clase c. Se emplea la distancia coseno

$$d(u, v) = 1 - \frac{u^\top v}{\|u\| \, \|v\|}, \qquad u, v \in \mathbb{R}^D.$$

Con la notación anterior (X_k los K vecinos más cercanos de $h(x)$ en X_{set} y X_k^i los K vecinos más cercanos de x_i en $X_{\text{set}} \setminus \{x_i\}$), se definen dos muestras de distancias:

$$A(x) = \{\, d(h(x), x_i) : x_i \in X_k \,\}, \qquad n_1 = |A(x)| = K,$$
$$B(x) = \{\, d(x_i, x_j) : x_i \in X_k,\ x_j \in X_k^i \,\}, \qquad n_2 = |B(x)| = K^2,$$

donde $B(x)$ se entiende como multiconjunto (una misma distancia puede aparecer varias veces). Se contrasta la hipótesis nula de que las distancias de $A(x)$ y de $B(x)$ siguen la

misma distribución frente a la alternativa unilateral de que las de $A(x)$ son estocásticamente mayores, es decir, de que x está más lejos de sus vecinos que estos de los suyos.

Sea R_1 la suma de los rangos de los elementos de $A(x)$ en la muestra conjunta de $M = n_1 + n_2 = K + K^2$ distancias, asignando a los empates el rango medio, y sea

$$U(x) = R_1 - \frac{n_1(n_1+1)}{2}$$

el estadístico de Mann-Whitney (apartado 6.2). Se definen:

1. *Puntuación del artículo* [62]: el p-valor unilateral $p(x) = \mathbb{P}_{H_0}\big(U \geq U(x)\big)$. Valores altos indican pertenencia a la distribución de entrenamiento, y x se clasifica como OOD si $p(x) < \alpha$ para un nivel de significación α prefijado.
2. *Puntuación empleada en este trabajo*: el opuesto del estadístico tipificado

$$z(x) = \frac{U(x) - \frac{n_1 n_2}{2} - \frac{1}{2}}{\sigma_U}, \qquad \sigma_U^2 = \frac{n_1 n_2}{12}\left[(M+1) - \frac{\sum_g (t_g^3 - t_g)}{M(M-1)}\right],$$

donde t_g es el número de distancias empatadas en el grupo g y el término $-\frac{1}{2}$ es la corrección por continuidad. La puntuación es $s_{\text{STOOD}}(x) = -z(x)$.

Observación 5.16 (Equivalencia de ambas puntuaciones). Con la aproximación normal, $p(x) \approx 1 - \Phi\big(z(x)\big)$, que es una función estrictamente decreciente de $z(x)$. Por tanto, $p(x)$ y $-z(x)$ ordenan las imágenes de la misma forma, y las métricas basadas en el orden (AUROC, FPR@95, CCR@FPR5) coinciden salvo empates numéricos. Con $K = 500$ hay $M = 250\,500$ distancias, y para muchas imágenes OOD el p-valor es menor que el menor número representable en coma flotante: se redondea a cero y se pierde el orden entre ellas. El estadístico $z(x)$ no tiene ese problema (apartado 11.3).

Observación 5.17 (Elección del test). El artículo justifica el uso de un test no paramétrico porque las distancias, al ser estrictamente positivas, no siguen una distribución normal (lo comprueban con el test de Shapiro-Wilk), y los tests no paramétricos son preferibles en ese caso. Lo describe como un test de Wilcoxon-Mann-Whitney con hipótesis nula $X - Y \leq 0$ y alternativa $X - Y > 0$. Como $A(x)$ y $B(x)$ tienen tamaños distintos (K frente a K^2) y sus elementos no están emparejados, el test aplicable es el de Mann-Whitney para dos muestras independientes, y no el de rangos con signo de Wilcoxon para datos pareados. Esta es la interpretación adoptada en este trabajo.

Hiperparámetros y coste computacional. El método tiene tres hiperparámetros [62]: la distancia d (coseno, adecuada para espacios de alta dimensión), el número de vecinos K y la proporción N_f de características empleadas. Los autores prueban $K \in \{9, 18, 36, 72, 144, 288, 500\}$ y el conjunto de entrenamiento completo, observan que el rendimiento mejora con K pero con ganancias decrecientes, y fijan $K = 500$ como compromiso entre rendimiento y tiempo de cálculo. N_f selecciona las características más relevantes de la penúltima capa según su relevancia absoluta calculada con CRP. Para un conjunto de referencia de tamaño N y características de dimensión D, el coste por imagen es $O(ND + N\log N + M\log M)$, que para K grande se reduce a $O(N\log N + K^2 \log K)$ dominado por el cálculo de distancias y la ordenación.

La segunda etapa genera explicaciones para el usuario final, en la línea de la inteligencia artificial explicable BLUE (responsable, legal, confiable y ética) y en dos pasos:

1. *Búsqueda de vecinos.* Se muestran las imágenes de entrenamiento más cercanas a x en el espacio de características. Como la puntuación se basa precisamente en esas distancias, los vecinos explican de forma directa por qué la puntuación es alta o baja: si se parecen visualmente a x, la decisión ID está respaldada por ejemplos validados; si no, la imagen no tiene precedentes cercanos.

2. *Visualización de características.* Para las características más relevantes, seleccionadas con CRP (apartado 7.2), se muestra dónde aparecen en la imagen de test y en sus vecinos. El usuario puede comprobar si la imagen comparte con sus vecinos los mismos conceptos o si la decisión se apoya en características ajenas a la tarea, como un fondo o un objeto irrelevante, lo que puede revelar un sesgo del modelo.

Esta etapa resulta especialmente útil en los casos dudosos: en lugar de una decisión opaca, el sistema presenta al usuario los ejemplos validados más próximos y le pregunta, de forma implícita, si la nueva imagen debe procesarse aunque no se parezca a ninguno de ellos.

6. Inferencia estadística

[PENDIENTE: introducción del capítulo] La inferencia estadística se usa en el contexto de la herramienta STOOD-X haciendo uso de diferentes tests y estadísticos con los que poder corrobar estadísticamente las distribuciones que siguen las muestras. Siendo así capaces de distinguri entre las muestras ID y las OOD.

6.1. Fundamentos de los contrastes de hipótesis

Definición 6.1 (Contraste de hipótesis)**. [PENDIENTE: definición]**

Definición 6.2 (p-valor)**. [PENDIENTE: definición]**

Proposición 6.3 (Distribución del p-valor bajo la hipótesis nula)**.** ***[PENDIENTE: enunciado]***

Demostración. **[PENDIENTE: demostración]** □

6.2. El test de Mann-Whitney

[PENDIENTE: introducción al test (Mann y Whitney [45]; Wilcoxon [76]; Canavos [9])]

Definición 6.4 (Estadístico U de Mann-Whitney)**. [PENDIENTE: definición]**

Proposición 6.5 (Media y varianza de U bajo la hipótesis nula)**.** ***[PENDIENTE: enunciado]***

Demostración. **[PENDIENTE: demostración]** □

Teorema 6.6 (Aproximación normal)**.** ***[PENDIENTE: enunciado]***

Proposición 6.7 (Relación entre U y el AUROC)**.** ***[PENDIENTE: enunciado]***

Demostración. **[PENDIENTE: demostración]** □

Observación 6.8 (Empates, corrección de continuidad y saturación)**. [PENDIENTE: desarrollo]**

Observación 6.9 (Hipótesis de independencia)**. [PENDIENTE: desarrollo]**

6.3. El test de McNemar

[PENDIENTE: planteamiento (McNemar [46])]

Proposición 6.10 (Distribución del estadístico de McNemar)**.** ***[PENDIENTE: enunciado]***

Demostración. **[PENDIENTE: demostración]** □

Tabla 6.1.: Tabla de contingencia del test de McNemar entre Swin-S y ConvNeXt-S sobre las 12.618 imágenes del test ID. En negrita, los pares discordantes.

	ConvNeXt-S acierta	ConvNeXt-S falla
Swin-S acierta	12.045	**179**
Swin-S falla	**154**	240

Teorema 6.11 (Teorema central del límite)**.** *Sean $X_1, X_2, \ldots, X_n$ n variables aleatorias i.i.d. cuya distribución no está especificada y que presentan una media μ y una varianza σ^2 finitas. El promedio muestral $\bar{X} = \frac{1}{n}\sum_{i=1}^{n} X_i$ tiene una distribución con media μ y varianza $\frac{\sigma^2}{n}$.*

De esta forma, para n grande, la distribución de $\frac{\bar{X}-\mu}{\sigma/\sqrt{n}}$ es aproximadamente una normal con media cero y desviación estándar uno, independientemente del modelo de probabilidad del que se tomó la muestra. Por tanto, concluimos que para valores de n suficientemente grandes la variable aleatoria

$$Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$$

es aproximadamente $N(0,1)$.

Teorema 6.12 (Teorema de De Moivre-Laplace)**.** *Sea $X \sim \text{Bin}(n,p)$ una variable aleatoria binomial, con media np y desviación estándar $\sqrt{np(1-p)}$. Entonces, cuando $n \to \infty$, la distribución de la variable*

$$Y = \frac{X - np}{\sqrt{np(1-p)}}$$

tiende a la normal estándar $N(0,1)$.

Se considera esta aproximación adecuada tanto para $np > 5$ como para $p <= 1/2$, o cuando $n(1-p) > 5$ para $p > 1/2$. Esto es

$$\mathbb{P}(a \leq X_B \leq b) \approx \mathbb{P}\left(\frac{a-np}{\sqrt{np(1-p)}} \leq Z_N \leq \frac{b-np}{\sqrt{np(1-p)}}\right)$$

Aplicación en el estudio. Se ha usado para comprobar si realmente existe una diferencia entre los modelos Swin-S y ConvNeXt-S, evaluados sobre las mismas 12.618 imágenes del test ID (cuadro 6.1). Denotamos por a el número de imágenes en las que ambos aciertan (12.045), por b aquellas en las que solo acierta Swin-S (179), por c aquellas en las que solo acierta ConvNeXt-S (154) y por d aquellas en las que ambos fallan (240).

Hipótesis:

- H_0: ambos modelos presentan la misma capacidad de acierto. Cuando discrepan, cada uno tiene una probabilidad de $\frac{1}{2}$ de ser el que acierta.
- H_1: dicha probabilidad es distinta de $\frac{1}{2}$.

Bajo H_0, y condicionando al número de pares discordantes, $n = b + c = 179 + 154 = 333$, el número de pares favorables a Swin-S sigue una distribución binomial (proposición 6.10):

$$b \sim \text{Bin}\left(333, \tfrac{1}{2}\right), \qquad \mathbb{E}[b] = \frac{333}{2} = 166{,}5, \qquad \text{Var}(b) = 333 \cdot \frac{1}{2}\left(1 - \frac{1}{2}\right) = 83{,}25.$$

Versión exacta. El p-valor bilateral es la probabilidad, bajo H_0, de obtener un reparto al menos tan desequilibrado como el observado:

$$p = 2\,\mathbb{P}(X \geq 179) = 0{,}188, \qquad X \sim \text{Bin}\left(333, \tfrac{1}{2}\right).$$

Aproximación normal. Una binomial es una suma de n variables de Bernoulli independientes. Por el teorema central del límite, que en el caso de la binomial es el teorema de De Moivre-Laplace [9], para un valor de n lo suficientemente grande es aproximadamente normal. Tipificando se tiene:

$$Z = \frac{b - n/2}{\sqrt{n/4}} \overset{\text{aprox.}}{\sim} N(0,1).$$

Sustituyendo $n = b + c$, se tiene $b - \frac{n}{2} = \frac{b-c}{2}$ y $\sqrt{n/4} = \frac{\sqrt{b+c}}{2}$, de modo que

$$Z = \frac{b-c}{\sqrt{b+c}} = \frac{179 - 154}{\sqrt{333}} = \frac{25}{18{,}248} = 1{,}370.$$

Al trabajar con la normal, que es continua, se obtiene un resultado más aproximado aplicando la corrección de continuidad, debido a la naturaleza discreta de los datos:

$$Z_c = \frac{|b-c| - 1}{\sqrt{b+c}} = \frac{24}{18{,}248} = 1{,}315.$$

El p-valor bilateral es entonces

$$p = 2\,(1 - \Phi(1{,}315)) = 2 \cdot 0{,}0942 = 0{,}188,$$

que coincide con el exacto. Sin la corrección se obtendría $p = 0{,}171$, que subestima el p-valor. Equivalentemente, $\chi^2_c = Z^2_c = 1{,}730$ sigue aproximadamente una distribución χ^2_1, y $\mathbb{P}(\chi^2_1 \geq 1{,}730) = 0{,}188$.

Decisión. Con un nivel de significación $\alpha = 0{,}05$, como $p = 0{,}188 > \alpha$, no se rechaza la hipótesis nula: no hay evidencia de que Swin-S y ConvNeXt-S difieran en exactitud. Para rechazarla, la región crítica $\chi^2_c > \chi^2_{1;0{,}95} = 3{,}841$ exigiría $|b - c| \geq 37$. Un caso podría ser por ejemplo que Swin-S ganara 185 de los 333 pares discordantes en lugar de 179.

Limitación. El test supone que los pares discordantes son independientes. Esta hipótesis no se cumple del todo, porque las imágenes de una misma lámina están relacionadas (capítulo 13). Por ello, el resultado se ha contrastado con un *bootstrap* pareado por lámina (apartado 6.4), que conduce a la misma conclusión: la diferencia de exactitud es de $+0{,}0020$ $[-0{,}0013;\ +0{,}0049]$, un intervalo que contiene el cero.

6.4. Intervalos de confianza *bootstrap*

[PENDIENTE: planteamiento]

Dada una muestra $(x_1, \ldots, x_n)$, el método *bootstrap* consiste en:

1. Consideramos la muestra de partida como una variable que presenta los n valores posibles, teniendo una probabilidad de $1/n$ de tomar cada valor; es decir, su distribución

es la distribución empírica

$$F_n(t) = \frac{1}{n}\sum_{i=1}^{n} \mathbb{1}(x_i \leq t).$$

Mediante el método de Montecarlo tomamos una muestra de tamaño n de esta distribución. Esto equivaldría a tomar una muestra aleatoria con reemplazamiento de los valores observados. Así pues, se obtiene la muestra

$$x^{*b} = (x_1^{*b}, \ldots, x_n^{*b}), \qquad x_j^{*b} = x_{I_j}, \quad I_1, \ldots, I_n \overset{\text{i.i.d.}}{\sim} \mathcal{U}\{1, \ldots, n\},$$

de modo que $\mathbb{P}^*(x_j^{*b} = x_i) = 1/n$ para cada i si los valores son distintos.

2. Sobre la muestra generada se calcula el estimador:

$$\hat{\theta}_b^* = \hat{\theta}(x_1^{*b}, \ldots, x_n^{*b}).$$

3. Se repiten los pasos 1 y 2 un número B grande de veces (1000, por ejemplo). De esta forma se obtiene una secuencia de B valores del estimador, $\hat{\theta}_1^*, \ldots, \hat{\theta}_B^*$, que se considerará una aproximación de la distribución de $\hat{\theta}$. Su media será

$$\bar{\theta}^* = \frac{1}{B}\sum_{b=1}^{B} \hat{\theta}_b^*,$$

y su varianza,

$$\widehat{\mathrm{Var}}^*(\hat{\theta}) = \frac{1}{B}\sum_{b=1}^{B} (\hat{\theta}_b^* - \bar{\theta}^*)^2.$$

[52]

Definición 6.13 (Intervalo *bootstrap* por percentiles [16])**.** Sean $\hat{\theta}_{(1)}^* \leq \hat{\theta}_{(2)}^* \leq \cdots \leq \hat{\theta}_{(B)}^*$ las réplicas *bootstrap* ordenadas de menor a mayor y sea $\alpha \in (0, 1)$. El intervalo *bootstrap* por percentiles de nivel $1 - \alpha$ para θ es

$$\left[\hat{\theta}_{(\lceil B\times\alpha/2\rceil)}^*,\ \hat{\theta}_{(\lceil B\times(1-\alpha/2)\rceil)}^*\right].$$

donde [ ] indica redondear al entero más próximo. [52]

Observación 6.14 (Bootstrap estratificado, pareado y por lámina). **[PENDIENTE: desarrollo]**

6.5. Predicción conforme

Un clasificador como el de la definición 3.18 devuelve, para cada imagen, una distribución sobre las clases, pero sus probabilidades son una medida heurística de la incertidumbre: nada garantiza que estén bien calibradas [3]. La *predicción conforme* transforma esa medida heurística en una garantía estadística: a partir de un modelo ya entrenado y de un conjunto de calibración no usado en el entrenamiento, construye para cada entrada un *conjunto de predicción* que contiene la clase verdadera con una probabilidad elegida por el usuario, sin suponer nada sobre la distribución de los datos ni sobre el modelo, y con validez para

tamaños de muestra finitos [3]. El marco procede de los trabajos de Vovk, Gammerman y Shafer [74, 63]; aquí se sigue la versión dividida (*split*) que presentan Angelopoulos y Bates [3].

En toda la sección, $\alpha \in (0,1)$ es el *nivel de error* elegido por el usuario. Vovk et al. lo llaman nivel de significación y lo denotan ϵ [74].

6.5.1. Intercambiabilidad y predicción conforme dividida

La única hipótesis que necesitan las garantías es que los datos de calibración y el de prueba sean intercambiables.

Definición 6.15 (Intercambiabilidad [74, secs. 2.1.1 y 2.1.5])**.** Una sucesión finita de variables aleatorias $Z_1, \dots, Z_N$ es *intercambiable* si, para toda permutación σ de $\{1, \dots, N\}$, el vector $(Z_{\sigma(1)}, \dots, Z_{\sigma(N)})$ tiene la misma distribución que $(Z_1, \dots, Z_N)$.

Es decir, la distribución conjunta no depende del orden de los datos. Toda sucesión de variables independientes e idénticamente distribuidas es intercambiable [74], de modo que las garantías que siguen valen en particular en el caso i.i.d.; Angelopoulos y Bates enuncian sus resultados con esa hipótesis y señalan que se mantienen bajo la condición, más débil, de intercambiabilidad [3].

Sea $\{(X_i, Y_i)\}_{i=1}^{n}$ un conjunto de *calibración*, disjunto del de entrenamiento, y sea $s \colon \mathcal{X} \times \mathcal{Y} \to \mathbb{R}$ una *puntuación de no conformidad*: una función que toma valores mayores cuanto peor concuerdan x e y según el modelo [3, 74].

Definición 6.16 (Predicción conforme dividida [3, sec. 1.1 y ap. D])**.** Sean $s_i = s(X_i, Y_i)$, $i = 1, \dots, n$, las puntuaciones de calibración, $s_{(1)} \le \cdots \le s_{(n)}$ esas puntuaciones ordenadas de menor a mayor y

$$k = \left\lceil (n+1)(1-\alpha) \right\rceil.$$

El *umbral conforme* es $\hat{q} = s_{(k)}$ si $k \le n$ y $\hat{q} = +\infty$ si $k > n$. El *conjunto de predicción* de una nueva entrada x es

$$C(x) = \left\{ y \in \mathcal{Y} : s(x, y) \le \hat{q} \right\}.$$

El umbral $\hat{q}$ es, esencialmente, el cuantil $1 - \alpha$ de las puntuaciones de calibración, con una pequeña corrección por el tamaño finito de la muestra [3]. Vovk et al. llaman a esta versión *predictor conforme inductivo*: el conjunto de entrenamiento se divide en un conjunto de entrenamiento propiamente dicho, con el que se ajusta el modelo, y uno de calibración, con el que se calcula el umbral [74]. Cuando $k > n$, el conjunto de calibración es demasiado pequeño para el nivel pedido y el conjunto de predicción contiene todas las clases [3].

6.5.2. p-valor conforme y cobertura

Las garantías de la predicción conforme se apoyan en un p-valor construido con los rangos de las puntuaciones.

Proposición 6.17 (p-valor conforme [74, secs. 2.2.3 y 4.2])**.** *Sean $S_1, \dots, S_n, S_{n+1}$ variables aleatorias reales intercambiables y*

$$p = \frac{1 + \#\{\, i \in \{1, \dots, n\} : S_i \ge S_{n+1} \,\}}{n+1}.$$

Entonces p es superuniforme*: $\mathbb{P}(p \le u) \le u$ para todo $u \in [0,1]$.*

Demostración. Para cada $j \in \{1, \dots, n+1\}$, sea $R_j = \#\{\, i \in \{1, \dots, n+1\} : S_i \geq S_j \,\}$, de modo que $p = R_{n+1}/(n+1)$. Fijado un entero m, veamos que como mucho m índices cumplen $R_j \leq m$. Si A es el conjunto de esos índices y $j^* \in A$ es uno con la menor puntuación S_{j^*}, todos los $i \in A$ cumplen $S_i \geq S_{j^*}$, luego $R_{j^*} \geq |A|$ y, como $R_{j^*} \leq m$, se tiene $|A| \leq m$. Por tanto, $\sum_{j=1}^{n+1} \mathbb{1}\{R_j \leq m\} \leq m$.

Por la intercambiabilidad, el vector $(R_1, \dots, R_{n+1})$ tiene la misma distribución que cualquier permutación suya, así que todas las R_j tienen la misma distribución. Tomando esperanzas,

$$(n+1)\,\mathbb{P}(R_{n+1} \leq m) = \sum_{j=1}^{n+1} \mathbb{P}(R_j \leq m) = \mathbb{E}\Big[\sum_{j=1}^{n+1} \mathbb{1}\{R_j \leq m\}\Big] \leq m.$$

Por último, $p \leq u$ equivale a $R_{n+1} \leq \lfloor u(n+1) \rfloor$, y con $m = \lfloor u(n+1) \rfloor$ se obtiene $\mathbb{P}(p \leq u) \leq \lfloor u(n+1) \rfloor/(n+1) \leq u$. □

El p-valor mide qué fracción de las puntuaciones es al menos tan anómala como la nueva. Cuanto menor es, menos se parece el nuevo dato a los de calibración, y rechazar cuando $p \leq \alpha$ es un contraste de la hipótesis de que el dato es intercambiable con los de calibración, con probabilidad de error de tipo I a lo sumo α [3, 74]. Este es el fundamento de la detección OOD conforme del capítulo 12. Como el p-valor solo toma los valores $1/(n+1), 2/(n+1), \dots, 1$, no es exactamente uniforme (compárese con la proposición 6.3); Vovk et al. obtienen un p-valor exactamente uniforme rompiendo los empates con una variable aleatoria uniforme independiente, lo que llaman predictores conformes *suavizados* [74].

Teorema 6.18 (Cobertura marginal [3])**.** *Si $(X_1, Y_1), \dots, (X_n, Y_n), (X_{n+1}, Y_{n+1})$ son intercambiables y C es el conjunto de predicción de la definición 6.16, entonces*

$$\mathbb{P}\big(Y_{n+1} \in C(X_{n+1})\big) \geq 1 - \alpha.$$

Demostración. Si $k > n$, entonces $\hat{q} = +\infty$ y $C(X_{n+1}) = \mathcal{Y}$, de modo que la cobertura es 1. Supongamos $k \leq n$ y sean $s_i = s(X_i, Y_i)$ y $s_{n+1} = s(X_{n+1}, Y_{n+1})$; estas puntuaciones son intercambiables porque se obtienen aplicando la misma función s a datos intercambiables. Si $Y_{n+1} \notin C(X_{n+1})$, entonces $s_{n+1} > s_{(k)}$, de modo que las k puntuaciones de calibración más pequeñas son menores que s_{n+1} y como mucho $n-k$ son mayores o iguales que ella. Con la notación de la proposición 6.17, aplicada a $S_i = s_i$,

$$p \leq \frac{1 + n - k}{n+1} \leq \frac{1 + n - (n+1)(1-\alpha)}{n+1} = \alpha.$$

Por la proposición 6.17, $\mathbb{P}\big(Y_{n+1} \notin C(X_{n+1})\big) \leq \mathbb{P}(p \leq \alpha) \leq \alpha$. □

La garantía es *marginal*: la probabilidad se toma a la vez sobre los datos de calibración y sobre el de prueba, de modo que se cumple en promedio y no para cada imagen ni para cada clase [3, 2]. Además, la garantía se cumple para cualquier puntuación, pero la utilidad de los conjuntos depende de ella: si la puntuación ordena bien los datos según el error del modelo, los conjuntos son pequeños para las entradas fáciles y grandes para las difíciles, y si no, los conjuntos pueden ser inútiles aunque la cobertura sea correcta [3].

Observación 6.19 (Cota superior). Si las puntuaciones tienen una distribución conjunta con-

tinua, de modo que no hay empates, la cobertura está también acotada superiormente:

$$\mathbb{P}\big(Y_{n+1} \in C(X_{n+1})\big) \leq 1 - \alpha + \frac{1}{n+1}.$$

Angelopoulos y Bates enuncian este resultado y remiten su demostración a Lei et al. (2018); en la práctica, la condición de continuidad puede asegurarse añadiendo a la puntuación un ruido aleatorio despreciable [3]. Así, con calibraciones grandes la cobertura es prácticamente $1 - \alpha$.

Observación 6.20 (Cobertura condicionada a la calibración). El teorema 6.18 promedia también sobre el conjunto de calibración. Fijado este, la cobertura sobre infinitos datos de prueba es una variable aleatoria que, según Angelopoulos y Bates, que atribuyen el resultado a Vovk, sigue una distribución

$$\mathrm{Beta}(n+1-l,\ l), \qquad l = \lfloor (n+1)\alpha \rfloor,$$

de media $1 - l/(n+1)$ [3]. Como $n+1-l = k$, se trata de una $\mathrm{Beta}(k, n+1-k)$. Su dispersión decrece como $O(n^{-1/2})$: con calibraciones pequeñas, la cobertura obtenida con una calibración concreta puede alejarse bastante de $1 - \alpha$ [3]. Si además la cobertura se estima con n_{val} datos de prueba, la proporción observada sigue una distribución beta-binomial, con media $1 - l/(n+1)$ y desviación típica

$$\sqrt{\frac{l\,(n+1-l)\,(n+n_{\mathrm{val}}+1)}{n_{\mathrm{val}}\,(n+1)^2\,(n+2)}};$$

estas expresiones permiten comprobar si una cobertura observada es compatible con la teoría [3].

6.5.3. Puntuaciones para clasificación

En clasificación, la puntuación se construye a partir de las probabilidades del modelo. Sea $\hat{\pi}_x(y)$ la probabilidad que el modelo asigna a la clase y para la entrada x (definición 3.17), sea $o_x(y)$ el rango de y al ordenar las clases de más a menos probable ($o_x(y) = 1$ para la más probable) y sea

$$\rho_x(y) = \sum_{y' \,:\, \hat{\pi}_x(y') > \hat{\pi}_x(y)} \hat{\pi}_x(y')$$

la probabilidad total de las clases más probables que y [2].

Definición 6.21 (Puntuaciones LAC y APS [3, 2, 59])**.** La *puntuación LAC* es uno menos la probabilidad de la clase:

$$s_{\mathrm{LAC}}(x, y) = 1 - \hat{\pi}_x(y).$$

La *puntuación APS* (*Adaptive Prediction Sets*) es la probabilidad acumulada de las clases que preceden a y, más una fracción aleatoria de la probabilidad de y:

$$s_{\mathrm{APS}}(x, y, u) = \rho_x(y) + u\,\hat{\pi}_x(y), \qquad u \sim U(0,1),$$

donde u es independiente de todo lo demás y se genera una vez por dato.

Con la puntuación LAC, el conjunto de predicción contiene todas las clases cuya probabi-

lidad supera $1-\hat{q}$ [3]. Angelopoulos y Bates indican que esta puntuación da los conjuntos de menor tamaño medio, pero tiende a infracubrir los subgrupos difíciles y a sobrecubrir los fáciles [3]. La puntuación APS, propuesta por Romano et al. y presentada por Angelopoulos y Bates, imita el procedimiento que se usaría si las probabilidades fueran exactas: añadir clases de más a menos probable hasta reunir una probabilidad $1-\alpha$. Así usa las probabilidades de todas las clases, y no solo la de la clase verdadera [3, 59]. El término aleatorio $u\,\hat{\pi}_x(y)$ suaviza el salto discreto que produce la inclusión de cada clase y afecta como mucho a una de ellas [2]; con él, el conjunto puede llegar a ser vacío.

Definición 6.22 (RAPS [2, sec. 2.2])**.** Dados $\lambda \geq 0$ y $k_{\text{reg}} \geq 0$, la puntuación RAPS (*Regularized Adaptive Prediction Sets*) es

$$s_{\text{RAPS}}(x, y, u) = \rho_x(y) + u\,\hat{\pi}_x(y) + \lambda\,\big(o_x(y) - k_{\text{reg}}\big)^{+},$$

donde $(z)^{+} = \max\{z, 0\}$. Para $\lambda = 0$ coincide con la puntuación APS.

Angelopoulos et al. observan que los conjuntos APS son a menudo más grandes de lo necesario, porque dependen de las probabilidades pequeñas y ruidosas de las clases poco probables, cuyo orden es en buena parte aleatorio. La penalización añade λ por cada posición más allá de la k_{reg}, de modo que esas clases solo entran si el umbral es mucho mayor [2]. RAPS conserva la cobertura del teorema 6.18 y, según sus experimentos en ImageNet, da conjuntos mucho más pequeños que APS con la misma cobertura [2]. Los autores proponen elegir k_{reg} y λ con un conjunto de ajuste separado del de calibración [2]. A cambio de conjuntos más pequeños, una penalización fuerte reduce la adaptatividad: los conjuntos varían menos con la dificultad de la imagen [2].

6.5.4. Predicción conforme condicionada por clase (Mondrian)

La garantía del teorema 6.18 es marginal y puede repartirse de forma desigual entre clases: una cobertura muy alta en las clases frecuentes puede compensar una cobertura baja en las raras. Vovk et al. señalan que, cuando los errores en distintas categorías tienen consecuencias distintas, no se puede permitir que tasas de error bajas en unas compensen tasas excesivas en otras [74]. Para obtener la cobertura en cada clase basta calibrar por separado dentro de cada una [3]. Vovk et al. estudian esta construcción dentro de los predictores conformes *Mondrian*, que dividen los datos en categorías y calibran dentro de cada categoría; el caso en que la categoría es la etiqueta es el predictor conforme Mondrian condicionado por la etiqueta [74].

Definición 6.23 (Predicción conforme Mondrian [3, sec. 4.2], [74, sec. 4.6])**.** Para cada clase y, sean n_y el número de datos de calibración de la clase, $s^{(y)}_{(1)} \leq \cdots \leq s^{(y)}_{(n_y)}$ sus puntuaciones ordenadas y $k_y = \lceil (n_y + 1)(1-\alpha) \rceil$. El umbral de la clase es $\hat{q}_y = s^{(y)}_{(k_y)}$ si $k_y \leq n_y$ y $\hat{q}_y = +\infty$ si $k_y > n_y$, y el conjunto de predicción es

$$C(x) = \big\{\, y \in \mathcal{Y} : s(x, y) \leq \hat{q}_y \,\big\}.$$

En la prueba no se conoce la clase verdadera, de modo que cada clase candidata y se compara con su propio umbral $\hat{q}_y$ [3]. Si los datos de calibración y el de prueba son i.i.d., el

conjunto cumple la garantía por clase

$$\mathbb{P}\big(Y_{n+1} \in C(X_{n+1}) \mid Y_{n+1} = y\big) \geq 1 - \alpha \qquad \text{para toda clase } y,$$

resultado que Angelopoulos y Bates atribuyen a Vovk y que Vovk et al. obtienen como caso particular de la validez de los predictores Mondrian [3, 74]. Intuitivamente, condicionado a las etiquetas, los datos de calibración de la clase y y un dato de prueba de esa clase son intercambiables, y basta aplicar el teorema 6.18 dentro de la clase. El precio es que cada umbral se calcula con menos datos que el umbral marginal.

El tamaño de la calibración de cada clase condiciona el umbral, como precisa el siguiente resultado.

Proposición 6.24 (Umbral infinito y umbral máximo en Mondrian)**.** *Con la notación de la definición 6.23:*

1. *El umbral de la clase y es infinito ($k_y > n_y$) si y solo si $n_y < (1-\alpha)/\alpha$.*
2. *El umbral es la mayor puntuación de calibración de la clase ($k_y = n_y$) si y solo si $(1-\alpha)/\alpha \leq n_y < (2-\alpha)/\alpha$.*

Con $\alpha = 0{,}05$, el umbral es infinito si $n_y \leq 18$ y es el máximo si $19 \leq n_y \leq 38$; con $\alpha = 0{,}10$, si $n_y \leq 8$ y si $9 \leq n_y \leq 18$, respectivamente.

Demostración. Como n_y es entero, $\lceil t \rceil > n_y$ si y solo si $t > n_y$, y $\lceil t \rceil = n_y$ si y solo si $n_y - 1 < t \leq n_y$. Con $t = (n_y+1)(1-\alpha)$:

1. $(n_y+1)(1-\alpha) > n_y$ equivale a $1 > (n_y+1)\alpha$, es decir, a $n_y < (1-\alpha)/\alpha$.
2. $(n_y+1)(1-\alpha) \leq n_y$ equivale a $n_y \geq (1-\alpha)/\alpha$, y $(n_y+1)(1-\alpha) > n_y - 1$ equivale a $2 > (n_y+1)\alpha$, es decir, a $n_y < (2-\alpha)/\alpha$.

Para $\alpha = 0{,}05$, $(1-\alpha)/\alpha = 19$ y $(2-\alpha)/\alpha = 39$; para $\alpha = 0{,}10$, 9 y 19. □

Cuando el umbral es la mayor puntuación de calibración de la clase, basta un solo dato de calibración con una puntuación muy alta (una imagen de la clase a la que el modelo asigna una probabilidad muy baja) para que la clase entre en casi todos los conjuntos de predicción. Este efecto se observa en la apartado 12.3.

7. Explicabilidad

[PENDIENTE: introducción del capítulo: modelos de caja negra frente a caja blanca (petición del tutor, reunión del 30 oct); el trabajo se centra en LRP y CRP]

Los conjuntos de datos de alta dimensión suelen contener correlaciones espurias: asociaciones entre variables que no responden a una relación causal, sino, por ejemplo, a un factor común. Un ejemplo clásico es la correlación entre las ventas de helados y el número de asesinatos, que aumentan a la vez durante los meses de verano porque ambos dependen de la temperatura. Ante varias variables correlacionadas, un modelo puede apoyarse en cualquiera de ellas para predecir, y nada garantiza que elija la que generaliza correctamente. Cuando un modelo acierta basándose en características que no tienen relación con la tarea, se habla de un predictor *Clever Hans*, en alusión al caballo que parecía resolver operaciones aritméticas cuando en realidad respondía a gestos involuntarios de su dueño [35]. En histopatología, por ejemplo, un clasificador podría apoyarse en la tinción, el escáner o el centro de origen de las imágenes en lugar de en la morfología del tejido. **[PENDIENTE: enlazar con los resultados propios: control interno del capítulo de detección OOD y firma de lámina del capítulo de fuga por lámina]**

Una solución posible es la selección de características, que consiste en proporcionar al modelo solo un conjunto reducido de variables adecuadas [20]. Sin embargo, esta estrategia es difícil de aplicar en el reconocimiento de imágenes, donde el papel de cada píxel individual no está fijado de antemano.

El aprendizaje automático explicable aborda el problema en sentido inverso: primero se entrena el modelo sin restringir las características de entrada y, una vez entrenado, se analiza cuáles ha aprendido a utilizar. A partir de esta información, las características inadecuadas pueden eliminarse y el modelo puede volver a entrenarse con datos corregidos [48]. Un método sencillo para obtener estas explicaciones es la descomposición de Taylor, que desarrolla la predicción $f(x)$ en torno a un punto de referencia cercano $\tilde{x}$ [48]:

$$f(x) = f(\tilde{x}) + \sum_{i=1}^{d} (x_i - \tilde{x}_i) \cdot \left[\nabla f(\tilde{x})\right]_i + \dots$$

Cada uno de los términos de primer orden, es decir, cada sumando de la capítulo 7, mide cuánto contribuye la variable de entrada correspondiente a la predicción, y el conjunto de todos ellos constituye la explicación. A pesar de su sencillez, este procedimiento resulta inestable cuando se aplica a redes neuronales profundas [48]. Esta inestabilidad se debe a varias limitaciones bien conocidas de las funciones que implementan dichas redes:

- *Gradientes fragmentados* (*shattered gradients*) [6]: aunque el valor de la función $f(x)$ suele ser preciso, su gradiente presenta mucho ruido.
- *Ejemplos adversarios* [70]: perturbaciones muy pequeñas de la entrada x pueden alterar de forma drástica el valor de $f(x)$.

Debido a estas limitaciones, es difícil encontrar un punto de referencia $\tilde{x}$ adecuado cuyo gradiente $\nabla f(\tilde{x})$ sea también significativo, lo que impide obtener una explicación fiable [50].

Numerosas técnicas han sido propuestas para abordar mejor la complejidad de las redes neuronales profundas. A continuación nos vamos a centrar en *Layer-wise Relevance Propagation* (LRP) [5], una técnica que aprovecha la estructura de grafo de la red neuronal para calcular explicaciones de forma rápida y fiable.

7.1. Layer-wise Relevance Propagation (LRP)

LRP [5, 48] es una técnica de explicación aplicable a cualquier modelo con estructura de red neuronal, con independencia del tipo de entrada: imágenes, vídeos o texto. Su funcionamiento consiste en propagar la predicción $f(x)$ hacia atrás a través de la red, capa a capa, mediante reglas de propagación locales diseñadas específicamente para este fin.

Este proceso de propagación está sujeto a una propiedad de conservación: toda la relevancia que recibe una neurona debe repartirse íntegramente entre las neuronas de la capa anterior, sin que se cree ni se pierda relevancia por el camino. Este comportamiento es análogo al de las leyes de conservación de Kirchhoff en los circuitos eléctricos, y lo comparten también otros métodos de explicación [34, 64, 80].

Sean j y k neuronas de dos capas consecutivas de la red, de modo que j pertenece a la capa inferior. Dadas las puntuaciones de relevancia $(R_k)_k$ de una capa, su propagación a las neuronas de la capa inferior se obtiene aplicando la regla

$$R_j = \sum_k \frac{z_{jk}}{\sum_j z_{jk}} R_k.$$

La cantidad z_{jk} representa en qué medida la neurona j ha contribuido a que la neurona k sea relevante, mientras que el denominador de la apartado 7.1 garantiza que se cumpla la propiedad de conservación. La propagación se repite capa a capa y finaliza al alcanzar las variables de entrada.

Proposición 7.1 (Conservación de la relevancia)**.** *Supongamos que en una capa se aplica la apartado 7.1, con $\sum_j z_{jk} \neq 0$ para toda neurona k, y que el índice j recorre todas las neuronas de la capa inferior. Entonces*

$$\sum_j R_j = \sum_k R_k.$$

En consecuencia, si la propagación se inicia en la salida con $R = f(x)$ y la apartado 7.1 se aplica en todas las capas, la relevancia total de las variables de entrada es $f(x)$, salvo la parte asignada en cada capa a las neuronas de sesgo. En particular, si la red no tiene sesgos,

$$\sum_{i=1}^{d} R_i = f(x).$$

Demostración. Sumando la apartado 7.1 sobre j e intercambiando el orden de las sumas finitas,

$$\sum_j R_j = \sum_j \sum_k \frac{z_{jk}}{\sum_{j'} z_{j'k}} R_k = \sum_k \frac{\sum_j z_{jk}}{\sum_{j'} z_{j'k}} R_k = \sum_k R_k,$$

donde el cociente vale 1 para cada k por ser el denominador no nulo. (Aquí se escribe j' para el índice del denominador solo para distinguirlo del índice de la suma exterior.) Aplicando la proposición 7.1 capa a capa desde la salida, donde la relevancia total es $f(x)$, hasta la

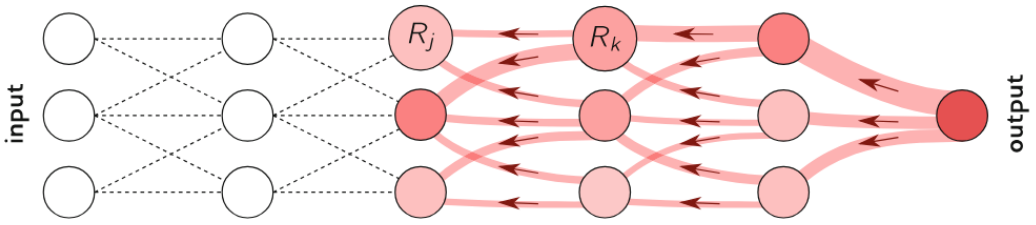

Figura 7.1.: Propagación de la predicción $f(x)$ hacia atrás a través de la red, capa a capa, mediante LRP. Fuente: Montavon et al. [48].

entrada, la relevancia total se mantiene igual a $f(x)$ en cada capa. Las neuronas de sesgo no tienen capa inferior, así que la relevancia que reciben no se propaga más; si no hay sesgos, toda la relevancia llega a las variables de entrada. □

La figura 7.1 ilustra el procedimiento completo.

Aunque LRP difiere de la aproximación de Taylor descrita anteriormente, cada paso de la propagación puede interpretarse como una descomposición de Taylor propia, aplicada sobre magnitudes locales del grafo de la red [49] (apartado 7.1.2).

7.1.1. Reglas de propagación

Consideremos redes neuronales profundas con activaciones ReLU (*rectified linear unit*), la opción más extendida en las aplicaciones actuales [48], formadas por neuronas del tipo

$$a_k = \max\Big(0,\ \sum_{j=0}^{n} a_j w_{jk}\Big),$$

donde $a_1, \ldots, a_n$ son las activaciones de la capa inferior y se añade una neurona ficticia $a_0 = 1$ cuyo peso w_{0k} representa el sesgo de la neurona k.

En las reglas que siguen, j recorre las neuronas de la capa inferior, incluida la neurona del sesgo $a_0 = 1$ (apartado 7.1.1), y k las de la capa superior. Se denota por $z_k = \sum_{j=0}^{n} a_j w_{jk}$ la preactivación de la neurona k.

Definición 7.2 (Regla básica, LRP-o [5])**.** La regla LRP-o reparte la relevancia de cada neurona k en proporción a la contribución de cada entrada a su activación, tal como aparece en la apartado 7.1.1:

$$R_j = \sum_k \frac{a_j w_{jk}}{\sum_{j=0}^{n} a_j w_{jk}} R_k = \sum_k \frac{a_j w_{jk}}{z_k} R_k.$$

Esta regla cumple propiedades elementales deseables. Por ejemplo, si $a_j = 0$ o $w_{jk} = 0$ para todo k, entonces $R_j = 0$: una neurona inactiva, un peso nulo y la ausencia de conexión reciben el mismo tratamiento. Sin embargo, aplicada de forma uniforme a toda la red, produce una explicación equivalente a Gradiente × Entrada [65, 48]. Hereda, por tanto, el ruido del gradiente de las redes profundas descrito anteriormente, lo que motiva el diseño de reglas más robustas.

Definición 7.3 (Regla épsilon, LRP-ε [5])**.** Sea $\varepsilon > 0$. La regla LRP-ε añade este término al denominador de la regla LRP-0:

$$R_j = \sum_k \frac{a_j w_{jk}}{\varepsilon + z_k} R_k.$$

Defecto que corrige. En LRP-0, cuando las contribuciones a la activación de una neurona son débiles o se compensan entre sí, el denominador z_k es pequeño y la relevancia redistribuida se amplifica, lo que introduce ruido en la explicación. El término ε absorbe parte de la relevancia precisamente en esas neuronas. Cuanto mayor es ε, solo sobreviven a esta absorción los factores explicativos más destacados, lo que da lugar a explicaciones más concentradas en pocas variables y con menos ruido [48]. A cambio, la conservación deja de ser exacta: sumando la definición 7.3 sobre j se obtiene

$$\sum_j R_j = \sum_k \frac{z_k}{\varepsilon + z_k} R_k,$$

que se reduce a $\sum_k R_k$ cuando $\varepsilon \to 0$, es decir, cuando la regla se reduce a LRP-0.

En la práctica, para que el denominador no se anule cuando $z_k < 0$, se suma $\varepsilon\,\mathrm{sign}(z_k)$ en lugar de ε, con el convenio $\mathrm{sign}(0) = 1$ [1].

Definición 7.4 (Regla gamma, LRP-γ [48])**.** Sea $\gamma \geq 0$ y sea $w_{jk}^+ = \max(0, w_{jk})$ la parte positiva de cada peso. La regla LRP-γ favorece las contribuciones positivas frente a las negativas:

$$R_j = \sum_k \frac{a_j\left(w_{jk} + \gamma w_{jk}^+\right)}{\sum_{j=0}^n a_j\left(w_{jk} + \gamma w_{jk}^+\right)} R_k.$$

Para $\gamma = 0$ se recupera la regla LRP-0.

Defecto que corrige. Cuando en una neurona coexisten contribuciones positivas y negativas de magnitud parecida, la relevancia que reciben las neuronas de la capa inferior puede crecer mucho, tanto en positivo como en negativo, a medida que se propaga, y la explicación se vuelve inestable. El parámetro γ controla cuánto se favorecen las contribuciones positivas: al aumentarlo, las negativas pierden peso progresivamente. El predominio de las contribuciones positivas limita el crecimiento de la relevancia durante la propagación y produce explicaciones más estables [48]. La idea de tratar de forma asimétrica las contribuciones positivas y negativas procede de la regla LRP-$\alpha\beta$ [5].

Observación 7.5 (Caso límite: la regla z^+). Si $\sum_j a_j w_{jk}^+ > 0$, al dividir el numerador y el denominador de la definición 7.4 entre γ y hacer $\gamma \to \infty$ se obtiene

$$R_j = \sum_k \frac{a_j w_{jk}^+}{\sum_{j=0}^n a_j w_{jk}^+} R_k,$$

que es la regla z^+ [49]. Esta regla equivale a LRP-$\alpha_1\beta_0$ [5] y a *excitation backprop* [80, 48].

La expresión anterior supone activaciones no negativas, como las que produce la ReLU. Cuando las activaciones de entrada pueden ser negativas, la regla z^+ se formula con la parte positiva de cada contribución [1]:

Definición 7.6 (Regla z^+)**.**

$$R_j = \sum_k \frac{(a_j w_{jk})^+}{\sum_{j=0}^{n} (a_j w_{jk})^+} R_k, \qquad (t)^+ = \max(0, t).$$

Si $a_j \geq 0$ para todo j, se tiene $(a_j w_{jk})^+ = a_j w_{jk}^+$ y se recupera la expresión de la observación 7.5.

Definición 7.7 (Regla *flat*, LRP-$\flat$ [1])**.** La regla *flat* reparte la relevancia de cada neurona k a partes iguales entre las neuronas de la capa inferior conectadas con ella, sin tener en cuenta pesos ni activaciones:

$$R_j = \sum_k \frac{1}{n_k} R_k,$$

donde n_k es el número de neuronas de la capa inferior conectadas con k.

[PENDIENTE: para qué se usa: en la primera capa suaviza el mapa en el espacio de entrada y lo hace invariante a la normalización de la entrada [1]]

[PENDIENTE: reglas por capa: recomendación de Montavon et al. (LRP-0 en capas superiores, ε en intermedias, γ en inferiores) y composite LRP$_{\varepsilon\text{-}z^+\text{-}\flat}$ de Achtibat et al.; describir la configuración final usada en ConvNeXt (variante A, results_crp/fase5/scripts/composite_final.py)]

7.1.2. LRP como descomposición de Taylor profunda

Aunque LRP se ha presentado como un conjunto de reglas de propagación, estas reglas admiten una justificación teórica dentro del marco de la *descomposición de Taylor profunda* (*Deep Taylor Decomposition*, DTD) [49, 48]. La idea consiste en sustituir el desarrollo de Taylor de la red completa, que resulta inestable (capítulo 7), por una sucesión de desarrollos de Taylor locales, uno en cada neurona.

Concretamente, la relevancia R_k de una neurona se considera función de las activaciones de la capa inferior, $a = (a_j)_j$, y se desarrolla en primer orden en torno a un punto de referencia $\tilde{a}$:

$$R_k(a) = R_k(\tilde{a}) + \sum_{j=0}^{n} (a_j - \tilde{a}_j) \left[\nabla R_k(\tilde{a})\right]_j + \dots$$

Cada término de primer orden indica qué parte de R_k debe asignarse a la neurona j. Sin embargo, la relación entre a y R_k puede ser muy compleja, por lo que no es inmediato elegir el punto de referencia ni calcular el gradiente.

Para obtener una expresión cerrada, DTD sustituye la función de relevancia real por un *modelo de relevancia* más sencillo. En redes con activaciones ReLU se utiliza la activación ReLU modulada

$$\widehat{R}_k(a) = \max\Big(0, \sum_{j=0}^{n} a_j w_{jk}\Big) \cdot c_k,$$

donde c_k es una constante elegida de modo que $\widehat{R}_k(a) = R_k(a)$ en el punto observado; es decir, si la neurona está activa ($z_k > 0$), $c_k = R_k / z_k$. Tratar c_k como constante está justificado cuando la relevancia de las capas superiores se ha obtenido con las reglas LRP-0, LRP-ε o LRP-γ [48]. Como la función ReLU es lineal en su región activa, el desarrollo de $\widehat{R}_k$ es exacto

en primer orden:

$$\widehat{R}_k(a) = \widehat{R}_k(\tilde{a}) + \sum_{j=0}^{n} (a_j - \tilde{a}_j)\, w_{jk} c_k,$$

y el término de orden cero puede hacerse tan pequeño como se quiera eligiendo $\tilde{a}$ cerca del punto de corte de la ReLU.

La relevancia que recibe cada neurona j es, entonces, la suma de los términos de primer orden de todas las neuronas k a las que está conectada, cada una desarrollada en su propio punto de referencia $\tilde{a}^{(k)}$:

$$R_j = \sum_k \big(a_j - \tilde{a}_j^{(k)}\big)\, w_{jk} c_k.$$

Cada elección del punto de referencia da lugar a una forma distinta de redistribuir la relevancia. La siguiente proposición formaliza una observación de Montavon et al. [48]: algunas elecciones concretas recuperan las reglas de la apartado 7.1.1.

Proposición 7.8 (Reglas LRP como casos de DTD)**.** *Supongamos que todas las neuronas k de la capa superior son activas ($z_k > 0$) y sea $c_k = R_k / z_k$.*

1. *Si $\tilde{a}^{(k)} = 0$ para todo k, la apartado 7.1.2 coincide con la regla LRP-0 (definición 7.2).*
2. *Si $\tilde{a}^{(k)} = \frac{\varepsilon}{z_k + \varepsilon}\, a$ para todo k, con $\varepsilon > 0$, la apartado 7.1.2 coincide con la regla LRP-ε (definición 7.3).*

Demostración. Sustituyendo $c_k = R_k / z_k$ en la apartado 7.1.2 se obtiene

$$R_j = \sum_k \big(a_j - \tilde{a}_j^{(k)}\big)\, \frac{w_{jk}}{z_k}\, R_k.$$

Caso 1. Si $\tilde{a}^{(k)} = 0$, entonces $a_j - \tilde{a}_j^{(k)} = a_j$ para todo k, y la apartado 7.1.2 queda

$$R_j = \sum_k \frac{a_j w_{jk}}{z_k}\, R_k,$$

que es exactamente la regla LRP-0 (definición 7.2).

Caso 2. Si $\tilde{a}^{(k)} = \frac{\varepsilon}{z_k + \varepsilon}\, a$, entonces, para cada k,

$$a_j - \tilde{a}_j^{(k)} = a_j - \frac{\varepsilon}{z_k + \varepsilon}\, a_j = \frac{z_k + \varepsilon - \varepsilon}{z_k + \varepsilon}\, a_j = \frac{z_k}{z_k + \varepsilon}\, a_j,$$

donde el denominador no se anula porque $z_k > 0$ y $\varepsilon > 0$. Sustituyendo en la apartado 7.1.2, el factor z_k se cancela:

$$R_j = \sum_k \frac{z_k}{z_k + \varepsilon}\, a_j\, \frac{w_{jk}}{z_k}\, R_k = \sum_k \frac{a_j w_{jk}}{\varepsilon + z_k}\, R_k,$$

que es la regla LRP-ε (definición 7.3). □

La regla LRP-γ también se obtiene de este modo, tomando como punto de referencia la intersección entre el punto de corte de la ReLU y una recta que parte de a en una dirección que favorece los pesos positivos. Para las tres reglas puede demostrarse que el punto de referencia cumple $\tilde{a} \geq 0$ [49], de modo que pertenece al dominio de las activaciones ReLU.

Además, cuanto más cerca está $\tilde{a}$ de a, más ligada al dato concreto es la explicación: LRP-0 es la regla con mayor distancia, mientras que LRP-ε y LRP-γ la reducen considerablemente [48].

7.1.3. Canonización y arquitecturas modernas

[PENDIENTE: canonización: BatchNorm, sesgos, conexiones residuales y particularidades de ConvNeXt]

7.1.4. Interpretación probabilística de la regla z^+

[PENDIENTE: definición, proposición (submultiplicatividad del coeficiente de Dobrushin) y su relación con la insensibilidad a la clase]

7.2. Concept Relevance Propagation

[PENDIENTE: CRP]

Parte III.

Experimentación, resultados y discusión

8. Materiales y métodos

8.1. Conjunto de datos ID

Como punto de partida contábamos con una base de datos de imágenes médicas clasificadas según el tipo de enfermedad que presentaban. La base contaba con las siguientes clases: `Adenocarcinoma_ductal`, `Glandulas_no_neoplasicas`, `Gleason_4_fusionadas`, `Gleason_5_comedonecrosis`, `No_Cancer`, `Carcinoma_intraductal`, `Gleason_3`, `Gleason_4_glomeruloide`, `Gleason_5_no_glandulas`, `PIN_de_alto_grado`, `Estroma`, `Gleason_4_cribiformes`, `Gleason_4_pobremente_formadas` e `Inflamatorio`.

La información de este apartado procede del artículo del conjunto de datos [4]. El muestreo tisular fue realizado por patólogos experimentados con un amplio conocimiento en hispatología del cancer de próstata. En definitiva nuestro conjunto de datos consiste en muestras de prostatectomía radical, durante su obtención las piezas se procesaron en un procesador automático de tejidos, se deshidrataron y se incluyeron en parafina. Se obtuvieron cortes de 3–5 µm de grosor con un micrótomo, que se montaron en portaobjetos de vidrio, se desparafinaron y se tiñeron con hematoxilina y eosina (H&E).

Las preparaciones teñidas con H&E se digitalizaron con un escáner de preparaciones completas Aperio/Leica AT2 a 20× aumentos, con una resolución de escaneo de 50.000 píxeles por pulgada (0,5 µm/píxel). Las anotaciones se realizaron sobre 85 de esas imágenes de lámina completa (WSI). Al igual que en el muestreo tisular todas las imágenes fueron segmentadas manualmente por patólogos experimentados con un amplio conocimiento de la histología del cáncer de próstata. Las regiones anotadas se clasificaron en 14 categorías histológicas distintas que reflejan patrones morfológicos reconocidos en la práctica clínica.

Cada WSI anotada se dividió en parches cuadrados de tamaño $H \times H = 224 \times 224$ píxeles, y para evitar continuaciones directas entre una imagen y otra se aplicó un paso (*stride*) de $p = 256$ píxeles. Un parche se asignaba a una clase concreta si más del 75 % de sus píxeles pertenecían a una región anotada como dicha clase; en caso contrario, se descartaba.

Respecto a las clases aparece cierto grado de confusión entre las siguientes casos. Estas similitudes han sido halladas mediante el análisis de las matrices de confusión de los 5 modelos, considerando que únicamente existe una confusión real entre clases cuando todos los modelos la presentan. Además como referencia se usará los datos de la matriz de confusión de swin_small_patch4_window7_224 que se pueden observar en la figura 9.10:

- **Gleason 3, glándulas no neoplásicas y glándulas 4 fusionadas:** Dado el conjunto de imágenes de Gleason 3 un 8,6 % es clasificado como glándula no neoplásica y 4,7 % como Gleason 4 fusionadas.
- **Gleason 4 fusionadas con Gleason 3 y Gleason 4 cribiformes:** Las imágenes son clasificadas como Gleason 3 en 1,6 % de los casos y en Gleason 4 cribiformes en un 4 %.
- **Glomeruloides con Gleason 4 cribiformes:** Las imágenes son clasificadas en la clase incorrecta en un 32 % de los casos y un acierto de 52 %. Cabe destacar el caso del mo-

delo efficientnetv2_s el cual llega a tener una clasificacion incorrecta como cribiformes del 36 % y un acierto del 48 %.

- **Gleason 5 comedonecrosis con Gleason 4 cribiformes:** Este error de clasificacion es espcialmente particular, pues lo modelos de clasificar mal una muestra solo es clasificada en la clase Gleason 4 cribiformes. Todos los modelos presentan un error similar, 14,28 % de clasificacion incorrecta frente al 85,7 % de acierto. El caso más grave lo presenta el modelo Resnet50 con 23,21 % en la clase equivocada nombrada y un 66,07 % de acierto.

G3 estan bien delimitadas y en g4 hay una organización más anormal, según la partición que haga una clasificación gleason 3 puede pertenecer a gleason 4, depende subjetividad

Ambas son proliferacion tumorales de patrón cribiforme, por lo que mantienen una estructura similar lo único que difieren es en la necrósis central que presentan gleason 5 que puede ser dificil de determinar si ocupa superficie menor o si no aparece bien en el parche.

[REVISAR: traducción casi literal; parafrasear y citar] [REVISAR: añadida la frase de las 85 WSI anotadas (dato del artículo, como se pidió); la primera frase atribuye el apartado al artículo, en lugar del título «información extraída del paper de Iván Sevillano» de las notas]

8.2. Partición e integridad

Inicialmente el repositorio cuenta con dos subcarpetas, `train` y `val`, con un total de 126.109 imágenes (113.491 en `train` y 12.618 en `val`), cuya distribución por clase se recoge en la cuadro 8.2. **[REVISAR: las notas daban un total de 126.192; el real es 126.109 (113.491 + 12.618; results_integridad)] [REVISAR: la figura de tarta de las notas se sustituye por la cuadro 8.2, generada a partir de results_integridad]**

El primer reto al que nos enfrentamos es el de poder crear un modelo de aprendizaje supervisado que, dada una imagen de nuestro conjunto de datos, sea capaz de clasificarla en una de las respectivas clases con la mayor precisión posible.

Para comenzar se necesita un conjunto de entrenamiento, uno de validación y uno de test. Así pues, dada la estructura inicial del conjunto de datos, se optó por utilizar el directorio `val`, que presentaba una menor cantidad de imágenes en comparación con `train`, para realizar el test, y a su vez `train` se dividió de forma estratificada por clase, en proporción 80/20, en dos carpetas: una mayor para el entrenamiento y una menor para la validación. Se cuenta así con un total de 90.800 imágenes para entrenamiento, 22.691 para validación y 12.618 para test. El reparto se hizo sin fijar una semilla aleatoria, por lo que no es reproducible. **[REVISAR: añadidos el carácter estratificado 80/20 de la división y la ausencia de semilla (results_integridad, apartado 5)]**

Categoría	Clase	Descripción
Tejido no maligno	Estroma (HS)	Tejido de sostén de la próstata; es músculo liso y tejido conjuntivo.
	Glándulas no neoplásicas (NG)	Glándulas prostáticas normales. Son estructuras huecas con dos capas de células (basal y luminal).
	Tejido sano no estromal	Tejido benigno que no pertenece a ninguna de las clases anteriores, como por ejemplo vasos sanguíneos o tejido adíposo. Se trata de una clase pequeña.
	Tejido inflamatorio	Acúmulo de células inmunitarias; no se trata de cáncer y se identifica mediante muchos núcleos pequeños, oscuros, redondos y muy juntos.
Gleason 3	Gleason 3 (G3)	Cáncer con glándulas bien formadas e individuales. Más pequeñas que las normales y se encuentran entre glándulas sanas.
Gleason 4	Cribiformes (G4c)	Masa grande de células atravesada por muchas luces pequeñas, como un colador.
	Fusionadas (G4f)	Glándulas que se han unido unas con otras sin estroma entre ellas, formando estructuras irregulares.
	Pobremente formadas (G4p)	Debido a que en el campo de la medicina hay muchas escalas de grises, ciertas muestras no pueden ser clasificadas en ninguna clase en concreto por lo que se decide clasificar todas estas muestras independientes en una misma clase conjunta. Correspondería a una subclase de Gleason 4 caracterizadas por ser estructuras glandulares tumorales pequeñas, irregulares y mal definidas, con luces glandulares difíciles de identificar o prácticamente ausentes. Presentan una arquitectura incompleta que impide reconocer la formación de glándulas bien delimitadas, característica del patrón Gleason 3.
	Glomeruloides (G4g)	Glándula dilatada con un ovillo de células dentro, unido a un lado de la pared.
Gleason 5	Comedonecrosis (G5c)	Nidos sólidos o cribiformes de células tumorales con un centro de células muertas (necrosis), que se ve como un material rosado y sucio con restos de núcleos.
	Sin glándulas	El tumor ya no forma glándulas. Aparecen láminas sólidas, cordones o células sueltas infiltrando el estroma. Es el patrón más agresivo.
Lesiones que no se gradúan con Gleason	PIN de alto grado	Conductos y glándulas preexistentes (con su forma normal) revestidos por células con aspecto atípico (núcleos grandes, nucléolos visibles).
	Carcinoma intraductal (IC)	Células malignas que rellenan y ensanchan los conductos existentes, formando patrones sólidos o cribiformes densos y con mucha más atipia que el PIN.
	Adenocarcinoma ductal (DA)*	Una variante del cáncer de próstata que crece formando glándulas grandes revestidas por células altas y alargadas (cilíndricas), a menudo con estructuras papilares.

Tabla 8.1.: Explicación breve de cada clase.

* DA presenta 13117 parches pero de solo 12 pacientes; esto refleja la alta probabilidad de que se entrene con parches de una misma lámina que también presente parches en test.

Tabla 8.2.: Número de imágenes por clase en la partición original del conjunto ID (carpetas `train` y `val`) y en la partición usada en este trabajo (el `train` original dividido 80/20 por clase en entrenamiento y validación; el `val` original como test).

	Original		Partición del TFG		
Clase	Train	Val	Train	Validación	Test
`Adenocarcinoma_ductal`	18.917	2.102	15.134	3.783	2.102
`Carcinoma_intraductal`	1.083	121	867	216	121
`Estroma`	22.219	2.469	17.776	4.443	2.469
`Glandulas_no_neoplasicas`	32.304	3.590	25.844	6.460	3.590
`Gleason_3`	2.275	253	1.820	455	253
`Gleason_4_cribiformes`	12.723	1.414	10.179	2.544	1.414
`Gleason_4_fusionadas`	6.938	771	5.551	1.387	771
`Gleason_4_glomeruloide`	218	25	175	43	25
`Gleason_4_pobremente_formadas`	1.136	127	909	227	127
`Gleason_5_comedonecrosis`	499	56	400	99	56
`Gleason_5_no_glandulas`	10.908	1.213	8.727	2.181	1.213
`Inflamatorio`	714	80	572	142	80
`No_Cancer`	1.081	121	865	216	121
`PIN_de_alto_grado`	2.476	276	1.981	495	276
Total	113.491	12.618	90.800	22.691	12.618

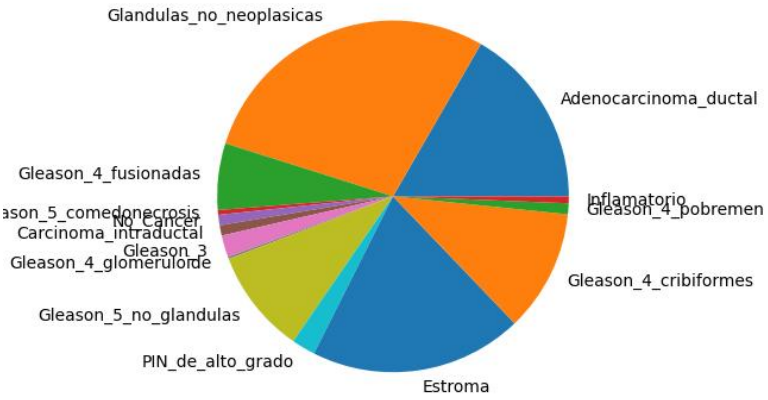

Figura 8.1.: Distribución por clase del conjunto de entrenamiento. **[REVISAR: pie de figura redactado por el agente; las etiquetas de la gráfica aparecen cortadas y solapadas: regenerar]**

8.2.1. Verificación de la integridad

[PENDIENTE: verificación de la integridad de la partición]

Tabla 8.3.: Diseño de los conjuntos OOD: papel de cada conjunto, qué cambia respecto al conjunto ID y objetivo de su inclusión. Entre paréntesis, el número de imágenes.

Conjunto	Papel	¿Qué cambia respecto al ID?	Objetivo
(A) NCT-CRC: TUM + NORM (23.080)	Near-OOD	Otro órgano (colon, tejido glandular) y otro centro; misma escala	Buscamos ver si es capaz de rechazar un tejido muy parecido al original
(B) NCT-CRC: STR, LYM, MUS (por separado)	Control interno	Otro centro; tejidos parecidos a clases de entrenamiento (estroma e inflamatorio)	Tejidos nuevamente parecidos a ID: determinamos si descarta por el centro o por el tejido
(C) PANDA (10.000) [8, 28]	Cambio de centro y de escala	Mismo órgano (próstata), otros centros y escáneres; aumento mucho menor (cada tesela abarca una región de tejido mucho mayor) y más fondo blanco	Comprobar si el detector señala tejido del mismo órgano adquirido en condiciones muy distintas
Control de resolución (12.618)	Control	Las mismas imágenes del test ID, reducidas a 128 px y ampliadas a 224 px	Valorar únicamente el efecto de la pérdida de detalle (no reproduce la escala de PANDA)
DTD / *Textures*	Far-OOD	No es tejido: texturas genéricas	Referencia sencilla: el detector debe señalarla como OOD
NCT-CRC: ADI, BACK, DEB, MUC	Anexo (capítulo B)	Grasa, fondo, restos, moco	

8.3. Conjuntos OOD

Cuadro 8.3 resume los conjuntos OOD empleados, el papel de cada uno y qué cambia respecto al conjunto ID.

[REVISAR: tabla de las notas: corregidas erratas y redacción mínima («si descarta por el centro o por el tejido», «discriminación», «órgano»)]

8.3.1. NCT-CRC-HE-100K-NONORM

- Este es un conjunto de 100.000 parches no superpuestos de imágenes histológicas teñidas con hematoxilina y eosina (H&E) de cáncer colorrectal humano (CRC) y tejido normal [31, 32].
- Todas las imágenes son de 224×224 píxeles (px) a 0,5 micras por píxel (MPP). Se utiliza la versión NONORM, generada a partir de los mismos datos originales pero sin normalización de color, para no introducir un cambio artificial en la distribución [44].
- Las clases de tejido son: tejido adiposo (ADI), fondo (BACK), desechos (DEB), linfocitos (LYM), moco (MUC), músculo liso (MUS), mucosa normal del colon (NORM), estroma asociado al cáncer (STR) y epitelio de adenocarcinoma colorrectal (TUM).
- Estas imágenes se extrajeron manualmente de $N = 86$ portaobjetos de tejido de cáncer humano teñidos con H&E, de muestras embebidas en parafina y fijadas en formalina (FFPE) del NCT Biobank (Centro Nacional de Enfermedades Tumorales, Heidelberg, Alemania) y del archivo de patología UMM (University Medical Center Mannheim, Mannheim, Alemania). Las muestras de tejido contenían portaobjetos tumorales primarios de CRC y tejido tumoral de metástasis hepáticas de CRC; las clases de tejido normal se aumentaron con regiones no tumorales de muestras de gastrectomía para aumentar la variabilidad.

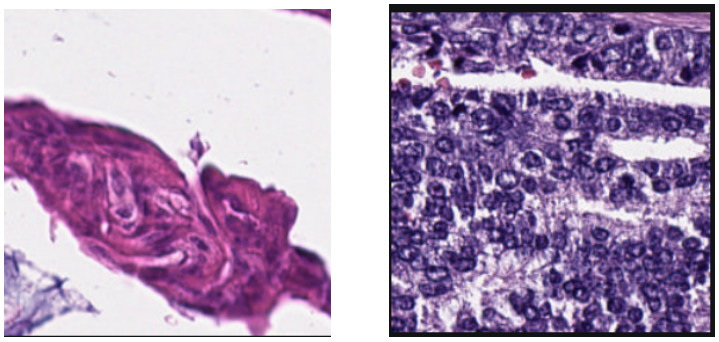

(a) (b)

Figura 8.2.: Comparativa del adenocarcinoma colorrectal frente al adenocarcinoma ductal del conjunto ID. **[REVISAR: figura extraída del docx, regenerar; indicar qué panel es cada tejido]**

[REVISAR: traducción casi literal; parafrasear y citar] [REVISAR: la referencia que acompañaba a NONORM en las notas (DOI 10.1109/ISBI.2009.5193250) es el método de normalización de Macenko, que se aplica a la versión normalizada NCT-CRC-HE-100K y no a NONORM: reubicar la cita] [REVISAR: el enlace al conjunto de datos (Zenodo) de las notas se sustituye por la cita a Kather et al.]

El control interno consiste en evaluar el detector con distintas clases de un mismo conjunto de datos, NCT-CRC-HE-100K [32]. Todas sus imágenes proceden del mismo centro y presentan, por tanto, el mismo *covariate shift* respecto a los datos ID, pero solo TUM y NORM son tejido de otro órgano (*semantic shift*). Las clases consideradas son TUM (epitelio de adenocarcinoma colorrectal), NORM (mucosa colónica normal), STR (estroma asociado al cáncer, que cabría esperar que se parezca a la clase ID de estroma, HS), LYM (linfocitos, que cabría esperar que se parezcan a la clase ID Inflamatorio) y MUS (músculo liso, que también podría parecerse al estroma ID, ya que el estroma prostático contiene músculo liso). Si el detector rechaza las imágenes de STR, LYM y MUS con la misma capacidad que las de TUM y NORM, aunque se parezcan más a las clases ID, esto indicaría que es sensible principalmente al *covariate shift*. Las imágenes de PANDA son del mismo órgano, pero proceden de otros centros y se adquirieron a una escala muy distinta, por lo que combinan varios cambios respecto a los datos ID; el control de imágenes ID a 128 px permite valorar únicamente el efecto de la pérdida de detalle. Por último, el conjunto Textures (DTD) sirve como referencia de que el detector funciona correctamente.

8.3.2. PANDA

PANDA (próstata de otros centros). Biopsias del mismo órgano (próstata) y mismo tipo de tinción, pero de escáneres y hospitales distintos (Karolinska Institute / Radboud University) [8]. Se utilizan 10.000 teselas de 128×128 px del conjunto público preparado por iafoss [28]. En él, cada biopsia se lee en el nivel de menor resolución de la imagen original, se divide en teselas de 128×128 px y se conservan las 16 con más tejido, es decir, las de menor suma de intensidades. A esta escala, cada tesela abarca una región de tejido mucho mayor que un parche ID (en ella caben decenas de glándulas). Si una biopsia no llega a 16 teselas, se completan con teselas blancas, lo que explica las 291 teselas sin tejido presentes

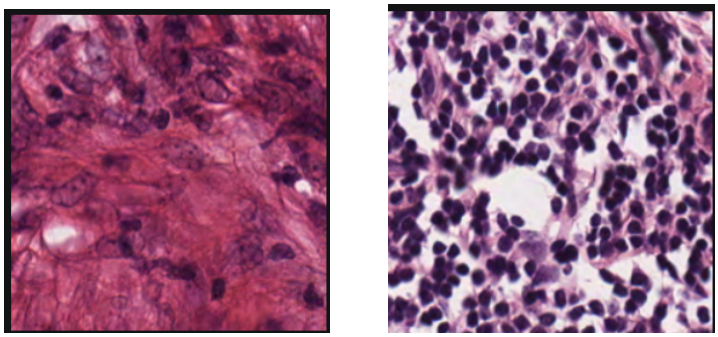

(a) STR (b) LYM

Figura 8.3.: Ejemplos de imágenes de STR y LYM. **[REVISAR: figura extraída del docx, regenerar; comprobar el orden de los paneles]**

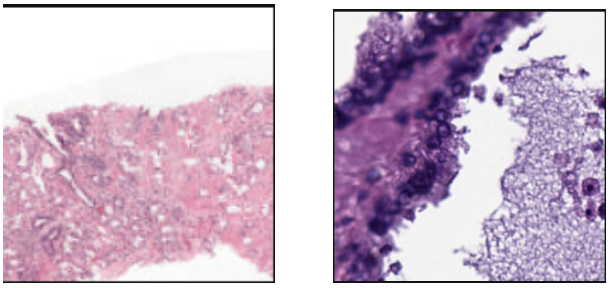

(a) (b)

Figura 8.4.: PANDA frente a nuestras imágenes ID. **[REVISAR: figura extraída del docx, regenerar; indicar qué panel es cada conjunto]**

en el conjunto. Para su evaluación, las teselas se reescalan a 224 px.

De las 168.256 teselas del conjunto (10.516 biopsias con 16 teselas cada una), se seleccionaron al azar 10.000 (muestreo uniforme sin reemplazo, sin semilla fija), procedentes de 6.568 biopsias distintas (entre 1 y 6 teselas por biopsia; mediana 1).

8.3.3. Control de resolución y DTD

[PENDIENTE: control de resolución y DTD [10]]

8.4. Entorno de ejecución

Vamos a usar el repositorio OpenOOD [77] para continuar con nuestro análisis de resultados. **[REVISAR: el enlace a GitHub se sustituye por la cita; el enlace al cuaderno de Colab con la explicación de uso y su captura de pantalla no van a la memoria]**

[PENDIENTE: hardware y software]

8.5. Protocolo de entrenamiento

8.5.1. DataLoader

Para una primera aproximación del modelo hemos decidido crear un conjunto de imágenes menor a partir del original, el cual sirve para pruebas y para comprobar el funcionamiento correcto de nuestro modelo antes de pasar a entrenar con el conjunto de datos original. Este, al igual que el conjunto de datos original, cuenta con tres carpetas: inicialmente se seleccionaron 10 imágenes de cada carpeta de la estructura original del conjunto de datos para crear uno nuevo, pero con un número mucho más reducido de imágenes. Posteriormente se aplicó el mismo procedimiento de separar `train` en dos nuevas carpetas de `train` y `val`, y el `val` original pasó a ser test. Debido a esto, el resultado final ha sido una estructura de tres carpetas: `train` con 139 imágenes, `val` con 55 y test con 167. **[REVISAR: la figura de tarta del conjunto reducido de las notas no se incluye; las cifras quedan en el texto]**

8.5.2. Learner

En cuanto al optimizador, vamos a usar AdamW (Loshchilov y Hutter [43]), pues se trata de una versión mejorada del optimizador Adam (Kingma y Ba [33]) con la mejora añadida de que cuenta con *weight decay* (apartado 3.4). En la implementación de fastai es cierto que el nombre asociado es el de Adam, pero es debido a una decisión de fastai de adoptar la versión mejorada del optimizador bajo el nombre de la original. **[REVISAR: las notas citaban solo a Kingma y Ba (Adam); para AdamW la cita correcta es Loshchilov y Hutter (2019)]**

Debido a la complejidad del problema, no tardó en aparecer el error de memoria *CUDA out of memory*. Para manejar este problema sin alterar la arquitectura del modelo **[PENDIENTE: sustituir por fuente académica]** se optó por reducir el tamaño del lote a la mitad, pasando así de 128 imágenes por lote a 64. Las otras medidas tomadas fueron adaptar el *learner* para trabajar con precisión de 16 bits [47], ahorrando así memoria, liberar la caché de la memoria al iniciar la ejecución y, por último, reducir el número de *workers* de 8 a 4, planteando la posibilidad de que la creación de hebras separadas para el tratamiento del problema pudiera estar influyendo en una mayor lentitud de ejecución del modelo. **[REVISAR: «infiriendo» corregido a «influyendo»] [REVISAR: añadida la cita a Micikevicius et al. (2018) para la precisión mixta]**

[PENDIENTE: completar la configuración del entrenamiento (preprocesado, pérdida con *label smoothing*, política de entrenamiento y parada temprana)] [PENDIENTE: explicar la diferencia de protocolo: Swin-S con `fit_one_cycle` sin congelar; los otros cuatro modelos con `fine_tune`]

Llegados a este punto, solo queda probar con diversos modelos ya preentrenados, hacerles un ajuste fino (*fine tuning*) y analizar cuál genera mejores resultados, que será por tanto con el que sigamos trabajando a lo largo del proyecto (capítulo 9).

9. Clasificación ID

[PENDIENTE: introducción del capítulo: cinco arquitecturas preentrenadas con ajuste fino (ViT-B/16, ResNet-50, ConvNeXt-S, EfficientNetV2-S y Swin-S) y evaluación en el test ID]

9.1. Comparación de los cinco modelos

9.1.1. Resultados globales

[REVISAR: la tabla de exactitudes de las notas (salida de `resultados.txt`) se sustituye por la cuadro 9.1, generada a partir de results_fase1, con IC; las exactitudes coinciden salvo Swin-S (0,96870 → 0,9688) y ResNet-50 (0,89634 → 0,8964), por una imagen de diferencia en la inferencia con precisión mixta]

[PENDIENTE: análisis de la cuadro 9.1] [PENDIENTE: la comparación no es homogénea: Swin-S y los otros cuatro modelos se entrenaron con protocolos distintos (apartado 8.5.2); explicar su efecto]

[PENDIENTE: conclusión parcial]

9.1.2. Curvas de entrenamiento y matrices de confusión

Pérdida en test: 0,6788; exactitud en test: 0,9525. **[PENDIENTE: análisis]**

Pérdida en test: 0,8892; exactitud en test: 0,8964. **[REVISAR: las notas daban 0,8963 (`resultados.txt`); se usa el valor de results_fase1]** **[PENDIENTE: análisis]**

Pérdida en test: 0,6424; exactitud en test: 0,9668. **[PENDIENTE: análisis]**

[PENDIENTE: análisis (pérdida en test: 0,6757; exactitud en test: 0,9538)]

[PENDIENTE: análisis (pérdida en test: 0,6356; exactitud en test: 0,9688)]

[PENDIENTE: conclusión parcial de las curvas y matrices de confusión]

9.1.3. Sensibilidad por clase

[PENDIENTE: análisis de la cuadro 9.2]

Tabla 9.1.: Clasificación de las 14 clases en el test ID (12.618 imágenes) con los cinco modelos: exactitud, F1 macro y *balanced accuracy* (más alto es mejor). IC del 95 % por *bootstrap* (1.000 remuestreos, semilla 0) sobre imágenes y sobre láminas (remuestreo de las 95 láminas). ConvNeXt-S se evalúa a 256 px y el resto a 224 px, cada uno con el preprocesado de su entrenamiento.

Modelo	Exactitud	IC 95 % (imagen)	IC 95 % (lámina)	F1 macro	IC 95 % (imagen)	IC 95 % (lámina)	*Balanced acc.*
Swin-S	0,9688	[0,9658; 0,9717]	[0,9589; 0,9768]	0,9082	[0,8919; 0,9224]	[0,8491; 0,9314]	0,8907
ConvNeXt-S	0,9668	[0,9635; 0,9700]	[0,9571; 0,9748]	0,9086	[0,8922; 0,9222]	[0,8583; 0,9322]	0,8990
EfficientNetV2-S	0,9538	[0,9500; 0,9575]	[0,9412; 0,9645]	0,8719	[0,8522; 0,8878]	[0,7906; 0,8963]	0,8583
ViT-B/16	0,9525	[0,9487; 0,9559]	[0,9391; 0,9631]	0,8740	[0,8565; 0,8883]	[0,8007; 0,8966]	0,8674
ResNet-50	0,8964	[0,8913; 0,9020]	[0,8687; 0,9166]	0,7620	[0,7434; 0,7796]	[0,6678; 0,7904]	0,7375

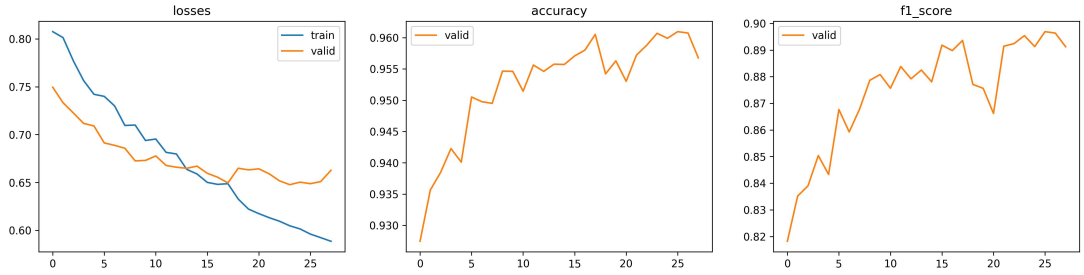

Figura 9.1.: ViT-B/16 (`vit_base_patch16_224`): curvas de entrenamiento.

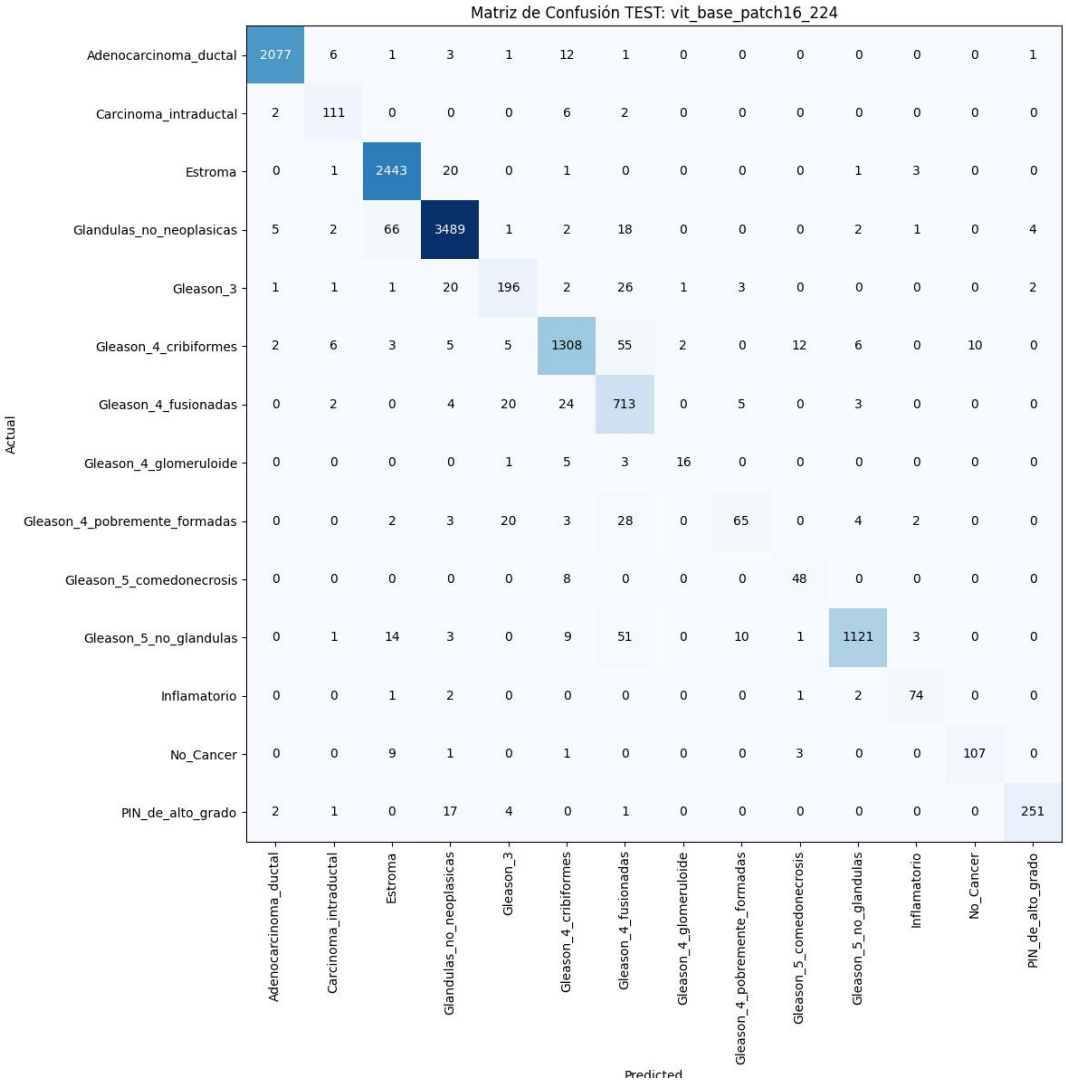

Figura 9.2.: ViT-B/16 (`vit_base_patch16_224`): matriz de confusión en el test.

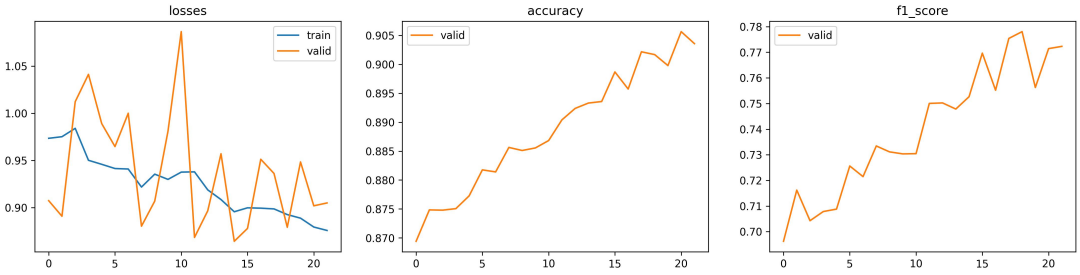

Figura 9.3.: ResNet-50 (`resnet50`): curvas de entrenamiento.

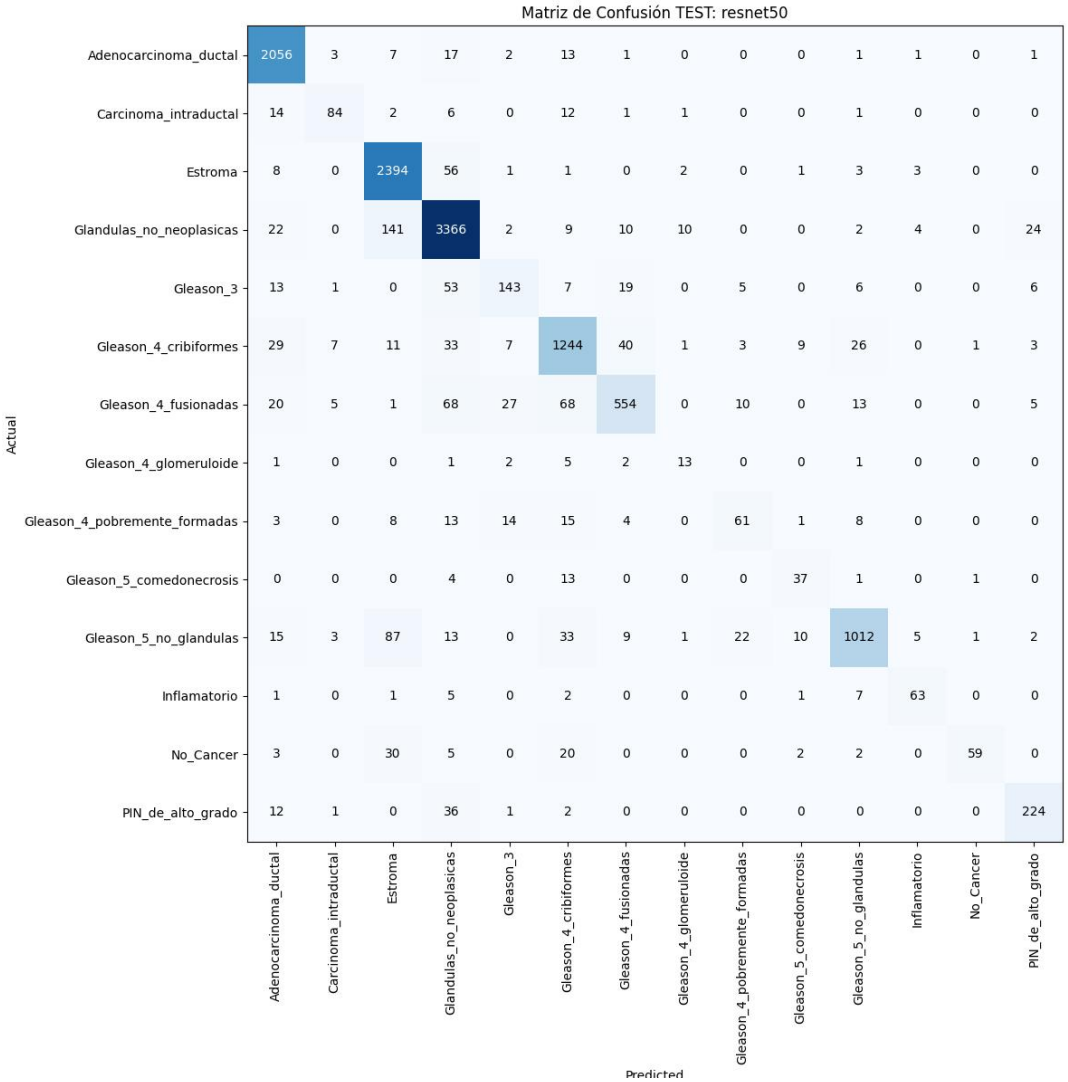

Figura 9.4.: ResNet-50 (`resnet50`): matriz de confusión en el test.

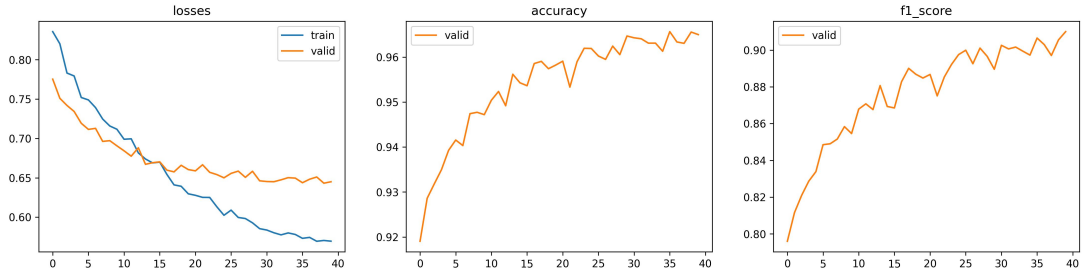

Figura 9.5.: ConvNeXt-S (`convnext_small`, entrenado y evaluado a 256 px): curvas de entrenamiento.

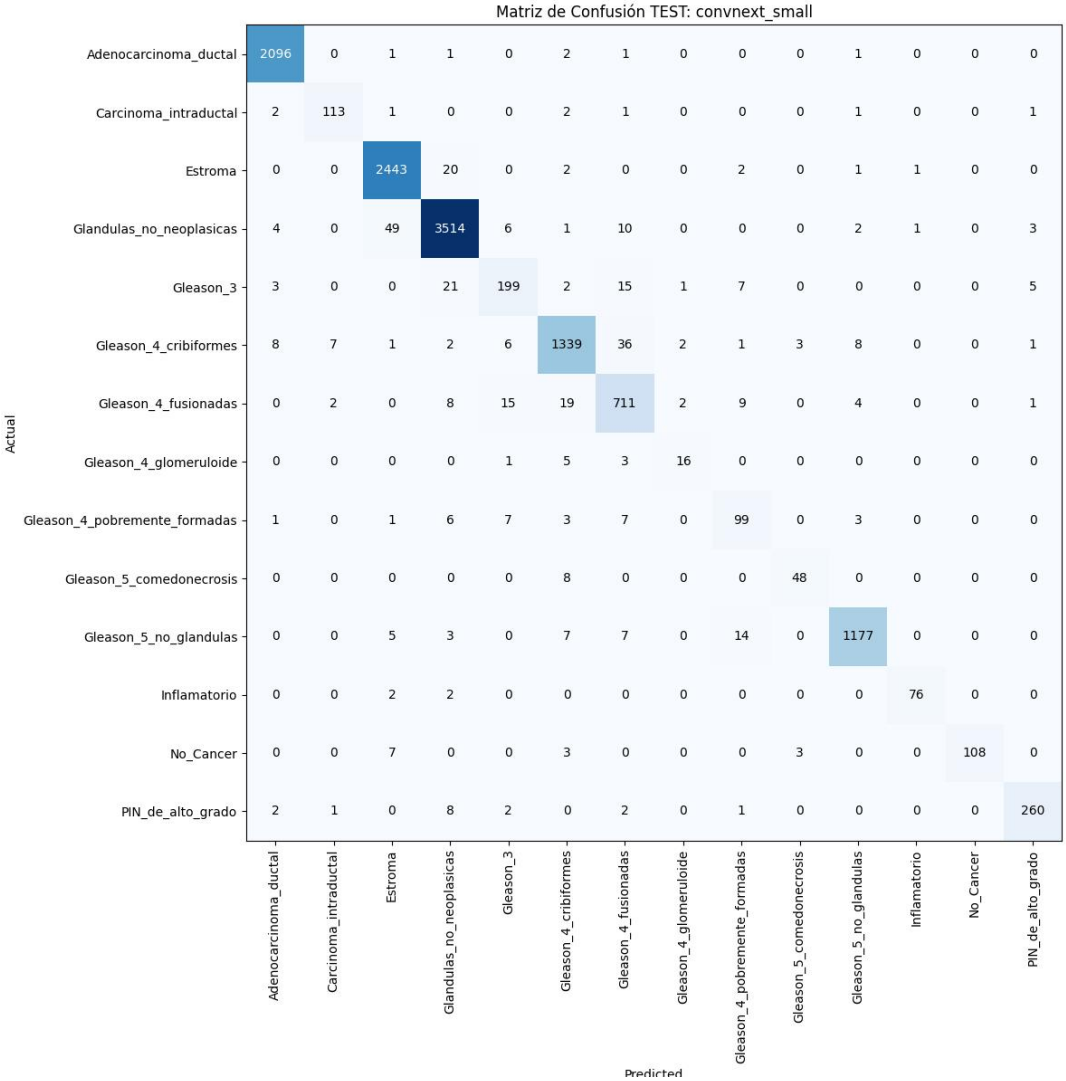

Figura 9.6.: ConvNeXt-S (`convnext_small`, entrenado y evaluado a 256 px): matriz de confusión en el test.

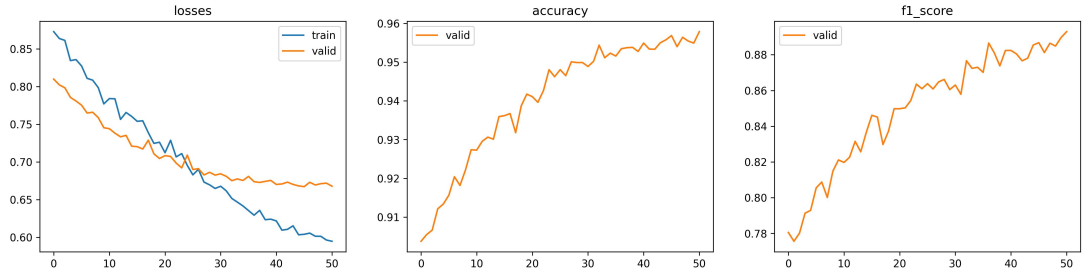

Figura 9.7.: EfficientNetV2-S (`tf_efficientnetv2_s`): curvas de entrenamiento.

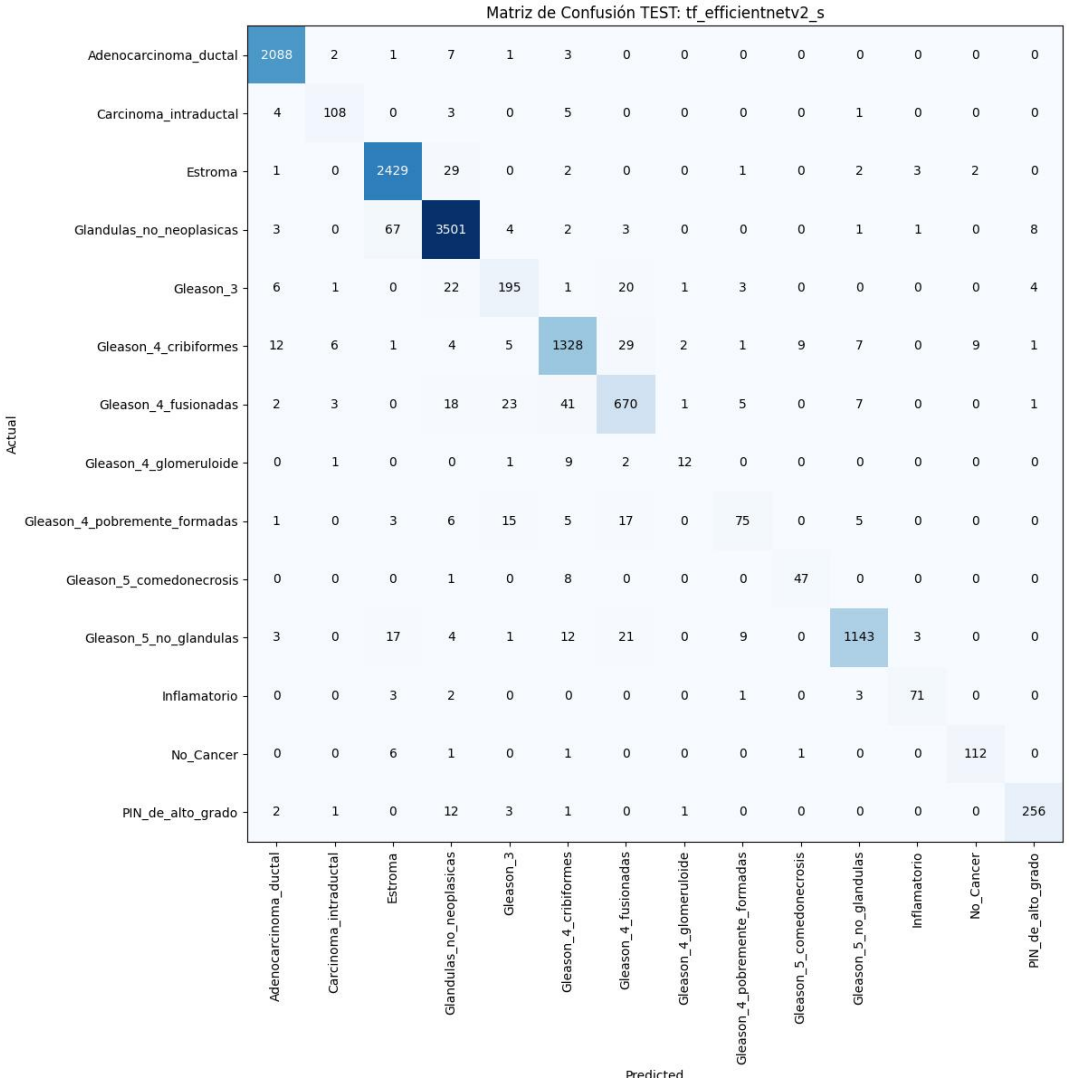

Figura 9.8.: EfficientNetV2-S (`tf_efficientnetv2_s`): matriz de confusión en el test.

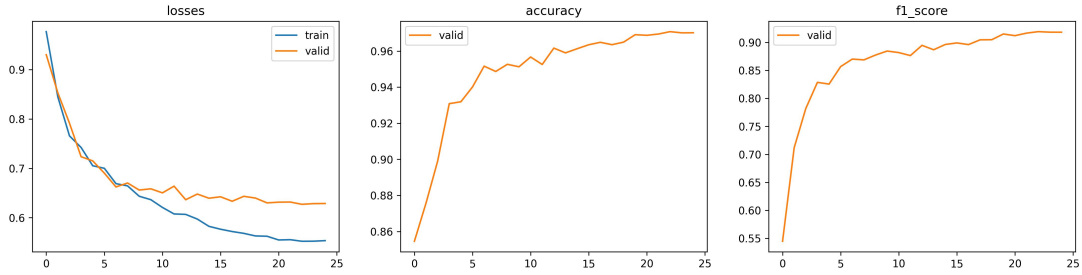

Figura 9.9.: Swin-S (`swin_small_patch4_window7_224`): curvas de entrenamiento.

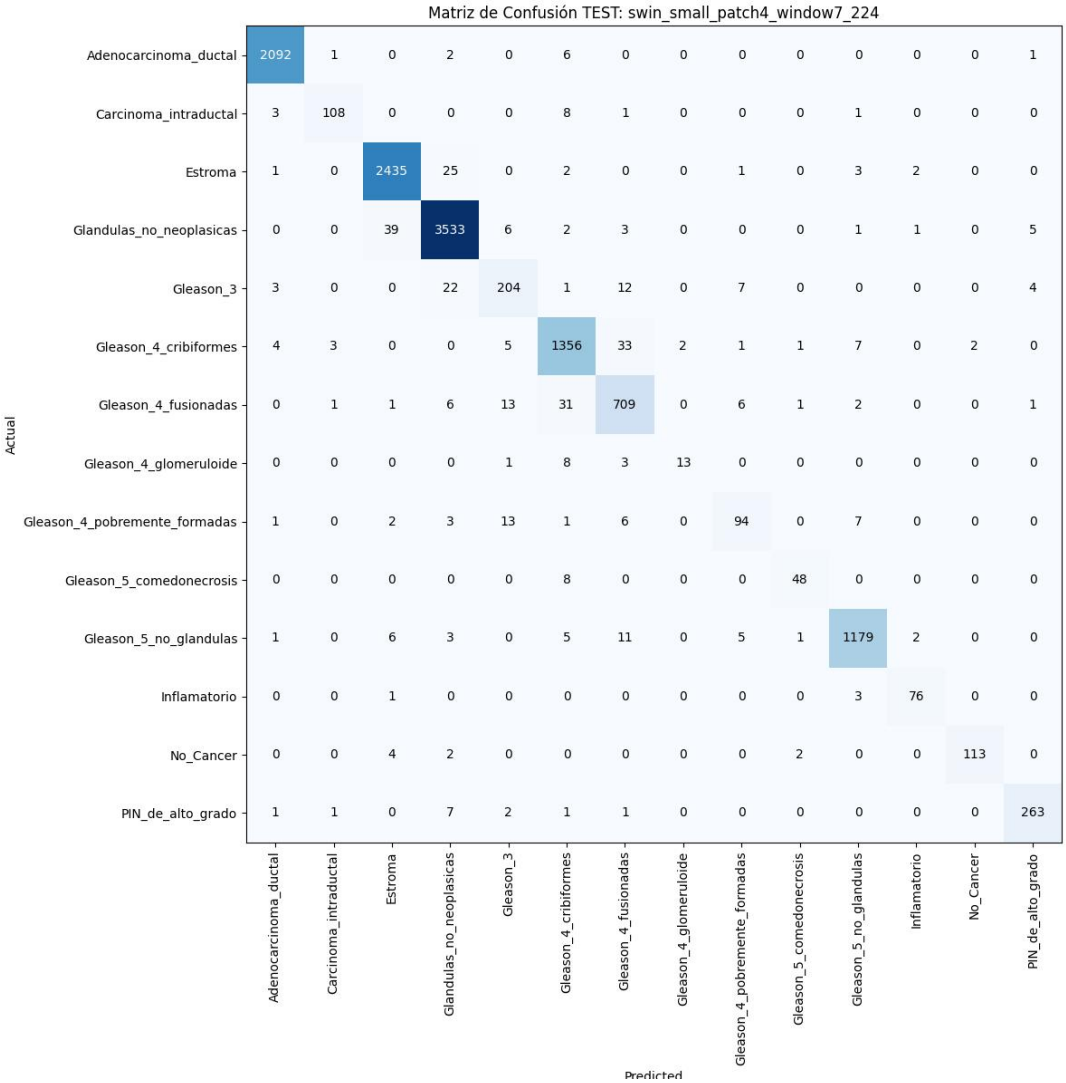

Figura 9.10.: Swin-S (`swin_small_patch4_window7_224`): matriz de confusión en el test.

Tabla 9.2.: Sensibilidad (*recall*) por clase en el test ID de los cinco modelos (más alto es mejor); n: imágenes de test de la clase. En negrita, el mejor valor de cada clase.

Clase	n	Swin-S	ConvNeXt-S	EfficientNetV2-S	ViT-B/16	ResNet-50
`Glandulas_no_neoplasicas`	3.590	**0,98**	0,98	0,98	0,97	0,94
`Estroma`	2.469	0,99	**0,99**	0,98	**0,99**	0,97
`Adenocarcinoma_ductal`	2.102	1,00	**1,00**	0,99	0,99	0,98
`Gleason_4_cribiformes`	1.414	**0,96**	0,95	0,94	0,93	0,88
`Gleason_5_no_glandulas`	1.213	**0,97**	0,97	0,94	0,92	0,83
`Gleason_4_fusionadas`	771	0,92	0,92	0,87	**0,92**	0,72
`PIN_de_alto_grado`	276	**0,95**	0,94	0,93	0,91	0,81
`Gleason_3`	253	**0,81**	0,79	0,77	0,77	0,57
`Gleason_4_pobremente_formadas`	127	0,74	**0,78**	0,59	0,51	0,48
`Carcinoma_intraductal`	121	0,89	**0,93**	0,89	0,92	0,69
`No_Cancer`	121	**0,93**	0,89	0,93	0,88	0,49
`Inflamatorio`	80	**0,95**	**0,95**	0,89	0,93	0,79
`Gleason_5_comedonecrosis`	56	**0,86**	**0,86**	0,84	**0,86**	0,66
`Gleason_4_glomeruloide`	25	0,52	**0,64**	0,48	**0,64**	0,52

Tabla 9.3.: Tabla de contingencia de aciertos de Swin-S y ConvNeXt-S sobre las mismas 12.618 imágenes de test. Test de McNemar: p exacto (binomial) $= 0{,}188$; χ^2 con corrección de continuidad $= 1{,}73$ ($p = 0{,}188$). *Bootstrap* pareado de la diferencia de exactitud Swin-S − ConvNeXt-S: +0,0020 [-0,0011; 0,0049] ($p = 0{,}18$; por lámina [-0,0013; 0,0049], $p = 0{,}24$); de F1 macro: −0,0004 [-0,0135; 0,0107] ($p = 0{,}98$).

	ConvNeXt-S acierta	ConvNeXt-S falla
Swin-S acierta	12.045	179
Swin-S falla	154	240

[PENDIENTE: conclusión parcial]

9.2. Elección del modelo

El modelo Swin Transformer obtiene la mayor exactitud (96,88 %), seguido muy de cerca por ConvNeXt (96,68 %). Dada la escasa diferencia entre ambos, cualquiera de los dos sería una base adecuada; se selecciona Swin por ser el que mejor resultado ha obtenido. **[REVISAR: exactitud del Swin-S: 96,87 % en las notas, 96,88 % en results_fase1 (valor único de la memoria)] [REVISAR: la diferencia no es estadísticamente significativa (McNemar $p = 0{,}19$, cuadro 9.3; ConvNeXt-S tiene además mayor F1 macro y *balanced accuracy*): la elección no puede justificarse por un mejor resultado, sino presentarse como elección entre dos modelos empatados]**

La superioridad de esta arquitectura radica en tres pilares fundamentales: **[REVISAR: justificación sin respaldo bibliográfico; reformular o citar Liu et al. 2021]**

1. **Jerarquización y ventanas desplazadas (*shifted windows*).** A diferencia de los Vision Transformers (ViT) estándar, que operan con parches globales, el Swin Transformer utiliza un mecanismo de ventanas jerárquicas. Esto permite capturar relaciones espaciales tanto a nivel local (textura, morfología de tejidos) como global (anatomía estructural de la lesión).

2. **Eficiencia en el contexto local.** La capacidad de contextualizar parches mediante ventanas de 7×7 (`window7`) permite que el modelo se enfoque en características relevantes

Tabla 9.4.: Clasificación agrupada en el test ID a partir de las predicciones de 14 clases (más alto es mejor). Cinco categorías: NM (`No_Cancer`, estroma, glándulas no neoplásicas, inflamatorio), G3, G4, G5 y NT (PIN de alto grado, carcinoma intraductal, adenocarcinoma ductal). Binario: maligno = G3 + G4 + G5 + NT. Sens.: sensibilidad; Esp.: especificidad; BA: *balanced accuracy*. Referencia: XCiT-Medium del artículo del conjunto de datos [4], con otro reparto de NM y NT (su BA se calcula como la media de Sens. y Esp.).

	5 categorías		Binario			
Modelo	Exactitud (%)	BA	Exactitud (%)	Sens.	Esp.	BA
Swin-S	98,25	0,945	99,33	0,991	0,996	0,993
ConvNeXt-S	98,07	0,940	99,25	0,991	0,994	0,992
EfficientNetV2-S	97,24	0,926	98,86	0,983	0,995	0,989
ViT-B/16	97,16	0,925	98,93	0,986	0,993	0,989
ResNet-50	93,08	0,840	96,02	0,942	0,979	0,960
XCiT-M (artículo)	98,34	–	99,25	0,984	0,997	0,990

sin verse afectado por el ruido de fondo, algo que los modelos de atención global (como `vit_base_patch16`) pueden ignorar al tratar todas las regiones por igual. **[REVISAR: «mediante window7» se ha desarrollado como «mediante ventanas de 7×7 (`window7`)»]**

3. **Inductividad de la imagen.** Al igual que ConvNeXt, el Swin Transformer integra principios de las redes convolucionales (sesgo inductivo), lo que facilita el aprendizaje de características jerárquicas desde resoluciones finas a gruesas. Esto permite una convergencia más eficiente y un mejor aprovechamiento de la información contenida en las imágenes médicas.

La diferencia mínima obtenida entre el Swin Transformer y ConvNeXt (+0,0020) indica que ambas arquitecturas están alcanzando un techo de rendimiento cercano al límite de información útil extraíble del conjunto de datos. **[REVISAR: diferencia corregida de 0,0019 a +0,0020 (results_fase1); además, la afirmación del «techo de rendimiento» no está respaldada por los resultados]**

- **Complementariedad de enfoques.** El hecho de que modelos basados en atención jerárquica y arquitecturas convolucionales modernas compitan por el primer puesto sugiere que las características más relevantes para el diagnóstico están siendo bien capturadas por ambos paradigmas.

Por tanto, el modelo con el que nos vamos a quedar para proseguir en nuestro estudio es el `swin_small_patch4_window7_224`.

[PENDIENTE: conclusión parcial]

9.3. Agrupaciones clínicas

[PENDIENTE: análisis de la cuadro 9.4]

[PENDIENTE: análisis de la cuadro 9.5 y de la figura 9.11]

[PENDIENTE: conclusión parcial]

Tabla 9.5.: Sensibilidad de las categorías G3, G4 y G5 en el test ID (más alto es mejor). Son las categorías directamente comparables con el artículo del conjunto de datos [4], porque coinciden en número de imágenes.

Modelo	G3 ($n = 253$)	G4 ($n = 2.337$)	G5 ($n = 1.269$)
Swin-S	0,806	0,968	0,968
ConvNeXt-S	0,787	0,964	0,965
EfficientNetV2-S	0,771	0,940	0,938
ViT-B/16	0,775	0,953	0,922
ResNet-50	0,565	0,864	0,835
XCiT-M (artículo)	0,814	0,967	0,978

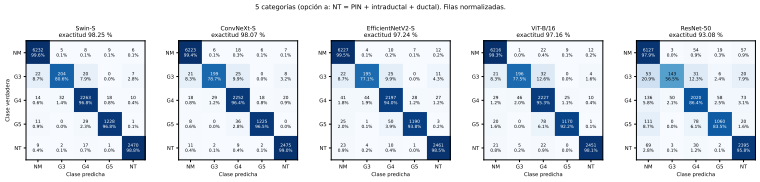

Figura 9.11.: Matrices de confusión de la clasificación agrupada en cinco categorías (NM, G3, G4, G5 y NT) en el test ID.

9.4. Discusión

[PENDIENTE: discusión global]

10. Detección OOD

[PENDIENTE: introducción del capítulo: modelo, 16 métodos (13 de OpenOOD y tres configuraciones de STOOD-X), nueve conjuntos (cuadro 8.3) y métricas (apartados 4.3.1, 4.3.2 y 4.3.4); IC por *bootstrap* (apartado 6.4)]

[REVISAR: la tabla principal de las notas (`tabla_principal_ood.tex`) se divide en una tabla por bloque; las tablas de AUPR van al capítulo A]

10.1. Near-OOD principal

Los resultados muestran una separación clara entre familias de métodos. Los métodos que operan sobre el espacio de características (ViM, MDS, KNN, RMDS y STOOD-X) superan de forma sistemática a los basados únicamente en los logits, en todos los conjuntos evaluados. En el near-OOD principal (NCT-CRC TUM + NORM), los primeros alcanzan un AUROC de entre 0,953 y 0,969, frente a 0,821–0,876 de MSP, MaxLogit y Energy. La diferencia es aún mayor en el punto de trabajo: el FPR@95 baja de 0,879 (MSP) a valores entre 0,128 y 0,173, y el CCR@FPR5 sube de 0,118 a más de 0,82. Esto indica que el vector de características de 768 dimensiones contiene información sobre la pertenencia a la distribución que se pierde al proyectarlo sobre los 14 logits. **[REVISAR: «de forma sistemática [...] en todos los conjuntos»: RMDS queda por debajo de MSP en LYM (AUROC 0,824 frente a 0,854, cuadro 10.3)] [REVISAR: el rango de FPR@95 (0,128–0,173) y el CCR@FPR5 (más de 0,82) valen para ViM, MDS, KNN y RMDS, pero no para STOOD-X (0,349 y 0,646)]**

Near-OOD principal. ViM (0,969 [0,968; 0,971]) y MDS (0,968) obtienen el mejor AUROC, mientras que RMDS logra el mejor FPR@95 (0,128) y el mejor CCR@FPR5 (0,868), con un AUROC significativamente inferior (0,954; cuadro 10.2). Ambos resultados no son contradictorios: el AUROC resume la separación en todos los umbrales, mientras que FPR@95 y CCR@FPR5 evalúan la zona de umbral exigente, que es la relevante en un contexto clínico (figura 10.2). Con el umbral que deja pasar solo el 5 % de las imágenes de colon, RMDS acepta y clasifica correctamente el 86,8 % del test ID, frente a un máximo posible de 96,9 %. No obstante, RMDS presenta un fallo marcado en la clase LYM (FPR@95 = 0,992; CCR@FPR5 = 0,008): una parte de los linfocitos de colon recibe puntuaciones superiores a las de las propias imágenes ID, por lo que ningún umbral permite rechazarlos sin descartar casi todo el ID. **[REVISAR: añadidas las referencias a la cuadro 10.2 y a la figura 10.2]**

[PENDIENTE: conclusión parcial]

10.2. Control interno: centro frente a tejido

Los resultados muestran que el principal motivo por el que una imagen se detecta como OOD es que procede de condiciones de adquisición distintas (otro centro y láminas no vistas). Con MDS, TUM (0,964), NORM (0,973) y LYM (0,967) obtienen los valores de AUROC más altos. El caso de LYM es el más revelador: pese a corresponder a un tipo de tejido presente en la próstata, se detecta con la misma capacidad que el tejido de colon. STR (0,944)

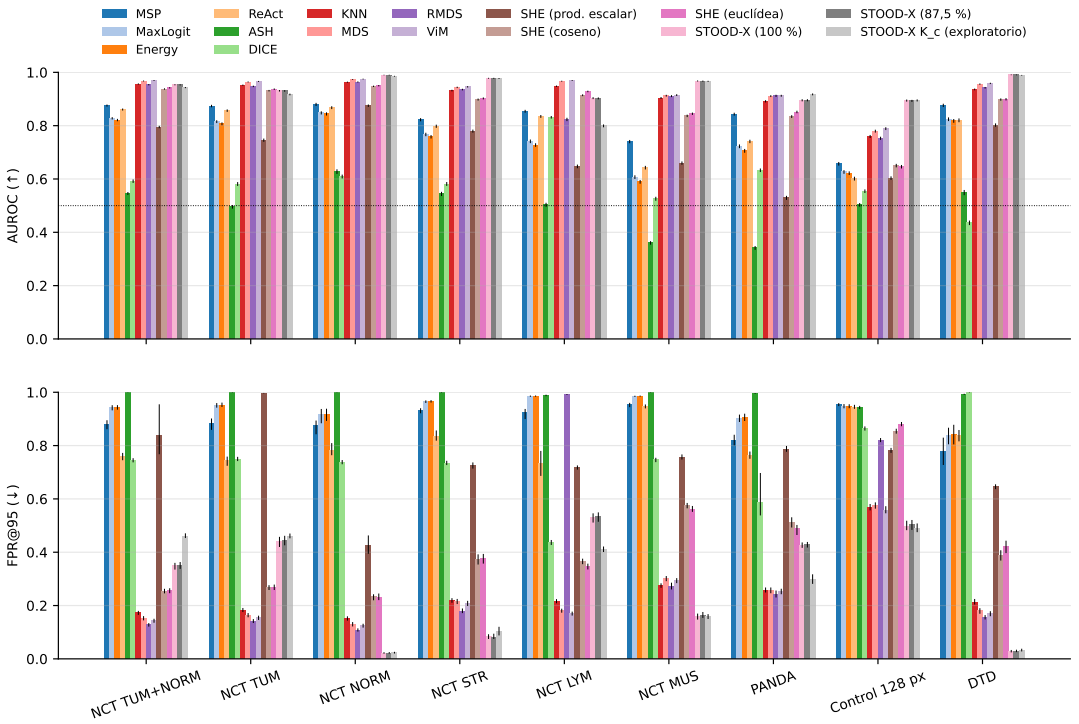

Figura 10.1.: AUROC (arriba; más alto es mejor) y FPR@95 (abajo; más bajo es mejor) de los 16 métodos en los nueve conjuntos, con IC del 95 % por *bootstrap*. Visión global de la comparación.

Tabla 10.1.: Near-OOD principal (NCT-CRC-HE-100K-NONORM, TUM+NORM): AUROC y CCR@FPR5 (más alto es mejor) y FPR@95 (más bajo es mejor) de los 16 métodos. IC del 95 % por *bootstrap* (1.000 remuestreos estratificados, semilla 0). Clase positiva: OOD. En negrita, el mejor valor entre los métodos no exploratorios. [a]ASH reduce la exactitud ID al 68,3 %. [†]Variante exploratoria ($K_c = \min(500, \lfloor n_c/2 \rfloor)$), propuesta tras ver datos OOD; no es el método principal.

Método	AUROC ↑ [IC 95 %]	FPR@95 ↓ [IC 95 %]	CCR@FPR5 ↑
Basados en logits			
MSP	0,876 [0,872; 0,879]	0,879 [0,861; 0,895]	0,118
MaxLogit	0,828 [0,823; 0,832]	0,942 [0,932; 0,952]	0,056
Energy	0,821 [0,817; 0,825]	0,944 [0,935; 0,952]	0,054
Modificación de activaciones			
ReAct	0,861 [0,857; 0,864]	0,760 [0,745; 0,773]	0,238
ASH[a]	0,546 [0,540; 0,551]	0,999 [0,998; 1,000]	0,001
DICE	0,592 [0,585; 0,598]	0,744 [0,737; 0,753]	0,254
Características y distancias			
KNN	0,956 [0,954; 0,958]	0,173 [0,165; 0,180]	0,825
MDS	0,968 [0,966; 0,969]	0,152 [0,144; 0,160]	0,844
RMDS	0,954 [0,951; 0,956]	**0,128** [0,121; 0,134]	**0,868**
ViM	**0,969** [0,968; 0,971]	0,143 [0,136; 0,150]	0,853
SHE (prod. escalar)	0,795 [0,790; 0,800]	0,837 [0,768; 0,955]	0,162
SHE (coseno)	0,938 [0,935; 0,940]	0,255 [0,246; 0,263]	0,743
SHE (euclídea)	0,942 [0,940; 0,944]	0,255 [0,246; 0,265]	0,742
STOOD-X			
STOOD-X (100 %)	0,953 [0,951; 0,955]	0,349 [0,335; 0,360]	0,646
STOOD-X (87,5 %)	0,953 [0,951; 0,955]	0,352 [0,338; 0,363]	0,644
STOOD-X K_c[†]	0,943 [0,941; 0,945]	0,461 [0,453; 0,471]	0,535

Tabla 10.2.: *Bootstrap* pareado (1.000 remuestreos, semilla 0) de la diferencia AUROC (RMDS) − AUROC (método) en el near-OOD principal (TUM+NORM). Diferencia positiva: RMDS es mejor. $p < 0{,}001$: ninguna réplica cruzó el cero. [a], [†]: como en cuadro 10.1.

Método	Diferencia	IC 95 %	p
MSP	+0,078	[0,075; 0,081]	$< 0{,}001$
MaxLogit	+0,126	[0,122; 0,130]	$< 0{,}001$
Energy	+0,133	[0,129; 0,136]	$< 0{,}001$
ReAct	+0,093	[0,090; 0,096]	$< 0{,}001$
ASH[a]	+0,408	[0,402; 0,414]	$< 0{,}001$
DICE	+0,362	[0,356; 0,369]	$< 0{,}001$
KNN	−0,003	[-0,004; -0,001]	0,00
MDS	−0,014	[-0,015; -0,012]	$< 0{,}001$
ViM	−0,016	[-0,017; -0,014]	$< 0{,}001$
SHE (prod. escalar)	+0,159	[0,155; 0,163]	$< 0{,}001$
SHE (coseno)	+0,016	[0,014; 0,018]	$< 0{,}001$
SHE (euclídea)	+0,012	[0,010; 0,014]	$< 0{,}001$
STOOD-X (100 %)	+0,000	[-0,002; 0,003]	0,75
STOOD-X (87,5 %)	+0,001	[-0,001; 0,003]	0,56
STOOD-X K_c[†]	+0,011	[0,008; 0,013]	$< 0{,}001$

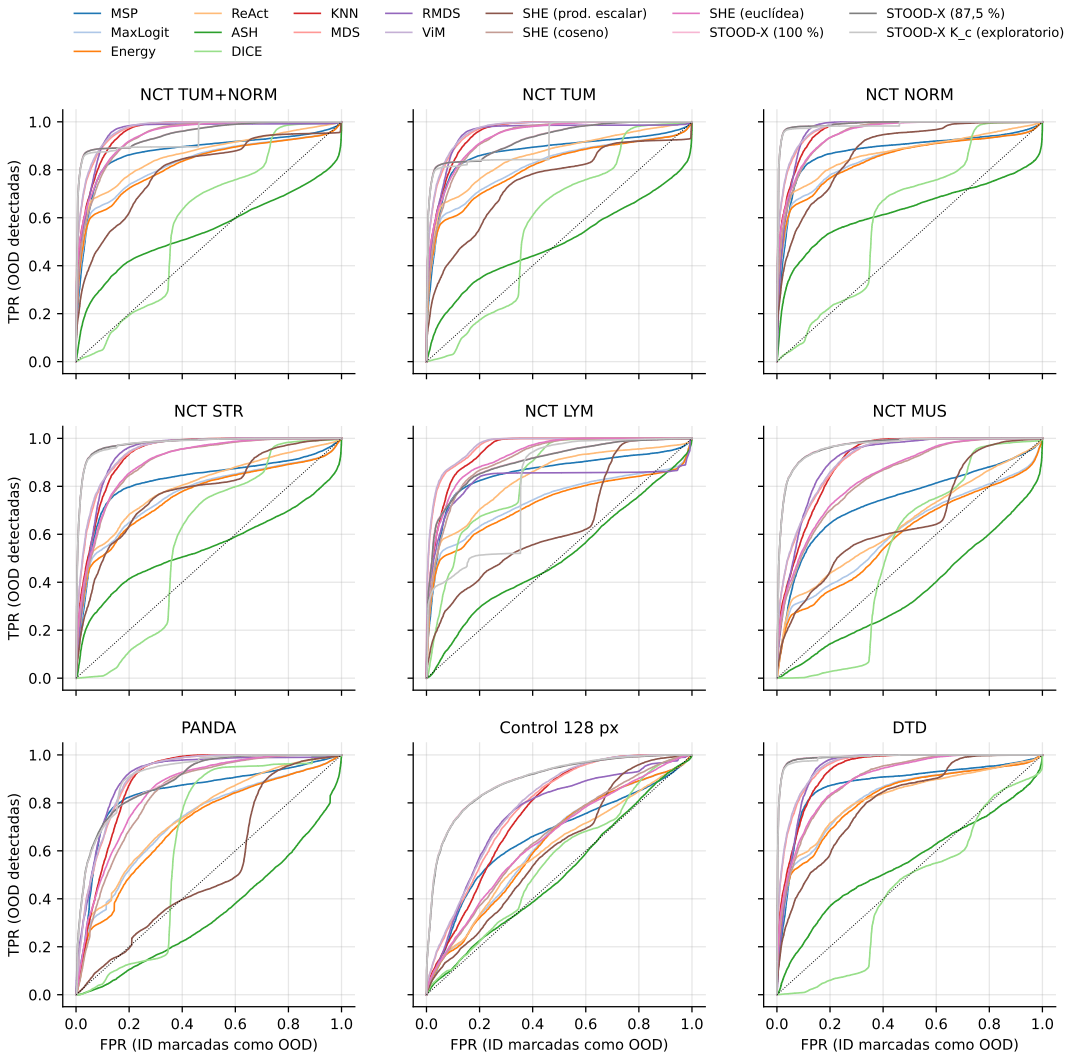

Figura 10.2.: Curvas ROC (TPR sobre OOD frente a FPR sobre ID) de todos los métodos, un panel por conjunto. Permiten ver dónde se separan los métodos: la zona de FPR baja frente al AUROC global explica por qué RMDS es el mejor en FPR@95 y no en AUROC.

Tabla 10.3.: Control interno con las clases de NCT-CRC-HE-100K-NONORM: tejido glandular de colon (TUM y NORM) frente a tejidos análogos a clases ID (STR, LYM y MUS). AUROC (más alto es mejor) y FPR@95 (más bajo es mejor). Clase positiva: OOD. [a]ASH reduce la exactitud ID al 68,3 %. [†]Variante exploratoria ($K_c = \min(500, \lfloor n_c/2 \rfloor)$), propuesta tras ver datos OOD; no es el método principal.

	AUROC ↑					FPR@95 ↓				
Método	TUM	NORM	STR	LYM	MUS	TUM	NORM	STR	LYM	MUS
Basados en logits										
MSP	0,873	0,880	0,823	0,854	0,740	0,882	0,875	0,931	0,923	0,954
MaxLogit	0,815	0,848	0,767	0,741	0,607	0,952	0,916	0,965	0,985	0,985
Energy	0,807	0,844	0,759	0,727	0,589	0,952	0,918	0,966	0,986	0,986
Modificación de activaciones										
ReAct	0,856	0,868	0,798	0,835	0,643	0,743	0,783	0,836	0,734	0,946
ASH[a]	0,496	0,628	0,544	0,504	0,361	0,999	0,999	0,998	0,989	0,999
DICE	0,581	0,609	0,581	0,831	0,525	0,750	0,738	0,734	0,436	0,746
Características y distancias										
KNN	0,952	0,963	0,932	0,948	0,904	0,183	0,152	0,219	0,216	0,275
MDS	0,964	0,973	0,944	0,967	0,912	0,164	0,129	0,215	0,181	0,301
RMDS	0,947	0,964	0,935	0,824	0,911	0,142	0,109	0,180	0,992	0,272
ViM	0,966	0,975	0,946	0,969	0,915	0,154	0,124	0,209	0,170	0,293
SHE (prod. escalar)	0,746	0,875	0,780	0,647	0,660	0,997	0,426	0,725	0,718	0,757
SHE (coseno)	0,931	0,948	0,898	0,914	0,837	0,267	0,233	0,373	0,365	0,574
SHE (euclídea)	0,937	0,950	0,902	0,928	0,845	0,267	0,231	0,378	0,346	0,562
STOOD-X										
STOOD-X (100 %)	0,931	0,990	0,978	0,903	0,968	0,440	0,022	0,083	0,531	0,159
STOOD-X (87,5 %)	0,930	0,990	0,978	0,903	0,967	0,444	0,022	0,082	0,533	0,164
STOOD-X K_c[†]	0,917	0,985	0,977	0,799	0,966	0,461	0,023	0,101	0,411	0,158

y MUS (0,912) resultan algo más difíciles de detectar, lo que indica que la similitud con las clases ID influye en parte, aunque los valores siguen siendo altos. Este resultado es coherente con lo señalado por Yang et al. [78]: los detectores OOD tienden a ser más sensibles al desplazamiento de covariables que al cambio semántico.

[PENDIENTE: conclusión parcial]

10.3. PANDA: cambio de centro y de escala

Respecto a PANDA, la comparación con el control debe interpretarse con especial cuidado, ya que sus imágenes presentan más diferencias que el mero reescalado. Además de proceder de otros centros, las teselas se extrajeron del nivel de menor resolución de las imágenes originales, con un aumento mucho menor, de modo que cada una abarca una región de tejido muy superior a los 112 μm de los parches ID; además, contienen mucho más fondo blanco (63 % frente a 21 %). Los métodos de distancia detectan PANDA (AUROC $\approx$ 0,91) mejor que el control ($\approx$ 0,77–0,79), pero esta diferencia no puede atribuirse solo al cambio de centro, ya que se combina con los cambios de escala y de contenido de fondo. En STOOD-X, ambos AUROC coinciden (0,895 y 0,894) y su puntuación no distingue PANDA del control (AUROC 0,475 [0,467; 0,482]). Sin embargo, cerca de un tercio de las imágenes de ambos conjuntos alcanza el valor extremo del estadístico (observación 6.8), por lo que esta coincidencia refleja la pérdida de capacidad de ordenación por saturación más que una sensibilidad específica a la resolución. Excluir las 291 teselas sin tejido no modifica ninguna de estas conclusiones. Aislar el efecto del centro requeriría extraer las imágenes de PANDA a la misma escala que

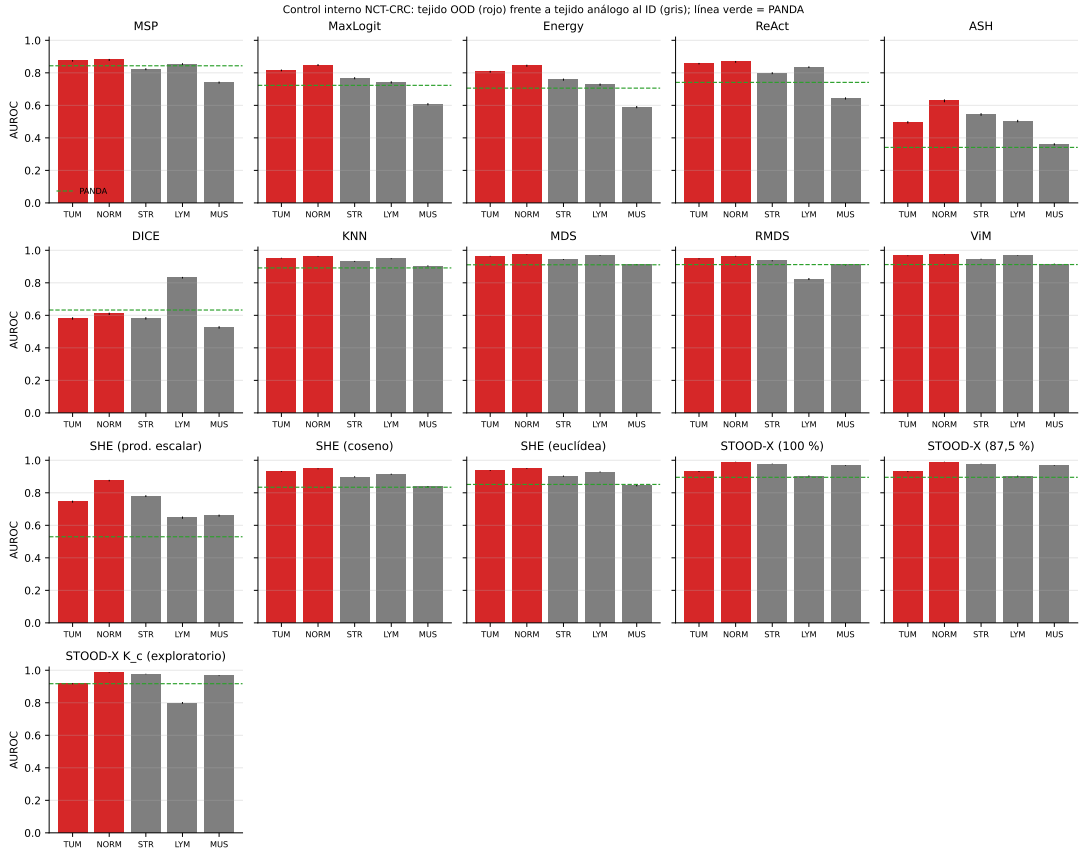

Figura 10.3.: AUROC por clase de NCT-CRC (TUM y NORM en rojo; STR, LYM y MUS en gris) para cada método, con PANDA como línea de referencia. Control interno del centro frente al tejido: si las clases afines se detectan casi igual que TUM y NORM, el detector responde al centro.

Tabla 10.4.: PANDA (próstata de otros centros, adquirida a una escala mucho menor) frente al control de resolución (las mismas imágenes del test ID reducidas a 128 px). AUROC (más alto es mejor) y FPR@95 (más bajo es mejor). Diferencia: AUROC de PANDA menos AUROC del control. IC del 95 % por *bootstrap* (1.000 remuestreos estratificados, semilla 0). Clase positiva: OOD. [a]ASH reduce la exactitud ID al 68,3 %. [†]Variante exploratoria ($K_c = \min(500, \lfloor n_c/2 \rfloor)$), propuesta tras ver datos OOD; no es el método principal.

	AUROC ↑ [IC 95 %]			FPR@95 ↓	
Método	PANDA	Control 128 px	Diferencia	PANDA	Control
Basados en logits					
MSP	0,843 [0,838; 0,849]	0,657 [0,650; 0,664]	+0,186	0,821	0,953
MaxLogit	0,723 [0,716; 0,730]	0,626 [0,619; 0,633]	+0,097	0,904	0,948
Energy	0,706 [0,698; 0,713]	0,622 [0,615; 0,629]	+0,084	0,905	0,948
Modificación de activaciones					
ReAct	0,741 [0,734; 0,747]	0,602 [0,594; 0,609]	+0,140	0,764	0,945
ASH[a]	0,341 [0,334; 0,348]	0,503 [0,496; 0,510]	-0,162	0,996	0,944
DICE	0,633 [0,626; 0,639]	0,554 [0,547; 0,561]	+0,079	0,586	0,864
Características y distancias					
KNN	0,892 [0,887; 0,896]	0,760 [0,754; 0,765]	+0,132	0,256	0,569
MDS	0,911 [0,907; 0,914]	0,780 [0,774; 0,785]	+0,131	0,257	0,575
RMDS	0,912 [0,908; 0,916]	0,753 [0,747; 0,759]	+0,159	0,241	0,821
ViM	0,912 [0,909; 0,916]	0,789 [0,784; 0,794]	+0,123	0,252	0,558
SHE (prod. escalar)	0,530 [0,522; 0,537]	0,603 [0,596; 0,610]	-0,073	0,787	0,783
SHE (coseno)	0,834 [0,829; 0,839]	0,651 [0,644; 0,657]	+0,184	0,514	0,854
SHE (euclídea)	0,851 [0,847; 0,856]	0,646 [0,639; 0,653]	+0,205	0,488	0,881
STOOD-X					
STOOD-X (100 %)	0,895 [0,891; 0,899]	0,894 [0,890; 0,898]	+0,001	0,427	0,497
STOOD-X (87,5 %)	0,895 [0,891; 0,899]	0,893 [0,889; 0,897]	+0,002	0,428	0,505
STOOD-X K_c[†]	0,917 [0,914; 0,921]	0,895 [0,891; 0,898]	+0,023	0,300	0,490

los datos ID, lo que queda como trabajo futuro.

[PENDIENTE: conclusión parcial]

10.4. Far-OOD

Finalmente, en Textures, STOOD-X obtiene el mejor resultado (AUROC 0,991), lo que confirma, como era de esperar, que las imágenes ajenas al contexto médico se detectan sin dificultad. Esta mayor dificultad de detecciónd de Near-OOD frente a Far-OOD coincide con los resultados también obtenidos en [81]. No obstante, con MDS (0,956) Textures resulta más difícil de detectar que TUM, NORM o LYM, lo que indica que la dificultad que encuentra cada detector no coincide necesariamente con la distancia semántica intuitiva. .

[PENDIENTE: conclusión parcial]

10.5. Métodos basados en logits y en modificación de activaciones

Métodos basados en logits y en modificación de activaciones. MSP supera a MaxLogit y a Energy en los nueve conjuntos, al contrario de lo habitual en la literatura. Una explicación plausible es el uso de *label smoothing* durante el entrenamiento, que comprime la escala de los logits; comprobarlo requeriría entrenar el modelo sin esta técnica. Los métodos que modifican activaciones, diseñados para redes con activaciones ReLU y BatchNorm, no se

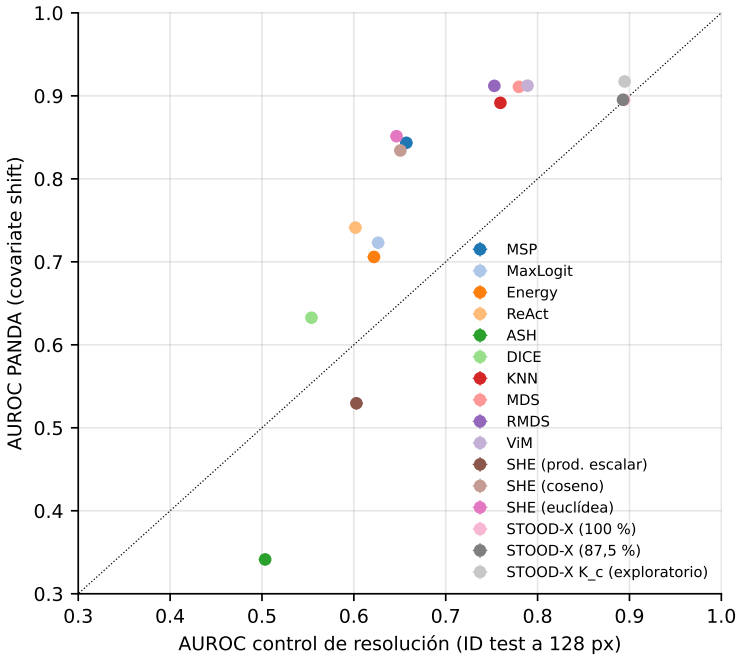

Figura 10.4.: AUROC en PANDA frente a AUROC en el control de resolución (test ID a 128 px), un punto por método con sus IC. La diagonal indica la misma capacidad de detección en ambos conjuntos. Como PANDA difiere también en escala y en contenido de fondo, quedar por encima de la diagonal no permite atribuir la diferencia solo al cambio de centro. STOOD-X queda sobre la diagonal por la saturación de su estadístico.

Tabla 10.5.: Far-OOD (DTD): AUROC y CCR@FPR5 (más alto es mejor) y FPR@95 (más bajo es mejor) de los 16 métodos. IC del 95 % por *bootstrap* (1.000 remuestreos estratificados, semilla 0). Clase positiva: OOD. En negrita, el mejor valor entre los métodos no exploratorios. [a]ASH reduce la exactitud ID al 68,3 %. [†]Variante exploratoria ($K_c = \min(500, \lfloor n_c/2 \rfloor)$), propuesta tras ver datos OOD; no es el método principal.

Método	AUROC ↑ [IC 95 %]	FPR@95 ↓ [IC 95 %]	CCR@FPR5 ↑
Basados en logits			
MSP	0,876 [0,870; 0,882]	0,780 [0,727; 0,830]	0,217
MaxLogit	0,824 [0,817; 0,831]	0,839 [0,805; 0,867]	0,158
Energy	0,818 [0,811; 0,825]	0,843 [0,805; 0,878]	0,154
Modificación de activaciones			
ReAct	0,820 [0,813; 0,827]	0,837 [0,816; 0,859]	0,160
ASH[a]	0,549 [0,539; 0,559]	0,993 [0,990; 0,994]	0,004
DICE	0,436 [0,427; 0,444]	0,999 [0,998; 1,000]	0,001
Características y distancias			
KNN	0,936 [0,933; 0,939]	0,214 [0,204; 0,225]	0,785
MDS	0,956 [0,953; 0,958]	0,181 [0,169; 0,190]	0,816
RMDS	0,942 [0,939; 0,945]	0,156 [0,148; 0,164]	0,840
ViM	0,959 [0,956; 0,961]	0,170 [0,160; 0,179]	0,827
SHE (prod. escalar)	0,802 [0,796; 0,809]	0,646 [0,637; 0,655]	0,353
SHE (coseno)	0,898 [0,894; 0,902]	0,387 [0,369; 0,407]	0,611
SHE (euclídea)	0,899 [0,895; 0,903]	0,422 [0,397; 0,443]	0,576
STOOD-X			
STOOD-X (100 %)	**0,991** [0,989; 0,992]	**0,028** [0,024; 0,033]	**0,949**
STOOD-X (87,5 %)	0,990 [0,989; 0,992]	0,030 [0,025; 0,034]	0,948
STOOD-X K_c [†]	0,989 [0,988; 0,990]	0,033 [0,028; 0,038]	0,946

Tabla 10.6.: Métodos basados en logits, en la modificación de activaciones y variantes de SHE: AUROC (más alto es mejor) en los nueve conjuntos y exactitud ID de la clasificación resultante. Clase positiva: OOD. [a] ASH modifica las características y con ellas la predicción.

Método	TUM+NORM	TUM	NORM	STR	LYM	MUS	PANDA	Control 128 px	DTD	Exact. ID (%)
Basados en logits										
MSP	0,876	0,873	0,880	0,823	0,854	0,740	0,843	0,657	0,876	96,87
MaxLogit	0,828	0,815	0,848	0,767	0,741	0,607	0,723	0,626	0,824	96,87
Energy	0,821	0,807	0,844	0,759	0,727	0,589	0,706	0,622	0,818	96,87
Modificación de activaciones										
ReAct	0,861	0,856	0,868	0,798	0,835	0,643	0,741	0,602	0,820	96,89
ASH[a]	0,546	0,496	0,628	0,544	0,504	0,361	0,341	0,503	0,549	68,33
DICE	0,592	0,581	0,609	0,581	0,831	0,525	0,633	0,554	0,436	96,84
Características y distancias										
SHE (prod. escalar)	0,795	0,746	0,875	0,780	0,647	0,660	0,530	0,603	0,802	96,87
SHE (coseno)	0,938	0,931	0,948	0,898	0,914	0,837	0,834	0,651	0,898	96,87
SHE (euclídea)	0,942	0,937	0,950	0,902	0,928	0,845	0,851	0,646	0,899	96,87

trasladan bien a un Swin Transformer con LayerNorm. ReAct mejora a Energy, pero no a MSP. DICE queda por debajo de Energy en ocho de los nueve conjuntos, con un AUROC inferior al azar en DTD (0,436). ASH colapsa por completo: al redistribuir la suma de las activaciones, que es negativa en el 27,5 % de las imágenes, invierte los logits y reduce la exactitud ID al 68,3 %. Por último, SHE con producto escalar resulta irregular (0,795), mientras que sus variantes con distancia coseno (0,938) y euclídea (0,942) mejoran notablemente, lo que apunta de nuevo a la incompatibilidad entre las características con signo del Swin y los supuestos del método. **[REVISAR: «al contrario de lo habitual en la literatura»: falta cita] [REVISAR: ReAct mejora a Energy en ocho de los nueve conjuntos; en el control de resolución queda por debajo (0,602 frente a 0,622)] [REVISAR: el 27,5 % se midió en la validación ID]**

[PENDIENTE: conclusión parcial]

10.6. Discusión

Conclusión. Ningún método domina en todas las métricas y conjuntos. ViM ofrece el mejor equilibrio global en AUROC; RMDS, el mejor comportamiento con umbrales exigentes, aunque con un fallo severo en LYM; y STOOD-X destaca en far-OOD y en varias clases de NCT-CRC, pero es el más sensible a la resolución. El hallazgo más relevante es que los mejores detectores responden sobre todo a las condiciones de adquisición, lo que condiciona su uso en un entorno multicéntrico.

[PENDIENTE: integración de las conclusiones parciales]

11. STOOD-X

[PENDIENTE: introducción del capítulo]

11.1. Implementación

El método se ha implementado siguiendo la descripción del artículo [62]. Se realiza un único test por imagen entre las K distancias de x y las K^2 distancias de sus vecinos mediante `scipy.stats.mannwhitneyu` (Virtanen et al. [73]).

[PENDIENTE: diferencias entre la implementación pública y la descripción del artículo, y motivo de la reimplementación] **[REVISAR: tono]**

11.2. Configuración

Se emplean la distancia coseno, $K = 500$ (el valor seleccionado en el artículo), el conjunto de entrenamiento ID de la clase predicha como referencia y dos configuraciones de características: el 100 % y el 87,5 % más presente. Dado que el criterio de relevancia del artículo se basa en CRP (apartado 7.2), que no es directamente aplicable a un Swin Transformer, la selección del 87,5 % se realiza mediante la presencia de cada característica (suma de sus valores absolutos en la clase), criterio utilizado en la implementación pública. Ningún hiperparámetro se ha ajustado con datos OOD. **[REVISAR: tono]**

11.3. Puntuación

Como puntuación de detección se utiliza el estadístico tipificado del test de Mann-Whitney, z, obtenido mediante la aproximación normal del estadístico U con corrección por empates y por continuidad (teorema 6.6 y observación 6.8). Dado que $p = 1 - \Phi(z)$ es una función monótona decreciente de z, la puntuación $-z$ induce la misma ordenación que el p-valor propuesto en STOOD-X, pero evita el subdesbordamiento numérico que se produce cuando $p < 10^{-308}$. Cuando todas las distancias de x superan a las de sus vecinos (separación completa), el estadístico alcanza su valor máximo y varias imágenes quedan empatadas. Esto afecta al 66 % de TUM + NORM pero solo al 0,6 % del test ID; su efecto está acotado en $\pm$0,003 en AUROC, y no altera FPR@95 ni CCR@FPR5 (cuadro 11.1).

[PENDIENTE: conclusión parcial]

11.4. Resultados

En el near-OOD principal (TUM + NORM), STOOD-X obtiene un AUROC de 0,953, estadísticamente indistinguible del de RMDS (0,954; $p = 0{,}75$ en el *bootstrap* pareado), aunque con un FPR@95 claramente mayor (0,349 frente a 0,128). Es el mejor método en NORM

Tabla 11.1.: Saturación de la puntuación $-z$ de STOOD-X (100 %, $K = 500$) por separación completa: proporción de imágenes con $U = n_1 n_2$ y cotas de su efecto en el AUROC (más alto es mejor), forzando el peor y el mejor orden entre las imágenes ID y OOD saturadas. FPR@95 y CCR@FPR5 no cambian en ningún conjunto.

Conjunto	Saturadas test ID	Saturadas OOD	AUROC	AUROC peor caso	AUROC mejor caso
TUM+NORM	0,6 %	66,3 %	0,953	0,951	0,955
TUM	0,6 %	59,0 %	0,931	0,929	0,933
NORM	0,6 %	78,2 %	0,990	0,987	0,992
STR	0,6 %	52,0 %	0,978	0,976	0,979
LYM	0,6 %	32,1 %	0,903	0,903	0,905
MUS	0,6 %	44,1 %	0,968	0,966	0,969
PANDA	0,6 %	19,4 %	0,895	0,895	0,896
Control 128 px	0,6 %	19,0 %	0,894	0,893	0,895
DTD	0,6 %	76,3 %	0,991	0,987	0,992

Tabla 11.2.: STOOD-X con el 100 % y el 87,5 % de las características ($K = 500$, puntuación $-z$) y la variante exploratoria K_c, frente a KNN y RMDS: AUROC (más alto es mejor) y FPR@95 (más bajo es mejor) en los nueve conjuntos. Clase positiva: OOD. †Variante exploratoria, propuesta tras ver datos OOD.

	STOOD-X (100 %)		STOOD-X (87,5 %)		STOOD-X K_c †		KNN		RMDS	
Conjunto	AUROC	FPR@95	AUROC	FPR@95	AUROC	FPR@95	AUROC	FPR@95	AUROC	FPR@95
TUM+NORM	0,953	0,349	0,953	0,352	0,943	0,461	0,956	0,173	0,954	0,128
TUM	0,931	0,440	0,930	0,444	0,917	0,461	0,952	0,183	0,947	0,142
NORM	0,990	0,022	0,990	0,022	0,985	0,023	0,963	0,152	0,964	0,109
STR	0,978	0,083	0,978	0,082	0,977	0,101	0,932	0,219	0,935	0,180
LYM	0,903	0,531	0,903	0,533	0,799	0,411	0,948	0,216	0,824	0,992
MUS	0,968	0,159	0,967	0,164	0,966	0,158	0,904	0,275	0,911	0,272
PANDA	0,895	0,427	0,895	0,428	0,917	0,300	0,892	0,256	0,912	0,241
Control 128 px	0,894	0,497	0,893	0,505	0,895	0,490	0,760	0,569	0,753	0,821
DTD	0,991	0,028	0,990	0,030	0,989	0,033	0,936	0,214	0,942	0,156

(AUROC 0,990), STR (0,978), MUS (0,968) y DTD (0,991). En PANDA alcanza 0,895, prácticamente igual que en el control de resolución (0,894); como se discute en la apartado 10.3, esta coincidencia se debe a la saturación del estadístico y no permite atribuir su detección a la resolución. Las configuraciones con el 100 % y el 87,5 % de las características son indistinguibles.

[PENDIENTE: conclusión parcial]

11.5. Calibración

Aunque el método propone el p-valor como medida de pertenencia, en el conjunto de validación ID el 82 % de las imágenes obtiene $p < 0{,}05$, con una distribución bimodal. Por tanto, el p-valor permite ordenar las imágenes, pero no puede interpretarse como nivel de significación. La causa probable es que las K^2 distancias de referencia no son independientes, ya que los vecinos comparten vecinos (observación 6.9). La calibración conforme sobre el conjunto de validación (apartado 12.1) recupera una tasa de falsas alarmas controlada.

[PENDIENTE: conclusión parcial]

Tabla 11.3.: Calibración de los p-valores de STOOD-X ($K = 500$) en la validación ID (solo datos ID), por clase predicha. Si el test estuviera calibrado, los p-valores seguirían una $U(0,1)$: KS D (distancia de Kolmogorov-Smirnov a la uniforme) cercano a 0 y alrededor de un 5 % de $p < 0{,}05$. n_c: imágenes de entrenamiento predichas en la clase (conjunto de referencia); n_{val}: imágenes de validación predichas en ella.

Clase predicha	n_c	n_{val}	KS D	$p < 0{,}05$	$p = 0$	$p = 1$	Mediana de p
`Glandulas_no_neoplasicas`	25.846	6.474	0,840	85,4 %	8,8 %	5,7 %	≈ 0
`Estroma`	17.783	4.472	0,804	82,2 %	6,1 %	6,2 %	≈ 0
`Adenocarcinoma_ductal`	15.135	3.785	0,812	82,6 %	7,5 %	7,2 %	≈ 0
`Gleason_4_cribiformes`	10.155	2.555	0,842	85,5 %	9,4 %	6,5 %	≈ 0
`Gleason_5_no_glandulas`	8.717	2.176	0,712	73,3 %	9,5 %	11,1 %	≈ 0
`Gleason_4_fusionadas`	5.584	1.391	0,813	82,7 %	8,0 %	6,9 %	≈ 0
`PIN_de_alto_grado`	1.979	484	0,798	82,2 %	9,3 %	8,1 %	≈ 0
`Gleason_3`	1.822	475	0,774	78,9 %	20,6 %	6,1 %	≈ 0
`Gleason_4_pobremente_formadas`	905	207	0,695	72,0 %	1,4 %	10,6 %	≈ 0
`No_Cancer`	868	214	0,691	71,5 %	0,9 %	15,0 %	≈ 0
`Carcinoma_intraductal`	866	207	0,574	57,5 %	1,0 %	26,6 %	≈ 0
`Inflamatorio`	568	132	0,510	53,0 %	12,1 %	23,5 %	0,003
`Gleason_5_comedonecrosis`	399	90	0,478	45,6 %	0,0 %	34,4 %	0,622
`Gleason_4_glomeruloide`	173	29	0,559	20,7 %	0,0 %	0,0 %	0,995
Todas	90.800	22.691	0,802	81,9 %	8,1 %	7,3 %	≈ 0

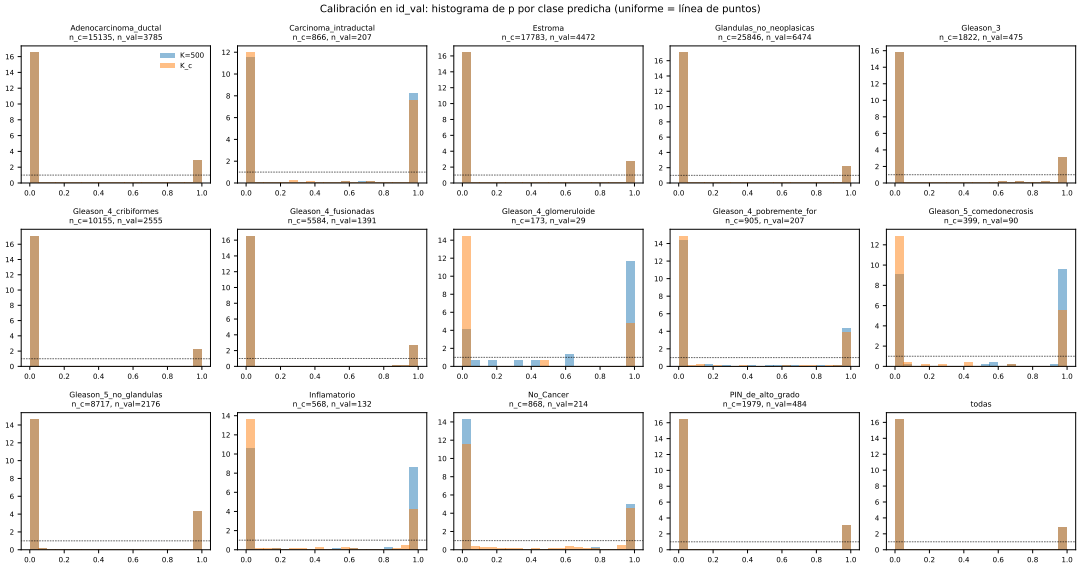

Figura 11.1.: Histogramas de los p-valores de STOOD-X en la validación ID por clase predicha, con $K = 500$ y con K_c; la línea de puntos es la densidad uniforme, que se obtendría si el test estuviera calibrado. Los p-valores son bimodales en 0 y 1.

Tabla 11.4.: Sensibilidad de STOOD-X al número de vecinos K (análisis de sensibilidad; *no* se usa para elegir K). Subconjunto de validación: 1.000 imágenes del test ID (estratificadas por clase) y 500 de cada conjunto OOD, semilla 0. Puntuación $-z$; 100 % de las características salvo indicación. AUROC: más alto es mejor; FPR@95: más bajo es mejor. Tiempo por imagen: GPU (cálculo de distancias) más CPU (test de Mann-Whitney). Última columna: proporción del test ID con $p = 0$ exacto (subdesbordamiento). †Variante exploratoria $K_c = \min(500, \lfloor n_c/2 \rfloor)$.

	TUM+NORM		LYM		PANDA		DTD		Tiempo	$p = 0$
K	AUROC	FPR@95	AUROC	FPR@95	AUROC	FPR@95	AUROC	FPR@95	(ms/img)	test ID
9	0,933	0,132	0,936	0,218	0,897	0,326	0,937	0,132	0,7	0,0 %
18	0,962	0,067	0,955	0,212	0,917	0,270	0,966	0,067	0,5	0,0 %
36	0,976	0,042	0,963	0,179	0,917	0,289	0,978	0,042	0,6	0,0 %
72	0,985	0,030	0,968	0,165	0,922	0,272	0,986	0,030	0,8	0,0 %
144	0,988	0,030	0,962	0,161	0,924	0,248	0,988	0,031	1,3	0,0 %
288	0,988	0,040	0,944	0,235	0,926	0,236	0,988	0,038	4,6	0,0 %
500	0,952	0,342	0,890	0,554	0,877	0,462	0,986	0,040	14,4	9,1 %
500 (87,5 %)	0,952	0,346	0,889	0,553	0,877	0,464	0,985	0,041	14,4	9,2 %
K_c†	0,941	0,474	0,790	0,428	0,900	0,291	0,985	0,045	13,2	9,0 %

11.6. Sensibilidad a K

En un análisis de sensibilidad sobre un subconjunto (cuadro 11.4), el rendimiento mejora hasta $K \approx 72$–288 y se degrada con $K = 500$. La degradación se concentra en las imágenes predichas en clases con pocas imágenes de entrenamiento (`Gleason_5_comedonecrosis`, 399; `Inflamatorio`, 568; `No_Cancer`, 868), donde K se aproxima al tamaño de la clase y se pierde la localidad del vecindario. En particular, el 10 % de las imágenes de TUM + NORM se predice como `Gleason_5_comedonecrosis`. Al excluir esas clases, la caída desaparece. Este análisis no se ha utilizado para elegir K, que se mantiene en el valor del artículo; una variante que adapta K al tamaño de la clase ($K_c = \min(500, \lfloor n_c/2 \rfloor)$) no mejoró los resultados.

[PENDIENTE: conclusión parcial]

11.7. Explicaciones por ejemplos

Siguiendo la segunda etapa del método, la figura 11.3 muestra imágenes representativas junto a sus cinco vecinos más cercanos de entrenamiento. Las imágenes de colon aceptadas como ID se predicen en su totalidad como `Gleason_5_comedonecrosis`, lo que ilustra visualmente el efecto descrito.

En cada figura, la primera columna es la imagen evaluada y las cinco siguientes, sus vecinos de entrenamiento, con la clase predicha, la puntuación (p y z) y las distancias en los títulos.

[PENDIENTE: análisis de los ejemplos del capítulo C (figuras C.1 a C.5; variante K_c: figura C.8)]

11.8. Discusión

[PENDIENTE: discusión global]

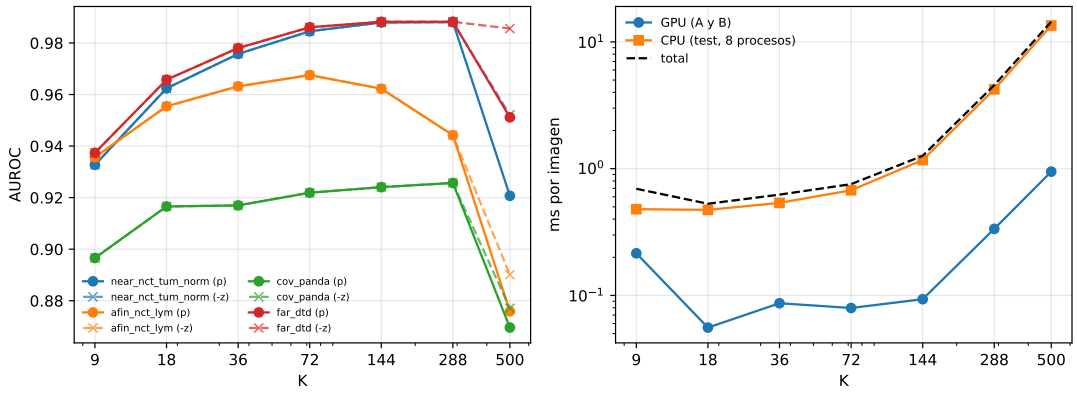

Figura 11.2.: Izquierda: AUROC con p y con $-z$ frente a K en TUM+NORM, LYM, PANDA y DTD. Derecha: tiempo por imagen (GPU, CPU y total) frente a K, en escala logarítmica. Muestra la caída con $K = 500$ y la diferencia entre p y $-z$ por subdesbordamiento.

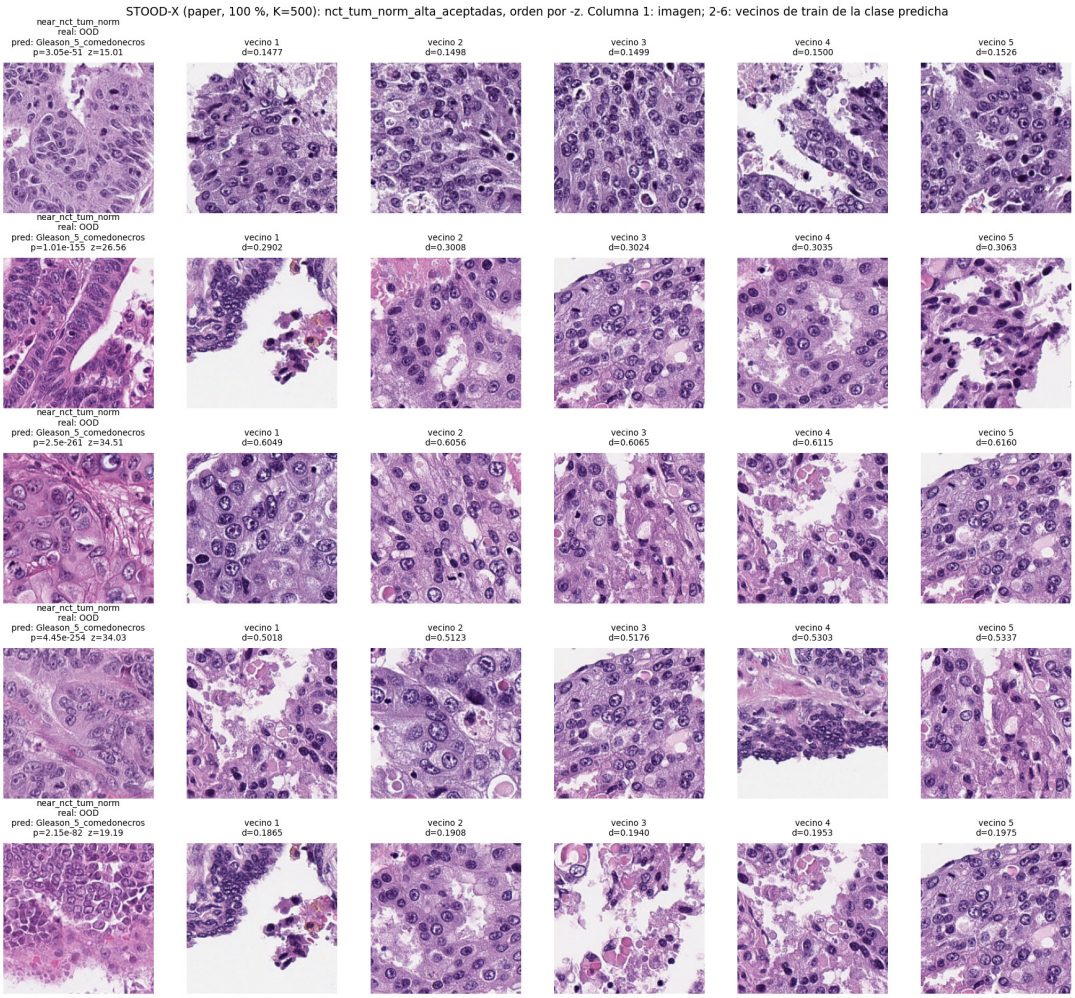

Figura 11.3.: STOOD-X ($K = 500$): cinco imágenes de TUM+NORM aceptadas como ID (puntuación $-z$ más alta) y sus cinco vecinos de entrenamiento de la clase predicha. Las cinco se predicen como `Gleason_5_comedonecrosis` ($n_c = 399 < K$).

12. Predicción conforme

Este capítulo aplica la predicción conforme (apartado 6.5) al Swin-S de dos formas. Primero, para calibrar el umbral de los detectores OOD de modo que la proporción de falsas alarmas en datos ID quede controlada (apartado 12.1). Después, para sustituir la predicción de una sola clase por conjuntos de predicción con cobertura garantizada, en su versión marginal (apartado 12.2) y condicionada por clase (apartado 12.3). En todos los casos, la calibración se hace con la validación ID y la evaluación, con el test ID, el control de resolución y los conjuntos OOD del capítulo 8.

Las garantías de la predicción conforme exigen que los datos de calibración y los de prueba sean intercambiables (definición 6.15), y en este trabajo esa hipótesis no está asegurada. La validación ID se usó durante el entrenamiento para elegir la época (con una parada temprana sobre la pérdida de validación) y procede de la carpeta de entrenamiento original, mientras que el test procede de la carpeta de validación original. Un indicio de que ambos conjuntos no se comportan igual es que la exactitud del Swin-S es del 97,02 % en la validación y del 96,88 % en el test. Por eso, las coberturas observadas en el test se contrastan en este capítulo con lo que predice la teoría.

12.1. Detección OOD conforme

Cada detector del capítulo 5 asigna a una imagen una puntuación $s(x)$, más alta cuanto más ID parece. Con las puntuaciones $s_1, \dots, s_n$ de las $n = 22.691$ imágenes de la validación ID se calcula el p-valor conforme

$$p(x) = \frac{1 + \#\{\, i : s_i \leq s(x) \,\}}{n + 1},$$

que es el de la proposición 6.17 con la puntuación de no conformidad $-s$, y la imagen se declara OOD si $p(x) \leq \alpha$. Si la validación y el test son intercambiables, la proporción de imágenes ID marcadas como OOD (falsas alarmas) es a lo sumo α [3, 74]. Es el uso de la predicción conforme para la detección de valores atípicos que describen Angelopoulos y Bates: el umbral se calibra con datos limpios y garantiza que no se devuelvan demasiados falsos positivos [3]. Se han evaluado cinco detectores con $\alpha \in \{0{,}01;\ 0{,}05;\ 0{,}10\}$ (cuadro 12.1).

Las falsas alarmas en el test ID son compatibles con α en los quince casos: el intervalo de confianza exacto contiene α para los cinco métodos y los tres niveles. A diferencia del FPR@95, que fija la tasa de detección de los datos OOD (apartado 4.3.2), este procedimiento fija la tasa de falsas alarmas sobre los ID sin usar ningún dato OOD, que es la situación de un despliegue real. Con $\alpha = 0{,}05$, STOOD-X es el detector que más detecta en TUM+NORM (0,879), PANDA (0,568) y DTD (0,972), y también el que más marca el control de resolución (0,596); ViM y MDS son los que más detectan en LYM (0,826 y 0,812). Con $\alpha = 0{,}01$, ViM y MDS detectan alrededor del 55 % de TUM+NORM (0,552 y 0,554), frente al 75 % de STOOD-X (0,748). Que el control de resolución se marque como OOD en una proporción apreciable es coherente con el criterio conservador de este trabajo (apartado 2.2.3), que considera OOD los cambios de apariencia que degradan el clasificador.

Tabla 12.1.: Detección OOD conforme con el umbral calibrado en la validación ID (22.691 imágenes). Falsas alarmas: proporción del test ID marcada como OOD, con IC exacto del 95 % (debe ser compatible con α si validación y test son intercambiables). Resto de columnas: proporción detectada como OOD en cada conjunto (más alto es mejor).

Método	α	Falsas alarmas test ID [IC 95 %]	TUM+NORM	LYM	PANDA	Control 128 px	DTD
MSP	0,01	0,009 [0,008; 0,011]	0,261	0,203	0,072	0,033	0,158
	0,05	0,050 [0,046; 0,054]	0,631	0,576	0,392	0,134	0,509
	0,10	0,098 [0,093; 0,103]	0,794	0,749	0,695	0,277	0,771
ViM	0,01	0,010 [0,008; 0,012]	0,552	0,569	0,110	0,077	0,437
	0,05	0,049 [0,045; 0,053]	0,796	0,826	0,448	0,209	0,721
	0,10	0,099 [0,094; 0,105]	0,902	0,886	0,646	0,324	0,857
MDS	0,01	0,010 [0,009; 0,012]	0,554	0,554	0,118	0,077	0,431
	0,05	0,049 [0,046; 0,053]	0,786	0,812	0,448	0,201	0,707
	0,10	0,099 [0,094; 0,104]	0,892	0,878	0,637	0,312	0,843
RMDS	0,01	0,010 [0,008; 0,011]	0,359	0,348	0,184	0,043	0,173
	0,05	0,052 [0,048; 0,056]	0,694	0,606	0,430	0,150	0,542
	0,10	0,098 [0,093; 0,103]	0,897	0,725	0,700	0,297	0,818
STOOD-X 100 % ($-z$)	0,01	0,011 [0,009; 0,013]	0,748	0,385	0,272	0,263	0,841
	0,05	0,049 [0,046; 0,053]	0,879	0,671	0,568	0,596	0,972
	0,10	0,103 [0,097; 0,108]	0,889	0,753	0,705	0,724	0,986

Conclusión parcial. La calibración conforme convierte cualquier puntuación de detección en un detector con una tasa de falsas alarmas controlada, que en el test ID se cumple para todos los métodos y niveles evaluados. Con ese control, STOOD-X es el detector que más muestras OOD señala en casi todos los conjuntos, mientras que ViM y MDS destacan en LYM.

12.2. Conjuntos de predicción APS y RAPS

Los conjuntos de predicción se calculan con las puntuaciones APS y RAPS de las definiciones 6.21 y 6.22, sobre las probabilidades del Swin-S. La validación ID se divide en dos partes: el 80 % (18.153 imágenes) se usa para calibrar y el 20 % restante (4.538) para elegir los hiperparámetros de RAPS, como proponen Angelopoulos et al. [2]. En esa parte de ajuste, con $k_{\text{reg}} = 1$, el valor $\lambda = 0{,}5$ es el que da el menor tamaño medio entre los probados (0,001 a 0,5). Con estos valores, cada clase a partir de la segunda suma una penalización de al menos 0,5, de modo que, en la práctica, los conjuntos RAPS tienen tamaño 0 o 1. Se usan las versiones aleatorizadas, con una variable $u \sim U(0,1)$ por imagen, que admiten conjuntos vacíos.

Antes de aplicarlas, se comprobó la implementación con una simulación: en 1.000 particiones aleatorias con $n = 4.000$ imágenes de calibración, la cobertura media coincide con lo que predicen el teorema 6.18 y la observación 6.19, que la sitúan entre $1-\alpha$ y $1-\alpha+1/(n+1)$, dentro de dos errores estándar para APS y RAPS con ambos valores de α (por ejemplo, 0,9500 para APS con $\alpha = 0{,}05$). Es el diagnóstico que recomiendan Angelopoulos y Bates: repetir el procedimiento con distintas calibraciones y comprobar que la cobertura media se acerca a $1-\alpha$ [3].

En el test ID, la cobertura está cerca de $1-\alpha$ en los cuatro casos (cuadro 12.2 y figura 12.1). APS con $\alpha = 0{,}05$ queda 0,005 por debajo (0,945 [0,941; 0,949]), y su intervalo no contiene 0,95; pero ese intervalo solo recoge la variabilidad del test. Si se añade la de la calibración mediante la distribución beta-binomial de la observación 6.20, con $n = 18.153$ y

Tabla 12.2.: Conjuntos de predicción APS y RAPS sobre las probabilidades del Swin-S, calibrados con el 80 % de la validación ID. Cobertura: proporción de imágenes cuya clase verdadera está en el conjunto (objetivo $1 - \alpha$), con IC exacto del 95 %; tamaño medio del conjunto (más pequeño es mejor a igual cobertura) y proporción de conjuntos vacíos.

		Test ID			Control 128 px	
Método	α	Cobertura [IC 95 %]	Tamaño	Vacíos	Cobertura	Tamaño
APS	0,05	0,945 [0,941; 0,949]	1,04	3,9 %	0,922	1,25
RAPS	0,05	0,948 [0,944; 0,952]	0,98	2,1 %	0,894	0,99
APS	0,10	0,897 [0,892; 0,902]	0,95	8,4 %	0,871	1,07
RAPS	0,10	0,898 [0,892; 0,903]	0,93	7,2 %	0,852	0,94

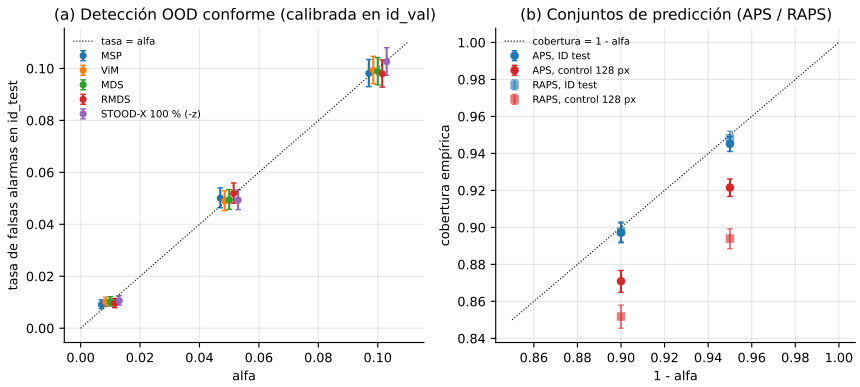

Figura 12.1.: Cobertura de los conjuntos de predicción APS y RAPS en el test ID y en el control de resolución frente al objetivo $1 - \alpha$.

Tabla 12.3.: Tamaño medio de los conjuntos de predicción APS y RAPS en el test ID y en los conjuntos OOD. Un tamaño mayor fuera de distribución indica que el conjunto refleja la incertidumbre ante entradas OOD.

Método	α	Test ID	TUM+NORM	TUM	NORM	STR	LYM	MUS	PANDA	Control 128 px	DTD
APS	0,05	1,04	3,14	3,12	3,16	2,08	2,72	1,74	1,69	1,25	2,51
RAPS	0,05	0,98	1,04	1,04	1,05	1,00	1,02	0,99	0,99	0,99	1,01
APS	0,10	0,95	2,37	2,34	2,41	1,53	2,00	1,35	1,28	1,07	1,82
RAPS	0,10	0,93	1,00	1,00	1,01	0,96	0,98	0,96	0,96	0,94	0,98

$n_{\text{val}} = 12.618$, la desviación típica de la cobertura es de unos 0,0025, y el déficit equivale a unas 1,9 desviaciones típicas: compatible con el azar, aunque también con la falta de intercambiabilidad. Los conjuntos son pequeños, con un tamaño medio cercano a 1, y entre el 2 y el 8 % son vacíos. Como la exactitud del Swin-S (96,88 %) supera $1 - \alpha$, el método puede devolver un conjunto vacío, es decir, abstenerse, en una parte de las imágenes y seguir cumpliendo la cobertura.

En el control de resolución, en cambio, la garantía se rompe: con $\alpha = 0{,}05$, la cobertura baja a 0,922 con APS y a 0,894 con RAPS. Es lo esperable, porque estas imágenes tienen las mismas etiquetas que el test ID pero distinta apariencia (desplazamiento de covariables), y las garantías del teorema 6.18 suponen que los datos de prueba proceden de la misma distribución que los de calibración [3].

La garantía es además marginal y no por clase (figura 12.2). Con $\alpha = 0{,}05$, la cobertura es de 0,68 con APS y 0,52 con RAPS en `Gleason_4_glomeruloide`, de 0,79 y 0,73 en `Gleason_4_pobremente_formadas` y de 0,87 y 0,79 en `Gleason_3`. APS compensa en parte devolviendo conjuntos mayores en esas clases (unas 1,44 clases de media, frente a algo menos de 1 en las clases grandes), mientras que los conjuntos RAPS tienen en ellas un tamaño de 1 o menos. Es el compromiso entre tamaño y adaptatividad que describen Angelopoulos et al.: una regularización fuerte da conjuntos más pequeños, pero menos sensibles a la dificultad de cada imagen [2].

Fuera de distribución, el tamaño de los conjuntos APS crece (cuadro 12.3): con $\alpha = 0{,}05$ pasa de 1,04 en el test ID a 3,14 en TUM+NORM, 2,72 en LYM, 2,51 en DTD, 1,69 en PANDA y 1,25 en el control de resolución. Angelopoulos y Bates señalan que los conjuntos crecen cuando el modelo está inseguro y que su tamaño indica la certeza del modelo [3]: aquí, el tamaño APS funciona como una señal de que la entrada es OOD. Con RAPS esa señal desaparece, porque la penalización mantiene el tamaño cerca de 1 en todos los conjuntos (entre 0,99 y 1,05 con $\alpha = 0{,}05$).

Conclusión parcial. En el test ID, APS y RAPS dan una cobertura compatible con $1 - \alpha$ y conjuntos de tamaño cercano a 1, pero la garantía es marginal: las clases pequeñas y difíciles quedan por debajo del objetivo. APS reacciona a la incertidumbre con conjuntos más grandes en esas clases y fuera de distribución, mientras que RAPS, con la regularización elegida, pierde esa información. Ninguno mantiene la cobertura en el control de resolución.

12.3. Predicción conforme Mondrian

Para corregir la infracobertura de las clases pequeñas se aplica la versión Mondrian (definición 6.23), que calibra un umbral por clase, con las puntuaciones LAC y APS y la misma

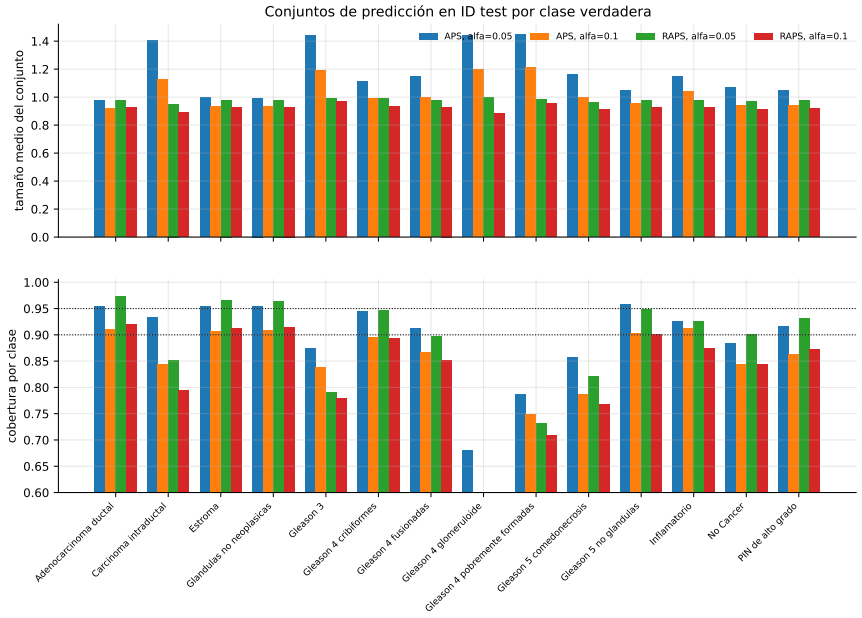

Figura 12.2.: Cobertura y tamaño medio de los conjuntos APS y RAPS por clase en el test ID.

calibración que la versión marginal (cuadro 12.4).

La cobertura global es prácticamente la misma en ambas versiones (con LAC y $\alpha = 0{,}05$, 0,948 en las dos), pero con $\alpha = 0{,}05$ el tamaño medio de los conjuntos se duplica: de 0,96 a 1,98 con LAC y de 1,04 a 2,15 con APS. Con $\alpha = 0{,}10$ apenas cambia (de 0,91 a 0,94 con LAC y de 0,95 a 0,98 con APS); la causa de esa diferencia se analiza al final de la sección. En el control de resolución ninguna versión mantiene la garantía y, con LAC, la versión Mondrian empeora la cobertura (de 0,859 a 0,777 con $\alpha = 0{,}05$ y de 0,726 a 0,649 con $\alpha = 0{,}10$).

Por clases (cuadro 12.5 y figura 12.3), la versión marginal sobrecubre las clases grandes, con coberturas de 0,97 a 0,99 en `Adenocarcinoma_ductal`, `Estroma` y `Glandulas_no_`

Tabla 12.4.: Predicción conforme marginal frente a Mondrian (condicionada por clase) con las puntuaciones LAC y APS. Cobertura (objetivo $1 - \alpha$) con IC exacto del 95 %, tamaño medio del conjunto, número de clases con cobertura puntual por debajo de $1 - \alpha$ en el test ID y cobertura en el control de resolución (*covariate shift* con las mismas etiquetas).

Puntuación	α	Versión	Cobertura test ID [IC 95 %]	Tamaño medio	Clases $< 1 - \alpha$	Cobertura control 128 px
APS	0,05	Marginal	0,945 [0,941; 0,949]	1,04	10 / 14	0,922
APS	0,05	Mondrian	0,946 [0,942; 0,950]	2,15	11 / 14	0,923
APS	0,10	Marginal	0,897 [0,892; 0,902]	0,95	9 / 14	0,871
APS	0,10	Mondrian	0,899 [0,894; 0,904]	0,98	10 / 14	0,874
LAC	0,05	Marginal	0,948 [0,944; 0,952]	0,96	10 / 14	0,859
LAC	0,05	Mondrian	0,948 [0,944; 0,952]	1,98	8 / 14	0,777
LAC	0,10	Marginal	0,901 [0,896; 0,906]	0,91	10 / 14	0,726
LAC	0,10	Mondrian	0,901 [0,896; 0,906]	0,94	7 / 14	0,649

Tabla 12.5.: Cobertura por clase en el test ID con la puntuación LAC y $\alpha = 0{,}05$: versión marginal frente a Mondrian (objetivo: 0,95 en cada clase). n_y: imágenes de calibración de la clase; $k_y = \lceil (n_y + 1)(1 - \alpha) \rceil$. $^{\max}$: $k_y = n_y$, el umbral es la mayor puntuación de calibración de la clase.

			Cobertura		Tamaño medio	
Clase	n_y	k_y	Marginal	Mondrian	Marginal	Mondrian
`Gleason_4_glomeruloide`	33	$33^{\max}$	0,400	1,000	0,72	1,60
`Gleason_5_comedonecrosis`	82	79	0,804	0,946	0,89	2,11
`Inflamatorio`	113	109	0,850	1,000	0,86	2,08
`Carcinoma_intraductal`	169	162	0,793	0,983	0,82	2,03
`Gleason_4_pobremente_formadas`	174	167	0,606	0,874	0,76	2,15
`No_Cancer`	174	167	0,901	0,934	0,94	1,98
`Gleason_3`	359	342	0,719	0,901	0,83	2,04
`PIN_de_alto_grado`	391	373	0,928	0,957	0,96	2,01
`Gleason_4_fusionadas`	1.111	1.057	0,873	0,943	0,92	2,04
`Gleason_5_no_glandulas`	1.757	1.671	0,955	0,955	0,96	2,00
`Gleason_4_cribiformes`	2.037	1.937	0,924	0,944	0,94	2,01
`Adenocarcinoma_ductal`	3.020	2.870	0,992	0,959	0,99	1,97
`Estroma`	3.536	3.361	0,974	0,945	0,98	1,96
`Glandulas_no_neoplasicas`	5.197	4.939	0,972	0,946	0,98	1,96

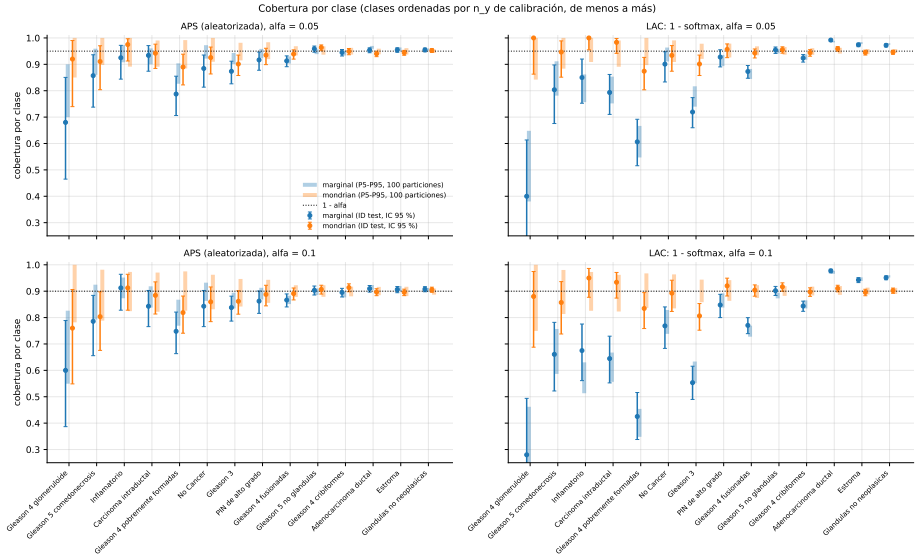

Figura 12.3.: Cobertura por clase en el test ID de la predicción conforme marginal y Mondrian.

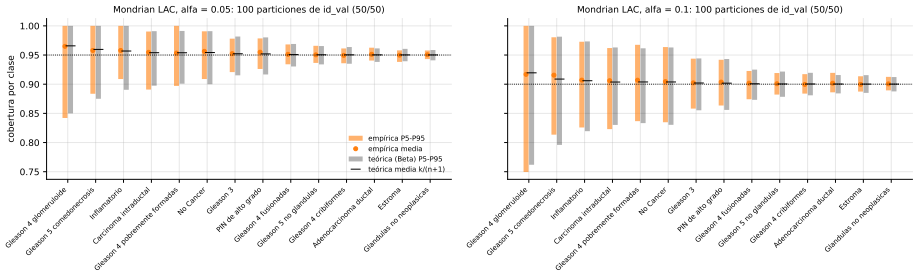

Figura 12.4.: Cobertura por clase en 100 particiones aleatorias de la validación ID (50 % calibración, 50 % evaluación) frente a la distribución teórica Beta$(k_y, n_y + 1 - k_y)$.

`neoplasicas`, e infracubre mucho las pequeñas: 0,400 en `Gleason_4_glomeruloide` y 0,606 en `Gleason_4_pobremente_formadas`. Es la situación que describen Vovk et al. para la clasificación asimétrica: tasas de error bajas en unas categorías compensan tasas excesivas en otras [74]. La versión Mondrian iguala la cobertura entre clases, aunque `Gleason_4_pobremente_formadas` (0,874 [0,803; 0,926]) y `Gleason_3` (0,901 [0,858; 0,935]) siguen por debajo de 0,95, con intervalos que no contienen ese valor.

Para saber si esas desviaciones caben dentro de la variabilidad esperable, la validación ID se dividió en 100 particiones aleatorias, cada una con la mitad para calibrar y la otra mitad para evaluar, y se comparó la cobertura obtenida en cada clase con la distribución teórica de la observación 6.20, aplicada dentro de cada clase (figura 12.4). Con LAC y $\alpha = 0{,}05$, la versión Mondrian coincide con la teoría en todas las clases: las coberturas medias van de 0,949 a 0,965, frente a medias teóricas de 0,950 a 0,966. La versión marginal, en cambio, infracubre de forma sistemática las clases pequeñas; en `Gleason_4_glomeruloide`, su cobertura media es de 0,51, con los percentiles 5 y 95 en 0,38 y 0,65. Sin embargo, en el test la cobertura Mondrian de `Gleason_4_pobremente_formadas` (0,874) y de `Gleason_3` (0,901) queda por debajo del percentil 5 de las particiones (0,897 y 0,921). Como dentro de la validación la versión Mondrian se comporta como predice la teoría, este resultado indica que, en esas clases, la validación y el test no son intercambiables.

Queda por explicar por qué los conjuntos Mondrian duplican su tamaño con $\alpha = 0{,}05$ (figura 12.5). La causa es `Gleason_4_glomeruloide`, que tiene $n_y = 33$ imágenes de calibración. Por la proposición 6.24, con $\alpha = 0{,}05$ y $19 \leq n_y \leq 38$ el umbral de la clase es su mayor puntuación de calibración. Esa puntuación la fija una sola imagen, que el modelo predice como `Gleason_4_cribiformes` con una probabilidad de 0,921 y a la que asigna una probabilidad de 0,0047 para su clase verdadera; con LAC, el umbral es $\hat{q}_y = 0{,}995$, de modo que la clase entra en el conjunto siempre que su probabilidad sea al menos 0,005. Esto ocurre en el 99,2 % de las imágenes del test ID; sin esa clase, el tamaño medio sería de 0,99.

Que casi ninguna probabilidad baje de 0,005 se debe al *label smoothing* con que se entrenó el modelo. Con $\varepsilon = 0{,}1$ y $K = 14$ clases, el óptimo de la pérdida asigna a cada clase no verdadera una probabilidad de $\varepsilon/K \approx 0{,}00714$ (proposición 3.22). En el test, la mediana de las probabilidades de las clases no predichas es 0,00682, y el 98,1 % de ellas está entre $\varepsilon/(2K)$ y $2\varepsilon/K$: un «suelo» que queda por encima del umbral de 0,005. Con $\alpha = 0{,}10$ el efecto desaparece: el umbral de la clase pasa a ser $\hat{q}_y = 0{,}988$, la clase solo entra si su probabilidad es al menos 0,012 y aparece en el 2,3 % de los conjuntos.

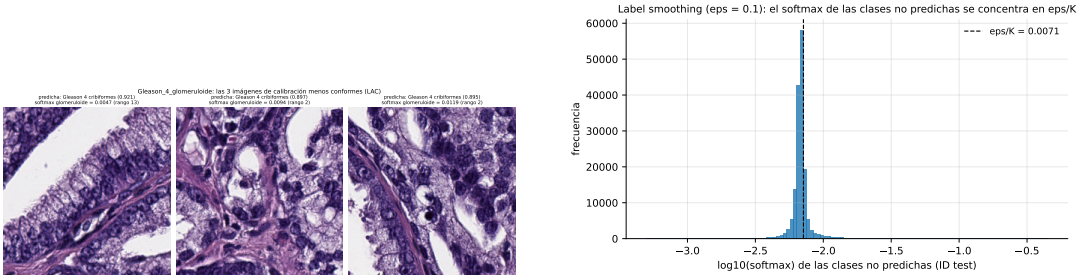

(a) Imágenes de calibración que fijan el umbral de `Gleason_4_glomeruloide`.

(b) Distribución del softmax de las clases no predichas y «suelo» ε/K.

Figura 12.5.: Causa del aumento del tamaño de los conjuntos con Mondrian y $\alpha = 0{,}05$.

Conclusión parcial. La versión Mondrian corrige la infracobertura de las clases pequeñas sin cambiar la cobertura global, y dentro de la validación se comporta como predice la teoría. Tiene dos costes: con clases muy pequeñas, su umbral depende de una sola imagen y, combinado con el *label smoothing*, puede duplicar el tamaño de los conjuntos; y, con LAC, es más frágil ante el desplazamiento de covariables. Las clases en las que no alcanza la cobertura en el test son las mismas en las que la validación y el test no parecen intercambiables.

12.4. Discusión

La predicción conforme aporta al sistema garantías que no dependen del modelo: calibrada con la validación ID, la detección OOD controla la tasa de falsas alarmas en todos los métodos y niveles evaluados, y los conjuntos de predicción alcanzan una cobertura compatible con el objetivo en el test ID. Los resultados muestran también sus límites. La garantía de APS y RAPS es marginal y deja por debajo del objetivo a las clases pequeñas, que en este conjunto de datos son patrones de Gleason difíciles de distinguir; la versión Mondrian lo corrige, a costa de conjuntos mayores cuando una clase tiene muy pocos datos de calibración y de una peor cobertura ante el desplazamiento de covariables con LAC. Además, el tamaño de los conjuntos APS crece fuera de distribución y puede servir como señal complementaria a los detectores del capítulo 10, mientras que la regularización de RAPS la elimina.

Ninguna variante mantiene la cobertura en el control de resolución, lo que confirma que las garantías dependen de que los datos de prueba se parezcan a los de calibración [3]; por eso conviene combinar los conjuntos de predicción con la detección OOD, que señala precisamente esas entradas. Por último, la intercambiabilidad entre validación y test no está asegurada en este trabajo, y el análisis por particiones apunta a que falla en `Gleason_4_pobremente_formadas` y `Gleason_3`: las garantías deben leerse con esa reserva.

13. Fuga por lámina

[PENDIENTE: introducción del capítulo]

13.1. Identificación de las láminas

[PENDIENTE: identificación de las láminas a partir de los nombres de fichero] **[REVISAR: deducción a partir de los nombres de fichero: 95 láminas y rejilla de 224 px, frente a las 85 WSI y el paso de 256 px del artículo]**

[PENDIENTE: análisis de la cuadro 13.1]

13.2. Fuga en el espacio de características

[PENDIENTE: análisis de la cuadro 13.2]

[PENDIENTE: conclusión parcial]

13.3. Efecto sobre la detección OOD

[PENDIENTE: análisis de la cuadro 13.3]

[PENDIENTE: análisis de la cuadro 13.4 y de la figura 13.1]

[PENDIENTE: conclusión parcial]

13.4. Limitación metodológica

[PENDIENTE: limitación metodológica]

Tabla 13.1.: Fuga entre particiones por lámina, deducida de los nombres de fichero (`<lámina>_<x>_<y>_<tamaño>.png`): láminas compartidas, proporción de parches cuya lámina aparece en la partición de referencia y proporción con un parche contiguo (8 vecinos a 224 px) en ella.

Comparación	Láminas compartidas	Con su lámina en la referencia	Con un parche contiguo en la referencia
`val` original respecto a `train` original	95 / 95	100,0 %	99,5 %
Validación respecto a entrenamiento (TFG)	95 / 95	100,0 %	98,9 %
Test respecto a entrenamiento (TFG)	95 / 95	100,0 %	99,0 %

Tabla 13.2.: Vecino más cercano en entrenamiento (distancia coseno, características de 768 dimensiones del Swin-S) de cada parche del test ID: proporción que es de la misma lámina, de la misma lámina y contiguo, y de la misma clase. Azar: proporción esperada de misma lámina eligiendo el vecino al azar dentro de la clase.

Clase	n	Misma lámina	Misma lámina y contiguo	Misma clase	Azar (misma lámina)
Todas	12.618	0,933	0,192	0,972	0,153
`Adenocarcinoma_ductal`	2.102	0,922	0,149	0,997	0,201
`Carcinoma_intraductal`	121	0,884	0,248	0,926	0,113
`Estroma`	2.469	0,935	0,286	0,990	0,135
`Glandulas_no_neoplasicas`	3.590	0,938	0,155	0,985	0,139
`Gleason_3`	253	0,874	0,233	0,810	0,063
`Gleason_4_cribiformes`	1.414	0,932	0,161	0,965	0,109
`Gleason_4_fusionadas`	771	0,936	0,127	0,918	0,172
`Gleason_4_glomeruloide`	25	0,800	0,040	0,560	0,275
`Gleason_4_pobremente_formadas`	127	0,913	0,150	0,756	0,179
`Gleason_5_comedonecrosis`	56	0,964	0,304	0,857	0,276
`Gleason_5_no_glandulas`	1.213	0,951	0,228	0,979	0,064
`Inflamatorio`	80	0,838	0,500	0,988	0,134
`No_Cancer`	121	0,934	0,248	0,934	0,415
`PIN_de_alto_grado`	276	0,964	0,159	0,957	0,642

Tabla 13.3.: Sensibilidad de la detección OOD a la fuga por lámina: KNN y MDS con todo el entrenamiento como referencia (original) → excluyendo, para cada parche del test ID, los parches de entrenamiento de su lámina (*leave-one-slide-out*). AUROC y CCR@FPR5: más alto es mejor; FPR@95: más bajo es mejor. Los conjuntos OOD se puntúan con todo el entrenamiento.

	KNN			MDS		
Conjunto	AUROC	FPR@95	CCR@FPR5	AUROC	FPR@95	CCR@FPR5
TUM+NORM	0,956 → 0,926	0,173 → 0,273	0,825 → 0,726	0,968 → 0,942	0,152 → 0,251	0,844 → 0,746
TUM	0,952 → 0,919	0,183 → 0,291	0,815 → 0,708	0,964 → 0,936	0,164 → 0,265	0,832 → 0,733
NORM	0,963 → 0,938	0,152 → 0,244	0,845 → 0,754	0,973 → 0,952	0,129 → 0,223	0,865 → 0,774
STR	0,932 → 0,887	0,219 → 0,350	0,779 → 0,650	0,944 → 0,902	0,215 → 0,342	0,783 → 0,657
LYM	0,948 → 0,913	0,216 → 0,346	0,783 → 0,653	0,967 → 0,941	0,181 → 0,291	0,816 → 0,707
MUS	0,904 → 0,844	0,275 → 0,427	0,724 → 0,573	0,912 → 0,854	0,301 → 0,464	0,699 → 0,535
PANDA	0,892 → 0,823	0,256 → 0,403	0,743 → 0,597	0,911 → 0,847	0,257 → 0,404	0,741 → 0,595
Control 128 px	0,760 → 0,634	0,569 → 0,804	0,431 → 0,196	0,780 → 0,660	0,575 → 0,809	0,425 → 0,191
DTD	0,936 → 0,894	0,214 → 0,342	0,785 → 0,655	0,956 → 0,922	0,181 → 0,291	0,816 → 0,707

Tabla 13.4.: Control interno de NCT-CRC-HE-100K-NONORM con y sin la lámina de cada parche en la referencia: AUROC (más alto es mejor) por clase y en PANDA, y diferencia entre LYM y la media de TUM y NORM.

Método	Versión	TUM	NORM	STR	LYM	MUS	PANDA	LYM − media(TUM, NORM)
KNN	original	0,952	0,963	0,932	0,948	0,904	0,892	−0,010
	sin lámina	0,919	0,938	0,887	0,913	0,844	0,823	−0,016
MDS	original	0,964	0,973	0,944	0,967	0,912	0,911	−0,002
	sin lámina	0,936	0,952	0,902	0,941	0,854	0,847	−0,002

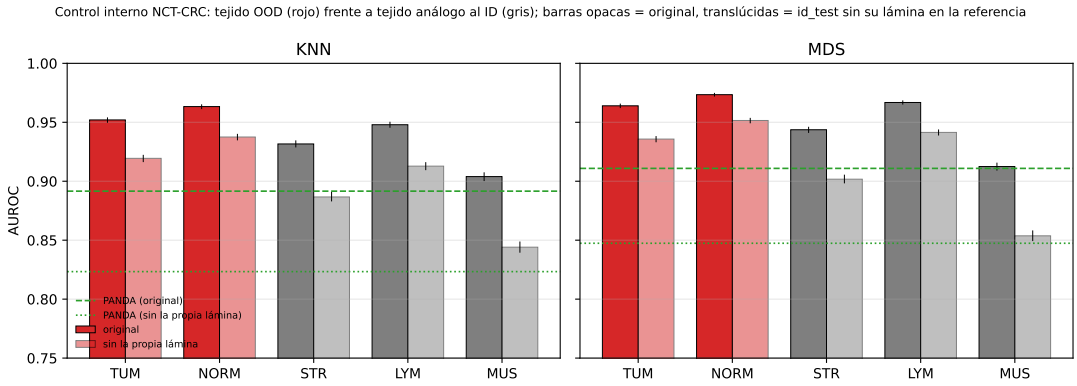

Figura 13.1.: AUROC por clase de NCT-CRC con KNN y MDS, con todo el entrenamiento como referencia y sin la lámina de cada parche del test.

14. Explicabilidad y eliminación de sesgos

[PENDIENTE: capítulo en desarrollo]

Parte IV.

Conclusiones y trabajo futuro

15. Conclusiones y trabajo futuro

15.1. Conclusiones

[PENDIENTE: conclusiones, objetivo por objetivo]

15.2. Limitaciones

La detección OOD protege frente a imágenes raras o desconocidas, pero no frente a cambios en el criterio diagnóstico. Para eso hace falta revisar y reetiquetar los datos periódicamente.

[PENDIENTE: límites teóricos de la detección OOD: aprendibilidad (Fang et al. [17])]
[PENDIENTE: resto de limitaciones]

15.3. Trabajo futuro

[PENDIENTE: trabajo futuro]

Parte V.

Apéndices

A. Tablas de AUPR-In y AUPR-Out

Tabla A.1.: AUPR-In (clase positiva: ID) de los 16 métodos en los nueve conjuntos (más alto es mejor). [a]ASH reduce la exactitud ID al 68,3 %. †Variante exploratoria ($K_c = \min(500, \lfloor n_c/2 \rfloor)$), propuesta tras ver datos OOD; no es el método principal.

Método	TUM+NORM	TUM	NORM	STR	LYM	MUS	PANDA	Control 128 px	DTD
Basados en logits									
MSP	0,676	0,762	0,845	0,760	0,773	0,629	0,821	0,587	0,903
MaxLogit	0,602	0,689	0,815	0,706	0,639	0,515	0,719	0,590	0,872
Energy	0,594	0,681	0,813	0,699	0,627	0,503	0,709	0,588	0,869
Modificación de activaciones									
ReAct	0,690	0,783	0,851	0,767	0,783	0,563	0,764	0,558	0,867
ASH[a]	0,339	0,422	0,606	0,521	0,496	0,381	0,446	0,501	0,678
DICE	0,525	0,611	0,739	0,690	0,873	0,591	0,747	0,580	0,650
Características y distancias									
KNN	0,944	0,957	0,978	0,953	0,961	0,922	0,934	0,806	0,973
MDS	0,955	0,966	0,983	0,959	0,973	0,924	0,942	0,815	0,981
RMDS	0,899	0,909	0,980	0,958	0,704	0,924	0,924	0,725	0,977
ViM	0,958	0,968	0,984	0,960	0,975	0,926	0,943	0,823	0,983
SHE (prod. escalar)	0,592	0,628	0,908	0,789	0,697	0,652	0,643	0,641	0,901
SHE (coseno)	0,915	0,935	0,967	0,920	0,929	0,839	0,880	0,647	0,953
SHE (euclídea)	0,916	0,937	0,967	0,923	0,939	0,846	0,892	0,631	0,953
STOOD-X									
STOOD-X (100 %)	0,910	0,914	0,993	0,982	0,897	0,968	0,919	0,888	0,996
STOOD-X (87,5 %)	0,909	0,913	0,993	0,982	0,896	0,967	0,919	0,887	0,996
STOOD-X K_c †	0,897	0,904	0,989	0,981	0,848	0,966	0,941	0,891	0,995

Tabla A.2.: AUPR-Out (clase positiva: OOD) de los 16 métodos en los nueve conjuntos (más alto es mejor). [a]ASH reduce la exactitud ID al 68,3 %. †Variante exploratoria ($K_c = \min(500, \lfloor n_c/2 \rfloor)$), propuesta tras ver datos OOD; no es el método principal.

Método	TUM+NORM	TUM	NORM	STR	LYM	MUS	PANDA	Control 128 px	DTD
Basados en logits									
MSP	0,935	0,904	0,871	0,818	0,867	0,777	0,800	0,660	0,782
MaxLogit	0,913	0,866	0,846	0,774	0,792	0,676	0,678	0,616	0,730
Energy	0,910	0,861	0,844	0,766	0,779	0,658	0,651	0,612	0,727
Modificación de activaciones									
ReAct	0,929	0,892	0,868	0,793	0,843	0,698	0,685	0,610	0,742
ASH[a]	0,749	0,605	0,650	0,583	0,502	0,440	0,348	0,514	0,392
DICE	0,666	0,541	0,459	0,455	0,768	0,481	0,474	0,543	0,259
Características y distancias									
KNN	0,972	0,951	0,943	0,900	0,934	0,891	0,800	0,710	0,852
MDS	0,980	0,966	0,961	0,923	0,961	0,908	0,853	0,743	0,901
RMDS	0,969	0,951	0,928	0,889	0,870	0,892	0,868	0,717	0,830
ViM	0,981	0,967	0,963	0,926	0,965	0,910	0,853	0,752	0,907
SHE (prod. escalar)	0,883	0,795	0,833	0,757	0,658	0,700	0,457	0,586	0,659
SHE (coseno)	0,960	0,932	0,923	0,866	0,898	0,841	0,741	0,639	0,797
SHE (euclídea)	0,965	0,942	0,930	0,874	0,920	0,851	0,776	0,642	0,807
STOOD-X									
STOOD-X (100 %)	0,975	0,946	0,982	0,968	0,900	0,964	0,857	0,897	0,975
STOOD-X (87,5 %)	0,975	0,946	0,982	0,969	0,900	0,964	0,860	0,896	0,975
STOOD-X K_c †	0,970	0,937	0,978	0,967	0,784	0,963	0,873	0,897	0,973

B. Anexo: clases ADI, BACK, DEB y MUC de NCT-CRC

[PENDIENTE: breve introducción del anexo y análisis]

Tabla B.1.: Clases restantes de NCT-CRC-HE-100K-NONORM: tejido adiposo (ADI), fondo (BACK), restos celulares (DEB) y moco (MUC). AUROC (más alto es mejor) y FPR@95 (más bajo es mejor); clase positiva: OOD. [a], [†]: como en cuadro 10.1.

	AUROC ↑				FPR@95 ↓			
Método	ADI	BACK	DEB	MUC	ADI	BACK	DEB	MUC
Basados en logits								
MSP	0,736	0,884	0,798	0,735	0,769	0,904	0,987	0,977
MaxLogit	0,548	0,834	0,780	0,687	0,866	0,947	0,993	0,982
Energy	0,536	0,827	0,767	0,681	0,869	0,944	0,994	0,982
Modificación de activaciones								
ReAct	0,569	0,775	0,875	0,746	0,741	0,980	0,579	0,980
ASH[a]	0,469	0,617	0,608	0,448	0,954	0,928	0,989	0,999
DICE	0,561	0,334	0,742	0,483	0,551	0,993	0,673	0,907
Características y distancias								
KNN	0,725	0,952	0,956	0,944	0,599	0,151	0,136	0,164
MDS	0,758	0,968	0,975	0,961	0,531	0,128	0,096	0,144
RMDS	0,781	0,949	0,939	0,946	0,558	0,127	0,132	0,130
ViM	0,752	0,969	0,976	0,962	0,550	0,120	0,088	0,141
SHE (prod. escalar)	0,370	0,910	0,668	0,780	0,822	0,292	0,997	0,668
SHE (coseno)	0,646	0,931	0,940	0,918	0,693	0,236	0,165	0,269
SHE (euclídea)	0,660	0,925	0,951	0,923	0,681	0,247	0,167	0,267

C. Material complementario

C.1. Explicaciones por ejemplos de STOOD-X

[PENDIENTE: presentación de las figuras]

C.1.1. Con $K = 500$

C.1.2. Con la variante exploratoria K_c

[PENDIENTE: presentación de las figuras]

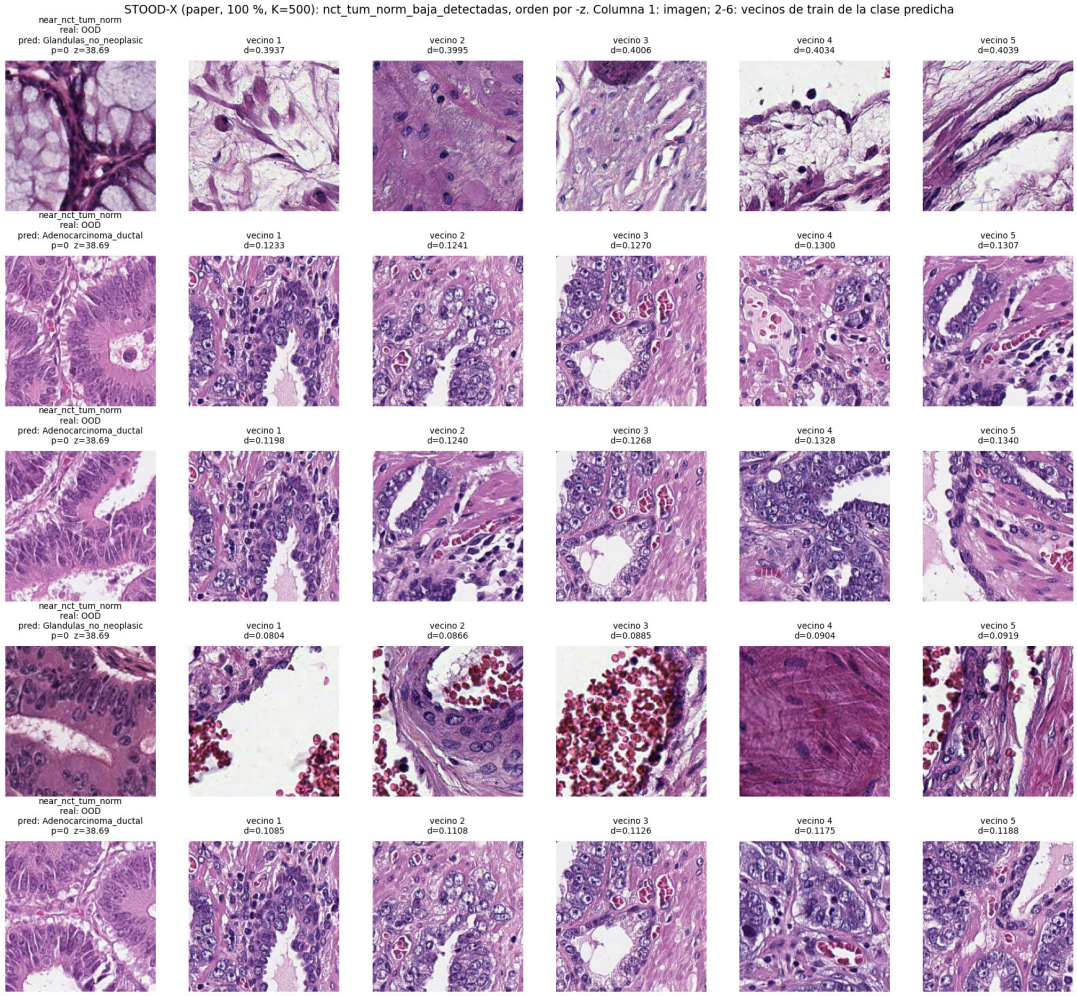

Figura C.1.: STOOD-X ($K = 500$): cinco imágenes de TUM+NORM bien detectadas como OOD y sus vecinos de entrenamiento de la clase predicha.

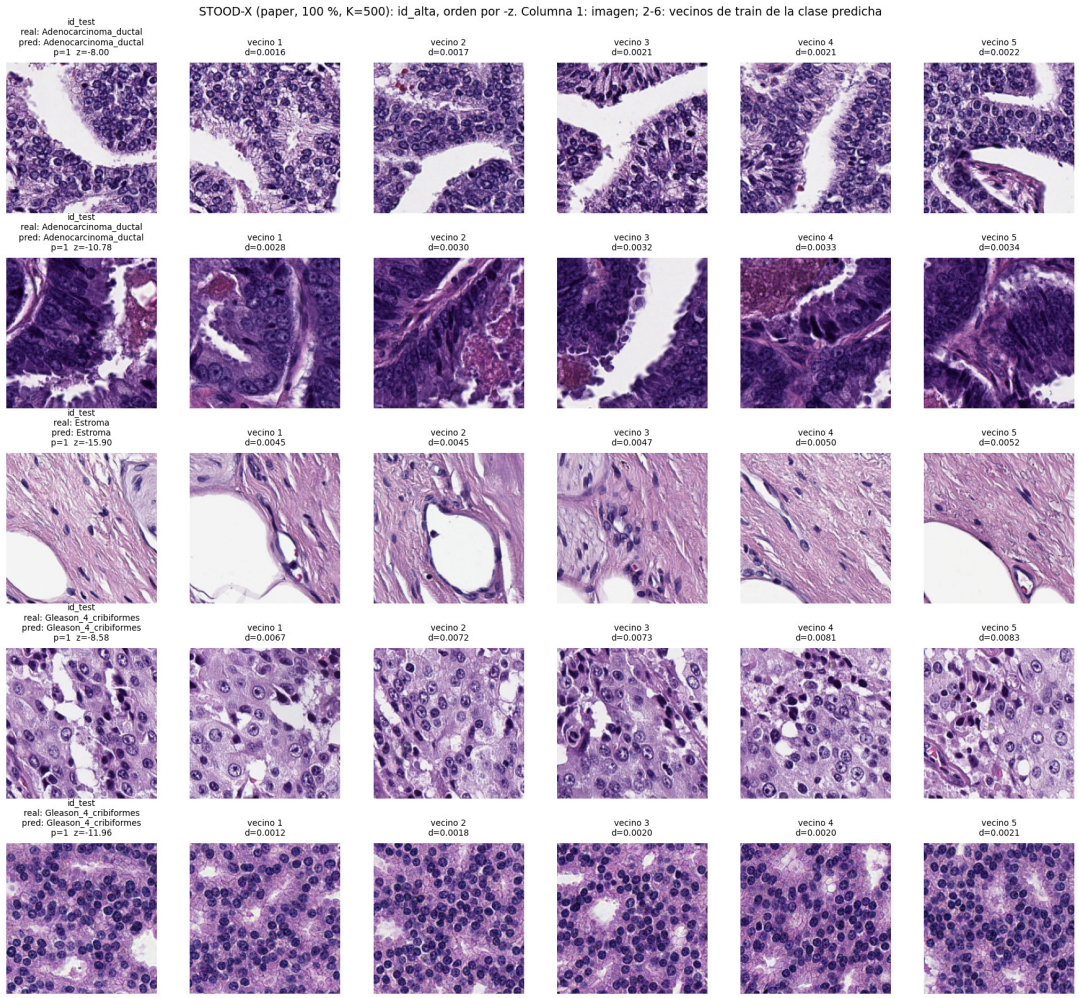

Figura C.2.: STOOD-X ($K = 500$): cinco imágenes ID con puntuación alta y sus vecinos de entrenamiento de la clase predicha: casos ID típicos.

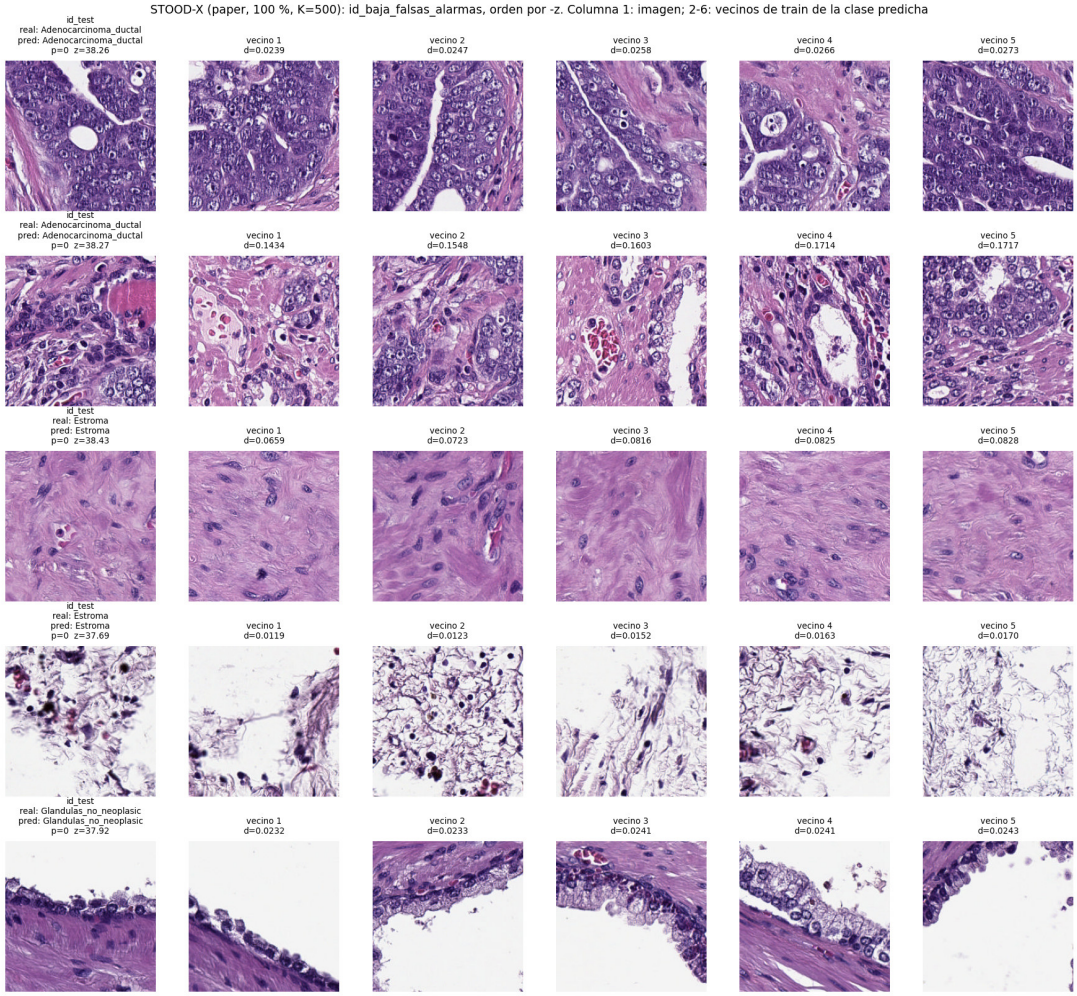

Figura C.3.: STOOD-X ($K = 500$): cinco imágenes ID con puntuación baja (falsas alarmas) y sus vecinos de entrenamiento (z saturada, ≈ 38).

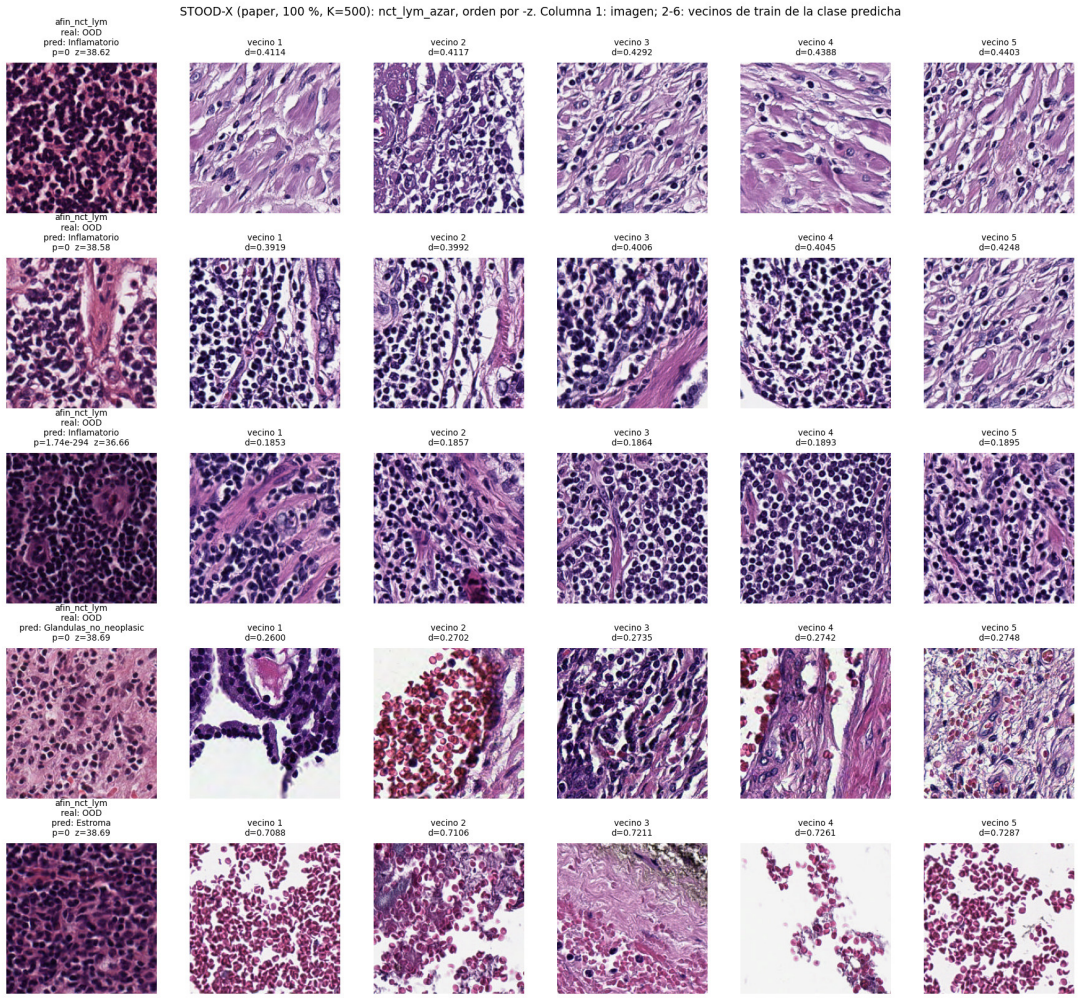

Figura C.4.: STOOD-X ($K = 500$): cinco imágenes de LYM elegidas al azar y sus vecinos de entrenamiento de la clase predicha.

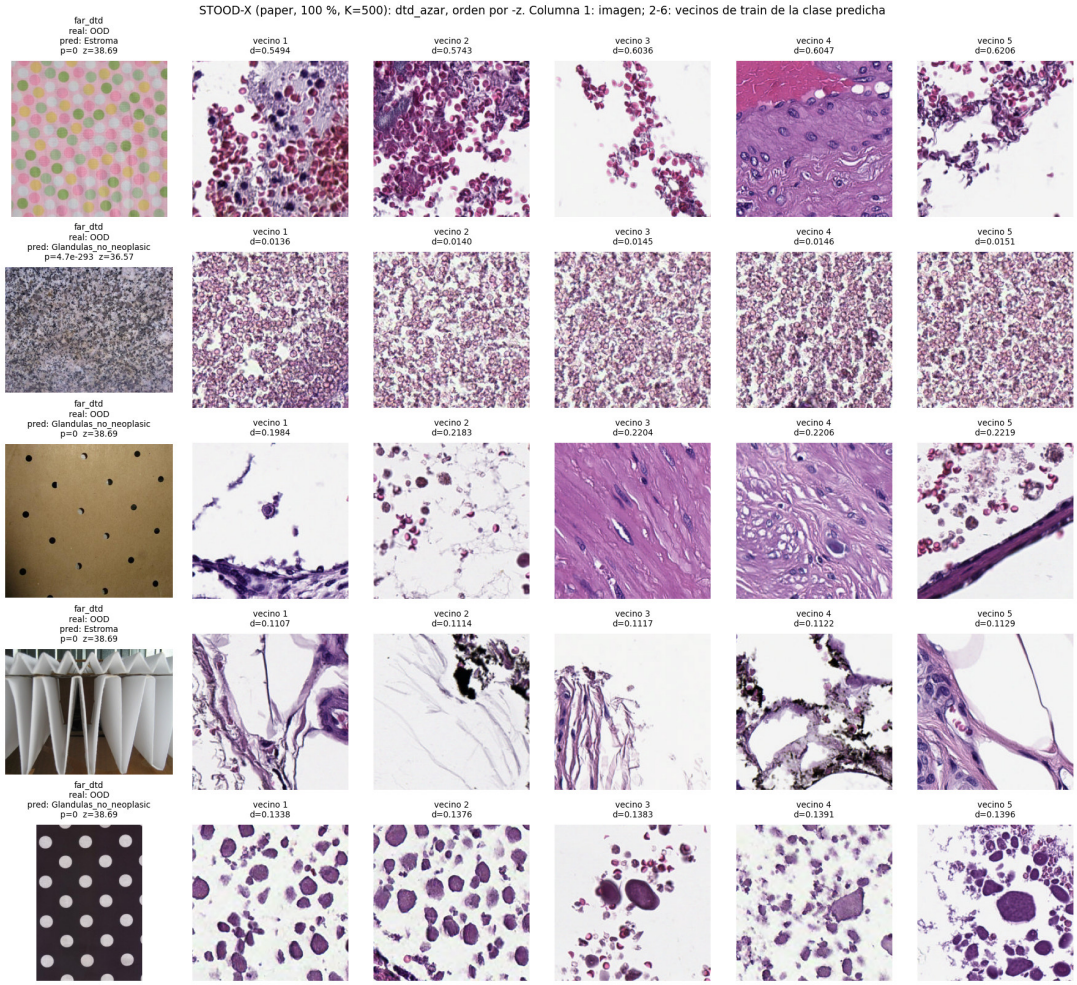

Figura C.5.: STOOD-X ($K = 500$): cinco imágenes de DTD elegidas al azar y sus vecinos de entrenamiento de la clase predicha.

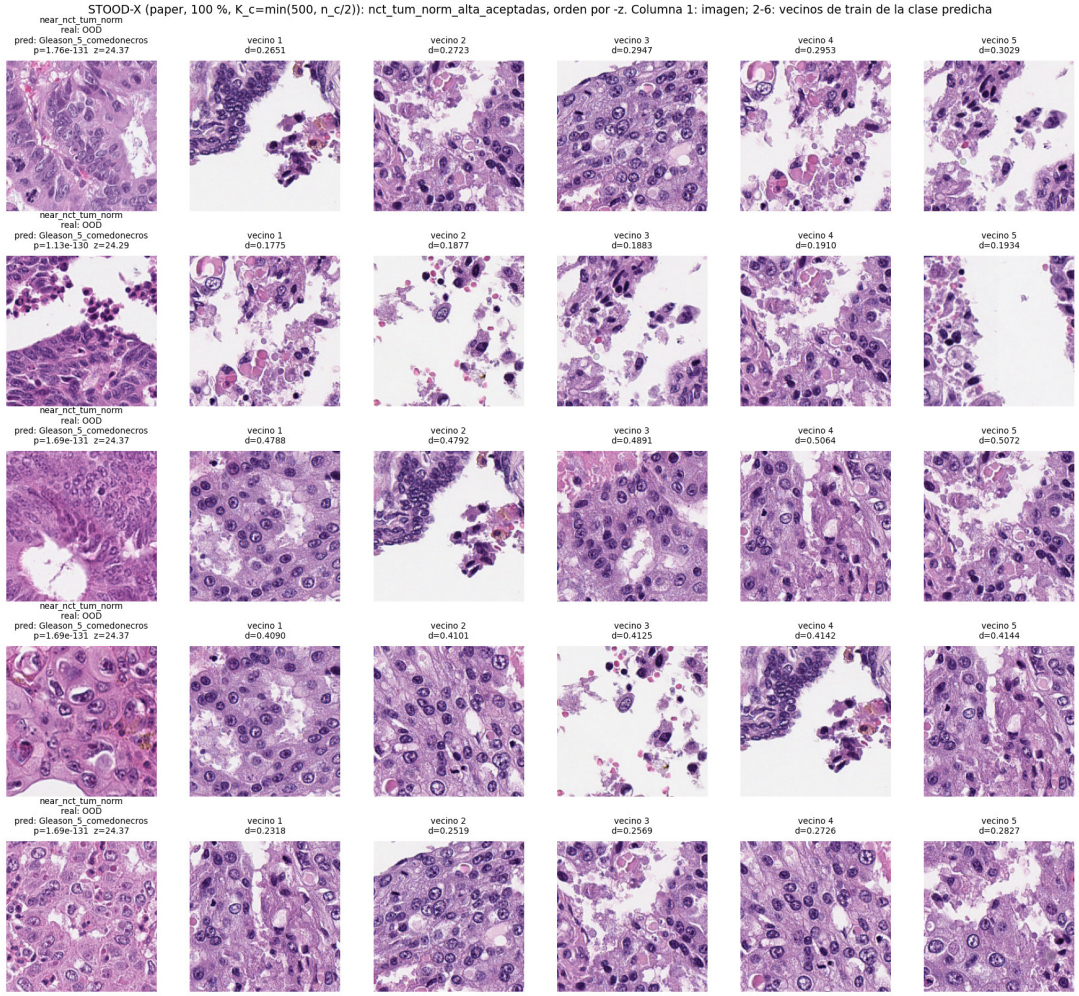

Figura C.6.: STOOD-X (variante exploratoria K_c): cinco imágenes de TUM+NORM aceptadas como ID y sus vecinos de entrenamiento de la clase predicha.

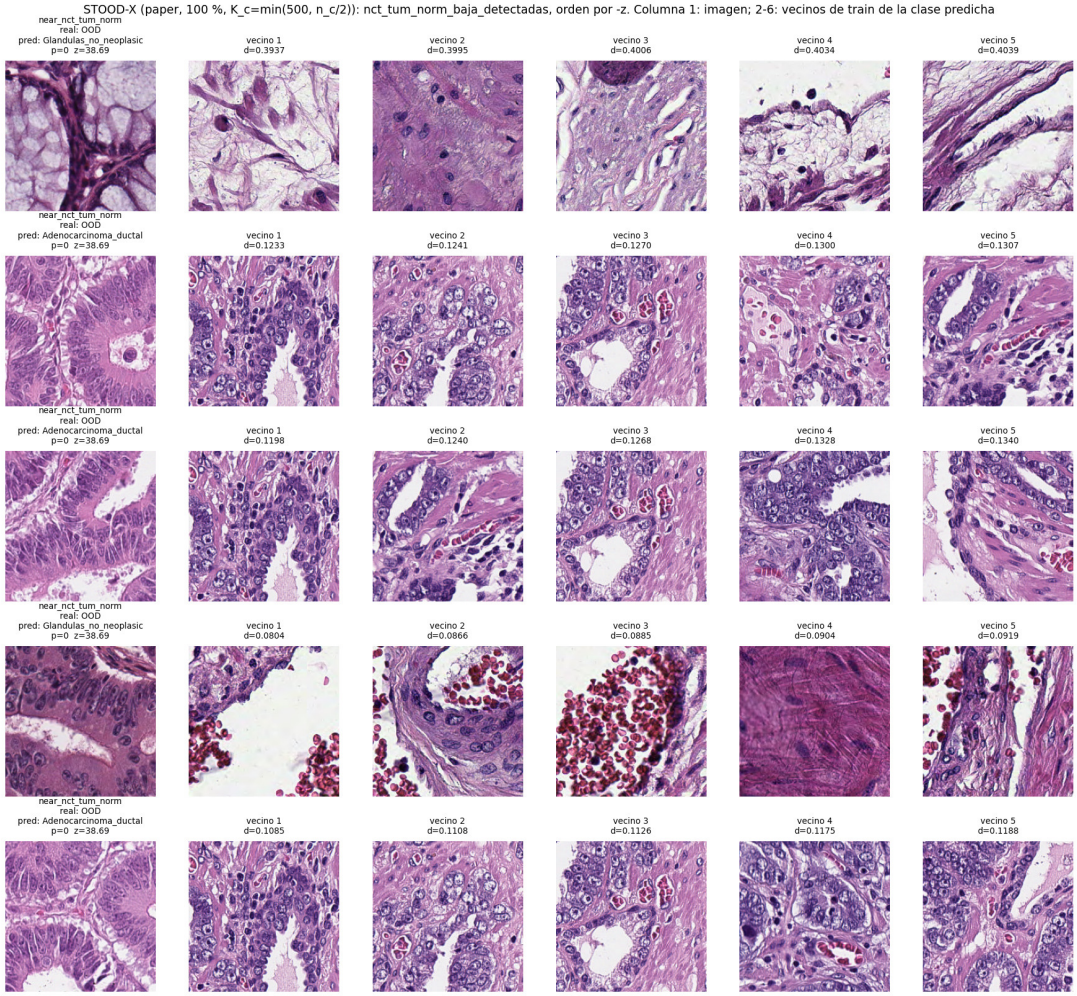

Figura C.7.: STOOD-X (variante exploratoria K_c): cinco imágenes de TUM+NORM bien detectadas como OOD y sus vecinos de entrenamiento de la clase predicha.

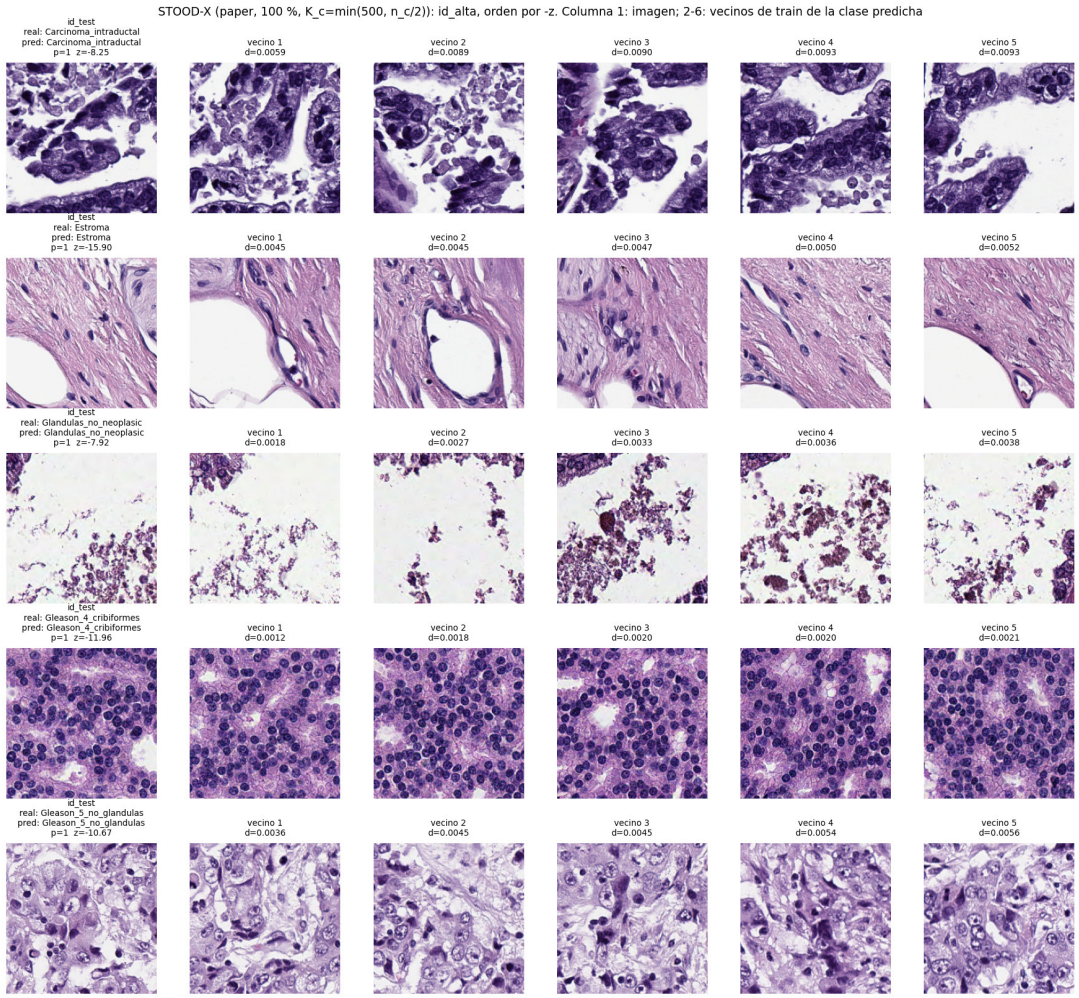

Figura C.8.: STOOD-X (variante exploratoria K_c): cinco imágenes ID con puntuación alta y sus vecinos de entrenamiento de la clase predicha.

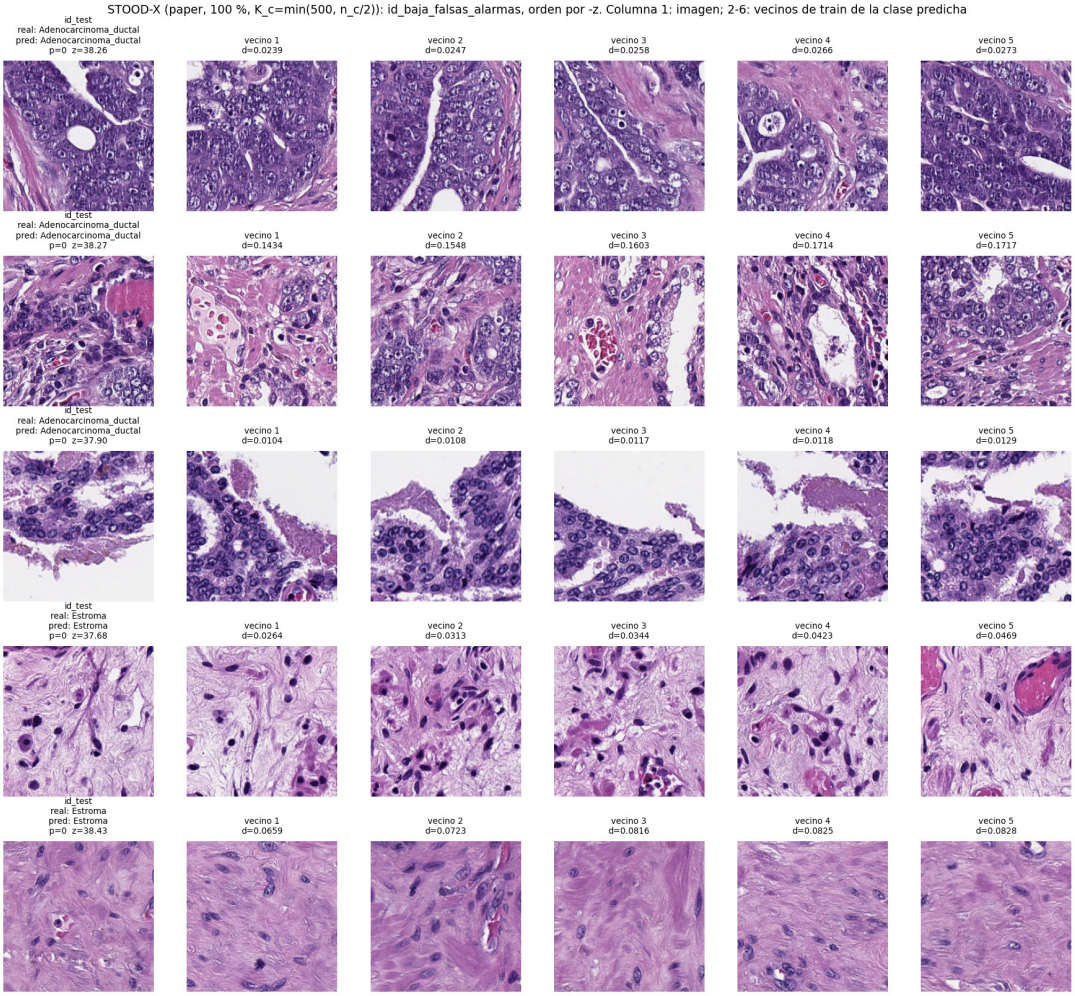

Figura C.9.: STOOD-X (variante exploratoria K_c): cinco imágenes ID con puntuación baja (falsas alarmas) y sus vecinos de entrenamiento de la clase predicha.

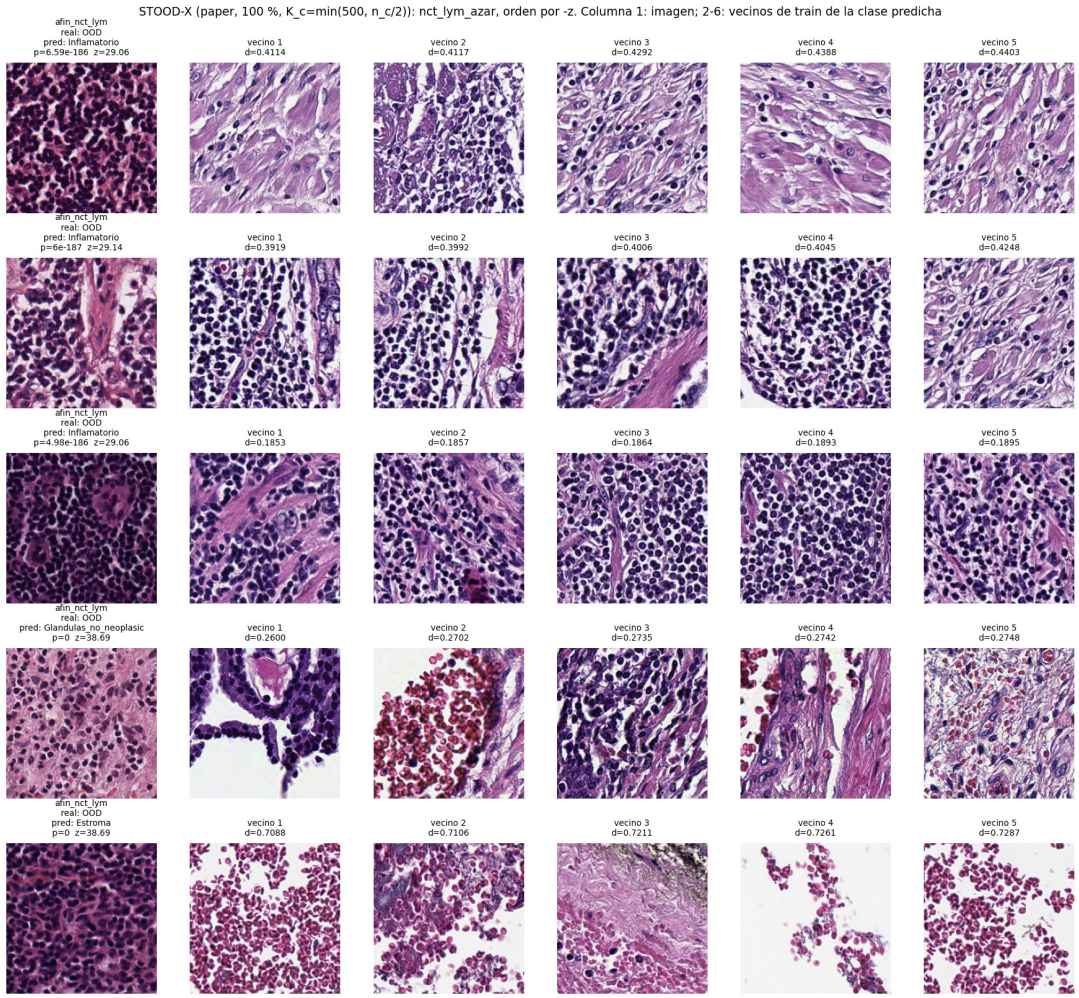

Figura C.10.: STOOD-X (variante exploratoria K_c): cinco imágenes de LYM elegidas al azar y sus vecinos de entrenamiento de la clase predicha.

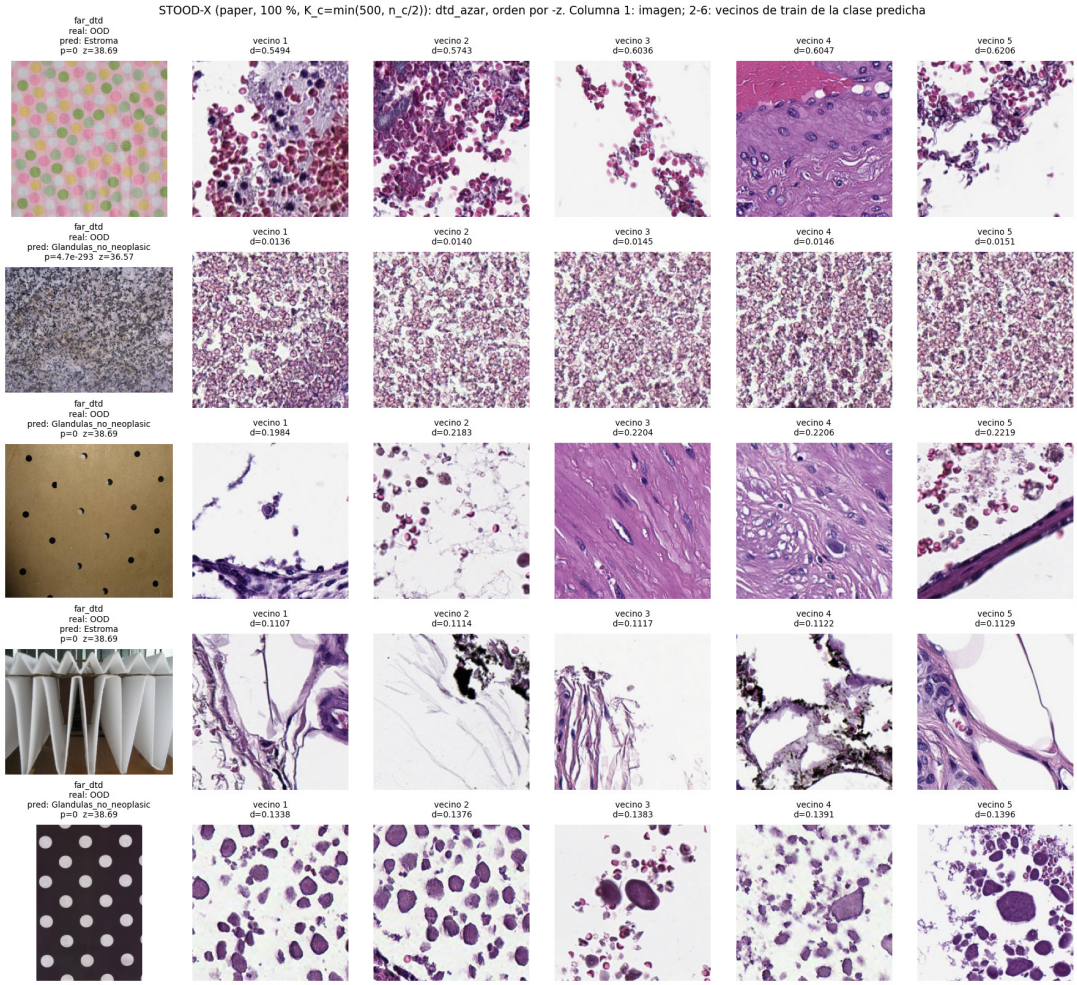

Figura C.11.: STOOD-X (variante exploratoria K_c): cinco imágenes de DTD elegidas al azar y sus vecinos de entrenamiento de la clase predicha.

C.2. Imágenes de muestra

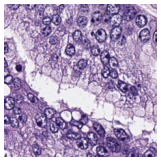

(a) Adenocarcinoma_ductal

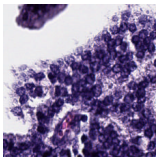

(b) Carcinoma_intraductal

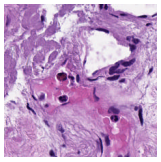

(c) Estroma

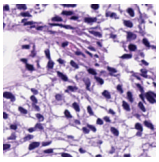

(d) Glandulas_no_neoplasicas

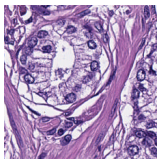

(e) Gleason_3

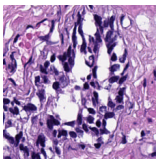

(f) Gleason_4_cribiformes

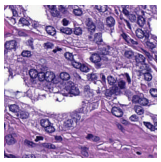

(g) Gleason_4_fusionadas

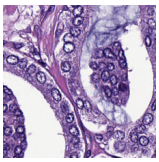

(h) Gleason_4_glomeruloide

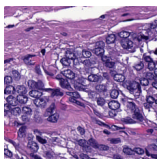

(i) Gleason_4_pobremente_formadas

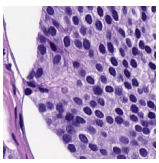

(j) Gleason_5_comedonecrosis

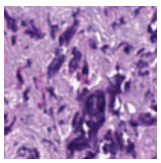

(k) Gleason_5_no_glandulas

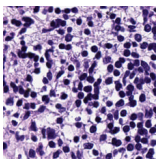

(l) Inflamatorio

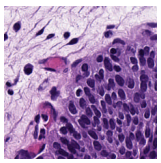

(m) No_Cancer

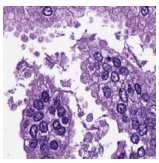

(n) PIN_de_alto_grado

Figura C.12.: Primera imagen de cada clase del conjunto de test, por orden de nombre de fichero. **[REVISAR: pie de figura redactado por el agente]**

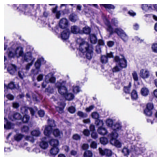

(a) Adenocarcinoma_ductal

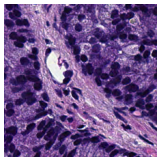

(b) Carcinoma_intraductal

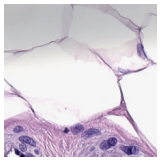

(c) Estroma

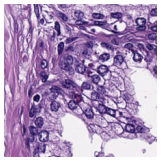

(d) Glandulas_no_neoplasicas

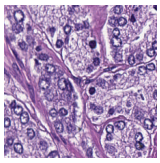

(e) Gleason_3

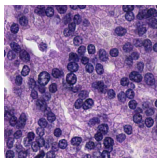

(f) Gleason_4_cribiformes

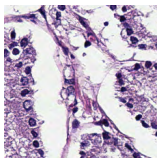

(g) Gleason_4_fusionadas

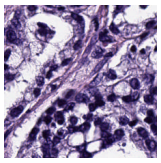

(h) Gleason_4_glomeruloide

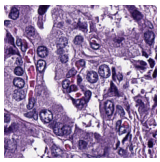

(i) Gleason_4_pobremente_formadas

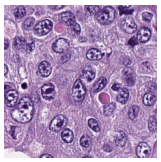

(j) Gleason_5_comedonecrosis

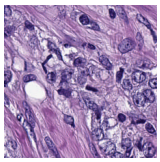

(k) Gleason_5_no_glandulas

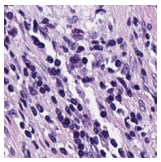

(l) Inflamatorio

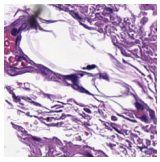

(m) No_Cancer

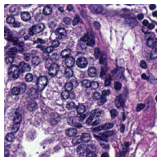

(n) PIN_de_alto_grado

Figura C.13.: Una imagen elegida al azar de cada clase del conjunto de test. **[REVISAR: pie de figura redactado por el agente]**

Bibliografía

[1] Reduan Achtibat, Maximilian Dreyer, Ilona Eisenbraun, Sebastian Bosse, Thomas Wiegand, Wojciech Samek, y Sebastian Lapuschkin. From attribution maps to human-understandable explanations through concept relevance propagation. *Nature Machine Intelligence*, 5(9):1006–1019, 2023.

[2] Anastasios Angelopoulos, Stephen Bates, Jitendra Malik, y Michael I. Jordan. Uncertainty sets for image classifiers using conformal prediction. En *International Conference on Learning Representations (ICLR)*, 2021. arXiv:2009.14193.

[3] Anastasios N. Angelopoulos y Stephen Bates. A gentle introduction to conformal prediction and distribution-free uncertainty quantification. *arXiv preprint arXiv:2107.07511*, 2021.

[4] Jacobo Ayensa-Jiménez, Denis Navarro, Iván Sevillano-García, Andrés Mena, Isabel Marquina, Sofía Hakim, Jorge Alfaro, Francisco Herrera, Manuel Doblaré, y Ángel Borque-Fernando. Fine-grained prostate cancer tissue classification through expert-annotated dataset and clinically interpretable deep learning. En *2026 IEEE Conference on Artificial Intelligence (CAI)*, páginas 1264–1269, 2026.

[5] Sebastian Bach, Alexander Binder, Grégoire Montavon, Frederick Klauschen, Klaus-Robert Müller, y Wojciech Samek. On pixel-wise explanations for non-linear classifier decisions by layer-wise relevance propagation. *PLOS ONE*, 10(7):e0130140, 2015.

[6] David Balduzzi, Marcus Frean, Lennox Leary, J. P. Lewis, Kurt Wan-Duo Ma, y Brian McWilliams. The shattered gradients problem: If resnets are the answer, then what is the question? En *Proceedings of the 34th International Conference on Machine Learning (ICML)*, volume 70 of *Proceedings of Machine Learning Research*, páginas 342–350, 2017. arXiv:1702.08591.

[7] Alejandro Barredo Arrieta, Natalia Díaz-Rodríguez, Javier Del Ser, Adrien Bennetot, Siham Tabik, Alberto Barbado, Salvador García, Sergio Gil-López, Daniel Molina, Richard Benjamins, Raja Chatila, y Francisco Herrera. Explainable artificial intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI. *Information Fusion*, 58:82–115, 2020.

[8] Wouter Bulten, Kimmo Kartasalo, Po-Hsuan Cameron Chen, Peter Ström, Hans Pinckaers, Kunal Nagpal, Yuannan Cai, David F. Steiner, Hester van Boven, Robert Vink, et al. Artificial intelligence for diagnosis and Gleason grading of prostate cancer: The PANDA challenge. *Nature Medicine*, 28(1):154–163, 2022.

[9] George C. Canavos. *Probabilidad y estadística: aplicaciones y métodos*. McGraw-Hill Interamericana, México, 2003.

[10] Mircea Cimpoi, Subhransu Maji, Iasonas Kokkinos, Sammy Mohamed, y Andrea Vedaldi. Describing textures in the wild. En *2014 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, páginas 3606–3613, 2014.

[11] B. J. Copeland y Britannica Editors. Connectionism. *Encyclopædia Britannica*, 2026. Accedido: 2026-11-12.

[12] George Cybenko. Approximation by superpositions of a sigmoidal function. *Mathematics of Control, Signals and Systems*, 2(4):303–314, 1989.

[13] Akshay Raj Dhamija, Manuel Günther, y Terrance E. Boult. Reducing network agnostophobia. En *Advances in Neural Information Processing Systems (NeurIPS)*, 2018. arXiv:1811.04110.

[14] Andrija Djurisic, Nebojsa Bozanic, Arjun Ashok, y Rosanne Liu. Extremely simple activation shaping for out-of-distribution detection. En *International Conference on Learning Representations (ICLR)*, 2023. arXiv:2209.09858.

[15] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, y Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. En *International Conference on Learning Representations (ICLR)*, 2021. arXiv:2010.11929.

[16] B. Efron. Bootstrap methods: Another look at the jackknife. *The Annals of Statistics*, 7(1):1–26, 1979.

[17] Zhen Fang, Yixuan Li, Jie Lu, Jiahua Dong, Bo Han, y Feng Liu. Is out-of-distribution detection learnable? En *Advances in Neural Information Processing Systems (NeurIPS)*, 2022. arXiv:2210.14707.

[18] Tom Fawcett. An introduction to ROC analysis. *Pattern Recognition Letters*, 27(8):861–874, 2006.

[19] Ian Goodfellow, Yoshua Bengio, y Aaron Courville. *Deep Learning*. MIT Press, Cambridge, MA, 2016.

[20] Isabelle Guyon y André Elisseeff. An introduction to variable and feature selection. *Journal of Machine Learning Research*, 3:1157–1182, 2003.

[21] Kaiming He, Xiangyu Zhang, Shaoqing Ren, y Jian Sun. Deep residual learning for image recognition. En *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, páginas 770–778, 2016.

[22] Dan Hendrycks, Steven Basart, Mantas Mazeika, Andy Zou, Joe Kwon, Mohammadreza Mostajabi, Jacob Steinhardt, y Dawn Song. Scaling out-of-distribution detection for real-world settings. En *International Conference on Machine Learning (ICML)*, 2022. arXiv:1911.11132.

[23] Dan Hendrycks y Kevin Gimpel. Gaussian error linear units (GELUs). *arXiv preprint arXiv:1606.08415*, 2016.

[24] Dan Hendrycks y Kevin Gimpel. A baseline for detecting misclassified and out-of-distribution examples in neural networks. En *International Conference on Learning Representations (ICLR)*, 2017. arXiv:1610.02136.

[25] Kurt Hornik, Maxwell Stinchcombe, y Halbert White. Multilayer feedforward networks are universal approximators. *Neural Networks*, 2(5):359–366, 1989.

[26] Frederick M. Howard, James Dolezal, Sara Kochanny, Jefree Schulte, Heather Chen, Lara Heij, Dezheng Huo, Rita Nanda, Olufunmilayo I. Olopade, Jakob N. Kather, Nicole Cipriani, Robert L. Grossman, y Alexander T. Pearson. The impact of site-specific digital histology signatures on deep learning model accuracy and bias. *Nature Communications*, 12:4423, 2021.

[27] Rui Huang, Andrew Geng, y Yixuan Li. On the importance of gradients for detecting distributional shifts in the wild. En *Advances in Neural Information Processing Systems (NeurIPS)*, 2021. arXiv:2110.00218.

[28] iafoss. PANDA 16x128x128 tiles data. Conjunto de datos de Kaggle, https://www.kaggle.com/iafoss/panda-16x128x128-tiles-data. Consultado el 26/10/2026. VERIFICAR: autor (tomado del nombre de usuario de la URL) y fecha de publicación, que la página no muestra sin iniciar sesión.

[29] Conor Igoe, Youngseog Chung, Ian Char, y Jeff Schneider. How useful are gradients for OOD detection really? *arXiv preprint arXiv:2205.10439*, 2022.

[30] Ibrahem Kandel y Mauro Castelli. How deeply to fine-tune a convolutional neural network: A case study using a histopathology dataset. *Applied Sciences*, 10(10):3359, 2020.

[31] Jakob Nikolas Kather, Niels Halama, y Alexander Marx. 100,000 histological images of human colorectal cancer and healthy tissue. Zenodo, 2018. Versión v0.1.

[32] Jakob Nikolas Kather, Johannes Krisam, Pornpimol Charoentong, Tom Luedde, Esther Herpel, Cleo-Aron Weis, Timo Gaiser, Alexander Marx, Nektarios A. Valous, Dyke Ferber, et al. Predicting survival from colorectal cancer histology slides using deep learning: A retrospective multicenter study. *PLOS Medicine*, 16(1):e1002730, 2019.

[33] Diederik P. Kingma y Jimmy Ba. Adam: A method for stochastic optimization. En *3rd International Conference on Learning Representations (ICLR)*, 2015. arXiv:1412.6980.

[34] Will Landecker, Michael D. Thomure, Luis M. A. Bettencourt, Melanie Mitchell, Garrett T. Kenyon, y Steven P. Brumby. Interpreting individual classifications of hierarchical networks. En *2013 IEEE Symposium on Computational Intelligence and Data Mining (CIDM)*, páginas 32–38, 2013.

[35] Sebastian Lapuschkin, Stephan Wäldchen, Alexander Binder, Grégoire Montavon, Wojciech Samek, y Klaus-Robert Müller. Unmasking Clever Hans predictors and assessing what machines really learn. *Nature Communications*, 10:1096, 2019.

[36] Kimin Lee, Kibok Lee, Honglak Lee, y Jinwoo Shin. A simple unified framework for detecting out-of-distribution samples and adversarial attacks. En *Advances in Neural Information Processing Systems (NeurIPS)*, 2018. arXiv:1807.03888.

[37] Moshe Leshno, Vladimir Ya. Lin, Allan Pinkus, y Shimon Schocken. Multilayer feedforward networks with a nonpolynomial activation function can approximate any function. *Neural Networks*, 6(6):861–867, 1993.

[38] Shiyu Liang, Yixuan Li, y R. Srikant. Enhancing the reliability of out-of-distribution image detection in neural networks. En *International Conference on Learning Representations (ICLR)*, 2018. arXiv:1706.02690.

[39] Jasper Linmans, Stefan Elfwing, Jeroen van der Laak, y Geert Litjens. Predictive uncertainty estimation for out-of-distribution detection in digital pathology. *Medical Image Analysis*, 83:102655, 2023.

[40] Weitang Liu, Xiaoyun Wang, John D. Owens, y Yixuan Li. Energy-based out-of-distribution detection. En *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*, 2020. arXiv:2010.03759.

[41] Ze Liu, Yutong Lin, Yue Cao, Han Hu, Yixuan Wei, Zheng Zhang, Stephen Lin, y Baining Guo. Swin transformer: Hierarchical vision transformer using shifted windows. En *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*, páginas 9992–10002, 2021.

[42] Zhuang Liu, Hanzi Mao, Chao-Yuan Wu, Christoph Feichtenhofer, Trevor Darrell, y Saining Xie. A ConvNet for the 2020s. En *2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, páginas 11966–11976, 2022.

[43] Ilya Loshchilov y Frank Hutter. Decoupled weight decay regularization. En *International Conference on Learning Representations (ICLR)*, 2019. arXiv:1711.05101.

[44] Marc Macenko, Marc Niethammer, J. S. Marron, David Borland, John T. Woosley, Xiaojun Guan, Charles Schmitt, y Nancy E. Thomas. A method for normalizing histology slides for quantitative analysis. En *2009 IEEE International Symposium on Biomedical Imaging: From Nano to Macro*, páginas 1107–1110, 2009.

[45] H. B. Mann y D. R. Whitney. On a test of whether one of two random variables is stochastically larger than the other. *The Annals of Mathematical Statistics*, 18(1):50–60, 1947.

[46] Quinn McNemar. Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, 12(2):153–157, 1947.

[47] Paulius Micikevicius, Sharan Narang, Jonah Alben, Gregory Diamos, Erich Elsen, David Garcia, Boris Ginsburg, Michael Houston, Oleksii Kuchaiev, Ganesh Venkatesh, y Hao Wu. Mixed precision training. En *International Conference on Learning Representations (ICLR)*, 2018. arXiv:1710.03740.

[48] Grégoire Montavon, Alexander Binder, Sebastian Lapuschkin, Wojciech Samek, y Klaus-Robert Müller. Layer-wise relevance propagation: An overview. En *Explainable AI: Interpreting, Explaining and Visualizing Deep Learning*, volume 11700 of *Lecture Notes in Artificial Intelligence*, páginas 193–209. Springer, 2019.

[49] Grégoire Montavon, Sebastian Lapuschkin, Alexander Binder, Wojciech Samek, y Klaus-Robert Müller. Explaining nonlinear classification decisions with deep Taylor decomposition. *Pattern Recognition*, 65:211–222, 2017.

[50] Grégoire Montavon, Wojciech Samek, y Klaus-Robert Müller. Methods for interpreting and understanding deep neural networks. *Digital Signal Processing*, 73:1–15, 2018.

[51] Rafael Müller, Simon Kornblith, y Geoffrey Hinton. When does label smoothing help? En *Advances in Neural Information Processing Systems (NeurIPS)*, 2019. arXiv:1906.02629.

[52] Daniel Peña. *Fundamentos de Estadística*. El Libro Universitario. Manuales. Alianza Editorial, Madrid, 2 edition, 2008. 4.ª reimpresión.

[53] Allan Pinkus. Approximation theory of the MLP model in neural networks. *Acta Numerica*, 8:143–195, 1999.

[54] Simon J. D. Prince. *Understanding Deep Learning*. MIT Press, 2023.

[55] Foster J. Provost, Tom Fawcett, y Ron Kohavi. The case against accuracy estimation for comparing induction algorithms. En *Proceedings of the Fifteenth International Conference on Machine Learning (ICML '98)*, páginas 445–453, San Francisco, CA, USA, 1998. Morgan Kaufmann.

[56] Hubert Ramsauer, Bernhard Schäfl, Johannes Lehner, Philipp Seidl, Michael Widrich, Lukas Gruber, Markus Holzleitner, Milena Pavlović, Geir Kjetil Sandve, Victor Greiff, David Kreil, Michael Kopp, Günter Klambauer, Johannes Brandstetter, y Sepp Hochreiter. Hopfield networks is all you need. En *International Conference on Learning Representations (ICLR)*, 2021.

[57] Russell Reed y Robert J. Marks II. *Neural Smithing: Supervised Learning in Feedforward Artificial Neural Networks*. MIT Press, Cambridge, MA, 1999.

[58] Jie Ren, Stanislav Fort, Jeremiah Liu, Abhijit Guha Roy, Shreyas Padhy, y Balaji Lakshminarayanan. A simple fix to Mahalanobis distance for improving near-OOD detection. *arXiv preprint arXiv:2106.09022*, 2021.

[59] Yaniv Romano, Matteo Sesia, y Emmanuel J. Candès. Classification with valid and adaptive coverage. En *Advances in Neural Information Processing Systems 33 (NeurIPS 2020)*, 2020. arXiv:2006.02544.

[60] Joan Serrà, David Álvarez, Vicenç Gómez, Olga Slizovskaia, José F. Núñez, y Jordi Luque. Input complexity and out-of-distribution detection with likelihood-based generative models. En *International Conference on Learning Representations (ICLR)*, 2020. arXiv:1909.11480.

[61] Iván Sevillano García. *Inteligencia Artificial Explicable: Métodos para generación, evaluación y corrección de explicaciones*. PhD thesis, Universidad de Granada, Granada, May 2025. Tesis doctoral. ISBN 979-13-7015-043-3.

[62] Iván Sevillano-García, Julián Luengo, y Francisco Herrera. STOOD-X: Explainable out-of-distribution detection via nonparametric statistical testing on large-scale datasets. *Pattern Recognition*, 177:113254, 2026.

[63] Glenn Shafer y Vladimir Vovk. A tutorial on conformal prediction. *Journal of Machine Learning Research*, 9:371–421, 2008. arXiv:0706.3188.

[64] Avanti Shrikumar, Peyton Greenside, y Anshul Kundaje. Learning important features through propagating activation differences. En *Proceedings of the 34th International Conference on Machine Learning (ICML)*, volume 70 of *Proceedings of Machine Learning Research*, páginas 3145–3153, 2017. arXiv:1704.02685.

[65] Avanti Shrikumar, Peyton Greenside, Anna Shcherbina, y Anshul Kundaje. Not just a black box: Learning important features through propagating activation differences. *arXiv preprint arXiv:1605.01713*, 2016.

[66] Andrea M. Storås, Maximilian Dreyer, Frederik Pahde, Sebastian Lapuschkin, Wojciech Samek, Pål Halvorsen, Thomas de Lange, Yuichi Mori, Alexander Hann, Tyler M. Berzin, Sravanthi Parasa, y Michael A. Riegler. Exploring the clinical value of concept-based AI explanations in gastrointestinal disease detection. *Scientific Reports*, 15:28860, 2025.

[67] Yiyou Sun, Chuan Guo, y Yixuan Li. ReAct: Out-of-distribution detection with rectified activations. En *Advances in Neural Information Processing Systems (NeurIPS)*, 2021. arXiv:2111.12797.

[68] Yiyou Sun y Yixuan Li. DICE: Leveraging sparsification for out-of-distribution detection. En *Computer Vision – ECCV 2022*, Lecture Notes in Computer Science, páginas 691–708. Springer, 2022.

[69] Yiyou Sun, Yifei Ming, Xiaojin Zhu, y Yixuan Li. Out-of-distribution detection with deep nearest neighbors. En *Proceedings of the 39th International Conference on Machine Learning (ICML)*, volume 162 of *Proceedings of Machine Learning Research*, páginas 20827–20840, 2022. arXiv:2204.06507.

[70] Christian Szegedy, Wojciech Zaremba, Ilya Sutskever, Joan Bruna, Dumitru Erhan, Ian Goodfellow, y Rob Fergus. Intriguing properties of neural networks. En *2nd International Conference on Learning Representations (ICLR)*, 2014. arXiv:1312.6199.

[71] C. J. Terleth. Artificial neural networks for flow field inference: A machine learning approach. Tesis de máster, Delft University of Technology, Delft, Países Bajos, 2019.

[72] Agastya Todi, Navya Narula, Moolchand Sharma, y Umesh Gupta. ConvNext: A contemporary architecture for convolutional neural networks for image classification. En *2023 3rd International Conference on Innovative Sustainable Computational Technologies (CISCT)*. IEEE, 2023.

[73] Pauli Virtanen, Ralf Gommers, Travis E. Oliphant, Matt Haberland, Tyler Reddy, David Cournapeau, Evgeni Burovski, Pearu Peterson, Warren Weckesser, Jonathan Bright, et al. SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, 17(3):261–272, 2020.

[74] Vladimir Vovk, Alexander Gammerman, y Glenn Shafer. *Algorithmic Learning in a Random World*. Springer, Cham, 2022. 2.ª edición.

[75] Haoqi Wang, Zhizhong Li, Litong Feng, y Wayne Zhang. ViM: Out-of-distribution with virtual-logit matching. En *2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, páginas 4911–4920, 2022.

[76] Frank Wilcoxon. Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80, 1945. VERIFICAR: Crossref solo da la página inicial (80); completar el rango de páginas.

[77] Jingkang Yang, Pengyun Wang, Dejian Zou, Zitang Zhou, Kunyuan Ding, Wenxuan Peng, Haoqi Wang, Guangyao Chen, Bo Li, Yiyou Sun, Xuefeng Du, Kaiyang Zhou, Wayne Zhang, Dan Hendrycks, Yixuan Li, y Ziwei Liu. OpenOOD: Benchmarking generalized out-of-distribution detection. En *Advances in Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track*, 2022. arXiv:2210.07242.

[78] Jingkang Yang, Kaiyang Zhou, Yixuan Li, y Ziwei Liu. Generalized out-of-distribution detection: A survey. *International Journal of Computer Vision*, 132:5635–5662, 2024.

[79] Qing Yu y Kiyoharu Aizawa. Unsupervised out-of-distribution detection by maximum classifier discrepancy. En *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, páginas 9518–9526, 2019.

[80] Jianming Zhang, Sarah Adel Bargal, Zhe Lin, Jonathan Brandt, Xiaohui Shen, y Stan Sclaroff. Top-down neural attention by excitation backprop. *International Journal of Computer Vision*, 126(10):1084–1102, 2018.

[81] Jingyang Zhang, Jingkang Yang, Pengyun Wang, Haoqi Wang, Yueqian Lin, Haoran Zhang, Yiyou Sun, Xuefeng Du, Yixuan Li, Ziwei Liu, Yiran Chen, y Hai Li. OpenOOD v1.5: Enhanced benchmark for out-of-distribution detection. *Journal of Data-centric Machine Learning Research*, 2024. arXiv:2306.09301.

[82] Jinsong Zhang, Qiang Fu, Xu Chen, Lun Du, Zelin Li, Gang Wang, Xiaoguang Liu, Shi Han, y Dongmei Zhang. Out-of-distribution detection based on in-distribution data patterns memorization with modern Hopfield energy. En *International Conference on Learning Representations (ICLR)*, 2023.

[83] David Zimmerer, Peter M. Full, Fabian Isensee, Paul Jäger, Tim Adler, Jens Petersen, Gregor Köhler, Tobias Ross, Annika Reinke, et al. MOOD 2020: A public benchmark for out-of-distribution detection and localization on medical images. *IEEE Transactions on Medical Imaging*, 41(10):2728–2738, 2022.