UNIVERSIDAD
DE GRANADA

Facultad de Ciencias y Escuela Técnica Superior de Ingenierías
Informática y de Telecomunicación

Doble Grado en Ingeniería Informática y Matemáticas

TRABAJO DE FIN DE GRADO

Inteligencia Artificial Explicable en medicina: métodos para introducir al humano en la adquisición de conocimiento

Santiago López Cerro

Curso académico 2026–2027

Inteligencia Artificial Explicable en medicina: métodos para introducir al humano en la adquisición de conocimiento

Santiago López Cerro

Santiago López Cerro *Inteligencia Artificial Explicable en medicina: métodos para introducir al humano en la adquisición de conocimiento*.

Trabajo de fin de Grado. Curso académico 2026–2027.

Responsable de tutorización

Francisco Herrera Triguero
Departamento de Ciencias de la Computación e Inteligencia Artificial

Iván Sevillano García
Departamento de Ciencias de la Computación e Inteligencia Artificial

Doble Grado en Ingeniería Informática y Matemáticas

Facultad de Ciencias y Escuela Técnica Superior de Ingenierías Informática y de Telecomunicación

Universidad de Granada

Declaración de originalidad

D./Dña. Santiago López Cerro

Declaro explícitamente que el trabajo presentado como Trabajo de Fin de Grado (TFG), correspondiente al curso académico 2026–2027, es original, entendido esto en el sentido de que no he utilizado para la elaboración del trabajo fuentes sin citarlas debidamente.

En Granada a 26 de octubre de 2026

Fdo: Santiago López Cerro

Dedicatoria (opcional)
Ver archivo `preliminares/dedicatoria.tex`

Agradecimientos

[PENDIENTE: agradecimientos]

Índice de acrónimos

Acrónimo	Significado
AD	Detección de anomalías (*Anomaly Detection*)
APS	*Adaptive Prediction Sets*
ASH	*Activation Shaping*
AUPR	Área bajo la curva precisión-exhaustividad (*Area Under the Precision-Recall curve*)
AUROC	Área bajo la curva ROC (*Area Under the Receiver Operating Characteristic curve*)
CCR	Tasa de clasificación correcta (*Correct Classification Rate*)
CNN	Red neuronal convolucional (*Convolutional Neural Network*)
CRP	*Concept Relevance Propagation*
DICE	*Directed Sparsification*
DTD	*Describable Textures Dataset*
EBO	*Energy-Based OOD*
FPR	Tasa de falsos positivos (*False Positive Rate*)
H&E	Hematoxilina y eosina
FFPE	Fijado en formalina e incluido en parafina (*Formalin-Fixed Paraffin-Embedded*)
ID	Dentro de la distribución (*In-Distribution*)
KNN	k vecinos más cercanos (*k-Nearest Neighbors*)
LAC	*Least Ambiguous set-valued Classifier*
LDA	Análisis discriminante lineal (*Linear Discriminant Analysis*)
LOSO	*Leave-One-Slide-Out*
LRP	*Layer-wise Relevance Propagation*
MDS	*Mahalanobis Distance Score*
MLS	*MaxLogit Score*
MSP	*Maximum Softmax Probability*
ND	Detección de novedades (*Novelty Detection*)
OOD	Fuera de la distribución (*Out-of-Distribution*)
OSR	Reconocimiento en conjunto abierto (*Open Set Recognition*)
PCA	Análisis de componentes principales (*Principal Component Analysis*)
RAPS	*Regularized Adaptive Prediction Sets*
ReAct	*Rectified Activations*
RMDS	*Relative Mahalanobis Distance Score*
SHE	*Simplified Hopfield Energy*
STOOD-X	*Statistical nonparametric Test for OOD Detection with eXplainability*
TPR	Tasa de verdaderos positivos (*True Positive Rate*)
ViM	*Virtual-logit Matching*
WSI	Imagen de lámina completa (*Whole Slide Image*)

Acrónimo	**Significado**
XAI	Inteligencia artificial explicable (*eXplainable Artificial Intelligence*)

Summary

[PENDIENTE: summary en inglés (800–1500 palabras)]

Resumen

[PENDIENTE: resumen en castellano]

Índice general

Agradecimientos v

Índice de acrónimos vii

Summary ix

Resumen xi

I. Introducción y estado del arte 1

1. Introducción 3
- 1.1. Contexto . . . 3
- 1.2. Descripción del problema . . . 3
- 1.3. Motivación . . . 3
- 1.4. Preguntas de investigación e hipótesis . . . 3
- 1.5. Objetivos . . . 3
  - 1.5.1. Objetivos generales . . . 3
  - 1.5.2. Objetivos específicos . . . 3
- 1.6. Principales fuentes consultadas . . . 3
- 1.7. Estructura de la memoria . . . 3
- 1.8. Planificación . . . 4
  - 1.8.1. Planificación temporal . . . 4
  - 1.8.2. Planificación económica . . . 4

2. Estado del arte 5
- 2.1. Clasificación de histopatología con aprendizaje profundo . . . 5
- 2.2. Detección de datos fuera de distribución . . . 5
  - 2.2.1. Taxonomía de la detección OOD generalizada . . . 5
  - 2.2.2. Cambio semántico y desplazamiento de covariables . . . 6
  - 2.2.3. Near-OOD y far-OOD . . . 6
  - 2.2.4. Criterio conservador en medicina . . . 6
  - 2.2.5. Métodos excluidos . . . 6
- 2.3. Explicabilidad . . . 7
  - 2.3.1. El efecto Clever Hans . . . 7
  - 2.3.2. Explicaciones locales y conceptuales . . . 7
  - 2.3.3. LRP, CRP y explicaciones glocales . . . 7

II. Fundamentos matemáticos 9

3. Aprendizaje supervisado y redes profundas 11
- 3.1. El problema de clasificación supervisada . . . 11

3.2. Función de pérdida: entropía cruzada y *label smoothing* . . . 11
3.3. Optimización: Adam y AdamW . . . 11
3.4. Arquitecturas . . . 11
3.4.1. Redes neuronales convolucionales . . . 11
3.4.2. Transformers y Vision Transformer . . . 11
3.4.3. Swin Transformer . . . 12
3.4.4. ConvNeXt . . . 12

4. Formalización de la detección OOD y métricas **13**
4.1. Distribución de los datos y cambios de distribución . . . 13
4.2. Regla de decisión por umbral . . . 13
4.3. Métricas de evaluación . . . 13
4.3.1. Curva ROC y AUROC . . . 13
4.3.2. FPR@95 . . . 14
4.3.3. AUPR-In y AUPR-Out . . . 14
4.3.4. CCR@FPRx . . . 14

5. Métodos de detección post hoc **15**
5.1. Métodos basados en logits . . . 15
5.2. Métodos basados en la modificación de activaciones . . . 15
5.3. Métodos basados en características y distancias . . . 16
5.4. STOOD-X . . . 17

6. Inferencia estadística **19**
6.1. El test de Mann-Whitney . . . 19
6.2. Bootstrap y test de McNemar . . . 19
6.3. Predicción conforme . . . 19

7. Explicabilidad **21**
7.1. Layer-wise Relevance Propagation . . . 21
7.2. Concept Relevance Propagation . . . 21

III. Experimentación, resultados y discusión **23**

8. Materiales y métodos **25**
8.1. Conjunto de datos ID . . . 25
8.2. Partición e integridad . . . 25
8.2.1. Verificación de la integridad . . . 26
8.3. Conjuntos OOD . . . 26
8.3.1. NCT-CRC-HE-100K-NONORM . . . 26
8.3.2. PANDA . . . 29
8.3.3. Control de resolución y DTD . . . 29
8.4. Entorno de ejecución . . . 29
8.5. Protocolo de entrenamiento . . . 29
8.5.1. DataLoader . . . 29
8.5.2. Learner . . . 30

9. Clasificación ID **31**
9.1. Comparación de los cinco modelos . . . 31
9.1.1. Resultados globales . . . 31
9.1.2. Curvas de entrenamiento y matrices de confusión . . . 31
9.1.3. Sensibilidad por clase . . . 31
9.2. Elección del modelo . . . 37
9.3. Agrupaciones clínicas . . . 38
9.4. Discusión . . . 39

10. Detección OOD **41**
10.1. Near-OOD principal . . . 41
10.2. Control interno: centro frente a tejido . . . 43
10.3. Cambio de centro y resolución . . . 46
10.4. Far-OOD . . . 50
10.5. Métodos basados en logits y en modificación de activaciones . . . 50
10.6. Discusión . . . 51

11. STOOD-X **53**
11.1. Implementación . . . 53
11.2. Configuración . . . 53
11.3. Puntuación . . . 53
11.4. Resultados . . . 53
11.5. Calibración . . . 55
11.6. Sensibilidad a K . . . 55
11.7. Explicaciones por ejemplos . . . 57
11.8. Discusión . . . 57

12. Predicción conforme **63**
12.1. Detección OOD conforme . . . 63
12.2. Conjuntos de predicción APS y RAPS . . . 63
12.3. Predicción conforme Mondrian . . . 63
12.4. Discusión . . . 68

13. Fuga por lámina **69**
13.1. Identificación de las láminas . . . 69
13.2. Fuga en el espacio de características . . . 69
13.3. Efecto sobre la detección OOD . . . 69
13.4. Limitación metodológica . . . 69

14. Explicabilidad y eliminación de sesgos **73**

IV. Conclusiones y trabajo futuro **75**

15. Conclusiones y trabajo futuro **77**
15.1. Conclusiones . . . 77
15.2. Limitaciones . . . 77
15.3. Trabajo futuro . . . 77

V. Apéndices **79**

A. Tablas de AUPR-In y AUPR-Out **81**

B. Anexo: clases ADI, BACK, DEB y MUC de NCT-CRC **83**

C. Material complementario **85**

Bibliografía **87**

Parte I.

Introducción y estado del arte

1. Introducción

1.1. Contexto

[PENDIENTE: contexto]

1.2. Descripción del problema

[PENDIENTE: descripción del problema]

1.3. Motivación

[PENDIENTE: motivación]

1.4. Preguntas de investigación e hipótesis

[PENDIENTE: preguntas de investigación e hipótesis]

1.5. Objetivos

1.5.1. Objetivos generales

[PENDIENTE: objetivos generales]

1.5.2. Objetivos específicos

[PENDIENTE: objetivos específicos y grado de consecución]

1.6. Principales fuentes consultadas

[PENDIENTE: principales fuentes consultadas]

1.7. Estructura de la memoria

[PENDIENTE: estructura de la memoria]

1.8. Planificación

1.8.1. Planificación temporal

[PENDIENTE: planificación temporal y diagrama de Gantt]

1.8.2. Planificación económica

[PENDIENTE: planificación económica]

2. Estado del arte

2.1. Clasificación de histopatología con aprendizaje profundo

[PENDIENTE: estado del arte de la clasificación histopatológica]

2.2. Detección de datos fuera de distribución

2.2.1. Taxonomía de la detección OOD generalizada

[PENDIENTE: presentación de la taxonomía de Yang et al. [31]]

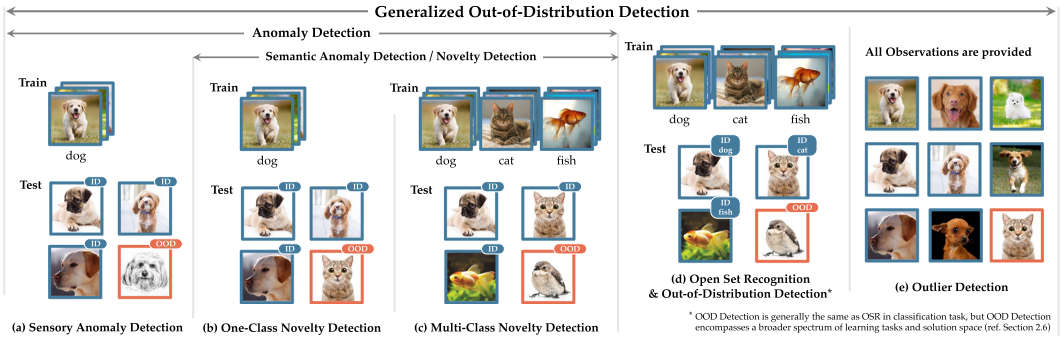


Figura 2.1.: Subtareas de la detección OOD generalizada: (a) detección de anomalías sensoriales, (b) detección de novedades de una clase, (c) detección de novedades multiclase, (d) reconocimiento en conjunto abierto y detección OOD y (e) detección de valores atípicos. Fuente: Yang et al. [31] (figura 2).

[PENDIENTE: situar el trabajo en la subtarea (d) de la figura 2.1 y justificar la inclusión de PANDA: en un contexto clínico también interesa avisar de cambios de apariencia que degradan el clasificador (la exactitud cae del 96,88 % en el test ID al 90,77 % en el control de resolución)]

Cierta literatura previa clasifica las anomalías en tres tipos: anomalías puntuales, anomalías condicionales o contextuales y anomalías grupales o colectivas (Pang et al. [21]; Chalapathy y Chawla [5]; Ruff et al. [22]). En este estudio, nos centramos principalmente en la detección de anomalías puntuales debido a su popularidad en aplicaciones prácticas y a su idoneidad para esclarecer las similitudes y diferencias entre las subtareas. **[REVISAR: traducción casi literal; parafrasear y citar]** **[REVISAR: «En este estudio» se refiere al survey de Yang et al., no a este TFG]**

Formalmente, OSR aborda el caso en el que las muestras OOD experimentan un cambio semántico durante las pruebas, es decir, $P(Y) \neq P'(Y)$. El objetivo de OSR es similar al de la detección de conjuntos abiertos multiclase (ND); la única diferencia radica en que OSR

requiere, además, una clasificación precisa de las muestras ID de $P(Y)$. **[PENDIENTE: citar]** **[REVISAR: traducción casi literal; parafrasear y citar]**

Evaluación OSR. Al igual que en AD y ND, las métricas para OSR incluyen puntuaciones F (*F-scores*), AUROC y AUPR. Asimismo, el rendimiento de la clasificación se evalúa mediante la precisión estándar para ID. Si bien las métricas mencionadas evalúan de forma independiente las capacidades de detección de novedades y de clasificación ID, algunos trabajos proponen criterios para una evaluación conjunta, como CCR@FPRx (Dhamija et al. [7]), que calcula la tasa de recuperación (*recall*) por clase cuando se alcanza una determinada tasa de falsos positivos (FPR) igual a x (por ejemplo, 10^{-1}). **[REVISAR: traducción casi literal; parafrasear y citar]**

2.2.2. Cambio semántico y desplazamiento de covariables

[PENDIENTE: introducción al cambio semántico y al desplazamiento de covariables]

Ambos conjuntos producen un cambio de distribución respecto al conjunto ID, pero de naturaleza distinta: PANDA corresponde a un desplazamiento de covariables, mientras que DTD introduce un cambio semántico.

2.2.3. Near-OOD y far-OOD

[PENDIENTE: near-OOD y far-OOD]

2.2.4. Criterio conservador en medicina

Aunque en clasificación general la detección OOD suele restringirse al cambio semántico, Yang et al. [31] señalan que en tareas de alto riesgo, como la clasificación de imágenes médicas (Zimmerer et al. [32]), se espera que los modelos sean conservadores y rechacen cualquier muestra que se desvíe de la distribución de entrenamiento. Siguiendo este criterio, en este trabajo se considera OOD tanto el cambio semántico (DTD) como el desplazamiento de covariables debido al cambio de centro (PANDA).

2.2.5. Métodos excluidos

No se han incluido métodos basados en gradientes, como ODIN (Liang et al. [16]) o GradNorm (Huang et al. [10]), por dos motivos. En primer lugar, requieren una pasada hacia atrás por cada imagen, lo que incrementa notablemente el coste de inferencia y dificulta su despliegue en un entorno clínico. En segundo lugar, Igoe et al. [11] indican que la eficacia de estos métodos no se debe tanto a la información del gradiente como a la magnitud de las características y a la distribución de salida, aspectos que ya quedan cubiertos por los métodos basados en características y en logits evaluados en este trabajo.

Dentro de los métodos basados en densidad se distinguen dos enfoques. El modelado mediante gaussianas condicionales por clase en el espacio de características (Lee et al. [15]) se ha incluido en la evaluación a través de MDS y RMDS. En cambio, no se han considerado los modelos generativos sobre el espacio de entrada, como los basados en flujos, por tres motivos: su entrenamiento resulta costoso y difícil de optimizar sobre imágenes de alta resolución; su verosimilitud presenta un fuerte sesgo hacia la complejidad de la entrada (Serrà et al. [23]), lo que en histopatología podría favorecer parches de baja complejidad,

como regiones de fondo o estroma; y su rendimiento suele quedar por detrás de los enfoques basados en clasificación (Yang et al. [31]).

[PENDIENTE: ubicar las citas a Zhang et al. (2021) y Fang et al. (2022)]

2.3. Explicabilidad

Yang et al. [31] identifican la explicabilidad como uno de los retos abiertos en la detección OOD. Este trabajo aborda dicho aspecto desde dos perspectivas complementarias: mediante STOOD-X, que proporciona explicaciones de las decisiones de detección, y mediante técnicas de relevancia por conceptos (CRP), que permiten identificar y eliminar características sesgadas del clasificador y analizar su efecto sobre la fiabilidad del sistema.

2.3.1. El efecto Clever Hans

[PENDIENTE: efecto Clever Hans en XAI y aprendizaje de relaciones espurias en la clasificación de imágenes]

2.3.2. Explicaciones locales y conceptuales

La diferencia que tiene CRP frente a los métodos de explicabilidad local es que estos otros reflejan las zonas en las que se ha fijado el modelo, pero no son capaces de determinar la importancia de estas características para la decisión final. **[PENDIENTE: desarrollar y citar (Achtibat et al. [1])]**

2.3.3. LRP, CRP y explicaciones glocales

[PENDIENTE: LRP, CRP y explicaciones glocales, usando el concepto de CRP glocal como en el artículo de CRP]

Parte II.

Fundamentos matemáticos

3. Aprendizaje supervisado y redes profundas

3.1. El problema de clasificación supervisada

Definición 3.1 (Problema de clasificación). **[PENDIENTE: definición formal]**

Proposición 3.2 (Optimalidad del clasificador de Bayes). ***[PENDIENTE: enunciado]***

Demostración. **[PENDIENTE: demostración]** □

3.2. Función de pérdida: entropía cruzada y *label smoothing*

Definición 3.3 (Función softmax). **[PENDIENTE: definición]**

Definición 3.4 (Entropía cruzada). **[PENDIENTE: definición]**

Proposición 3.5. ***[PENDIENTE: enunciado]***

Demostración. **[PENDIENTE: demostración]** □

Definición 3.6 (*Label smoothing*). **[PENDIENTE: definición]**

Proposición 3.7 (Óptimo de la pérdida con *label smoothing*). ***[PENDIENTE: enunciado]***

Demostración. **[PENDIENTE: demostración]** □

3.3. Optimización: Adam y AdamW

Definición 3.8 (Adam). **[PENDIENTE: reglas de actualización]**

Definición 3.9 (AdamW). **[PENDIENTE: reglas de actualización]**

Observación 3.10. **[PENDIENTE: observación]**

3.4. Arquitecturas

3.4.1. Redes neuronales convolucionales

Definición 3.11 (Convolución discreta). **[PENDIENTE: definición]**

3.4.2. Transformers y Vision Transformer

Definición 3.12 (Atención por producto escalar). **[PENDIENTE: definición]**

3.4.3. Swin Transformer

Proposición 3.13 (Coste de la atención por ventanas)**.** *[PENDIENTE: enunciado: complejidad global frente a por ventanas]*

3.4.4. ConvNeXt

[PENDIENTE: ConvNeXt]

4. Formalización de la detección OOD y métricas

4.1. Distribución de los datos y cambios de distribución

[PENDIENTE: introducción: factorización $P(X, Y) = P(Y \mid X)\, P(X)$]

Definición 4.1 (Desplazamiento de covariables)**. [PENDIENTE: definición]**

Definición 4.2 (Cambio semántico)**. [PENDIENTE: definición]**

4.2. Regla de decisión por umbral

Definición 4.3 (Detector OOD por umbral)**. [PENDIENTE: definición]**

4.3. Métricas de evaluación

Hay tres métricas que miden lo bien que mi clasificador separa ID de OOD. El inconveniente está en que no miden si la clasificación de las 14 clases es correcta. Para ello conviene mejor usar CCR@FPRx. Al final estas métricas se comportan como modelos de clasificación binaria en ID y OOD.

Evaluación. Además de las puntuaciones F, AUROC y AUPR, otra métrica comúnmente utilizada es FPR@TPRx, que mide la FPR cuando la TPR es x (por ejemplo, 0,95). Algunos trabajos también utilizan una métrica alternativa, TNR@TPRx, que es equivalente a $1 -$ FPR@TPRx. La detección de OOD también afecta al rendimiento de la clasificación de ID. **[REVISAR: traducción casi literal; parafrasear y citar]**

4.3.1. Curva ROC y AUROC

AUROC: representa la probabilidad de que el modelo asigne una puntuación o probabilidad más alta a un ejemplo positivo elegido al azar que a uno negativo. **Rango de valores:** va de 0 a 1; 0,5 representa que el modelo no tiene capacidad discriminatoria (equivale a adivinar al azar), 1 que el modelo tiene una clasificación perfecta, y los valores inferiores a 0,5 indican que el modelo invierte las clases (si se invierte la predicción, el valor pasa a ser $1 -$ valor). En este caso también la clase positiva es la OOD.

[PENDIENTE: citar a Fawcett [9] para la curva ROC]

Definición 4.4 (Curva ROC)**. [PENDIENTE: definición]**

Teorema 4.5 (Interpretación probabilística del AUROC)**. *[PENDIENTE: enunciado]***

Demostración. **[PENDIENTE: demostración]** □

Corolario 4.6 (AUROC empírico y estadístico U)**. *[PENDIENTE: enunciado]***

Demostración. **[PENDIENTE: demostración]** □

4.3.2. FPR@95

FPR@95: consiste en ajustar el umbral que delimita un caso como ID de forma que dicho umbral detecte el 95 % de las OOD. **[PENDIENTE: completar qué se mide con ese umbral (la proporción de ID rechazadas como OOD; más bajo es mejor)]**

Definición 4.7 (FPR@TPRx)**.** **[PENDIENTE: definición]**

4.3.3. AUPR-In y AUPR-Out

AUPR: esta métrica va acompañada de AUROC, ya que AUROC no es sensible a desbalance entre clases mientras que AUPR sí. Principalmente se basa en dos conceptos: precisión y exhaustividad (*recall*). De esta métrica obtenemos dos versiones: AUPR-In (mide lo bien que se recuperan imágenes de próstata sin que se cuelen OOD) y AUPR-Out (mide lo bien que se encuentran las OOD sin falsas alarmas sobre las de próstata). En el primer caso el caso positivo es ID y por eso mismo nos interesa un valor alto, y en el segundo el caso positivo es el OOD, por lo que también interesa un valor alto. **[REVISAR: las notas decían que en AUPR-Out interesa un valor «más bajo»; es incorrecto: en ambas versiones interesa un valor alto]**

Definición 4.8 (Precisión, exhaustividad y AUPR)**.** **[PENDIENTE: definición]**

4.3.4. CCR@FPRx

CCR@FPRx: se fija el umbral de modo que solo se acepte un x % de las imágenes OOD, y se mide la proporción de imágenes del test ID que son aceptadas y además correctamente clasificadas. Se calcula solo sobre el test ID; su máximo es la exactitud del clasificador.

Definición 4.9 (CCR@FPRx)**.** **[PENDIENTE: definición]**

5. Métodos de detección post hoc

[PENDIENTE: introducción del capítulo y notación común]

5.1. Métodos basados en logits

Grupo de los logits (números producidos por la red justo al final, antes de convertirlos en probabilidades):

- **MSP** (*Maximum Softmax Probability*): la probabilidad de la clase ganadora tras el softmax.
- **MLS** (*MaxLogit*): lo mismo que MSP, pero con el logit máximo sin pasar por softmax. La ventaja que ofrece este método es que el softmax normaliza y pierde información sobre la magnitud absoluta; el logit bruto la conserva.
- **EBO** (*Energy-Based OOD*): el logaritmo de la suma de las exponenciales de todos los logits. Funciona como una versión «suave» y diferenciable de la función $\max(x)$.

[REVISAR: en EBO, «de las exponenciales de los argumentos de todos los logits» se ha simplificado a «de las exponenciales de todos los logits»]

Definición 5.1 (Puntuaciones MSP, MaxLogit y Energy)**.** **[PENDIENTE: definición formal]**

Proposición 5.2 (LogSumExp como cota suave del máximo)**.** ***[PENDIENTE: enunciado]***

Demostración. **[PENDIENTE: demostración]** □

Observación 5.3 (Efecto del *label smoothing* sobre los logits). **[PENDIENTE: desarrollo]**

5.2. Métodos basados en la modificación de activaciones

Estos métodos modifican las activaciones o los pesos de la última capa del modelo antes de calcular la puntuación, con el objetivo de atenuar las señales anómalas que producen las imágenes OOD. Los tres calculan finalmente una puntuación de tipo Energy sobre los logits resultantes y fueron diseñados y evaluados originalmente sobre redes convolucionales con activaciones ReLU.

- **ReAct** (*Rectified Activations*) (Sun et al. [26]): parte de la observación de que las imágenes OOD tienden a producir activaciones anormalmente altas en algunas unidades de la penúltima capa, lo que sus autores atribuyen al uso de estadísticas de BatchNorm estimadas con datos ID y aplicadas sin cambios a datos OOD. Para atenuarlo, recorta cada activación del vector de características por encima de un umbral c, $\tilde{h} = \min(h, c)$, y calcula la puntuación Energy sobre los logits obtenidos a partir de las características recortadas. El umbral c se fija como el percentil 90 de las activaciones en el conjunto de validación ID.

- **ASH** (*Activation Shaping*) (Djurisic et al. [8]): actúa sobre el vector de características de cada imagen de forma individual. Conserva solo el 10 % de las activaciones de mayor valor (percentil 90), pone a cero el resto y ajusta las conservadas para compensar la información eliminada. En la variante empleada (ASH-B), todas las activaciones conservadas toman el mismo valor, igual a la suma total de las activaciones de la imagen dividida entre el número de activaciones conservadas. Después se calcula la puntuación Energy. Se aplica sobre las 768 características agregadas tras el *pooling*, como en la implementación de OpenOOD.
- **DICE** (*Directed Sparsification*) (Sun y Li [27]): actúa sobre los pesos de la última capa lineal en lugar de sobre las activaciones. Para cada conexión entre una característica y una clase, calcula su contribución media en el conjunto de entrenamiento ID (el peso multiplicado por la activación media de esa característica), conserva solo las conexiones de mayor contribución y pone a cero el resto (esparsidad del 90 %). Al eliminar las conexiones poco relevantes para los datos ID, reduce la varianza de la salida en las imágenes OOD y mejora su separación. La puntuación es la Energy de los logits calculados con la capa podada.

Definición 5.4 (ReAct, ASH-B y DICE)**.** **[PENDIENTE: definición formal]**

Observación 5.5 (Supuestos sobre el signo de las activaciones). **[PENDIENTE: desarrollo]**

5.3. Métodos basados en características y distancias

Grupo de métodos que comparan con la información de las características (*features*) de entrenamiento:

- **KNN**: guarda las características de entrenamiento (normalizadas) y, para cada imagen de test, mide la distancia a su k-ésimo vecino más cercano. Si está lejos de todo lo visto, es OOD.
- **MDS** (Mahalanobis): calcula la media de las características de cada clase y una covarianza compartida. La puntuación es la distancia de Mahalanobis a la media de la clase más cercana.
- **RMDS** (*Relative Mahalanobis*): igual que MDS, pero resta la distancia a una gaussiana global de todo el conjunto de datos. Así corrige el hecho de que algunas direcciones del espacio de características son «fondo» común a todas las imágenes y no información de clase. Suele funcionar mejor en near-OOD.
- **ViM** (*Virtual-logit Matching*): busca las direcciones principales del espacio de características de entrenamiento (análisis de componentes principales). Lo que queda fuera de ese subespacio principal (el residuo) se considera señal de OOD. Combina la norma de ese residuo con la energía de los logits.
- **SHE** (*Simplified Hopfield Energy*): en la preparación (`setup()`) pasa el conjunto de entrenamiento por la red y, para cada clase, calcula la media de las características solo de las imágenes que el modelo clasifica correctamente (etiqueta real igual a la predicción). Eso le da 14 «patrones» de referencia. En test, mira qué clase predice el modelo para la imagen y compara su característica con el patrón de esa clase (por producto escalar, distancia euclídea o coseno, según la configuración).

[PENDIENTE: citar los artículos originales de KNN, RMDS, ViM y SHE (no aparecen en las notas)]

Definición 5.6 (Puntuación KNN). **[PENDIENTE: definición]**

Definición 5.7 (Puntuación de Mahalanobis). **[PENDIENTE: definición]**

Proposición 5.8 (Relación con el análisis discriminante lineal). ***[PENDIENTE: enunciado]***

Demostración. **[PENDIENTE: demostración]** □

Definición 5.9 (Mahalanobis relativo). **[PENDIENTE: definición]**

Definición 5.10 (ViM). **[PENDIENTE: definición]**

Proposición 5.11 (Residuo de PCA como proyección ortogonal). ***[PENDIENTE: enunciado]***

Definición 5.12 (SHE). **[PENDIENTE: definición]**

5.4. STOOD-X

Se trata de una metodología post hoc de detección OOD en dos etapas [24]: una primera de detección, basada en un test estadístico no paramétrico sobre distancias en el espacio de características, y una segunda de explicación, que muestra al usuario los vecinos más cercanos y las características más relevantes compartidas con ellos.

Sea x una imagen cuya clase predicha por el modelo es c, y sea X_{set} el conjunto de características de entrenamiento de esa clase. Se denota $X_k = \{x_1, \ldots, x_K\}$ el conjunto de los K vecinos más cercanos de x en X_{set} según una distancia d y, para cada vecino x_i, X_k^i el conjunto de sus K vecinos más cercanos en $X_{\text{set}} \setminus \{x_i\}$. La hipótesis del método es que, si x pertenece a la distribución de entrenamiento, las distancias $D(x, X_k)$ y $D(x_i, X_k^i)$ siguen la misma distribución; si x es OOD, las primeras serán mayores. Para contrastarlo se aplica el test unilateral de Wilcoxon-Mann-Whitney (apartado 6.1) entre ambos conjuntos de distancias, con un total de $M = K + K^2$ distancias, y el p-valor resultante se utiliza como puntuación: valores altos indican pertenencia a la distribución.

Definición 5.13 (Puntuación de STOOD-X). **[PENDIENTE: definición formal]**

[PENDIENTE: segunda etapa del método: explicaciones]

6. Inferencia estadística

6.1. El test de Mann-Whitney

[PENDIENTE: introducción al test (Mann y Whitney [19]; Wilcoxon [29])] [PENDIENTE: sustituir por fuente académica (la explicación del test de las notas enlaza a un blog)]

Definición 6.1 (Estadístico U de Mann-Whitney)**. [PENDIENTE: definición]**

Proposición 6.2 (Media y varianza de U bajo la hipótesis nula)**.** ***[PENDIENTE: enunciado]***

Demostración. **[PENDIENTE: demostración]** □

Teorema 6.3 (Aproximación normal)**.** ***[PENDIENTE: enunciado]***

Observación 6.4 (Empates, corrección de continuidad y saturación)**. [PENDIENTE: desarrollo]**

Observación 6.5 (Hipótesis de independencia)**. [PENDIENTE: desarrollo]**

6.2. Bootstrap y test de McNemar

Definición 6.6 (Intervalo *bootstrap* por percentiles)**. [PENDIENTE: definición]**

Proposición 6.7 (Test de McNemar)**.** ***[PENDIENTE: enunciado]***

Demostración. **[PENDIENTE: demostración]** □

6.3. Predicción conforme

Predicción conforme. La predicción conforme (CP) se erige como un marco estadístico robusto en el aprendizaje automático, diseñado principalmente para proporcionar medidas de confianza para las predicciones (Shafer y Vovk [25]; Angelopoulos y Bates [2]). **[REVISAR: posible traducción casi literal (en las notas aparece bajo «Añadir esta parte de Inferencia Estadística»); comprobar la fuente, parafrasear y citar]**
[PENDIENTE: desarrollo de la predicción conforme dividida]

Definición 6.8 (Intercambiabilidad)**. [PENDIENTE: definición]**

Teorema 6.9 (Cobertura marginal)**.** ***[PENDIENTE: enunciado]***

Demostración. **[PENDIENTE: demostración]** □

Definición 6.10 (Puntuaciones LAC y APS)**. [PENDIENTE: definición]**

Definición 6.11 (Predicción conforme Mondrian)**. [PENDIENTE: definición]**

Proposición 6.12 (Umbral infinito y umbral máximo en Mondrian)**.** ***[PENDIENTE: enunciado]***

Demostración. **[PENDIENTE: demostración]** □

7. Explicabilidad

7.1. Layer-wise Relevance Propagation

Definición 7.1 (Relevancia y conservación). **[PENDIENTE: definición]**

Proposición 7.2 (Regla LRP-z^+ como descomposición de Taylor profunda). ***[PENDIENTE: enunciado]***

Demostración. **[PENDIENTE: demostración]** □

Definición 7.3 (Regla LRP-ε). **[PENDIENTE: definición]**

7.2. Concept Relevance Propagation

[PENDIENTE: CRP]

Parte III.

Experimentación, resultados y discusión

8. Materiales y métodos

8.1. Conjunto de datos ID

Como punto de partida contábamos con una base de datos de imágenes médicas clasificadas según el tipo de enfermedad que presentaban. La base contaba con las siguientes clases: `Adenocarcinoma_ductal`, `Glandulas_no_neoplasicas`, `Gleason_4_fusionadas`, `Gleason_5_comedonecrosis`, `No_Cancer`, `Carcinoma_intraductal`, `Gleason_3`, `Gleason_4_glomeruloide`, `Gleason_5_no_glandulas`, `PIN_de_alto_grado`, `Estroma`, `Gleason_4_cribiformes`, `Gleason_4_pobremente_formadas` e `Inflamatorio`.

La información de este apartado procede del artículo del conjunto de datos [3]. El muestreo tisular fue realizado por residentes de anatomía patológica o por patólogos titulados. Las piezas se procesaron en un procesador automático de tejidos, se deshidrataron y se incluyeron en parafina. Se obtuvieron cortes de 3–5 µm de grosor con un micrótomo, que se montaron en portaobjetos de vidrio, se desparafinaron y se tiñeron con hematoxilina y eosina (H&E).

Las preparaciones teñidas con H&E se digitalizaron con un escáner de preparaciones completas Aperio/Leica AT2 a 20× aumentos, con una resolución de escaneo de 50.000 píxeles por pulgada (0,5 µm/píxel). Las anotaciones se realizaron sobre 85 de esas imágenes de lámina completa (WSI). Todas las imágenes fueron segmentadas manualmente por patólogos experimentados con un amplio conocimiento de la histología del cáncer de próstata. Las regiones anotadas se clasificaron en 14 categorías histológicas distintas que reflejan patrones morfológicos reconocidos en la práctica clínica.

Cada WSI anotada se dividió en parches cuadrados de tamaño $H \times H = 224 \times 224$ píxeles, extraídos con un paso (*stride*) de $p = 256$ píxeles. Un parche se asignaba a una clase concreta si más del 75 % de sus píxeles pertenecían a una región anotada como dicha clase; en caso contrario, se descartaba.

[REVISAR: traducción casi literal; parafrasear y citar] [REVISAR: añadida la frase de las 85 WSI anotadas (dato del artículo, como se pidió); la primera frase atribuye el apartado al artículo, en lugar del título «información extraída del paper de Iván Sevillano» de las notas]

8.2. Partición e integridad

Inicialmente el repositorio cuenta con dos subcarpetas, `train` y `val`, con un total de 126.109 imágenes (113.491 en `train` y 12.618 en `val`), cuya distribución por clase se recoge en la cuadro 8.1. **[REVISAR: las notas daban un total de 126.192; el real es 126.109 (113.491 + 12.618; results_integridad)] [REVISAR: la figura de tarta de las notas se sustituye por la cuadro 8.1, generada a partir de results_integridad]**

El primer reto al que nos enfrentamos es el de poder crear un modelo de aprendizaje supervisado que, dada una imagen de nuestro conjunto de datos, sea capaz de clasificarla en una de las respectivas clases con la mayor precisión posible.

Tabla 8.1.: Número de imágenes por clase en la partición original del conjunto ID (carpetas `train` y `val`) y en la partición usada en este trabajo (el `train` original dividido 80/20 por clase en entrenamiento y validación; el `val` original como test).

	Original		Partición del TFG		
Clase	Train	Val	Train	Validación	Test
`Adenocarcinoma_ductal`	18.917	2.102	15.134	3.783	2.102
`Carcinoma_intraductal`	1.083	121	867	216	121
`Estroma`	22.219	2.469	17.776	4.443	2.469
`Glandulas_no_neoplasicas`	32.304	3.590	25.844	6.460	3.590
`Gleason_3`	2.275	253	1.820	455	253
`Gleason_4_cribiformes`	12.723	1.414	10.179	2.544	1.414
`Gleason_4_fusionadas`	6.938	771	5.551	1.387	771
`Gleason_4_glomeruloide`	218	25	175	43	25
`Gleason_4_pobremente_formadas`	1.136	127	909	227	127
`Gleason_5_comedonecrosis`	499	56	400	99	56
`Gleason_5_no_glandulas`	10.908	1.213	8.727	2.181	1.213
`Inflamatorio`	714	80	572	142	80
`No_Cancer`	1.081	121	865	216	121
`PIN_de_alto_grado`	2.476	276	1.981	495	276
Total	113.491	12.618	90.800	22.691	12.618

Para comenzar se necesita un conjunto de entrenamiento, uno de validación y uno de test. Así pues, dada la estructura inicial del conjunto de datos, se optó por utilizar el directorio `val`, que presentaba una menor cantidad de imágenes en comparación con `train`, para realizar el test, y a su vez `train` se dividió de forma estratificada por clase, en proporción 80/20, en dos carpetas: una mayor para el entrenamiento y una menor para la validación. Se cuenta así con un total de 90.800 imágenes para entrenamiento, 22.691 para validación y 12.618 para test. El reparto se hizo sin fijar una semilla aleatoria, por lo que no es reproducible. **[REVISAR: añadidos el carácter estratificado 80/20 de la división y la ausencia de semilla (results_integridad, apartado 5)]**

8.2.1. Verificación de la integridad

[PENDIENTE: verificación de la integridad de la partición]

8.3. Conjuntos OOD

Cuadro 8.2 resume los conjuntos OOD empleados, el papel de cada uno y qué cambia respecto al conjunto ID.

[REVISAR: tabla de las notas: corregidas erratas y redacción mínima («si descarta por el centro o por el tejido», «discriminación», «órgano»)]

8.3.1. NCT-CRC-HE-100K-NONORM

- Este es un conjunto de 100.000 parches no superpuestos de imágenes histológicas teñidas con hematoxilina y eosina (H&E) de cáncer colorrectal humano (CRC) y tejido

Tabla 8.2.: Diseño de los conjuntos OOD: papel de cada conjunto, qué cambia respecto al conjunto ID y objetivo de su inclusión. Entre paréntesis, el número de imágenes.

Conjunto	Papel	¿Qué cambia respecto al ID?	Objetivo
(A) NCT-CRC: TUM + NORM (23.080)	Near-OOD	Otro órgano (colon, tejido glandular) y otro centro; misma escala	Buscamos ver si es capaz de rechazar un tejido muy parecido al original
(B) NCT-CRC: STR, LYM, MUS (por separado)	Control interno	Otro centro; tejidos parecidos a clases de entrenamiento (estroma e inflamatorio)	Tejidos nuevamente parecidos a ID: determinamos si descarta por el centro o por el tejido
(C) PANDA (10.000)	*Covariate shift*	Mismo órgano (próstata), otro centro y escáner; menor resolución (128 px)	Al repetir el órgano, lo único que cambia es el *covariate shift*, por lo que una detección OOD reflejaría su discriminación por este motivo
Control de resolución (12.618)	Control	Las mismas imágenes del test ID, reducidas a 128 px y ampliadas a 224 px	Buscamos ver si se están clasificando imágenes como OOD solo por la resolución
DTD / *Textures*	Far-OOD	No es tejido: texturas genéricas	Clasificación sencilla: ha de clasificarla directamente como OOD
NCT-CRC: ADI, BACK, DEB, MUC	Anexo (capítulo B)	Grasa, fondo, restos, moco	

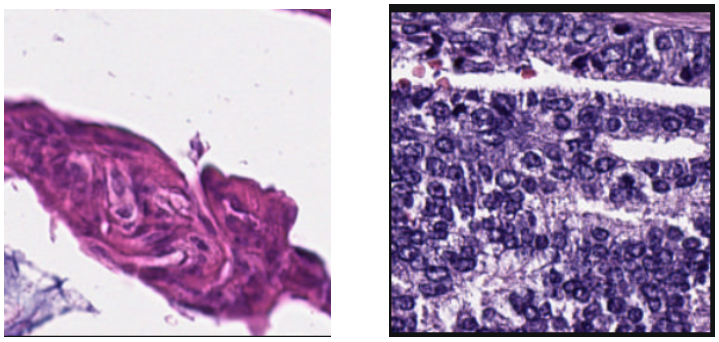
normal [12, 13].

- Todas las imágenes son de 224×224 píxeles (px) a 0,5 micras por píxel (MPP). Se utiliza la versión NONORM, generada a partir de los mismos datos originales pero sin normalización de color, para no introducir un cambio artificial en la distribución [18].
- Las clases de tejido son: tejido adiposo (ADI), fondo (BACK), desechos (DEB), linfocitos (LYM), moco (MUC), músculo liso (MUS), mucosa normal del colon (NORM), estroma asociado al cáncer (STR) y epitelio de adenocarcinoma colorrectal (TUM).
- Estas imágenes se extrajeron manualmente de $N = 86$ portaobjetos de tejido de cáncer humano teñidos con H&E, de muestras embebidas en parafina y fijadas en formalina (FFPE) del NCT Biobank (Centro Nacional de Enfermedades Tumorales, Heidelberg, Alemania) y del archivo de patología UMM (University Medical Center Mannheim, Mannheim, Alemania). Las muestras de tejido contenían portaobjetos tumorales primarios de CRC y tejido tumoral de metástasis hepáticas de CRC; las clases de tejido normal se aumentaron con regiones no tumorales de muestras de gastrectomía para aumentar la variabilidad.

[REVISAR: traducción casi literal; parafrasear y citar] [REVISAR: la referencia que acompañaba a NONORM en las notas (DOI 10.1109/ISBI.2009.5193250) es el método de normalización de Macenko, que se aplica a la versión normalizada NCT-CRC-HE-100K y no a NONORM: reubicar la cita] [REVISAR: el enlace al conjunto de datos (Zenodo) de las notas se sustituye por la cita a Kather et al.]

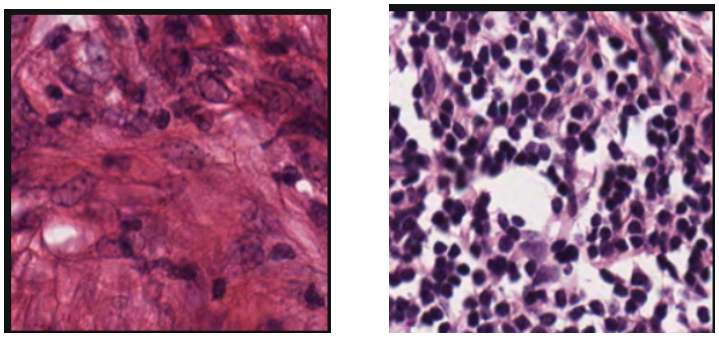
(A) TUM y NORM hacen referencia a epitelio de adenocarcinoma colorrectal y a mucosa normal del colon.

(B) STR, LYM y MUS hacen referencia a estroma asociado al cáncer, linfocitos y músculo liso.



(a) (b)

Figura 8.1.: Comparativa del adenocarcinoma colorrectal frente al adenocarcinoma ductal del conjunto ID. **[REVISAR: figura extraída del docx, regenerar; indicar qué panel es cada tejido]**

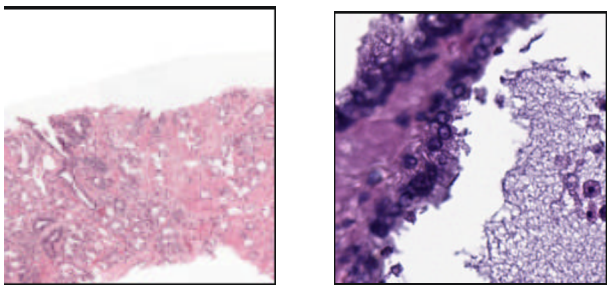


(a) STR (b) LYM

Figura 8.2.: Ejemplos de imágenes de STR y LYM. **[REVISAR: figura extraída del docx, regenerar; comprobar el orden de los paneles]**

8.3.2. PANDA

***Covariate shift*: PANDA (próstata de otro centro).** Biopsias del mismo órgano (próstata) y mismo tipo de tinción, pero de escáneres y hospitales distintos (Karolinska Institute / Radboud University) [4]. **[REVISAR: los enlaces a Kaggle de las notas se sustituyen por la cita a Bulten et al.]** **[PENDIENTE: fuente de los parches de 128 px de PANDA (conjunto de Kaggle «panda-16x128x128-tiles-data»): decidir cómo citarla]**



(a) (b)

Figura 8.3.: PANDA frente a nuestras imágenes ID. **[REVISAR: figura extraída del docx, regenerar; indicar qué panel es cada conjunto]**

8.3.3. Control de resolución y DTD

[PENDIENTE: control de resolución y DTD [6]]

8.4. Entorno de ejecución

Vamos a usar el repositorio OpenOOD [30] para continuar con nuestro análisis de resultados. **[REVISAR: el enlace a GitHub se sustituye por la cita; el enlace al cuaderno de Colab con la explicación de uso y su captura de pantalla no van a la memoria]**

[PENDIENTE: hardware y software]

8.5. Protocolo de entrenamiento

8.5.1. DataLoader

Para una primera aproximación del modelo hemos decidido crear un conjunto de imágenes menor a partir del original, el cual sirve para pruebas y para comprobar el funcionamiento correcto de nuestro modelo antes de pasar a entrenar con el conjunto de datos original. Este, al igual que el conjunto de datos original, cuenta con tres carpetas: inicialmente se seleccionaron 10 imágenes de cada carpeta de la estructura original del conjunto de datos para crear uno nuevo, pero con un número mucho más reducido de imágenes. Posteriormente se aplicó el mismo procedimiento de separar `train` en dos nuevas carpetas de `train` y `val`, y el `val` original pasó a ser test. Debido a esto, el resultado final ha sido una estructura de tres carpetas: `train` con 139 imágenes, `val` con 55 y test con 167. **[REVISAR: la figura de tarta del conjunto reducido de las notas no se incluye; las cifras quedan en el texto]**

8.5.2. Learner

En cuanto al optimizador, vamos a usar AdamW (Loshchilov y Hutter [17]), pues se trata de una versión mejorada del optimizador Adam (Kingma y Ba [14]) con la mejora añadida de que cuenta con *weight decay* (apartado 3.3). En la implementación de fastai es cierto que el nombre asociado es el de Adam, pero es debido a una decisión de fastai de adoptar la versión mejorada del optimizador bajo el nombre de la original. **[REVISAR: las notas citaban solo a Kingma y Ba (Adam); para AdamW la cita correcta es Loshchilov y Hutter (2019)]**

Debido a la complejidad del problema, no tardó en aparecer el error de memoria *CUDA out of memory*. Para manejar este problema sin alterar la arquitectura del modelo **[PENDIENTE: sustituir por fuente académica]** se optó por reducir el tamaño del lote a la mitad, pasando así de 128 imágenes por lote a 64. Las otras medidas tomadas fueron adaptar el *learner* para trabajar con precisión de 16 bits, ahorrando así memoria, liberar la caché de la memoria al iniciar la ejecución y, por último, reducir el número de *workers* de 8 a 4, planteando la posibilidad de que la creación de hebras separadas para el tratamiento del problema pudiera estar influyendo en una mayor lentitud de ejecución del modelo. **[REVISAR: «infiriendo» corregido a «influyendo»]** **[PENDIENTE: ¿citar a Micikevicius et al. [20] para el entrenamiento con precisión mixta?]**

[PENDIENTE: completar la configuración del entrenamiento (preprocesado, pérdida con *label smoothing*, política de entrenamiento y parada temprana)]

Llegados a este punto, solo queda probar con diversos modelos ya preentrenados, hacerles un ajuste fino (*fine tuning*) y analizar cuál genera mejores resultados, que será por tanto con el que sigamos trabajando a lo largo del proyecto (capítulo 9).

9. Clasificación ID

[PENDIENTE: introducción del capítulo: cinco arquitecturas preentrenadas con ajuste fino (ViT-B/16, ResNet-50, ConvNeXt-S, EfficientNetV2-S y Swin-S) y evaluación en el test ID]

9.1. Comparación de los cinco modelos

9.1.1. Resultados globales

Tabla 9.1.: Clasificación de las 14 clases en el test ID (12.618 imágenes) con los cinco modelos: exactitud, F1 macro y *balanced accuracy* (más alto es mejor). IC del 95 % por *bootstrap* (1.000 remuestreos, semilla 0) sobre imágenes y sobre láminas (remuestreo de las 95 láminas). ConvNeXt-S se evalúa a 256 px y el resto a 224 px, cada uno con el preprocesado de su entrenamiento.

Modelo	Exactitud	IC 95 % (imagen)	IC 95 % (lámina)	F1 macro	IC 95 % (imagen)	IC 95 % (lámina)	*Balanced acc.*
Swin-S	0,9688	[0,9658; 0,9717]	[0,9589; 0,9768]	0,9082	[0,8919; 0,9224]	[0,8491; 0,9314]	0,8907
ConvNeXt-S	0,9668	[0,9635; 0,9700]	[0,9571; 0,9748]	0,9086	[0,8922; 0,9222]	[0,8583; 0,9322]	0,8990
EfficientNetV2-S	0,9538	[0,9500; 0,9575]	[0,9412; 0,9645]	0,8719	[0,8522; 0,8878]	[0,7906; 0,8963]	0,8583
ViT-B/16	0,9525	[0,9487; 0,9559]	[0,9391; 0,9631]	0,8740	[0,8565; 0,8883]	[0,8007; 0,8966]	0,8674
ResNet-50	0,8964	[0,8913; 0,9020]	[0,8687; 0,9166]	0,7620	[0,7434; 0,7796]	[0,6678; 0,7904]	0,7375

[REVISAR: la tabla de exactitudes de las notas (salida de `resultados.txt`) se sustituye por la cuadro 9.1, generada a partir de results_fase1, con IC; las exactitudes coinciden salvo Swin-S (0,96870 → 0,9688) y ResNet-50 (0,89634 → 0,8964), por una imagen de diferencia en la inferencia con precisión mixta]

[PENDIENTE: análisis de la cuadro 9.1]

[PENDIENTE: conclusión parcial]

9.1.2. Curvas de entrenamiento y matrices de confusión

Pérdida en test: 0,6788; exactitud en test: 0,9525. **[PENDIENTE: análisis]**

Pérdida en test: 0,8892; exactitud en test: 0,8964. **[REVISAR: las notas daban 0,8963 (`resultados.txt`); se usa el valor de results_fase1]** **[PENDIENTE: análisis]**

Pérdida en test: 0,6424; exactitud en test: 0,9668. **[PENDIENTE: análisis]**

[PENDIENTE: análisis (pérdida en test: 0,6757; exactitud en test: 0,9538)]

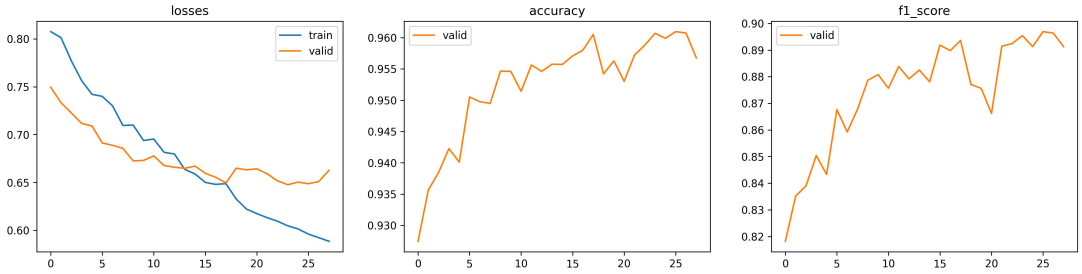
[PENDIENTE: análisis (pérdida en test: 0,6356; exactitud en test: 0,9688)]

[PENDIENTE: conclusión parcial de las curvas y matrices de confusión]

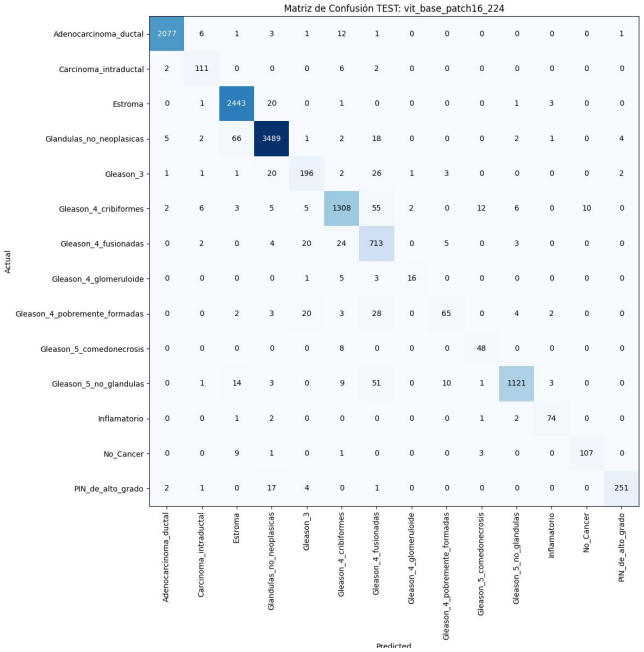
9.1.3. Sensibilidad por clase

[PENDIENTE: análisis de la cuadro 9.2]

[PENDIENTE: conclusión parcial]



(a) Curvas de entrenamiento.

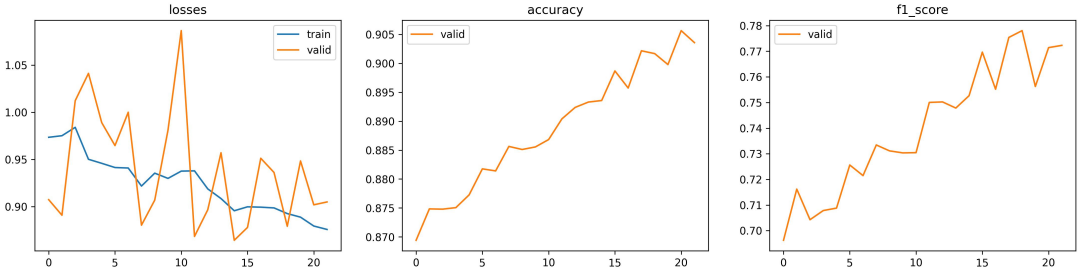


(b) Matriz de confusión en el test.

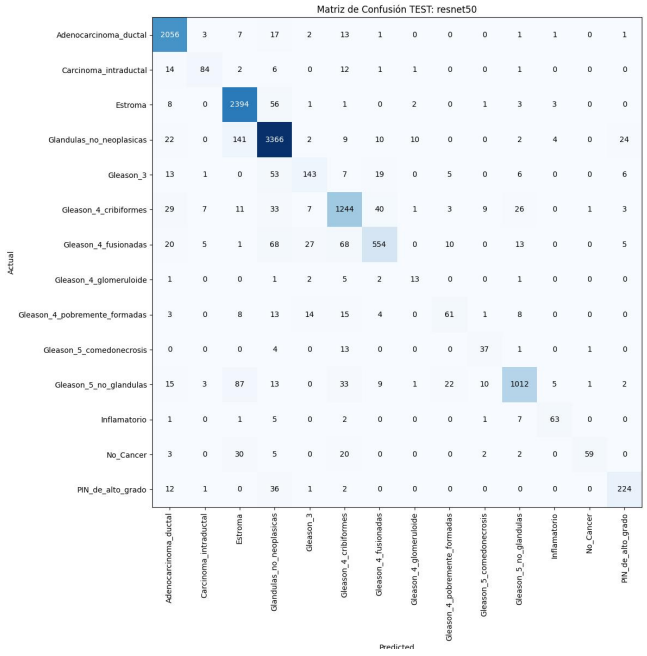
Figura 9.1.: ViT-B/16 (`vit_base_patch16_224`).

Tabla 9.2.: Sensibilidad (*recall*) por clase en el test ID de los cinco modelos (más alto es mejor); *n*: imágenes de test de la clase. En negrita, el mejor valor de cada clase.

Clase	*n*	Swin-S	ConvNeXt-S	EfficientNetV2-S	ViT-B/16	ResNet-50
`Glandulas_no_neoplasicas`	3.590	**0,98**	0,98	0,98	0,97	0,94
`Estroma`	2.469	0,99	**0,99**	0,98	**0,99**	0,97
`Adenocarcinoma_ductal`	2.102	1,00	**1,00**	0,99	0,99	0,98
`Gleason_4_cribiformes`	1.414	**0,96**	0,95	0,94	0,93	0,88
`Gleason_5_no_glandulas`	1.213	**0,97**	0,97	0,94	0,92	0,83
`Gleason_4_fusionadas`	771	0,92	0,92	0,87	**0,92**	0,72
`PIN_de_alto_grado`	276	**0,95**	0,94	0,93	0,91	0,81
`Gleason_3`	253	**0,81**	0,79	0,77	0,77	0,57
`Gleason_4_pobremente_formadas`	127	0,74	**0,78**	0,59	0,51	0,48
`Carcinoma_intraductal`	121	0,89	**0,93**	0,89	0,92	0,69
`No_Cancer`	121	**0,93**	0,89	0,93	0,88	0,49
`Inflamatorio`	80	**0,95**	**0,95**	0,89	0,93	0,79
`Gleason_5_comedonecrosis`	56	**0,86**	**0,86**	0,84	**0,86**	0,66
`Gleason_4_glomeruloide`	25	0,52	**0,64**	0,48	**0,64**	0,52

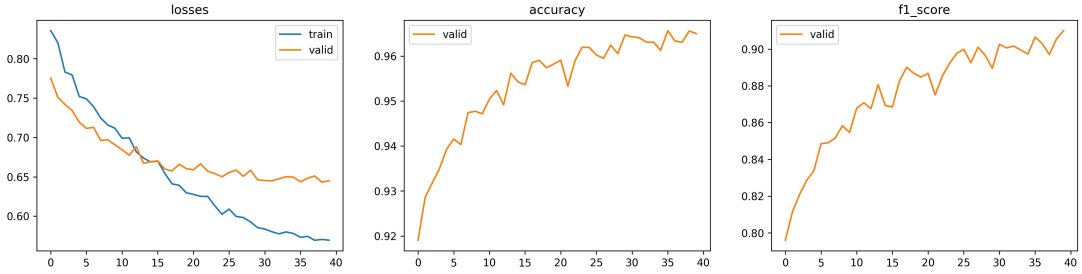


(a) Curvas de entrenamiento.

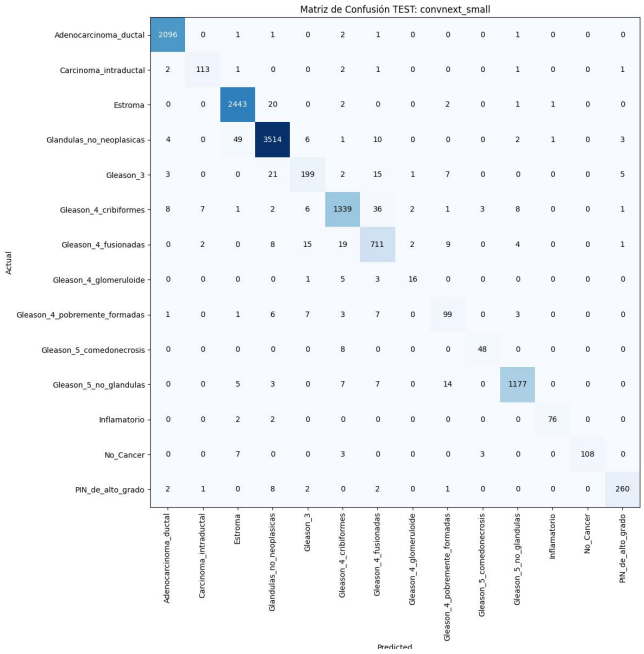


(b) Matriz de confusión en el test.

Figura 9.2.: ResNet-50 (`resnet50`).

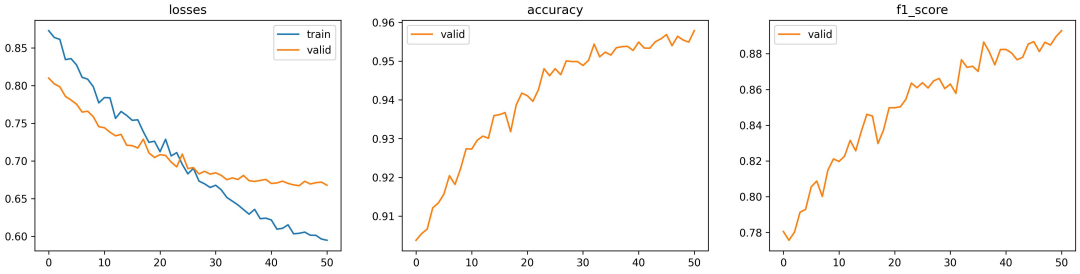


(a) Curvas de entrenamiento.

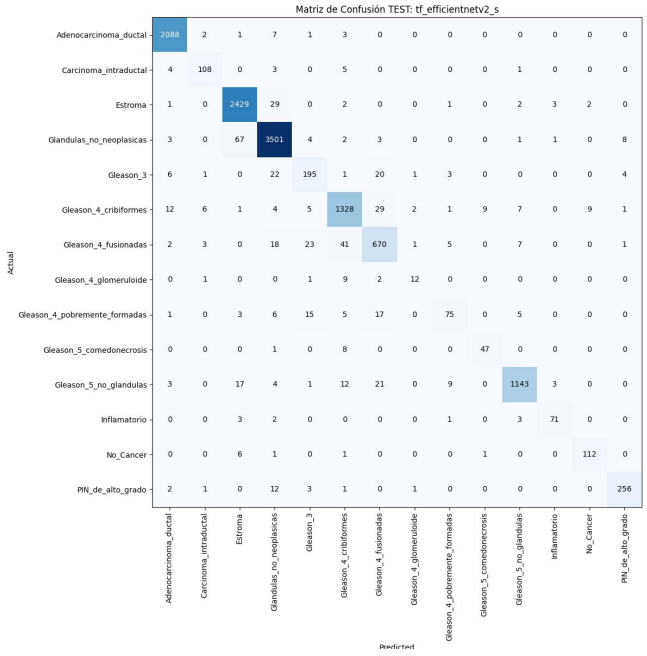


(b) Matriz de confusión en el test.

Figura 9.3.: ConvNeXt-S (`convnext_small`, entrenado y evaluado a 256 px).

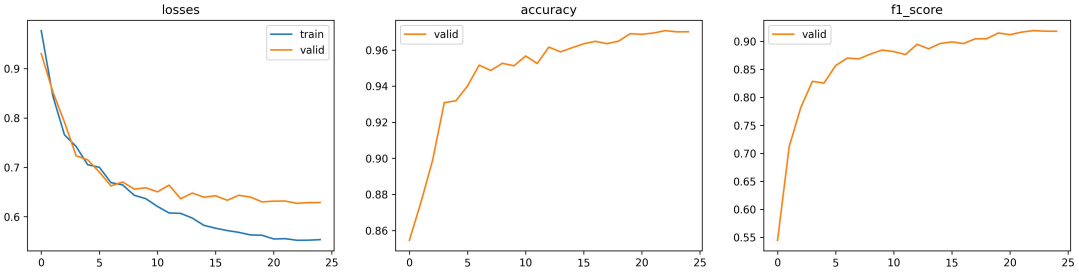


(a) Curvas de entrenamiento.

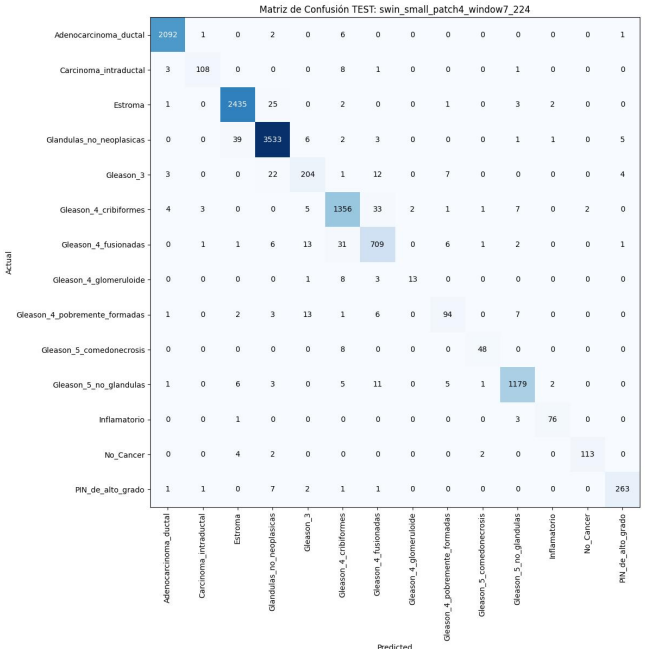


(b) Matriz de confusión en el test.

Figura 9.4.: EfficientNetV2-S (`tf_efficientnetv2_s`).



(a) Curvas de entrenamiento.



(b) Matriz de confusión en el test.

Figura 9.5.: Swin-S (`swin_small_patch4_window7_224`).

9.2. Elección del modelo

Tabla 9.3.: Tabla de contingencia de aciertos de Swin-S y ConvNeXt-S sobre las mismas 12.618 imágenes de test. Test de McNemar: p exacto (binomial) = 0,188; χ^2 con corrección de continuidad = 1,73 (p = 0,188). *Bootstrap* pareado de la diferencia de exactitud Swin-S − ConvNeXt-S: +0,0020 [-0,0011; 0,0049] (p = 0,18; por lámina [-0,0013; 0,0049], p = 0,24); de F1 macro: −0,0004 [-0,0135; 0,0107] (p = 0,98).

	ConvNeXt-S acierta	ConvNeXt-S falla
Swin-S acierta	12.045	179
Swin-S falla	154	240

El modelo Swin Transformer obtiene la mayor exactitud (96,88 %), seguido muy de cerca por ConvNeXt (96,68 %). Dada la escasa diferencia entre ambos, cualquiera de los dos sería una base adecuada; se selecciona Swin por ser el que mejor resultado ha obtenido. **[REVISAR: exactitud del Swin-S: 96,87 % en las notas, 96,88 % en results_fase1 (valor único de la memoria)] [REVISAR: la diferencia no es estadísticamente significativa (McNemar p = 0,19, cuadro 9.3; ConvNeXt-S tiene además mayor F1 macro y *balanced accuracy*): la elección no puede justificarse por un mejor resultado, sino presentarse como elección entre dos modelos empatados]**

La superioridad de esta arquitectura radica en tres pilares fundamentales: **[REVISAR: justificación sin respaldo bibliográfico; reformular o citar Liu et al. 2021]**

1. **Jerarquización y ventanas desplazadas (*shifted windows*).** A diferencia de los Vision Transformers (ViT) estándar, que operan con parches globales, el Swin Transformer utiliza un mecanismo de ventanas jerárquicas. Esto permite capturar relaciones espaciales tanto a nivel local (textura, morfología de tejidos) como global (anatomía estructural de la lesión).

2. **Eficiencia en el contexto local.** La capacidad de contextualizar parches mediante ventanas de 7×7 (`window7`) permite que el modelo se enfoque en características relevantes sin verse afectado por el ruido de fondo, algo que los modelos de atención global (como `vit_base_patch16`) pueden ignorar al tratar todas las regiones por igual. **[REVISAR: «mediante window7» se ha desarrollado como «mediante ventanas de 7×7 (`window7`)»]**

3. **Inductividad de la imagen.** Al igual que ConvNeXt, el Swin Transformer integra principios de las redes convolucionales (sesgo inductivo), lo que facilita el aprendizaje de características jerárquicas desde resoluciones finas a gruesas. Esto permite una convergencia más eficiente y un mejor aprovechamiento de la información contenida en las imágenes médicas.

La diferencia mínima obtenida entre el Swin Transformer y ConvNeXt (+0,0020) indica que ambas arquitecturas están alcanzando un techo de rendimiento cercano al límite de información útil extraíble del conjunto de datos. **[REVISAR: diferencia corregida de 0,0019 a +0,0020 (results_fase1); además, la afirmación del «techo de rendimiento» no está respaldada por los resultados]**

- **Complementariedad de enfoques.** El hecho de que modelos basados en atención jerárquica y arquitecturas convolucionales modernas compitan por el primer puesto sugiere que las características más relevantes para el diagnóstico están siendo bien capturadas por ambos paradigmas.

Por tanto, el modelo con el que nos vamos a quedar para proseguir en nuestro estudio es el `swin_small_patch4_window7_224`.

[PENDIENTE: conclusión parcial]

9.3. Agrupaciones clínicas

Tabla 9.4.: Clasificación agrupada en el test ID a partir de las predicciones de 14 clases (más alto es mejor). Cinco categorías: NM (`No_Cancer`, estroma, glándulas no neoplásicas, inflamatorio), G3, G4, G5 y NT (PIN de alto grado, carcinoma intraductal, adenocarcinoma ductal). Binario: maligno = G3 + G4 + G5 + NT. Sens.: sensibilidad; Esp.: especificidad; BA: *balanced accuracy*. Referencia: XCiT-Medium del artículo del conjunto de datos [3], con otro reparto de NM y NT (su BA se calcula como la media de Sens. y Esp.).

	5 categorías		Binario			
Modelo	Exactitud (%)	BA	Exactitud (%)	Sens.	Esp.	BA
Swin-S	98,25	0,945	99,33	0,991	0,996	0,993
ConvNeXt-S	98,07	0,940	99,25	0,991	0,994	0,992
EfficientNetV2-S	97,24	0,926	98,86	0,983	0,995	0,989
ViT-B/16	97,16	0,925	98,93	0,986	0,993	0,989
ResNet-50	93,08	0,840	96,02	0,942	0,979	0,960
XCiT-M (artículo)	98,34	–	99,25	0,984	0,997	0,990

[PENDIENTE: análisis de la cuadro 9.4]

Tabla 9.5.: Sensibilidad de las categorías G3, G4 y G5 en el test ID (más alto es mejor). Son las categorías directamente comparables con el artículo del conjunto de datos [3], porque coinciden en número de imágenes.

Modelo	G3 ($n = 253$)	G4 ($n = 2.337$)	G5 ($n = 1.269$)
Swin-S	0,806	0,968	0,968
ConvNeXt-S	0,787	0,964	0,965
EfficientNetV2-S	0,771	0,940	0,938
ViT-B/16	0,775	0,953	0,922
ResNet-50	0,565	0,864	0,835
XCiT-M (artículo)	0,814	0,967	0,978

[PENDIENTE: análisis de la cuadro 9.5 y de la figura 9.6]

[PENDIENTE: conclusión parcial]

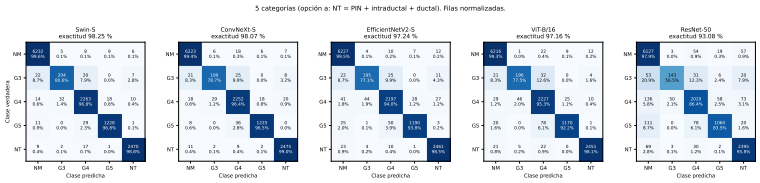


Figura 9.6.: Matrices de confusión de la clasificación agrupada en cinco categorías (NM, G3, G4, G5 y NT) en el test ID.

9.4. Discusión

[PENDIENTE: discusión global]

10. Detección OOD

[PENDIENTE: introducción del capítulo: modelo, 16 métodos (13 de OpenOOD y tres configuraciones de STOOD-X), nueve conjuntos (cuadro 8.2) y métricas (apartados 4.3.1, 4.3.2 y 4.3.4); IC por *bootstrap* (apartado 6.2)]

[REVISAR: la tabla principal de las notas (`tabla_principal_ood.tex`) se divide en una tabla por bloque; las tablas de AUPR van al capítulo A]

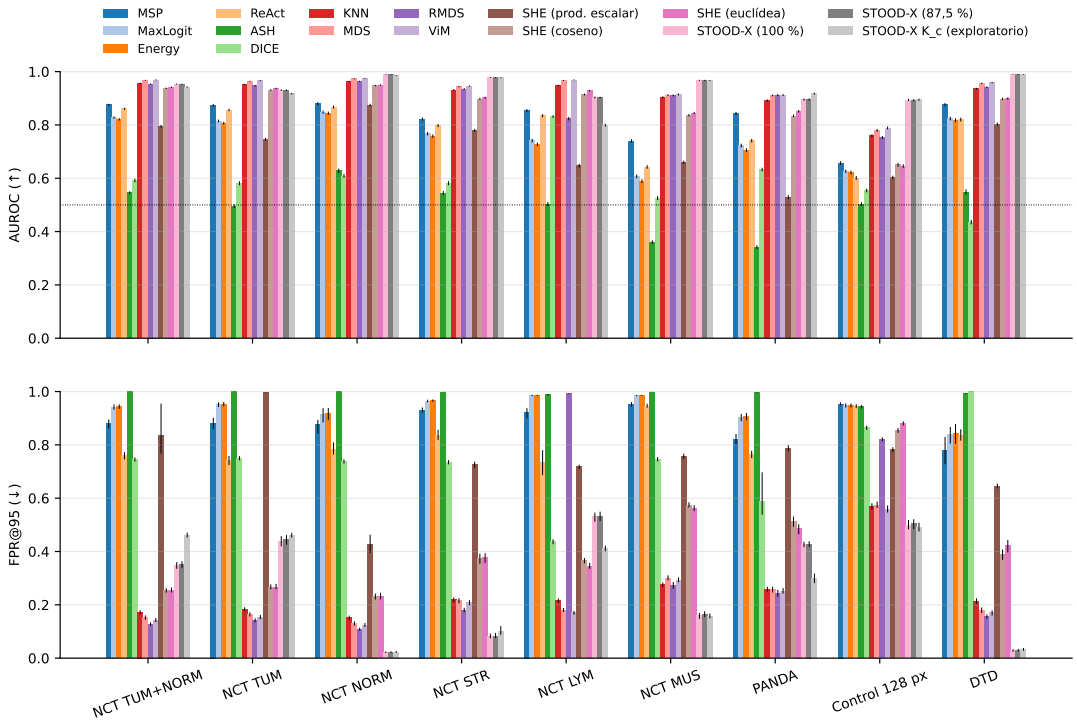


Figura 10.1.: AUROC (arriba; más alto es mejor) y FPR@95 (abajo; más bajo es mejor) de los 16 métodos en los nueve conjuntos, con IC del 95 % por *bootstrap*. Visión global de la comparación.

10.1. Near-OOD principal

Los resultados muestran una separación clara entre familias de métodos. Los métodos que operan sobre el espacio de características (ViM, MDS, KNN, RMDS y STOOD-X) superan de forma sistemática a los basados únicamente en los logits, en todos los conjuntos evaluados. En el near-OOD principal (NCT-CRC TUM + NORM), los primeros alcanzan un AUROC de entre 0,953 y 0,969, frente a 0,821–0,876 de MSP, MaxLogit y Energy. La diferencia es

Tabla 10.1.: Near-OOD principal (NCT-CRC-HE-100K-NONORM, TUM+NORM): AUROC y CCR@FPR5 (más alto es mejor) y FPR@95 (más bajo es mejor) de los 16 métodos. IC del 95 % por *bootstrap* (1.000 remuestreos estratificados, semilla 0). Clase positiva: OOD. En negrita, el mejor valor entre los métodos no exploratorios. [a]ASH reduce la exactitud ID al 68,3 %. [†]Variante exploratoria ($K_c = \min(500, \lfloor n_c/2 \rfloor)$), propuesta tras ver datos OOD; no es el método principal.

Método	AUROC ↑ [IC 95 %]	FPR@95 ↓ [IC 95 %]	CCR@FPR5 ↑
Basados en logits			
MSP	0,876 [0,872; 0,879]	0,879 [0,861; 0,895]	0,118
MaxLogit	0,828 [0,823; 0,832]	0,942 [0,932; 0,952]	0,056
Energy	0,821 [0,817; 0,825]	0,944 [0,935; 0,952]	0,054
Modificación de activaciones			
ReAct	0,861 [0,857; 0,864]	0,760 [0,745; 0,773]	0,238
ASH[a]	0,546 [0,540; 0,551]	0,999 [0,998; 1,000]	0,001
DICE	0,592 [0,585; 0,598]	0,744 [0,737; 0,753]	0,254
Características y distancias			
KNN	0,956 [0,954; 0,958]	0,173 [0,165; 0,180]	0,825
MDS	0,968 [0,966; 0,969]	0,152 [0,144; 0,160]	0,844
RMDS	0,954 [0,951; 0,956]	**0,128** [0,121; 0,134]	**0,868**
ViM	**0,969** [0,968; 0,971]	0,143 [0,136; 0,150]	0,853
SHE (prod. escalar)	0,795 [0,790; 0,800]	0,837 [0,768; 0,955]	0,162
SHE (coseno)	0,938 [0,935; 0,940]	0,255 [0,246; 0,263]	0,743
SHE (euclídea)	0,942 [0,940; 0,944]	0,255 [0,246; 0,265]	0,742
STOOD-X			
STOOD-X (100 %)	0,953 [0,951; 0,955]	0,349 [0,335; 0,360]	0,646
STOOD-X (87,5 %)	0,953 [0,951; 0,955]	0,352 [0,338; 0,363]	0,644
STOOD-X K_c[†]	0,943 [0,941; 0,945]	0,461 [0,453; 0,471]	0,535

aún mayor en el punto de trabajo: el FPR@95 baja de 0,879 (MSP) a valores entre 0,128 y 0,173, y el CCR@FPR5 sube de 0,118 a más de 0,82. Esto indica que el vector de características de 768 dimensiones contiene información sobre la pertenencia a la distribución que se pierde al proyectarlo sobre los 14 logits. **[REVISAR: «de forma sistemática [...] en todos los conjuntos»: RMDS queda por debajo de MSP en LYM (AUROC 0,824 frente a 0,854, cuadro 10.3)] [REVISAR: el rango de FPR@95 (0,128–0,173) y el CCR@FPR5 (más de 0,82) valen para ViM, MDS, KNN y RMDS, pero no para STOOD-X (0,349 y 0,646)]**

Near-OOD principal. ViM (0,969 [0,968; 0,971]) y MDS (0,968) obtienen el mejor AUROC, mientras que RMDS logra el mejor FPR@95 (0,128) y el mejor CCR@FPR5 (0,868), con un AUROC significativamente inferior (0,954; cuadro 10.2). Ambos resultados no son contradictorios: el AUROC resume la separación en todos los umbrales, mientras que FPR@95 y CCR@FPR5 evalúan la zona de umbral exigente, que es la relevante en un contexto clínico (figura 10.2). Con el umbral que deja pasar solo el 5 % de las imágenes de colon, RMDS acepta y clasifica correctamente el 86,8 % del test ID, frente a un máximo posible de 96,9 %. No obstante, RMDS presenta un fallo marcado en la clase LYM (FPR@95 = 0,992; CCR@FPR5 = 0,008): una parte de los linfocitos de colon recibe puntuaciones superiores a las de las propias imágenes ID, por lo que ningún umbral permite rechazarlos sin descartar casi todo el ID. **[REVISAR: añadidas las referencias a la cuadro 10.2 y a la figura 10.2]**

Tabla 10.2.: *Bootstrap* pareado (1.000 remuestreos, semilla 0) de la diferencia AUROC (RMDS) − AUROC (método) en el near-OOD principal (TUM+NORM). Diferencia positiva: RMDS es mejor. $p < 0{,}001$: ninguna réplica cruzó el cero. [a], †: como en cuadro 10.1.

Método	Diferencia	IC 95 %	p
MSP	+0,078	[0,075; 0,081]	< 0,001
MaxLogit	+0,126	[0,122; 0,130]	< 0,001
Energy	+0,133	[0,129; 0,136]	< 0,001
ReAct	+0,093	[0,090; 0,096]	< 0,001
ASH[a]	+0,408	[0,402; 0,414]	< 0,001
DICE	+0,362	[0,356; 0,369]	< 0,001
KNN	−0,003	[-0,004; -0,001]	0,00
MDS	−0,014	[-0,015; -0,012]	< 0,001
ViM	−0,016	[-0,017; -0,014]	< 0,001
SHE (prod. escalar)	+0,159	[0,155; 0,163]	< 0,001
SHE (coseno)	+0,016	[0,014; 0,018]	< 0,001
SHE (euclídea)	+0,012	[0,010; 0,014]	< 0,001
STOOD-X (100 %)	+0,000	[-0,002; 0,003]	0,75
STOOD-X (87,5 %)	+0,001	[-0,001; 0,003]	0,56
STOOD-X K_c †	+0,011	[0,008; 0,013]	< 0,001

[PENDIENTE: conclusión parcial]

10.2. Control interno: centro frente a tejido

Control interno: centro frente a tejido. Las clases afines de NCT-CRC permiten separar el efecto del cambio de centro del efecto del tipo de tejido. En ViM, MDS y KNN, los linfocitos (LYM), el tejido más similar entre órganos, se detectan con un AUROC (0,948–0,969) prácticamente igual al del tejido glandular de colon (TUM: 0,952–0,966; NORM: 0,963–0,975). Por tanto, estos detectores responden principalmente al **cambio de centro** (laboratorio, tinción,

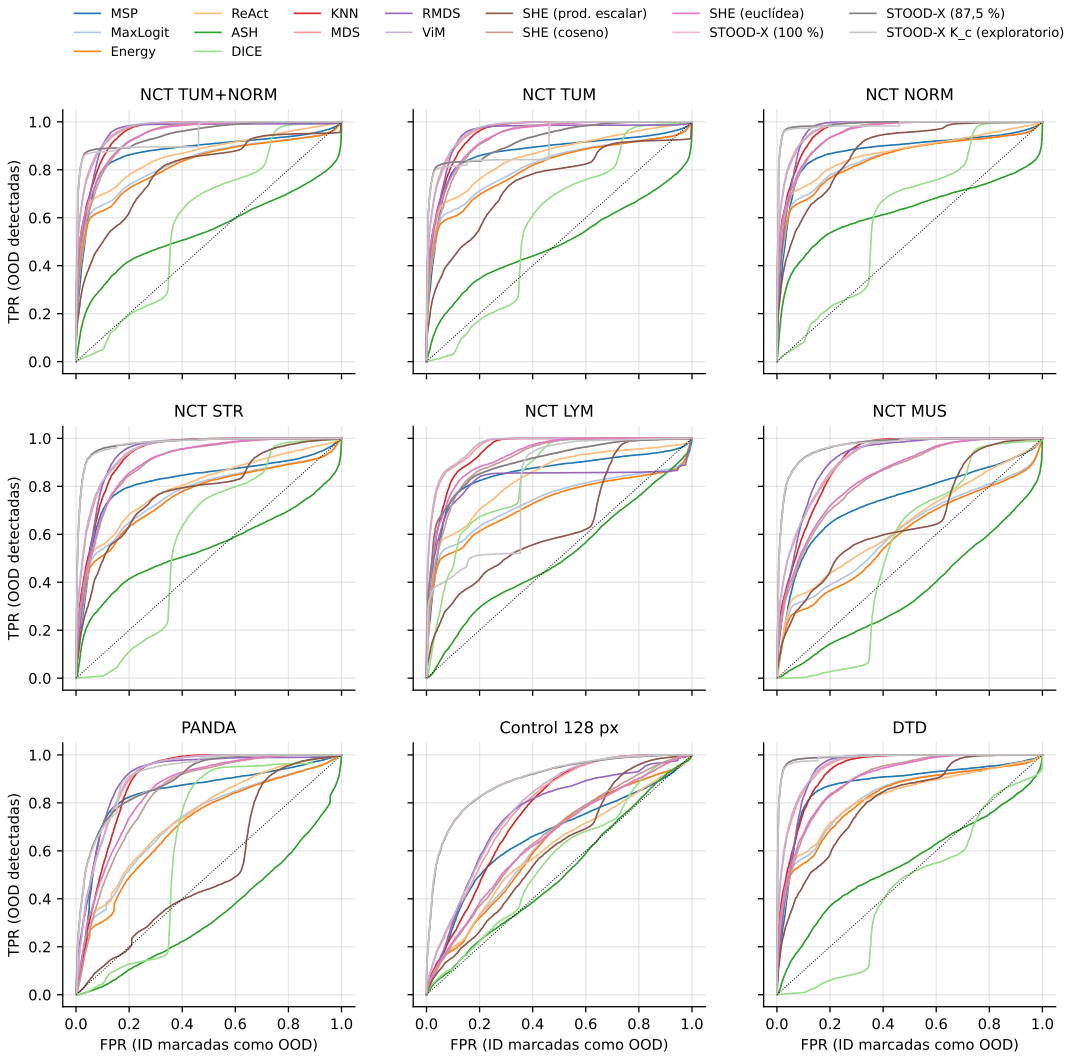


Figura 10.2.: Curvas ROC (TPR sobre OOD frente a FPR sobre ID) de todos los métodos, un panel por conjunto. Permiten ver dónde se separan los métodos: la zona de FPR baja frente al AUROC global explica por qué RMDS es el mejor en FPR@95 y no en AUROC.

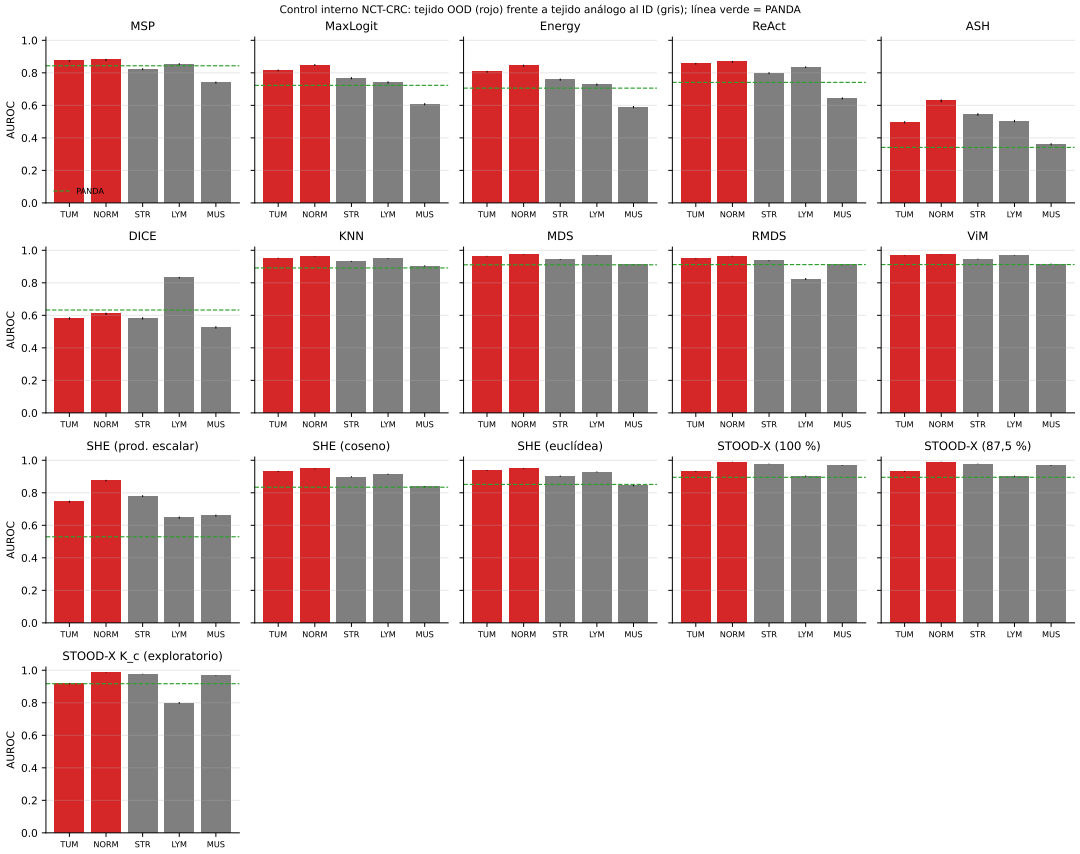


Figura 10.3.: AUROC por clase de NCT-CRC (TUM y NORM en rojo; STR, LYM y MUS en gris) para cada método, con PANDA como línea de referencia. Control interno del centro frente al tejido: si las clases afines se detectan casi igual que TUM y NORM, el detector responde al centro.

Tabla 10.3.: Control interno con las clases de NCT-CRC-HE-100K-NONORM: tejido glandular de colon (TUM y NORM) frente a tejidos análogos a clases ID (STR, LYM y MUS). AUROC (más alto es mejor) y FPR@95 (más bajo es mejor). Clase positiva: OOD. [a]ASH reduce la exactitud ID al 68,3 %. [†]Variante exploratoria ($K_c = \min(500, \lfloor n_c/2 \rfloor)$), propuesta tras ver datos OOD; no es el método principal.

	AUROC ↑					FPR@95 ↓				
Método	TUM	NORM	STR	LYM	MUS	TUM	NORM	STR	LYM	MUS
Basados en logits										
MSP	0,873	0,880	0,823	0,854	0,740	0,882	0,875	0,931	0,923	0,954
MaxLogit	0,815	0,848	0,767	0,741	0,607	0,952	0,916	0,965	0,985	0,985
Energy	0,807	0,844	0,759	0,727	0,589	0,952	0,918	0,966	0,986	0,986
Modificación de activaciones										
ReAct	0,856	0,868	0,798	0,835	0,643	0,743	0,783	0,836	0,734	0,946
ASH[a]	0,496	0,628	0,544	0,504	0,361	0,999	0,999	0,998	0,989	0,999
DICE	0,581	0,609	0,581	0,831	0,525	0,750	0,738	0,734	0,436	0,746
Características y distancias										
KNN	0,952	0,963	0,932	0,948	0,904	0,183	0,152	0,219	0,216	0,275
MDS	0,964	0,973	0,944	0,967	0,912	0,164	0,129	0,215	0,181	0,301
RMDS	0,947	0,964	0,935	0,824	0,911	0,142	0,109	0,180	0,992	0,272
ViM	0,966	0,975	0,946	0,969	0,915	0,154	0,124	0,209	0,170	0,293
SHE (prod. escalar)	0,746	0,875	0,780	0,647	0,660	0,997	0,426	0,725	0,718	0,757
SHE (coseno)	0,931	0,948	0,898	0,914	0,837	0,267	0,233	0,373	0,365	0,574
SHE (euclídea)	0,937	0,950	0,902	0,928	0,845	0,267	0,231	0,378	0,346	0,562
STOOD-X										
STOOD-X (100 %)	0,931	0,990	0,978	0,903	0,968	0,440	0,022	0,083	0,531	0,159
STOOD-X (87,5 %)	0,930	0,990	0,978	0,903	0,967	0,444	0,022	0,082	0,533	0,164
STOOD-X K_c[†]	0,917	0,985	0,977	0,799	0,966	0,461	0,023	0,101	0,411	0,158

escáner) y no a la naturaleza del tejido. Este resultado es coherente con lo señalado por Yang et al. [31]: los detectores OOD tienden a ser más sensibles al desplazamiento de covariables que al cambio semántico.

[PENDIENTE: conclusión parcial]

10.3. Cambio de centro y resolución

Cambio de centro y resolución. PANDA, compuesto por tejido prostático de otros centros, se detecta con AUROC ≈ 0,91 en los mejores métodos (ViM 0,912; RMDS 0,912; MDS 0,911). El control de resolución, formado por las mismas imágenes del test ID degradadas a 128 px, alcanza entre 0,753 y 0,789 en esos métodos. Al ser claramente inferior, la detección de PANDA no se explica únicamente por la pérdida de nitidez: el cambio de centro contribuye de forma propia. STOOD-X es la excepción, con valores prácticamente iguales en ambos conjuntos (0,895 y 0,894). Desde el punto de vista clínico, estos resultados implican que un sistema validado en un hospital rechazaría una fracción importante de imágenes de otro centro aun siendo del mismo órgano, lo que exigiría recalibrar el detector antes de su despliegue.

[PENDIENTE: conclusión parcial]

Tabla 10.4.: Cambio de centro y resolución: PANDA (próstata de otros centros) frente al control de resolución (las mismas imágenes del test ID reducidas a 128 px). AUROC (más alto es mejor) y FPR@95 (más bajo es mejor). Diferencia: AUROC de PANDA menos AUROC del control. IC del 95 % por *bootstrap* (1.000 remuestreos estratificados, semilla 0). Clase positiva: OOD. [a]ASH reduce la exactitud ID al 68,3 %. [†]Variante exploratoria ($K_c = \min(500, \lfloor n_c/2 \rfloor)$), propuesta tras ver datos OOD; no es el método principal.

	AUROC ↑ [IC 95 %]			FPR@95 ↓	
Método	PANDA	Control 128 px	Diferencia	PANDA	Control
Basados en logits					
MSP	0,843 [0,838; 0,849]	0,657 [0,650; 0,664]	+0,186	0,821	0,953
MaxLogit	0,723 [0,716; 0,730]	0,626 [0,619; 0,633]	+0,097	0,904	0,948
Energy	0,706 [0,698; 0,713]	0,622 [0,615; 0,629]	+0,084	0,905	0,948
Modificación de activaciones					
ReAct	0,741 [0,734; 0,747]	0,602 [0,594; 0,609]	+0,140	0,764	0,945
ASH[a]	0,341 [0,334; 0,348]	0,503 [0,496; 0,510]	-0,162	0,996	0,944
DICE	0,633 [0,626; 0,639]	0,554 [0,547; 0,561]	+0,079	0,586	0,864
Características y distancias					
KNN	0,892 [0,887; 0,896]	0,760 [0,754; 0,765]	+0,132	0,256	0,569
MDS	0,911 [0,907; 0,914]	0,780 [0,774; 0,785]	+0,131	0,257	0,575
RMDS	0,912 [0,908; 0,916]	0,753 [0,747; 0,759]	+0,159	0,241	0,821
ViM	0,912 [0,909; 0,916]	0,789 [0,784; 0,794]	+0,123	0,252	0,558
SHE (prod. escalar)	0,530 [0,522; 0,537]	0,603 [0,596; 0,610]	-0,073	0,787	0,783
SHE (coseno)	0,834 [0,829; 0,839]	0,651 [0,644; 0,657]	+0,184	0,514	0,854
SHE (euclídea)	0,851 [0,847; 0,856]	0,646 [0,639; 0,653]	+0,205	0,488	0,881
STOOD-X					
STOOD-X (100 %)	0,895 [0,891; 0,899]	0,894 [0,890; 0,898]	+0,001	0,427	0,497
STOOD-X (87,5 %)	0,895 [0,891; 0,899]	0,893 [0,889; 0,897]	+0,002	0,428	0,505
STOOD-X K_c[†]	0,917 [0,914; 0,921]	0,895 [0,891; 0,898]	+0,023	0,300	0,490

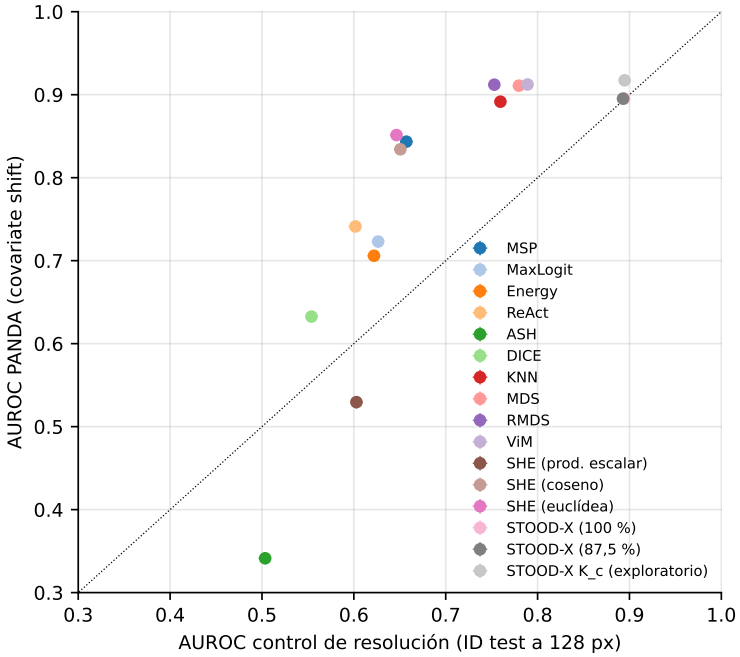


Figura 10.4.: AUROC en PANDA frente a AUROC en el control de resolución (test ID a 128 px), un punto por método con sus IC. Por encima de la diagonal, PANDA se detecta más de lo que explica la resolución; STOOD-X queda sobre la diagonal.

Tabla 10.5.: Far-OOD (DTD): AUROC y CCR@FPR5 (más alto es mejor) y FPR@95 (más bajo es mejor) de los 16 métodos. IC del 95 % por *bootstrap* (1.000 remuestreos estratificados, semilla 0). Clase positiva: OOD. En negrita, el mejor valor entre los métodos no exploratorios. [a]ASH reduce la exactitud ID al 68,3 %. [†]Variante exploratoria ($K_c = \min(500, \lfloor n_c/2 \rfloor)$), propuesta tras ver datos OOD; no es el método principal.

Método	AUROC ↑ [IC 95 %]	FPR@95 ↓ [IC 95 %]	CCR@FPR5 ↑
Basados en logits			
MSP	0,876 [0,870; 0,882]	0,780 [0,727; 0,830]	0,217
MaxLogit	0,824 [0,817; 0,831]	0,839 [0,805; 0,867]	0,158
Energy	0,818 [0,811; 0,825]	0,843 [0,805; 0,878]	0,154
Modificación de activaciones			
ReAct	0,820 [0,813; 0,827]	0,837 [0,816; 0,859]	0,160
ASH[a]	0,549 [0,539; 0,559]	0,993 [0,990; 0,994]	0,004
DICE	0,436 [0,427; 0,444]	0,999 [0,998; 1,000]	0,001
Características y distancias			
KNN	0,936 [0,933; 0,939]	0,214 [0,204; 0,225]	0,785
MDS	0,956 [0,953; 0,958]	0,181 [0,169; 0,190]	0,816
RMDS	0,942 [0,939; 0,945]	0,156 [0,148; 0,164]	0,840
ViM	0,959 [0,956; 0,961]	0,170 [0,160; 0,179]	0,827
SHE (prod. escalar)	0,802 [0,796; 0,809]	0,646 [0,637; 0,655]	0,353
SHE (coseno)	0,898 [0,894; 0,902]	0,387 [0,369; 0,407]	0,611
SHE (euclídea)	0,899 [0,895; 0,903]	0,422 [0,397; 0,443]	0,576
STOOD-X			
STOOD-X (100 %)	**0,991** [0,989; 0,992]	**0,028** [0,024; 0,033]	**0,949**
STOOD-X (87,5 %)	0,990 [0,989; 0,992]	0,030 [0,025; 0,034]	0,948
STOOD-X K_c [†]	0,989 [0,988; 0,990]	0,033 [0,028; 0,038]	0,946

10.4. Far-OOD

Far-OOD. En DTD, STOOD-X obtiene el mejor resultado (AUROC 0,991; FPR@95 0,028). Llama la atención que, para ViM, MDS y KNN, el far-OOD no resulta más fácil que el near-OOD (0,936–0,959 frente a 0,956–0,969). Esto refuerza la idea de que estos métodos son especialmente sensibles a las características de adquisición de las imágenes histológicas más que a su contenido semántico.

[PENDIENTE: conclusión parcial]

10.5. Métodos basados en logits y en modificación de activaciones

Tabla 10.6.: Métodos basados en logits, en la modificación de activaciones y variantes de SHE: AUROC (más alto es mejor) en los nueve conjuntos y exactitud ID de la clasificación resultante. Clase positiva: OOD. [a] ASH modifica las características y con ellas la predicción.

Método	TUM+NORM	TUM	NORM	STR	LYM	MUS	PANDA	Control 128 px	DTD	Exact. ID (%)
Basados en logits										
MSP	0,876	0,873	0,880	0,823	0,854	0,740	0,843	0,657	0,876	96,87
MaxLogit	0,828	0,815	0,848	0,767	0,741	0,607	0,723	0,626	0,824	96,87
Energy	0,821	0,807	0,844	0,759	0,727	0,589	0,706	0,622	0,818	96,87
Modificación de activaciones										
ReAct	0,861	0,856	0,868	0,798	0,835	0,643	0,741	0,602	0,820	96,89
ASH[a]	0,546	0,496	0,628	0,544	0,504	0,361	0,341	0,503	0,549	68,33
DICE	0,592	0,581	0,609	0,581	0,831	0,525	0,633	0,554	0,436	96,84
Características y distancias										
SHE (prod. escalar)	0,795	0,746	0,875	0,780	0,647	0,660	0,530	0,603	0,802	96,87
SHE (coseno)	0,938	0,931	0,948	0,898	0,914	0,837	0,834	0,651	0,898	96,87
SHE (euclídea)	0,942	0,937	0,950	0,902	0,928	0,845	0,851	0,646	0,899	96,87

Métodos basados en logits y en modificación de activaciones. MSP supera a MaxLogit y a Energy en los nueve conjuntos, al contrario de lo habitual en la literatura. Una explicación plausible es el uso de *label smoothing* durante el entrenamiento, que comprime la escala de los logits; comprobarlo requeriría entrenar el modelo sin esta técnica. Los métodos que modifican activaciones, diseñados para redes con activaciones ReLU y BatchNorm, no se trasladan bien a un Swin Transformer con LayerNorm. ReAct mejora a Energy, pero no a MSP. DICE queda por debajo de Energy en ocho de los nueve conjuntos, con un AUROC inferior al azar en DTD (0,436). ASH colapsa por completo: al redistribuir la suma de las activaciones, que es negativa en el 27,5 % de las imágenes, invierte los logits y reduce la exactitud ID al 68,3 %. Por último, SHE con producto escalar resulta irregular (0,795), mientras que sus variantes con distancia coseno (0,938) y euclídea (0,942) mejoran notablemente, lo que apunta de nuevo a la incompatibilidad entre las características con signo del Swin y los supuestos del método. **[REVISAR: «al contrario de lo habitual en la literatura»: falta cita] [REVISAR: ReAct mejora a Energy en ocho de los nueve conjuntos; en el control de resolución queda por debajo (0,602 frente a 0,622)] [REVISAR: el 27,5 % se midió en la validación ID]**

[PENDIENTE: conclusión parcial]

10.6. Discusión

Conclusión. Ningún método domina en todas las métricas y conjuntos. ViM ofrece el mejor equilibrio global en AUROC; RMDS, el mejor comportamiento con umbrales exigentes, aunque con un fallo severo en LYM; y STOOD-X destaca en far-OOD y en varias clases de NCT-CRC, pero es el más sensible a la resolución. El hallazgo más relevante es que los mejores detectores responden sobre todo a las condiciones de adquisición, lo que condiciona su uso en un entorno multicéntrico.

[PENDIENTE: integración de las conclusiones parciales]

11. STOOD-X

[PENDIENTE: introducción del capítulo]

11.1. Implementación

El método se ha implementado siguiendo la descripción del artículo [24]. Se realiza un único test por imagen entre las K distancias de x y las K^2 distancias de sus vecinos mediante `scipy.stats.mannwhitneyu` (Virtanen et al. [28]).

[PENDIENTE: diferencias entre la implementación pública y la descripción del artículo, y motivo de la reimplementación] **[REVISAR: tono]**

11.2. Configuración

Se emplean la distancia coseno, $K = 500$ (el valor seleccionado en el artículo), el conjunto de entrenamiento ID de la clase predicha como referencia y dos configuraciones de características: el 100 % y el 87,5 % más presente. Dado que el criterio de relevancia del artículo se basa en CRP (apartado 7.2), que no es directamente aplicable a un Swin Transformer, la selección del 87,5 % se realiza mediante la presencia de cada característica (suma de sus valores absolutos en la clase), criterio utilizado en la implementación pública. Ningún hiperparámetro se ha ajustado con datos OOD. **[REVISAR: tono]**

11.3. Puntuación

Como puntuación de detección se utiliza el estadístico tipificado del test de Mann-Whitney, z, obtenido mediante la aproximación normal del estadístico U con corrección por empates y por continuidad (teorema 6.3 y observación 6.4). Dado que $p = 1 - \Phi(z)$ es una función monótona decreciente de z, la puntuación $-z$ induce la misma ordenación que el p-valor propuesto en STOOD-X, pero evita el subdesbordamiento numérico que se produce cuando $p < 10^{-308}$. Cuando todas las distancias de x superan a las de sus vecinos (separación completa), el estadístico alcanza su valor máximo y varias imágenes quedan empatadas. Esto afecta al 66 % de TUM + NORM pero solo al 0,6 % del test ID; su efecto está acotado en $\pm$0,003 en AUROC, y no altera FPR@95 ni CCR@FPR5 (cuadro 11.1).

[PENDIENTE: conclusión parcial]

11.4. Resultados

En el near-OOD principal (TUM + NORM), STOOD-X obtiene un AUROC de 0,953, estadísticamente indistinguible del de RMDS (0,954; $p = 0{,}75$ en el *bootstrap* pareado), aunque con un FPR@95 claramente mayor (0,349 frente a 0,128). Es el mejor método en NORM (AUROC 0,990), STR (0,978), MUS (0,968) y DTD (0,991). En PANDA alcanza 0,895, prácticamente

Tabla 11.1.: Saturación de la puntuación $-z$ de STOOD-X (100 %, $K = 500$) por separación completa: proporción de imágenes con $U = n_1 n_2$ y cotas de su efecto en el AUROC (más alto es mejor), forzando el peor y el mejor orden entre las imágenes ID y OOD saturadas. FPR@95 y CCR@FPR5 no cambian en ningún conjunto.

Conjunto	Saturadas test ID	Saturadas OOD	AUROC	AUROC peor caso	AUROC mejor caso
TUM+NORM	0,6 %	66,3 %	0,953	0,951	0,955
TUM	0,6 %	59,0 %	0,931	0,929	0,933
NORM	0,6 %	78,2 %	0,990	0,987	0,992
STR	0,6 %	52,0 %	0,978	0,976	0,979
LYM	0,6 %	32,1 %	0,903	0,903	0,905
MUS	0,6 %	44,1 %	0,968	0,966	0,969
PANDA	0,6 %	19,4 %	0,895	0,895	0,896
Control 128 px	0,6 %	19,0 %	0,894	0,893	0,895
DTD	0,6 %	76,3 %	0,991	0,987	0,992

Tabla 11.2.: STOOD-X con el 100 % y el 87,5 % de las características ($K = 500$, puntuación $-z$) y la variante exploratoria K_c, frente a KNN y RMDS: AUROC (más alto es mejor) y FPR@95 (más bajo es mejor) en los nueve conjuntos. Clase positiva: OOD. †Variante exploratoria, propuesta tras ver datos OOD.

	STOOD-X (100 %)		STOOD-X (87,5 %)		STOOD-X K_c †		KNN		RMDS	
Conjunto	AUROC	FPR@95	AUROC	FPR@95	AUROC	FPR@95	AUROC	FPR@95	AUROC	FPR@95
TUM+NORM	0,953	0,349	0,953	0,352	0,943	0,461	0,956	0,173	0,954	0,128
TUM	0,931	0,440	0,930	0,444	0,917	0,461	0,952	0,183	0,947	0,142
NORM	0,990	0,022	0,990	0,022	0,985	0,023	0,963	0,152	0,964	0,109
STR	0,978	0,083	0,978	0,082	0,977	0,101	0,932	0,219	0,935	0,180
LYM	0,903	0,531	0,903	0,533	0,799	0,411	0,948	0,216	0,824	0,992
MUS	0,968	0,159	0,967	0,164	0,966	0,158	0,904	0,275	0,911	0,272
PANDA	0,895	0,427	0,895	0,428	0,917	0,300	0,892	0,256	0,912	0,241
Control 128 px	0,894	0,497	0,893	0,505	0,895	0,490	0,760	0,569	0,753	0,821
DTD	0,991	0,028	0,990	0,030	0,989	0,033	0,936	0,214	0,942	0,156

igual que en el control de resolución (0,894), lo que indica que su detección del cambio de centro se explica casi por completo por la diferencia de resolución. Las configuraciones con el 100 % y el 87,5 % de las características son indistinguibles.

[PENDIENTE: conclusión parcial]

11.5. Calibración

Tabla 11.3.: Calibración de los p-valores de STOOD-X ($K = 500$) en la validación ID (solo datos ID), por clase predicha. Si el test estuviera calibrado, los p-valores seguirían una $U(0,1)$: KS D (distancia de Kolmogorov-Smirnov a la uniforme) cercano a 0 y alrededor de un 5 % de $p < 0{,}05$. n_c: imágenes de entrenamiento predichas en la clase (conjunto de referencia); n_{val}: imágenes de validación predichas en ella.

Clase predicha	n_c	n_{val}	KS D	$p < 0{,}05$	$p = 0$	$p = 1$	Mediana de p
`Glandulas_no_neoplasicas`	25.846	6.474	0,840	85,4 %	8,8 %	5,7 %	≈ 0
`Estroma`	17.783	4.472	0,804	82,2 %	6,1 %	6,2 %	≈ 0
`Adenocarcinoma_ductal`	15.135	3.785	0,812	82,6 %	7,5 %	7,2 %	≈ 0
`Gleason_4_cribiformes`	10.155	2.555	0,842	85,5 %	9,4 %	6,5 %	≈ 0
`Gleason_5_no_glandulas`	8.717	2.176	0,712	73,3 %	9,5 %	11,1 %	≈ 0
`Gleason_4_fusionadas`	5.584	1.391	0,813	82,7 %	8,0 %	6,9 %	≈ 0
`PIN_de_alto_grado`	1.979	484	0,798	82,2 %	9,3 %	8,1 %	≈ 0
`Gleason_3`	1.822	475	0,774	78,9 %	20,6 %	6,1 %	≈ 0
`Gleason_4_pobremente_formadas`	905	207	0,695	72,0 %	1,4 %	10,6 %	≈ 0
`No_Cancer`	868	214	0,691	71,5 %	0,9 %	15,0 %	≈ 0
`Carcinoma_intraductal`	866	207	0,574	57,5 %	1,0 %	26,6 %	≈ 0
`Inflamatorio`	568	132	0,510	53,0 %	12,1 %	23,5 %	0,003
`Gleason_5_comedonecrosis`	399	90	0,478	45,6 %	0,0 %	34,4 %	0,622
`Gleason_4_glomeruloide`	173	29	0,559	20,7 %	0,0 %	0,0 %	0,995
Todas	90.800	22.691	0,802	81,9 %	8,1 %	7,3 %	≈ 0

Aunque el método propone el p-valor como medida de pertenencia, en el conjunto de validación ID el 82 % de las imágenes obtiene $p < 0{,}05$, con una distribución bimodal. Por tanto, el p-valor permite ordenar las imágenes, pero no puede interpretarse como nivel de significación. La causa probable es que las K^2 distancias de referencia no son independientes, ya que los vecinos comparten vecinos (observación 6.5). La calibración conforme sobre el conjunto de validación (apartado 12.1) recupera una tasa de falsas alarmas controlada.

[PENDIENTE: conclusión parcial]

11.6. Sensibilidad a K

En un análisis de sensibilidad sobre un subconjunto (cuadro 11.4), el rendimiento mejora hasta $K \approx 72$–288 y se degrada con $K = 500$. La degradación se concentra en las imágenes predichas en clases con pocas imágenes de entrenamiento (`Gleason_5_comedonecrosis`, 399; `Inflamatorio`, 568; `No_Cancer`, 868), donde K se aproxima al tamaño de la clase y se pierde la localidad del vecindario. En particular, el 10 % de las imágenes de TUM + NORM se predice como `Gleason_5_comedonecrosis`. Al excluir esas clases, la caída desaparece. Este análisis no se ha utilizado para elegir K, que se mantiene en el valor del artículo; una variante que adapta K al tamaño de la clase ($K_c = \min(500, \lfloor n_c/2 \rfloor)$) no mejoró los resultados.

[PENDIENTE: conclusión parcial]

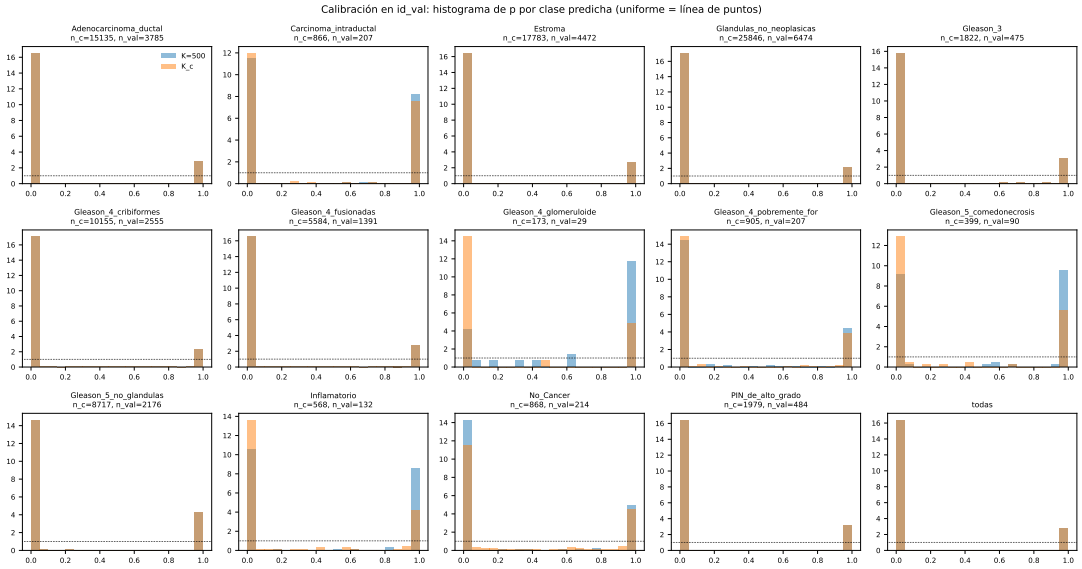


Figura 11.1.: Histogramas de los p-valores de STOOD-X en la validación ID por clase predicha, con $K = 500$ y con K_c; la línea de puntos es la densidad uniforme, que se obtendría si el test estuviera calibrado. Los p-valores son bimodales en 0 y 1.

Tabla 11.4.: Sensibilidad de STOOD-X al número de vecinos K (análisis de sensibilidad; *no* se usa para elegir K). Subconjunto de validación: 1.000 imágenes del test ID (estratificadas por clase) y 500 de cada conjunto OOD, semilla 0. Puntuación $-z$; 100 % de las características salvo indicación. AUROC: más alto es mejor; FPR@95: más bajo es mejor. Tiempo por imagen: GPU (cálculo de distancias) más CPU (test de Mann-Whitney). Última columna: proporción del test ID con $p = 0$ exacto (subdesbordamiento). †Variante exploratoria $K_c = \min(500, \lfloor n_c/2 \rfloor)$.

	TUM+NORM		LYM		PANDA		DTD		Tiempo	$p = 0$
K	AUROC	FPR@95	AUROC	FPR@95	AUROC	FPR@95	AUROC	FPR@95	(ms/img)	test ID
9	0,933	0,132	0,936	0,218	0,897	0,326	0,937	0,132	0,7	0,0 %
18	0,962	0,067	0,955	0,212	0,917	0,270	0,966	0,067	0,5	0,0 %
36	0,976	0,042	0,963	0,179	0,917	0,289	0,978	0,042	0,6	0,0 %
72	0,985	0,030	0,968	0,165	0,922	0,272	0,986	0,030	0,8	0,0 %
144	0,988	0,030	0,962	0,161	0,924	0,248	0,988	0,031	1,3	0,0 %
288	0,988	0,040	0,944	0,235	0,926	0,236	0,988	0,038	4,6	0,0 %
500	0,952	0,342	0,890	0,554	0,877	0,462	0,986	0,040	14,4	9,1 %
500 (87,5 %)	0,952	0,346	0,889	0,553	0,877	0,464	0,985	0,041	14,4	9,2 %
K_c †	0,941	0,474	0,790	0,428	0,900	0,291	0,985	0,045	13,2	9,0 %

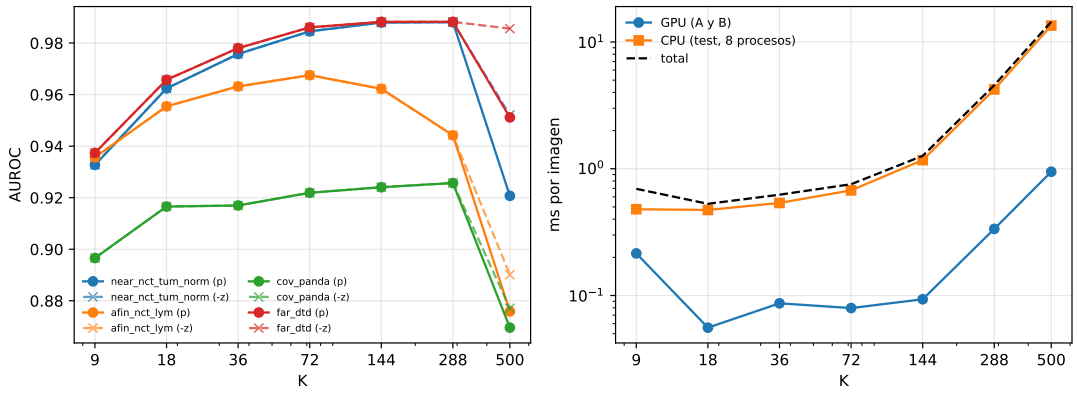


Figura 11.2.: Izquierda: AUROC con p y con $-z$ frente a K en TUM+NORM, LYM, PANDA y DTD. Derecha: tiempo por imagen (GPU, CPU y total) frente a K, en escala logarítmica. Muestra la caída con $K = 500$ y la diferencia entre p y $-z$ por subdesbordamiento.

11.7. Explicaciones por ejemplos

Siguiendo la segunda etapa del método, la figura 11.3 muestra imágenes representativas junto a sus cinco vecinos más cercanos de entrenamiento. Las imágenes de colon aceptadas como ID se predicen en su totalidad como `Gleason_5_comedonecrosis`, lo que ilustra visualmente el efecto descrito.

En cada figura, la primera columna es la imagen evaluada y las cinco siguientes, sus vecinos de entrenamiento, con la clase predicha, la puntuación (p y z) y las distancias en los títulos.

[PENDIENTE: análisis de las figuras 11.4 a 11.6]

11.8. Discusión

[PENDIENTE: discusión global]

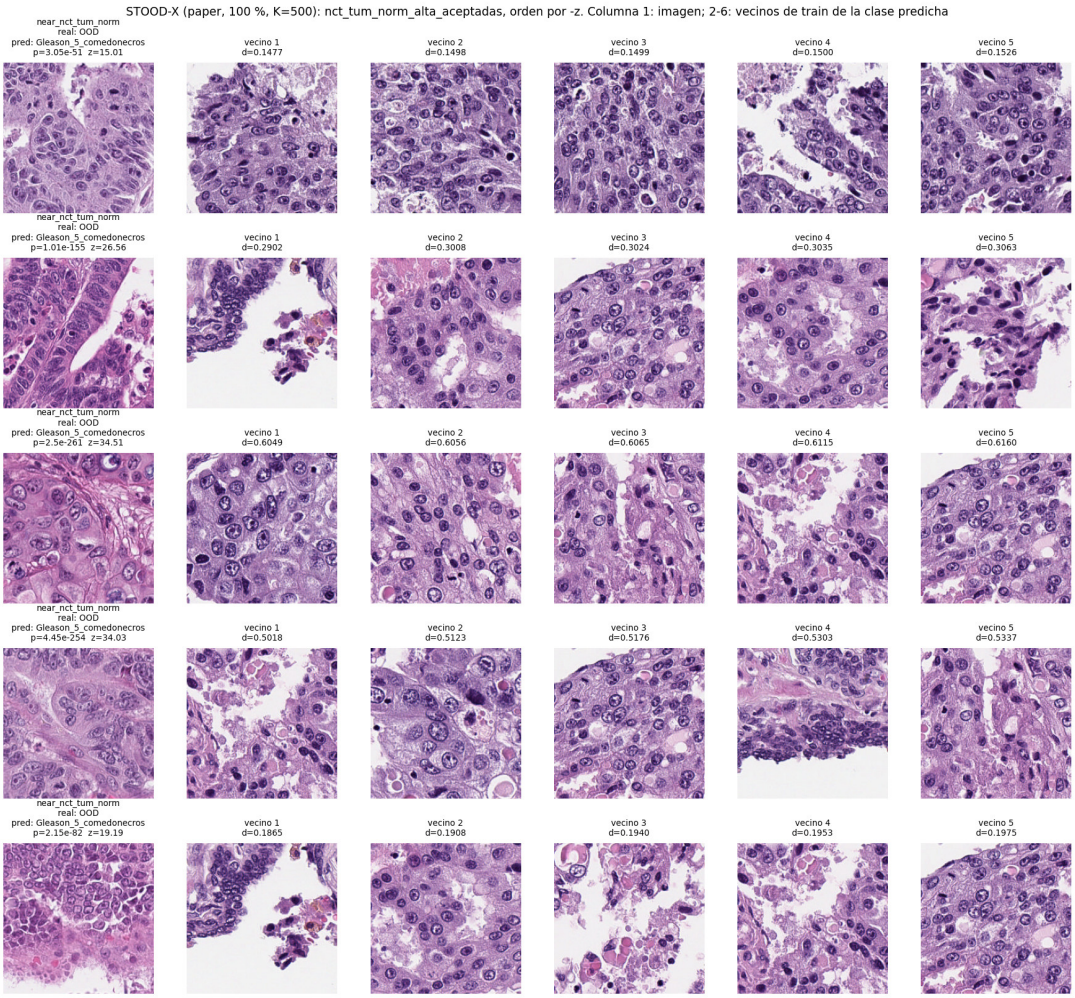


Figura 11.3.: STOOD-X ($K = 500$): cinco imágenes de TUM+NORM aceptadas como ID (puntuación $-z$ más alta) y sus cinco vecinos de entrenamiento de la clase predicha. Las cinco se predicen como `Gleason_5_comedonecrosis` ($n_c = 399 < K$).

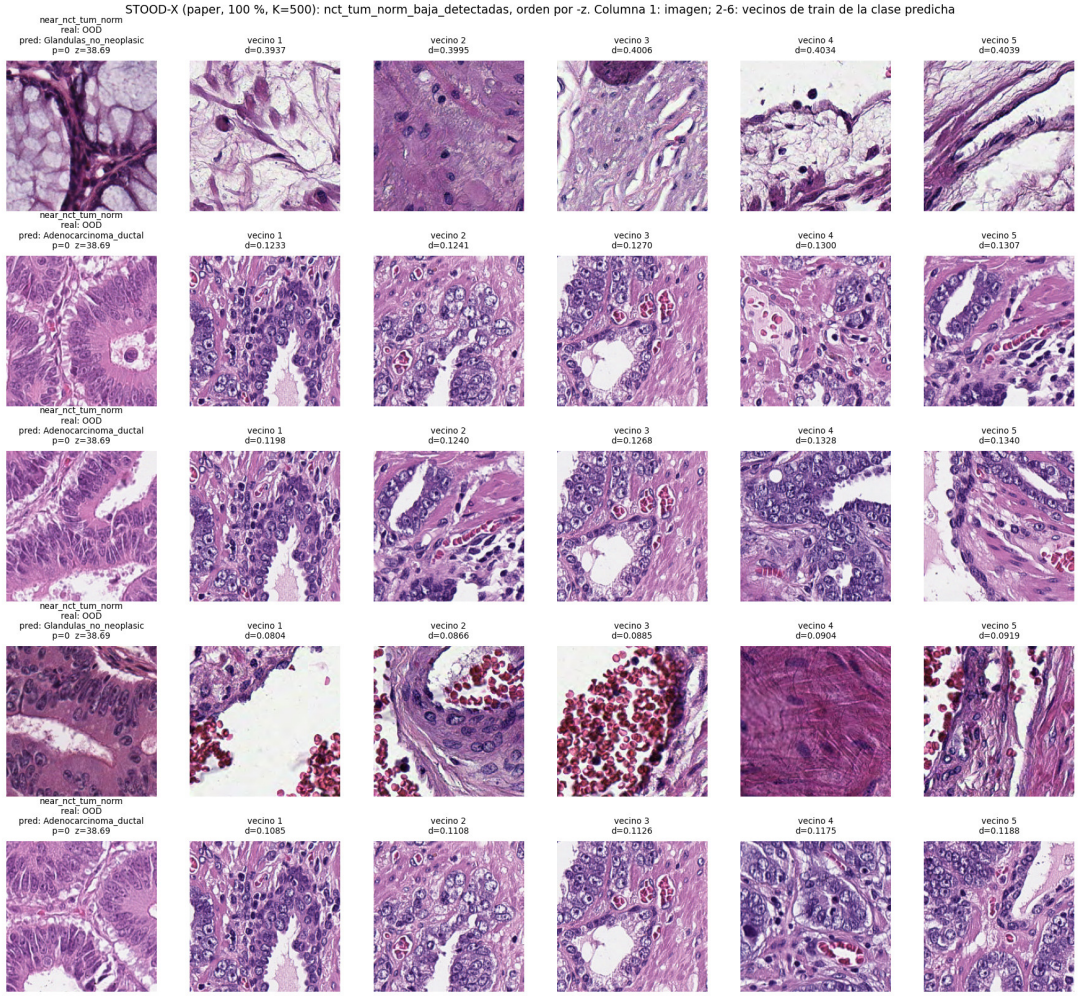


Figura 11.4.: STOOD-X ($K = 500$): cinco imágenes de TUM+NORM bien detectadas como OOD y sus vecinos de entrenamiento, visualmente distintos.

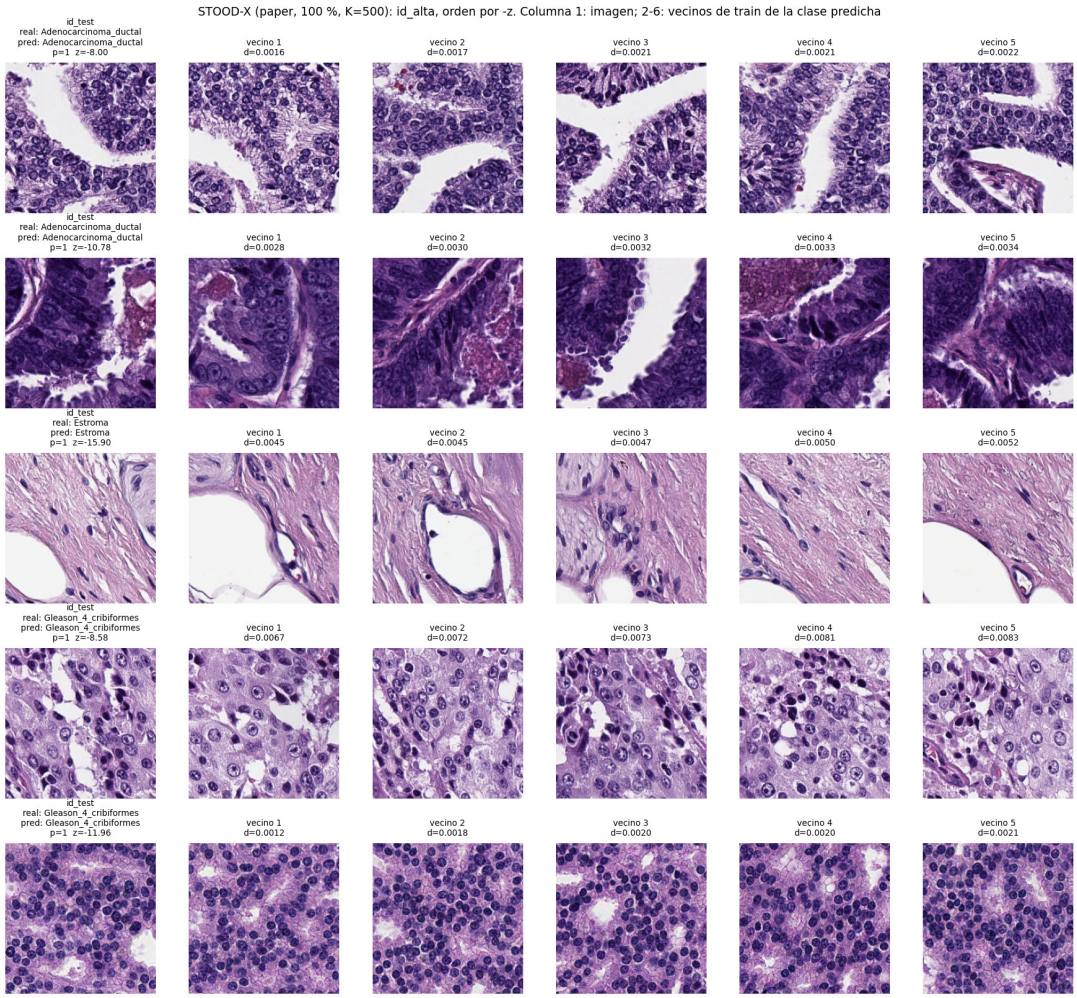


Figura 11.5.: STOOD-X ($K = 500$): cinco imágenes ID con puntuación alta y sus vecinos de entrenamiento: casos ID típicos.

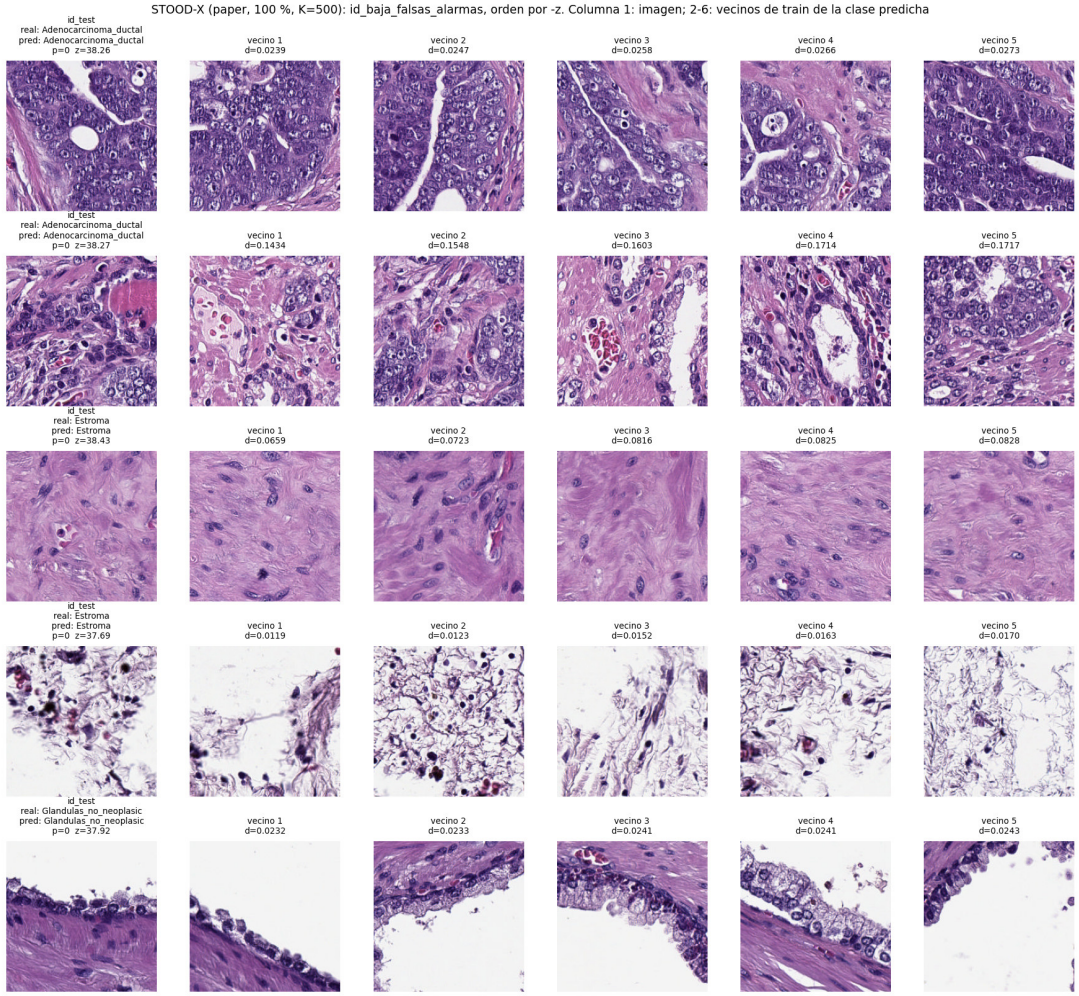


Figura 11.6.: STOOD-X ($K = 500$): cinco imágenes ID con puntuación baja (falsas alarmas) y sus vecinos de entrenamiento (z saturada, ≈ 38).

12. Predicción conforme

[PENDIENTE: introducción del capítulo y limitación de intercambiabilidad entre validación y test]

12.1. Detección OOD conforme

Tabla 12.1.: Detección OOD conforme con el umbral calibrado en la validación ID (22.691 imágenes). Falsas alarmas: proporción del test ID marcada como OOD, con IC exacto del 95 % (debe ser compatible con α si validación y test son intercambiables). Resto de columnas: proporción detectada como OOD en cada conjunto (más alto es mejor).

Método	α	Falsas alarmas test ID [IC 95 %]	TUM+NORM	LYM	PANDA	Control 128 px	DTD
MSP	0,01	0,009 [0,008; 0,011]	0,261	0,203	0,072	0,033	0,158
	0,05	0,050 [0,046; 0,054]	0,631	0,576	0,392	0,134	0,509
	0,10	0,098 [0,093; 0,103]	0,794	0,749	0,695	0,277	0,771
ViM	0,01	0,010 [0,008; 0,012]	0,552	0,569	0,110	0,077	0,437
	0,05	0,049 [0,045; 0,053]	0,796	0,826	0,448	0,209	0,721
	0,10	0,099 [0,094; 0,105]	0,902	0,886	0,646	0,324	0,857
MDS	0,01	0,010 [0,009; 0,012]	0,554	0,554	0,118	0,077	0,431
	0,05	0,049 [0,046; 0,053]	0,786	0,812	0,448	0,201	0,707
	0,10	0,099 [0,094; 0,104]	0,892	0,878	0,637	0,312	0,843
RMDS	0,01	0,010 [0,008; 0,011]	0,359	0,348	0,184	0,043	0,173
	0,05	0,052 [0,048; 0,056]	0,694	0,606	0,430	0,150	0,542
	0,10	0,098 [0,093; 0,103]	0,897	0,725	0,700	0,297	0,818
STOOD-X 100 % ($-z$)	0,01	0,011 [0,009; 0,013]	0,748	0,385	0,272	0,263	0,841
	0,05	0,049 [0,046; 0,053]	0,879	0,671	0,568	0,596	0,972
	0,10	0,103 [0,097; 0,108]	0,889	0,753	0,705	0,724	0,986

[PENDIENTE: análisis de la cuadro 12.1]
[PENDIENTE: conclusión parcial]

12.2. Conjuntos de predicción APS y RAPS

[PENDIENTE: análisis de la cuadro 12.2 y de la figura 12.1]
[PENDIENTE: análisis de la cuadro 12.3 y de la figura 12.2]
[PENDIENTE: conclusión parcial]

12.3. Predicción conforme Mondrian

[PENDIENTE: análisis de la cuadro 12.4]
[PENDIENTE: análisis de la cuadro 12.5 y de la figura 12.3]
[PENDIENTE: análisis de la figura 12.4]

Tabla 12.2.: Conjuntos de predicción APS y RAPS sobre las probabilidades del Swin-S, calibrados con el 80 % de la validación ID. Cobertura: proporción de imágenes cuya clase verdadera está en el conjunto (objetivo $1 - \alpha$), con IC exacto del 95 %; tamaño medio del conjunto (más pequeño es mejor a igual cobertura) y proporción de conjuntos vacíos.

		Test ID			Control 128 px	
Método	α	Cobertura [IC 95 %]	Tamaño	Vacíos	Cobertura	Tamaño
APS	0,05	0,945 [0,941; 0,949]	1,04	3,9 %	0,922	1,25
RAPS	0,05	0,948 [0,944; 0,952]	0,98	2,1 %	0,894	0,99
APS	0,10	0,897 [0,892; 0,902]	0,95	8,4 %	0,871	1,07
RAPS	0,10	0,898 [0,892; 0,903]	0,93	7,2 %	0,852	0,94

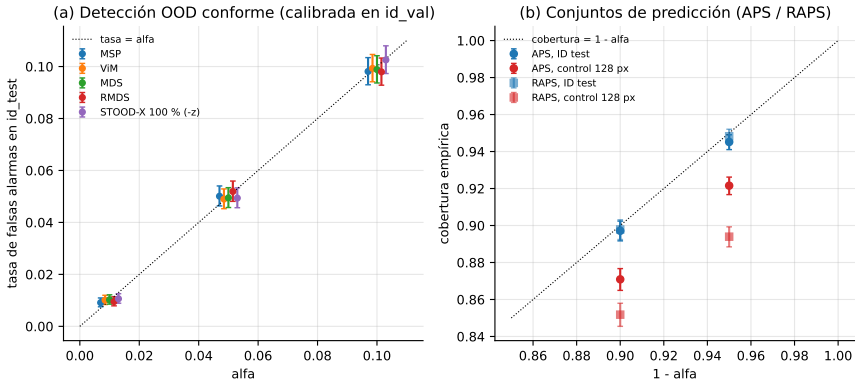


Figura 12.1.: Cobertura de los conjuntos de predicción APS y RAPS en el test ID y en el control de resolución frente al objetivo $1 - \alpha$.

Tabla 12.3.: Tamaño medio de los conjuntos de predicción APS y RAPS en el test ID y en los conjuntos OOD. Un tamaño mayor fuera de distribución indica que el conjunto refleja la incertidumbre ante entradas OOD.

Método	α	Test ID	TUM+NORM	TUM	NORM	STR	LYM	MUS	PANDA	Control 128 px	DTD
APS	0,05	1,04	3,14	3,12	3,16	2,08	2,72	1,74	1,69	1,25	2,51
RAPS	0,05	0,98	1,04	1,04	1,05	1,00	1,02	0,99	0,99	0,99	1,01
APS	0,10	0,95	2,37	2,34	2,41	1,53	2,00	1,35	1,28	1,07	1,82
RAPS	0,10	0,93	1,00	1,00	1,01	0,96	0,98	0,96	0,96	0,94	0,98

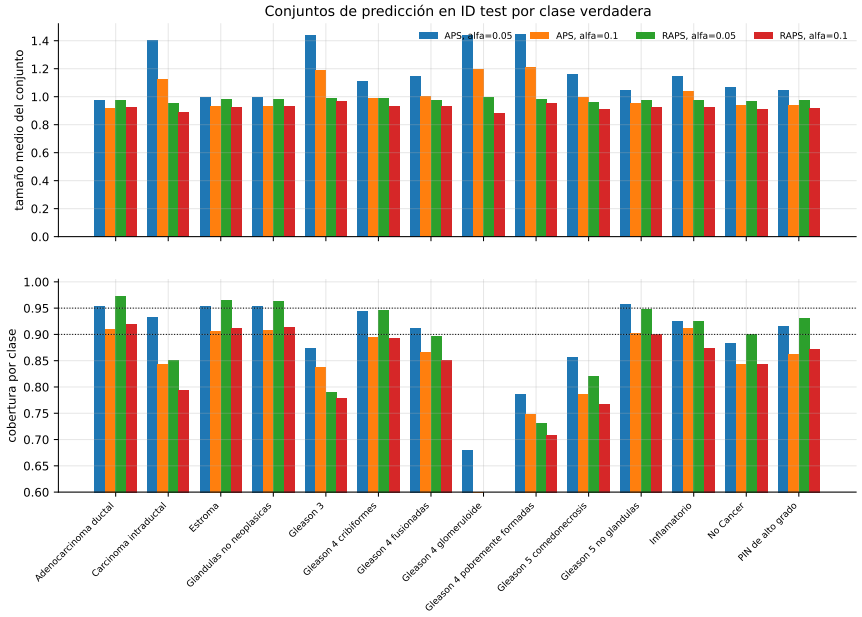


Figura 12.2.: Cobertura y tamaño medio de los conjuntos APS y RAPS por clase en el test ID.

Tabla 12.4.: Predicción conforme marginal frente a Mondrian (condicionada por clase) con las puntuaciones LAC y APS. Cobertura (objetivo $1-\alpha$) con IC exacto del 95 %, tamaño medio del conjunto, número de clases con cobertura puntual por debajo de $1-\alpha$ en el test ID y cobertura en el control de resolución (*covariate shift* con las mismas etiquetas).

Puntuación	α	Versión	Cobertura test ID [IC 95 %]	Tamaño medio	Clases $< 1-\alpha$	Cobertura control 128 px
APS	0,05	Marginal	0,945 [0,941; 0,949]	1,04	10 / 14	0,922
APS	0,05	Mondrian	0,946 [0,942; 0,950]	2,15	11 / 14	0,923
APS	0,10	Marginal	0,897 [0,892; 0,902]	0,95	9 / 14	0,871
APS	0,10	Mondrian	0,899 [0,894; 0,904]	0,98	10 / 14	0,874
LAC	0,05	Marginal	0,948 [0,944; 0,952]	0,96	10 / 14	0,859
LAC	0,05	Mondrian	0,948 [0,944; 0,952]	1,98	8 / 14	0,777
LAC	0,10	Marginal	0,901 [0,896; 0,906]	0,91	10 / 14	0,726
LAC	0,10	Mondrian	0,901 [0,896; 0,906]	0,94	7 / 14	0,649

Tabla 12.5.: Cobertura por clase en el test ID con la puntuación LAC y $\alpha = 0{,}05$: versión marginal frente a Mondrian (objetivo: 0,95 en cada clase). n_y: imágenes de calibración de la clase; $k_y = \lceil (n_y + 1)(1 - \alpha) \rceil$. ^{max}: $k_y = n_y$, el umbral es la mayor puntuación de calibración de la clase.

			Cobertura		Tamaño medio	
Clase	n_y	k_y	Marginal	Mondrian	Marginal	Mondrian
Gleason_4_glomeruloide	33	33^{max}	0,400	1,000	0,72	1,60
Gleason_5_comedonecrosis	82	79	0,804	0,946	0,89	2,11
Inflamatorio	113	109	0,850	1,000	0,86	2,08
Carcinoma_intraductal	169	162	0,793	0,983	0,82	2,03
Gleason_4_pobremente_formadas	174	167	0,606	0,874	0,76	2,15
No_Cancer	174	167	0,901	0,934	0,94	1,98
Gleason_3	359	342	0,719	0,901	0,83	2,04
PIN_de_alto_grado	391	373	0,928	0,957	0,96	2,01
Gleason_4_fusionadas	1.111	1.057	0,873	0,943	0,92	2,04
Gleason_5_no_glandulas	1.757	1.671	0,955	0,955	0,96	2,00
Gleason_4_cribiformes	2.037	1.937	0,924	0,944	0,94	2,01
Adenocarcinoma_ductal	3.020	2.870	0,992	0,959	0,99	1,97
Estroma	3.536	3.361	0,974	0,945	0,98	1,96
Glandulas_no_neoplasicas	5.197	4.939	0,972	0,946	0,98	1,96

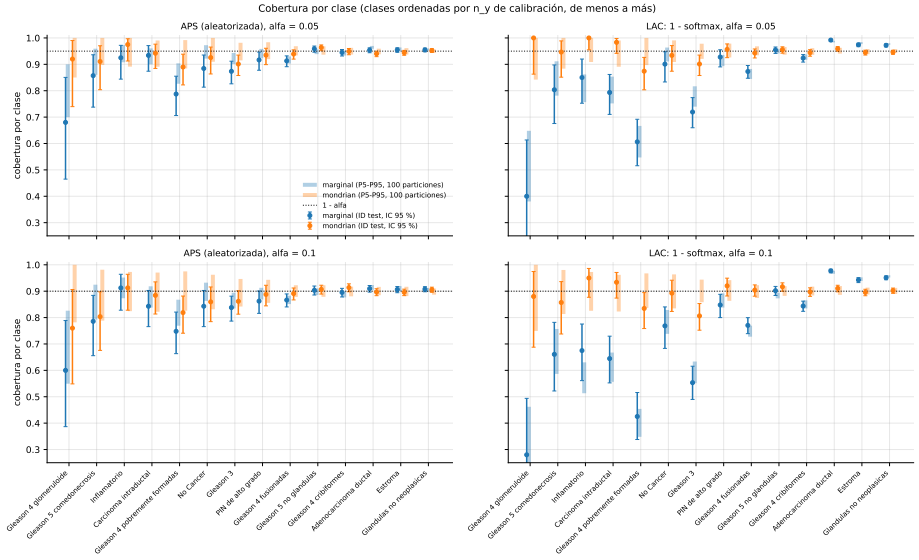


Figura 12.3.: Cobertura por clase en el test ID de la predicción conforme marginal y Mondrian.

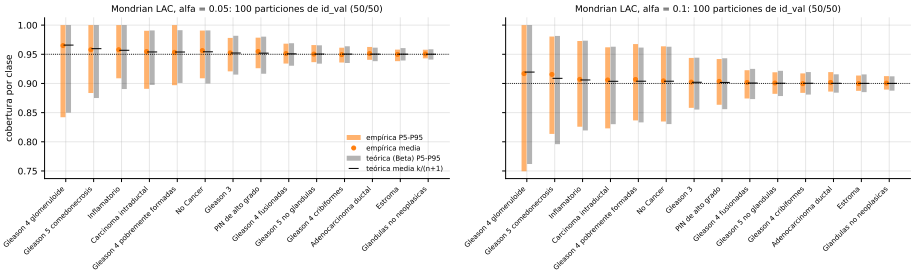
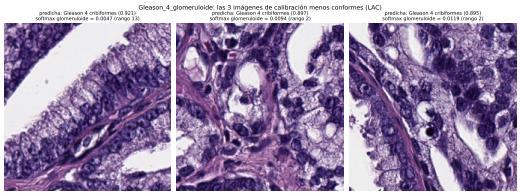
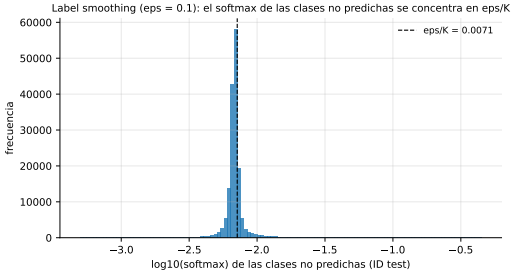


Figura 12.4.: Cobertura por clase en 100 particiones aleatorias de la validación ID (50 % calibración, 50 % evaluación) frente a la distribución teórica Beta$(k_y, n_y + 1 - k_y)$.



(a) Imágenes de calibración que fijan el umbral de `Gleason_4_glomeruloide`.



(b) Distribución del softmax de las clases no predichas y «suelo» ε/K.

Figura 12.5.: Causa del aumento del tamaño de los conjuntos con Mondrian y $\alpha = 0{,}05$.

[PENDIENTE: análisis de la figura 12.5]
[PENDIENTE: conclusión parcial]

12.4. Discusión

[PENDIENTE: discusión global]

13. Fuga por lámina

[PENDIENTE: introducción del capítulo]

13.1. Identificación de las láminas

[PENDIENTE: identificación de las láminas a partir de los nombres de fichero] **[REVISAR: deducción a partir de los nombres de fichero: 95 láminas y rejilla de 224 px, frente a las 85 WSI y el paso de 256 px del artículo]**

Tabla 13.1.: Fuga entre particiones por lámina, deducida de los nombres de fichero (`<lámina>_<x>_<y>_<tamaño>.png`): láminas compartidas, proporción de parches cuya lámina aparece en la partición de referencia y proporción con un parche contiguo (8 vecinos a 224 px) en ella.

Comparación	Láminas compartidas	Con su lámina en la referencia	Con un parche contiguo en la referencia
`val` original respecto a `train` original	95 / 95	100,0 %	99,5 %
Validación respecto a entrenamiento (TFG)	95 / 95	100,0 %	98,9 %
Test respecto a entrenamiento (TFG)	95 / 95	100,0 %	99,0 %

[PENDIENTE: análisis de la cuadro 13.1]

13.2. Fuga en el espacio de características

[PENDIENTE: análisis de la cuadro 13.2]
[PENDIENTE: conclusión parcial]

13.3. Efecto sobre la detección OOD

[PENDIENTE: análisis de la cuadro 13.3]
[PENDIENTE: análisis de la cuadro 13.4 y de la figura 13.1]
[PENDIENTE: conclusión parcial]

13.4. Limitación metodológica

[PENDIENTE: limitación metodológica]

Tabla 13.2.: Vecino más cercano en entrenamiento (distancia coseno, características de 768 dimensiones del Swin-S) de cada parche del test ID: proporción que es de la misma lámina, de la misma lámina y contiguo, y de la misma clase. Azar: proporción esperada de misma lámina eligiendo el vecino al azar dentro de la clase.

Clase	n	Misma lámina	Misma lámina y contiguo	Misma clase	Azar (misma lámina)
Todas	12.618	0,933	0,192	0,972	0,153
`Adenocarcinoma_ductal`	2.102	0,922	0,149	0,997	0,201
`Carcinoma_intraductal`	121	0,884	0,248	0,926	0,113
`Estroma`	2.469	0,935	0,286	0,990	0,135
`Glandulas_no_neoplasicas`	3.590	0,938	0,155	0,985	0,139
`Gleason_3`	253	0,874	0,233	0,810	0,063
`Gleason_4_cribiformes`	1.414	0,932	0,161	0,965	0,109
`Gleason_4_fusionadas`	771	0,936	0,127	0,918	0,172
`Gleason_4_glomeruloide`	25	0,800	0,040	0,560	0,275
`Gleason_4_pobremente_formadas`	127	0,913	0,150	0,756	0,179
`Gleason_5_comedonecrosis`	56	0,964	0,304	0,857	0,276
`Gleason_5_no_glandulas`	1.213	0,951	0,228	0,979	0,064
`Inflamatorio`	80	0,838	0,500	0,988	0,134
`No_Cancer`	121	0,934	0,248	0,934	0,415
`PIN_de_alto_grado`	276	0,964	0,159	0,957	0,642

Tabla 13.3.: Sensibilidad de la detección OOD a la fuga por lámina: KNN y MDS con todo el entrenamiento como referencia (original) → excluyendo, para cada parche del test ID, los parches de entrenamiento de su lámina (*leave-one-slide-out*). AUROC y CCR@FPR5: más alto es mejor; FPR@95: más bajo es mejor. Los conjuntos OOD se puntúan con todo el entrenamiento.

	KNN			MDS		
Conjunto	AUROC	FPR@95	CCR@FPR5	AUROC	FPR@95	CCR@FPR5
TUM+NORM	0,956 → 0,926	0,173 → 0,273	0,825 → 0,726	0,968 → 0,942	0,152 → 0,251	0,844 → 0,746
TUM	0,952 → 0,919	0,183 → 0,291	0,815 → 0,708	0,964 → 0,936	0,164 → 0,265	0,832 → 0,733
NORM	0,963 → 0,938	0,152 → 0,244	0,845 → 0,754	0,973 → 0,952	0,129 → 0,223	0,865 → 0,774
STR	0,932 → 0,887	0,219 → 0,350	0,779 → 0,650	0,944 → 0,902	0,215 → 0,342	0,783 → 0,657
LYM	0,948 → 0,913	0,216 → 0,346	0,783 → 0,653	0,967 → 0,941	0,181 → 0,291	0,816 → 0,707
MUS	0,904 → 0,844	0,275 → 0,427	0,724 → 0,573	0,912 → 0,854	0,301 → 0,464	0,699 → 0,535
PANDA	0,892 → 0,823	0,256 → 0,403	0,743 → 0,597	0,911 → 0,847	0,257 → 0,404	0,741 → 0,595
Control 128 px	0,760 → 0,634	0,569 → 0,804	0,431 → 0,196	0,780 → 0,660	0,575 → 0,809	0,425 → 0,191
DTD	0,936 → 0,894	0,214 → 0,342	0,785 → 0,655	0,956 → 0,922	0,181 → 0,291	0,816 → 0,707

Tabla 13.4.: Control interno de NCT-CRC-HE-100K-NONORM con y sin la lámina de cada parche en la referencia: AUROC (más alto es mejor) por clase y en PANDA, y diferencia entre LYM y la media de TUM y NORM.

Método	Versión	TUM	NORM	STR	LYM	MUS	PANDA	LYM − media(TUM, NORM)
KNN	original	0,952	0,963	0,932	0,948	0,904	0,892	−0,010
	sin lámina	0,919	0,938	0,887	0,913	0,844	0,823	−0,016
MDS	original	0,964	0,973	0,944	0,967	0,912	0,911	−0,002
	sin lámina	0,936	0,952	0,902	0,941	0,854	0,847	−0,002

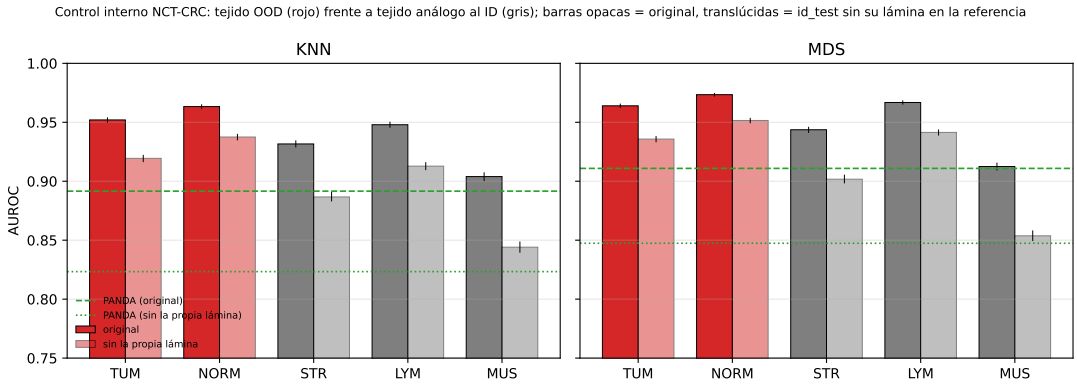


Figura 13.1.: AUROC por clase de NCT-CRC con KNN y MDS, con todo el entrenamiento como referencia y sin la lámina de cada parche del test.

14. Explicabilidad y eliminación de sesgos

[PENDIENTE: capítulo en desarrollo]

Parte IV.

Conclusiones y trabajo futuro

15. Conclusiones y trabajo futuro

15.1. Conclusiones

[PENDIENTE: conclusiones, objetivo por objetivo]

15.2. Limitaciones

La detección OOD protege frente a imágenes raras o desconocidas, pero no frente a cambios en el criterio diagnóstico. Para eso hace falta revisar y reetiquetar los datos periódicamente.
[PENDIENTE: resto de limitaciones]

15.3. Trabajo futuro

[PENDIENTE: trabajo futuro]

Parte V.

Apéndices

A. Tablas de AUPR-In y AUPR-Out

Tabla A.1.: AUPR-In (clase positiva: ID) de los 16 métodos en los nueve conjuntos (más alto es mejor). [a]ASH reduce la exactitud ID al 68,3 %. [†]Variante exploratoria ($K_c = \min(500, \lfloor n_c/2 \rfloor)$), propuesta tras ver datos OOD; no es el método principal.

Método	TUM+NORM	TUM	NORM	STR	LYM	MUS	PANDA	Control 128 px	DTD
Basados en logits									
MSP	0,676	0,762	0,845	0,760	0,773	0,629	0,821	0,587	0,903
MaxLogit	0,602	0,689	0,815	0,706	0,639	0,515	0,719	0,590	0,872
Energy	0,594	0,681	0,813	0,699	0,627	0,503	0,709	0,588	0,869
Modificación de activaciones									
ReAct	0,690	0,783	0,851	0,767	0,783	0,563	0,764	0,558	0,867
ASH[a]	0,339	0,422	0,606	0,521	0,496	0,381	0,446	0,501	0,678
DICE	0,525	0,611	0,739	0,690	0,873	0,591	0,747	0,580	0,650
Características y distancias									
KNN	0,944	0,957	0,978	0,953	0,961	0,922	0,934	0,806	0,973
MDS	0,955	0,966	0,983	0,959	0,973	0,924	0,942	0,815	0,981
RMDS	0,899	0,909	0,980	0,958	0,704	0,924	0,924	0,725	0,977
ViM	0,958	0,968	0,984	0,960	0,975	0,926	0,943	0,823	0,983
SHE (prod. escalar)	0,592	0,628	0,908	0,789	0,697	0,652	0,643	0,641	0,901
SHE (coseno)	0,915	0,935	0,967	0,920	0,929	0,839	0,880	0,647	0,953
SHE (euclídea)	0,916	0,937	0,967	0,923	0,939	0,846	0,892	0,631	0,953
STOOD-X									
STOOD-X (100 %)	0,910	0,914	0,993	0,982	0,897	0,968	0,919	0,888	0,996
STOOD-X (87,5 %)	0,909	0,913	0,993	0,982	0,896	0,967	0,919	0,887	0,996
STOOD-X K_c[†]	0,897	0,904	0,989	0,981	0,848	0,966	0,941	0,891	0,995

Tabla A.2.: AUPR-Out (clase positiva: OOD) de los 16 métodos en los nueve conjuntos (más alto es mejor). [a]ASH reduce la exactitud ID al 68,3 %. [†]Variante exploratoria ($K_c = \min(500, \lfloor n_c/2 \rfloor)$), propuesta tras ver datos OOD; no es el método principal.

Método	TUM+NORM	TUM	NORM	STR	LYM	MUS	PANDA	Control 128 px	DTD
Basados en logits									
MSP	0,935	0,904	0,871	0,818	0,867	0,777	0,800	0,660	0,782
MaxLogit	0,913	0,866	0,846	0,774	0,792	0,676	0,678	0,616	0,730
Energy	0,910	0,861	0,844	0,766	0,779	0,658	0,651	0,612	0,727
Modificación de activaciones									
ReAct	0,929	0,892	0,868	0,793	0,843	0,698	0,685	0,610	0,742
ASH[a]	0,749	0,605	0,650	0,583	0,502	0,440	0,348	0,514	0,392
DICE	0,666	0,541	0,459	0,455	0,768	0,481	0,474	0,543	0,259
Características y distancias									
KNN	0,972	0,951	0,943	0,900	0,934	0,891	0,800	0,710	0,852
MDS	0,980	0,966	0,961	0,923	0,961	0,908	0,853	0,743	0,901
RMDS	0,969	0,951	0,928	0,889	0,870	0,892	0,868	0,717	0,830
ViM	0,981	0,967	0,963	0,926	0,965	0,910	0,853	0,752	0,907
SHE (prod. escalar)	0,883	0,795	0,833	0,757	0,658	0,700	0,457	0,586	0,659
SHE (coseno)	0,960	0,932	0,923	0,866	0,898	0,841	0,741	0,639	0,797
SHE (euclídea)	0,965	0,942	0,930	0,874	0,920	0,851	0,776	0,642	0,807
STOOD-X									
STOOD-X (100 %)	0,975	0,946	0,982	0,968	0,900	0,964	0,857	0,897	0,975
STOOD-X (87,5 %)	0,975	0,946	0,982	0,969	0,900	0,964	0,860	0,896	0,975
STOOD-X K_c[†]	0,970	0,937	0,978	0,967	0,784	0,963	0,873	0,897	0,973

B. Anexo: clases ADI, BACK, DEB y MUC de NCT-CRC

[PENDIENTE: breve introducción del anexo y análisis]

Tabla B.1.: Clases restantes de NCT-CRC-HE-100K-NONORM: tejido adiposo (ADI), fondo (BACK), restos celulares (DEB) y moco (MUC). AUROC (más alto es mejor) y FPR@95 (más bajo es mejor); clase positiva: OOD. [a], [†]: como en cuadro 10.1.

	AUROC ↑				FPR@95 ↓			
Método	ADI	BACK	DEB	MUC	ADI	BACK	DEB	MUC
Basados en logits								
MSP	0,736	0,884	0,798	0,735	0,769	0,904	0,987	0,977
MaxLogit	0,548	0,834	0,780	0,687	0,866	0,947	0,993	0,982
Energy	0,536	0,827	0,767	0,681	0,869	0,944	0,994	0,982
Modificación de activaciones								
ReAct	0,569	0,775	0,875	0,746	0,741	0,980	0,579	0,980
ASH[a]	0,469	0,617	0,608	0,448	0,954	0,928	0,989	0,999
DICE	0,561	0,334	0,742	0,483	0,551	0,993	0,673	0,907
Características y distancias								
KNN	0,725	0,952	0,956	0,944	0,599	0,151	0,136	0,164
MDS	0,758	0,968	0,975	0,961	0,531	0,128	0,096	0,144
RMDS	0,781	0,949	0,939	0,946	0,558	0,127	0,132	0,130
ViM	0,752	0,969	0,976	0,962	0,550	0,120	0,088	0,141
SHE (prod. escalar)	0,370	0,910	0,668	0,780	0,822	0,292	0,997	0,668
SHE (coseno)	0,646	0,931	0,940	0,918	0,693	0,236	0,165	0,269
SHE (euclídea)	0,660	0,925	0,951	0,923	0,681	0,247	0,167	0,267

C. Material complementario

[PENDIENTE: material complementario]

Bibliografía

[1] Reduan Achtibat, Maximilian Dreyer, Ilona Eisenbraun, Sebastian Bosse, Thomas Wiegand, Wojciech Samek, y Sebastian Lapuschkin. From attribution maps to human-understandable explanations through concept relevance propagation. *Nature Machine Intelligence*, 5(9):1006–1019, 2023.

[2] Anastasios N. Angelopoulos y Stephen Bates. A gentle introduction to conformal prediction and distribution-free uncertainty quantification. *arXiv preprint arXiv:2107.07511*, 2021.

[3] Jacobo Ayensa-Jiménez, Denis Navarro, Iván Sevillano-García, Andrés Mena, Isabel Marquina, Sofía Hakim, Jorge Alfaro, Francisco Herrera, Manuel Doblaré, y Ángel Borque-Fernando. Fine-grained prostate cancer tissue classification through expert-annotated dataset and clinically interpretable deep learning. En *2026 IEEE Conference on Artificial Intelligence (CAI)*, páginas 1264–1269, 2026.

[4] Wouter Bulten, Kimmo Kartasalo, Po-Hsuan Cameron Chen, Peter Ström, Hans Pinckaers, Kunal Nagpal, Yuannan Cai, David F. Steiner, Hester van Boven, Robert Vink, et al. Artificial intelligence for diagnosis and Gleason grading of prostate cancer: The PANDA challenge. *Nature Medicine*, 28(1):154–163, 2022.

[5] Raghavendra Chalapathy y Sanjay Chawla. Deep learning for anomaly detection: A survey. *arXiv preprint arXiv:1901.03407*, 2019.

[6] Mircea Cimpoi, Subhransu Maji, Iasonas Kokkinos, Sammy Mohamed, y Andrea Vedaldi. Describing textures in the wild. En *2014 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, páginas 3606–3613, 2014.

[7] Akshay Raj Dhamija, Manuel Günther, y Terrance E. Boult. Reducing network agnostophobia. En *Advances in Neural Information Processing Systems (NeurIPS)*, 2018. arXiv:1811.04110.

[8] Andrija Djurisic, Nebojsa Bozanic, Arjun Ashok, y Rosanne Liu. Extremely simple activation shaping for out-of-distribution detection. En *International Conference on Learning Representations (ICLR)*, 2023. arXiv:2209.09858.

[9] Tom Fawcett. An introduction to ROC analysis. *Pattern Recognition Letters*, 27(8):861–874, 2006.

[10] Rui Huang, Andrew Geng, y Yixuan Li. On the importance of gradients for detecting distributional shifts in the wild. En *Advances in Neural Information Processing Systems (NeurIPS)*, 2021. arXiv:2110.00218.

[11] Conor Igoe, Youngseog Chung, Ian Char, y Jeff Schneider. How useful are gradients for OOD detection really? *arXiv preprint arXiv:2205.10439*, 2022.

[12] Jakob Nikolas Kather, Niels Halama, y Alexander Marx. 100,000 histological images of human colorectal cancer and healthy tissue. Zenodo, 2018. Versión v0.1.

[13] Jakob Nikolas Kather, Johannes Krisam, Pornpimol Charoentong, Tom Luedde, Esther Herpel, Cleo-Aron Weis, Timo Gaiser, Alexander Marx, Nektarios A. Valous, Dyke Ferber, et al. Predicting survival from colorectal cancer histology slides using deep learning: A retrospective multicenter study. *PLOS Medicine*, 16(1):e1002730, 2019.

[14] Diederik P. Kingma y Jimmy Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014. Publicado en ICLR 2015.

[15] Kimin Lee, Kibok Lee, Honglak Lee, y Jinwoo Shin. A simple unified framework for detecting out-of-distribution samples and adversarial attacks. En *Advances in Neural Information Processing Systems (NeurIPS)*, 2018. arXiv:1807.03888.

[16] Shiyu Liang, Yixuan Li, y R. Srikant. Enhancing the reliability of out-of-distribution image detection in neural networks. En *International Conference on Learning Representations (ICLR)*, 2018. arXiv:1706.02690.

[17] Ilya Loshchilov y Frank Hutter. Decoupled weight decay regularization. En *International Conference on Learning Representations (ICLR)*, 2019. arXiv:1711.05101.

[18] Marc Macenko, Marc Niethammer, J. S. Marron, David Borland, John T. Woosley, Xiaojun Guan, Charles Schmitt, y Nancy E. Thomas. A method for normalizing histology slides for quantitative analysis. En *2009 IEEE International Symposium on Biomedical Imaging: From Nano to Macro*, páginas 1107–1110, 2009.

[19] H. B. Mann y D. R. Whitney. On a test of whether one of two random variables is stochastically larger than the other. *The Annals of Mathematical Statistics*, 18(1):50–60, 1947.

[20] Paulius Micikevicius, Sharan Narang, Jonah Alben, Gregory Diamos, Erich Elsen, David Garcia, Boris Ginsburg, Michael Houston, Oleksii Kuchaiev, Ganesh Venkatesh, y Hao Wu. Mixed precision training. En *International Conference on Learning Representations (ICLR)*, 2018. arXiv:1710.03740.

[21] Guansong Pang, Chunhua Shen, Longbing Cao, y Anton van den Hengel. Deep learning for anomaly detection: A review. *ACM Computing Surveys*, 54(2):1–38, 2021. Las notas lo citan como 2020 (versión de arXiv); publicado en 2021.

[22] Lukas Ruff, Jacob R. Kauffmann, Robert A. Vandermeulen, Grégoire Montavon, Wojciech Samek, Marius Kloft, Thomas G. Dietterich, y Klaus-Robert Müller. A unifying review of deep and shallow anomaly detection. *Proceedings of the IEEE*, 109(5):756–795, 2021.

[23] Joan Serrà, David Álvarez, Vicenç Gómez, Olga Slizovskaia, José F. Núñez, y Jordi Luque. Input complexity and out-of-distribution detection with likelihood-based generative models. En *International Conference on Learning Representations (ICLR)*, 2020. arXiv:1909.11480.

[24] Iván Sevillano-García, Julián Luengo, y Francisco Herrera. STOOD-X: Explainable out-of-distribution detection via nonparametric statistical testing on large-scale datasets. *Pattern Recognition*, 177:113254, 2026.

[25] Glenn Shafer y Vladimir Vovk. A tutorial on conformal prediction. *Journal of Machine Learning Research*, 9:371–421, 2008. arXiv:0706.3188.

[26] Yiyou Sun, Chuan Guo, y Yixuan Li. ReAct: Out-of-distribution detection with rectified activations. En *Advances in Neural Information Processing Systems (NeurIPS)*, 2021. arXiv:2111.12797.

[27] Yiyou Sun y Yixuan Li. DICE: Leveraging sparsification for out-of-distribution detection. En *Computer Vision – ECCV 2022*, Lecture Notes in Computer Science, páginas 691–708. Springer, 2022.

[28] Pauli Virtanen, Ralf Gommers, Travis E. Oliphant, Matt Haberland, Tyler Reddy, David Cournapeau, Evgeni Burovski, Pearu Peterson, Warren Weckesser, Jonathan Bright, et al. SciPy 1.0: Fundamental algorithms for scientific computing in Python. *Nature Methods*, 17(3):261–272, 2020.

[29] Frank Wilcoxon. Individual comparisons by ranking methods. *Biometrics Bulletin*, 1(6):80, 1945. VERIFICAR: Crossref solo da la página inicial (80); completar el rango de páginas.

[30] Jingkang Yang, Pengyun Wang, Dejian Zou, Zitang Zhou, Kunyuan Ding, Wenxuan Peng, Haoqi Wang, Guangyao Chen, Bo Li, Yiyou Sun, Xuefeng Du, Kaiyang Zhou, Wayne Zhang, Dan Hendrycks, Yixuan Li, y Ziwei Liu. OpenOOD: Benchmarking generalized out-of-distribution detection. En *Advances in Neural Information Processing Systems (NeurIPS), Datasets and Benchmarks Track*, 2022. arXiv:2210.07242.

[31] Jingkang Yang, Kaiyang Zhou, Yixuan Li, y Ziwei Liu. Generalized out-of-distribution detection: A survey. *International Journal of Computer Vision*, 132:5635–5662, 2024.

[32] David Zimmerer, Peter M. Full, Fabian Isensee, Paul Jäger, Tim Adler, Jens Petersen, Gregor Köhler, Tobias Ross, Annika Reinke, et al. MOOD 2020: A public benchmark for out-of-distribution detection and localization on medical images. *IEEE Transactions on Medical Imaging*, 41(10):2728–2738, 2022.